

UNIVERSIDAD COMPLUTENSE DE MADRID

FACULTAD DE CIENCIAS BIOLÓGICAS



TESIS DOCTORAL

Desarrollo y aplicación de herramientas bioinformáticas
para la predicción de estructura de bucles de proteínas

MEMORIA PARA OPTAR AL GRADO DE DOCTOR

PRESENTADA POR

Iván Martín Hernández

DIRIGIDA POR

Pablo Chacón Montes

UNIVERSIDAD COMPLUTENSE DE MADRID

FACULTAD DE CIENCIAS BIOLÓGICAS

**PROGRAMA DE DOCTORADO EN BIOQUÍMICA, BIOLOGÍA MOLECULAR Y
BIOMEDICINA**



TESIS DOCTORAL

**Desarrollo y aplicación de herramientas bioinformáticas para la predicción de estructura
de bucles de proteínas**

MEMORIA PARA OPTAR AL GRADO DE DOCTOR

PRESENTADA POR

Iván Martín Hernández

DIRECTOR

Pablo Chacón Montes

Este trabajo ha sido realizado en el grupo de Bioinformática Estructural del Instituto de Química Física “Blas Cabrera”, perteneciente al Consejo Superior de Investigaciones Científicas (IQF-CSIC).

I. Agradecimientos y dedicatorias

No puedo comenzar de otra manera que recordando a la persona que más ilusión le hizo saber que iba a comenzar esta tesis. Mi abuelo Isidoro ha sido siempre el mayor ejemplo tanto para mí como para mis hermanos. Ha sido alguien que ha enfocado siempre su vida en conseguir lo mejor para su familia y todo lo que ha conseguido ha sido siempre para los demás. Ha emigrado, aprendido un idioma nuevo, regresado y siempre se ha esforzado para dar lo mejor a los que más quería. Aunque no entendía bien a que me iba a dedicar, siempre preguntaba e intentaba enterarse a su manera, y con bromas de por medio, cada vez que nos veíamos. Por desgracia, cuando apenas llevaba unos meses con la tesis, falleció por COVID durante la pandemia. Esta tesis va dedicada prácticamente para él.

Gracias a mis padres, nunca habría llegado a conseguir nada de como soy sin ellos, sin la educación y valores que he obtenido desde pequeño y forman parte de mí a día de hoy. Gracias por apoyarme y acompañarme en cada una de las etapas de mi vida, por estar siempre disponibles y aconsejando cuando lo he necesitado.

Raúl, Nuria, os quiero muchísimo, no podría haber tenido mejores hermanos. La familia no se elige, pero no podría haber tenido más suerte de haber crecido junto a vosotros. Cada uno de nosotros somos totalmente diferentes, pero si algo tengo seguro es que, aunque de pequeños siempre discutíamos por cualquier cosa superficial, ya de adultos estamos más unidos que nunca y siempre vamos a estar a muerte para cualquiera de los demás.

No puedo dejar de lado al resto de mi familia, mi abuela Lali, mis tíos Carlos y Rafa, mis primos, siempre han hecho sentirme querido. Cada vez que nos vemos o nos reunimos el tiempo se pasa volando y eso siempre es símbolo de que estas donde debes.

La familia no se elige, pero los amigos sí, y yo tengo la suerte de seguir teniendo los mejores. Gracias a Miguel Genovés juntos desde el colegio, compañero de mil viajes, o de mil tardes. Hemos perdido la costumbre de desayunar chocolate con churros todos los domingos al vivir más lejos, pero no la de buscar cualquier excusa para hacer algo juntos. Gracias a Gabriela Müller, amiga desde el primer día que nos conocimos, a su vez rivales y compañeros en hockey, aunque vivas ya en la otra punta del mundo, cada vez

que nos vemos es como si no hubiera pasado el tiempo. Miguel Daniel Mozo, con todas las letras, gracias. Una de las mejores personas con la que puede juntar la vida, el mayor apoyo que he tenido en las buenas y no tan buenas, y el mayor ejemplo a seguir como persona, científico, amigo, marido y dentro de poco padre que puedo tener. No puedo dejar de lado tampoco al resto de amigos de la etapa de la universidad, y que por suerte (aunque últimamente solo en bodas) nos seguimos viendo: Marisa, Giuse, Elena, Evelyn, David, Gara, Buce y Alicia.

Una de las recomendaciones que se hace siempre a la hora de empezar un doctorado es no solo elegir bien el tema que te interese, si no que el grupo donde vas a hacerlo encaje contigo. Pablo Chacón me abrió las puertas al grupo de bioinformática estructural durante el máster, e hizo realmente que me ilusionara en ese camino dentro de todas las posibilidades de la bioinformática. No tenía yo pensado hacer un doctorado, pero cuando me ofreció el puesto, sabía sin duda que, si no era con él, no sería en ninguna otra parte. Gracias por ser comprensivo y dejarme aire cuando lo necesitaba y por apretarme las tuercas cuando también era necesario. Gracias también a José Ramon, aunque de primeras me costaba seguir su código y su velocidad de razonamiento programando, con el tiempo empiezas a seguirle el ritmo, y siempre me ha ayudado con todo lo que necesitaba tanto dentro del laboratorio como fuera. Gracias también a Rubén, que, aunque doctorando en un grupo diferente, ha sido una luz de positivismo y buena energía siempre al alcance, con quien se ha compartido más que solo unas simples cervezas.

Por último, agradecer a todas las personas que en algún momento han formado parte de mi camino, y que por diversos motivos de la vida ya no compartimos sendero, puesto que no sería quien soy sin las experiencias y conocimiento que he ido obteniendo de cada situación que he vivido con ellas y que me han hecho crecer como persona. तुम हमेशा मेरी यादों का हिस्सा रहोगे.

II. Índice general

I.	AGRADECIMIENTOS Y DEDICATORIAS.....	I
II.	ÍNDICE GENERAL	III
III.	ÍNDICE DE FIGURAS.....	VII
IV.	ÍNDICE DE TABLAS.....	XI
V.	RESUMEN	XIII
VI.	SUMMARY	XV
VII.	LISTA DE ABREVIATURA	XVII
1.	INTRODUCCIÓN	- 1 -
1.1	BUCLES DE PROTEÍNAS	- 1 -
1.2	MÉTODOS DE PREDICCIÓN DE ESTRUCTURA DE BUCLES	- 2 -
1.3	ANTICUERPOS.....	- 5 -
1.3.1	Estructura 3D y la importancia de sus bucles.....	- 5 -
1.3.2	Como se produce un anticuerpo	- 16 -
1.3.3	Bases de datos de anticuerpos.....	- 19 -
1.3.4	Esquemas de numeración de anticuerpos.....	- 19 -
1.3.5	Métodos de predicción de Anticuerpos.....	- 22 -
1.3.6	Diseño estructural computacional como futuro de la ingeniería de anticuerpos ...	- 27 -
2.	OBJETIVOS	- 29 -
3.	MATERIALES Y MÉTODOS	- 31 -
3.1	DESARROLLO E IMPLEMENTACIÓN DE RCD+	- 31 -
3.1.1	Muestreo de bucles → RCD.....	- 32 -
3.1.2	Filtrado y selección de estructuras	- 36 -
3.1.3	Refinado con PyRosetta	- 44 -
3.1.4	Servidor online	- 46 -
3.2	APLICACIÓN DE KORP A PREDICCIÓN DE MUTACIONES.....	- 47 -
3.2.1	Conjuntos de datos de entrenamiento, de validación y evaluación	- 48 -
3.2.2	Comparación con otros métodos	- 49 -
3.3	MÉTRICAS Y TRATAMIENTOS	- 50 -
3.3.1	Métricas	- 50 -
3.3.2	Procesamiento de estructuras de anticuerpos.....	- 52 -
3.4	BASES DE DATOS DE ANTICUERPOS: SABDAB	- 54 -
3.5	CONJUNTOS DE EVALUACIÓN Y DE REFERENCIA	- 59 -

3.5.1 Conjunto de evaluación de KORP	- 59 -
3.5.2 Conjuntos de referencia para la predicción de anticuerpos	- 60 -
3.6 GENERACIÓN DE MAPAS DE RESTRICCIÓN PARA CDRs	- 64 -
3.6.1 Composición	- 64 -
3.6.2 Suavizados.....	- 66 -
3.6.3 Pasos de formación de mapas.....	- 67 -
3.6.4 Mapas de H3	- 70 -
3.6.5 Mapas del resto de CDRs.....	- 73 -
3.6.6 Implementación de los mapas.....	- 79 -
3.7 COMPARACIÓN CON OTROS MÉTODOS	- 82 -
3.7.1 RoAb	- 82 -
3.7.2 AF2	- 83 -
3.7.3 ABB1.....	- 84 -
3.7.4 ABL	- 84 -
3.7.5 ABB2.....	- 85 -
3.7.6 DAB.....	- 85 -
3.7.7 Cálculo de RMSD y generación de modelos de alta calidad	- 85 -
4. RESULTADOS	- 89 -
4.1 ACTUALIZACIÓN Y MEJORA DE RCD+	- 89 -
4.1.1 Optimización del término de Ramachandran en el potencial KORP.....	- 89 -
4.1.2 Actualización y optimización de PyRosetta	- 91 -
4.2 KORPM: KORP EN LA PREDICCIÓN DE ESTABILIDAD EN LA SUSTITUCIÓN DE AMINOÁCIDOS	- 93 -
4.3 RESULTADOS CON LOS MAPAS DE RESTRICCIÓN PARA H3 Y SELECCIÓN DE SUAVIZADO	- 95 -
4.4 COMPARACIÓN DE RCD+ CON ROAB EN H3	- 101 -
4.4.1 RoAb NGK-kink	- 101 -
4.4.2 Resultados servidor Rosie (2025)	- 102 -
4.5 ESTUDIO DE LOS MAPAS DE RESTRICCIÓN EN EL RESTO DE CDRs EN CRR	- 107 -
4.5.1 Resultados de los mapas de restricción de H1	- 108 -
4.5.2 Resultados de los mapas de restricción de H2	- 111 -
4.5.3 Resultados de los mapas de restricción de L1	- 113 -
4.5.4 Resultados de los mapas de restricción de L2	- 115 -
4.5.5 Resultados de los mapas de restricción de L3	- 117 -
4.5.6 Estudio del caso de 4hpy	- 119 -
4.6 RESULTADOS DE LOS MAPAS DE RESTRICCIÓN EN CRTH	- 123 -
4.6.1 Resultados en H3.....	- 124 -
4.6.2 Resultados en H1.....	- 128 -
4.6.3 Resultados en H2.....	- 130 -

4.6.4 Resultados en L1	- 133 -
4.6.5 Resultados en L2	- 135 -
4.6.6 Resultados en L3	- 137 -
4.6.7 Comparación de H1 entre 3nps y 4dn3	- 140 -
4.7 PRESENCIA DE ANTÍGENO VS AUSENCIA.....	- 145 -
4.8 RESULTADOS COMPARATIVOS CON OTROS MÉTODOS.....	- 146 -
4.8.1 Casos descartados.....	- 146 -
4.8.2 Valores de desviación: RMSD de los anclajes.....	- 148 -
4.8.3 Comparación general de los CDRs	- 148 -
4.8.4 Resultados en H3.....	- 151 -
4.8.5 Resultados en el resto de CDRs	- 155 -
5. CONCLUSIONES.....	- 173 -
6. APÉNDICES.....	- 177 -
7. BIBLIOGRAFÍA	- 189 -

III. Índice de figuras

Figura 1. Esquema estructural de los anticuerpos.....	- 6 -
Figura 2. Plegamiento de las regiones de los anticuerpos.....	- 7 -
Figura 3. Localización espacial de los bucles CDR en Fv.....	- 8 -
Figura 4. Similitud entre bucles L1 de diferentes estructuras y longitudes.....	- 9 -
Figura 5. Distribución de longitudes de los seis bucles CDR.....	- 10 -
Figura 6. Similitud estructural de los bucles CDR y de 18 conjuntos de bucles control respecto a los conjuntos de fragmentos no redundante no-IG.....	- 12 -
Figura 7. Conformaciones de H3.....	- 12 -
Figura 8. (A) Ejemplo de un bucle H3 con la construcción de LAT. (B) Geometría del kink. (C) Histograma de τ_{101} . (D) Histograma de α_{101}	- 14 -
Figura 9. Distribuciones de Ramachandran para las posiciones los anclajes de bucle CDR-H3 (92 y 103) y las 3 posiciones más cercanas del bucle a cada anclaje (93-95 y 100x-102) y para sus correspondientes posiciones en el conjunto de bucles con los mismo parámetros LAT.....	- 15 -
Figura 10. Organización de las líneas germinales de los loci de las cadenas H y L de inmunoglobulinas humanas.....	- 17 -
Figura 11. Esquema de las etapas para la predicción completa de un bucle en RCD+.....	- 31 -
Figura 12. Diagrama de flujo del proceso de cerrado de bucles mediante RCD.....	- 34 -
Figura 13. Variables que definen la relación 6D entre dos aminoácidos.....	- 37 -
Figura 14. Teselación del espacio circular para los ángulos θ y φ	- 39 -
Figura 15. Interfaz del servidor online de RCD+.....	- 46 -
Figura 16. Distribución de las especies, de la presencia/ausencia de antígeno, del tipo de anticuerpo y del método experimental sobre el total de estructuras depositadas en SabDab.....	- 55 -
Figura 17. Distribución del número de unidades antigenicas por PDB en las estructuras de anticuerpos del SAbDab.....	- 57 -
Figura 18. Distribución de la resolución en las estructuras de anticuerpos del SAbDab.....	- 57 -
Figura 19. Apariciones de cada bucle CDR en el total de estructuras de anticuerpos del SAbDab.....	- 58 -
Figura 20. Variabilidad de longitud para cada de bucle CDR en el total de estructuras de anticuerpos del SAbDab.....	- 59 -
Figura 21. Ejemplo de suavizado por interpolación.....	- 67 -
Figura 22. Mapas Ramachandran de restricción para la posición 94 de H3 con diferentes suavizados -	71 -
Figura 23. Mapas de restricción S2 para las posiciones del torso de H3.....	- 72 -
Figura 24. Distribuciones de Ramachandran en el sistema de mezclado de mapas.....	- 81 -
Figura 25. Mejora en la discriminación de bucles cercanos a la estructura nativa por el potencial KORP tras incorporar el termino de Ramachandran.....	- 90 -
Figura 26. Curvas ROC para todos los métodos de predicción de estabilidad en S^{sym}	- 94 -
Figura 27. Resultados Top1 en H3 de CRR con (verde) y sin mapa (naranja).....	- 97 -

Figura 28. Resultados Top10 en H3 de CRR con (verde) y sin mapa (naranja).	- 98 -
Figura 29. Casos representativos de H3 Top10 con y sin mapas de restricción con RCD+ en CRR.	- 100 -
Figura 30. Comparación de RMSD Top1 para los bucles H3 de CRR entre RCD+ (verde) y RoAb (morado) sobre estructura cristalográfica.....	- 102 -
Figura 31. Comparación de RMSD Top1 para los bucles H3 de CRR entre RCD (dorado) y RoAb (morado) sobre modelo de homología.....	- 104 -
Figura 32. Comparación de RMSD Top10 para los bucles H3 de CRR entre RCD (dorado) y RoAb (morado) sobre modelo de homología.....	- 105 -
Figura 33. Comparación de predicciones de Top1 de RoAb y RCD+ en cuatro casos ilustrativos.....	- 106 -
Figura 34. Evolución del RMSD mínimo medio por Top para CRR desde los modelos de RoAb para RCD+ (amarillo) y RoAb (morado).	- 107 -
Figura 35. RMSD medio de RCD+ ejecutado con y sin mapa en todos los bucles CDR en CRR.	- 107 -
Figura 36. Resultados Top10 en H1 de CRR con (verde) y sin mapa (naranja).	- 109 -
Figura 37. Casos representativos de H1 Top10 con y sin mapas de restricción con RCD+ en CRR.	- 110 -
Figura 38. Resultados Top10 en H2 de CRR con (verde) y sin mapa (naranja).	- 112 -
Figura 39. Casos representativos de H2 Top10 con y sin mapas de restricción con RCD+ en CRR.	- 112 -
Figura 40. Resultados Top10 en L1 de CRR con (verde) y sin mapa (naranja).	- 114 -
Figura 41. Casos representativos de L1 Top10 con y sin mapas de restricción con RCD+ en CRR.	- 114 -
Figura 42. Resultados Top10 en L2 de CRR con (verde) y sin mapa (naranja).	- 115 -
Figura 43. Casos representativos de L2 Top10 con y sin mapas de restricción con RCD+ en CRR.	- 116 -
Figura 44. Resultados Top10 en L3 de CRR con (verde) y sin mapa (naranja).	- 117 -
Figura 45. Casos representativos de L3 Top10 con y sin mapas de restricción con RCD+ en CRR.	- 118 -
Figura 46. Aminoácidos clave del antígeno en su interacción con el anticuerpo en 4hpy.	- 120 -
Figura 47 Estructura de 4hpy junto a su antígeno en los 6 bucles CDR.	- 121 -
Figura 48. Ángulos diedros de 4hpy (rojo) sobre los mapas de restricción para bucles H2 de 8 aminoácidos.	- 122 -
Figura 49. RMSD medio de RCD+ ejecutado con y sin mapa en todos los bucles CDR en CRTh.	- 124 -
Figura 50. Resultados Top10 en H3 de CRTh con (verde) y sin mapa (naranja).....	- 125 -
Figura 51. Casos representativos de H3 Top10 con y sin mapas de restricción con RCD en CRTh.	- 127 -
Figura 52. Bucle H1 Top10 de 5kmv sin mapa de restricción (naranja).	- 128 -
Figura 53. Resultados Top10 en H1 de CRTh con (verde) y sin mapa (naranja).....	- 129 -
Figura 54. Casos representativos de H1 Top10 con y sin mapas de restricción con RCD en CRTh.	- 130 -
Figura 55. Resultados Top10 en H2 de CRTh con (verde) y sin mapa (naranja).....	- 131 -
Figura 56. Casos representativos de H2 Top10 con y sin mapas de restricción con RCD en CRTh.	- 132 -
Figura 57. Resultados Top10 en L1 de CRTh con (verde) y sin mapa (naranja).	- 133 -
Figura 58. Casos representativos de L1 Top10 con y sin mapas de restricción con RCD en CRTh.	- 134 -
Figura 59. Resultados Top10 en L2 de CRTh con (verde) y sin mapa (naranja).	- 136 -
Figura 60. Casos representativos de L2 Top10 con y sin mapas de restricción con RCD en CRTh.	- 137 -

Figura 61. Resultados Top10 en L3 de CRTh con (verde) y sin mapa (naranja).	- 138 -
Figura 62. Casos representativos de L3 Top10 con y sin mapas de restricción con RCD en CRTh.....	- 139 -
Figura 63. Estructura nativa de H1 para los bucles 3nps (A) y 4dn3 (B) en 3 orientaciones.....	- 141 -
Figura 64. Estructura predicha con mapas de restricción de H1 para los bucles 3nps (A) y 4dn3 (B) en 3 orientaciones.....	- 142 -
Figura 65. Ángulos diedros de 3nps (amarillo) y 4dn3 (rojo) sobre los mapas de restricción para cada posición de bucles H1 de 7 residuos.	- 143 -
Figura 66. Representación del bucle H1 de 3nps y 4dn3 junto con el resto del anticuerpo..	- 144 -
Figura 67. Interacción entre el bucle H1 de 3nps nativo (gris), predicho (verde) y el antígeno (azul).	- 145 -
Figura 68. Comparación de los diferentes métodos de predicción de CDRs en el CRR y CRTh.	- 150 -
Figura 69. RMSD en H3 de cada método para cada caso del CRR.	- 152 -
Figura 70. RMSD en H3 de cada método para cada caso del CRTh.	- 153 -
Figura 71. Predicciones de todos los métodos en casos representativos de H3.	- 154 -
Figura 72. RMSD en H1 de cada método para cada caso del CRR.	- 156 -
Figura 73. RMSD en H1 de cada método para cada caso del CRTh.	- 157 -
Figura 74. Predicciones de todos los métodos en casos representativos de H1.	- 158 -
Figura 75. RMSD en H2 de cada método para cada caso del CRR.	- 159 -
Figura 76. RMSD en H2 de cada método para cada caso del CRTh.	- 161 -
Figura 77. Predicciones de todos los métodos en casos representativos de H2.	- 162 -
Figura 78. RMSD en L1 de cada método para cada caso del CRR.	- 163 -
Figura 79. RMSD en L1 de cada método para cada caso del CRTh.	- 164 -
Figura 80. Predicciones de todos los métodos en casos representativos de L1.	- 165 -
Figura 81. RMSD en L2 de cada método para cada caso del CRR.	- 166 -
Figura 82. RMSD en L2 de cada método para cada caso del CRTh.	- 167 -
Figura 83. Predicciones de todos los métodos en casos representativos de L2.	- 168 -
Figura 84. RMSD en L3 de cada método para cada caso del CRR.	- 169 -
Figura 85. RMSD en L3 de cada método para cada caso del CRTh.	- 170 -
Figura 86. Predicciones de todos los métodos en casos representativos de L3.	- 171 -

IV. Índice de tablas

Tabla 1. Número de segmentos de genes funcionales en loci de inmunoglobulina humana.	- 16 -
Tabla 2. Esquema de numeración de anticuerpos.	- 21 -
Tabla 3. CRR: Conjunto de referencia de Rosetta.	- 61 -
Tabla 4. CRTh: Conjunto de referencia de Terapéutico.	- 63 -
Tabla 5. Número de estructuras que componen cada subconjunto con valores de resolución y no redundancia (NR).	- 65 -
Tabla 6. Mapas de restricción específicos aplicados a cada posición de los bucles H1.	- 74 -
Tabla 7. Número de estructuras y distribución de cada posición para bucles H2.	- 74 -
Tabla 8. Esquema del mapa de restricción total de H2.	- 75 -
Tabla 9. Enriquecimiento de RCD+ en los bucles H2 de 8 aminoácidos de CRR, sin usar mapa, con solo el mapa específico de su longitud (propio) y con el mapa general.	- 75 -
Tabla 10. Esquema del mapa de restricción total de L1.	- 76 -
Tabla 11. Número de estructuras y distribución de cada posición para bucles L3.	- 78 -
Tabla 12. Esquema del mapa de restricción total de L3.	- 79 -
Tabla 13. Parámetros de RCD+ específicos para el cierre bucles CDR.	- 82 -
Tabla 14. Parámetros examinados en la optimización del potencial KORP.	- 89 -
Tabla 15. Comparación de RMSD (Top10) entre el protocolo de refinamiento original y el nuevo de RCD+ en CRR para el bucle H3.	- 93 -
Tabla 16. Resultados de todos los métodos de predicción de estabilidad en sustitución de aminoácidos para el conjunto de dato de evaluación simétrico S^{sym}	- 93 -
Tabla 17. Enriquecimiento de RCD+ en H3 de CRR sin mapa y para cada tipo de suavizado (S1 y S2).	- 96 -
Tabla 18. Comparación del suavizado de mapas en el CRR en el bucle H3 tras el refinamiento.	- 97 -
Tabla 19. Tiempo medio empleado en horas:minutos por caso en CRR, para el protocolo completo de cada método.	- 102 -
Tabla 20. Resultados de RMSD en H3 para RoAb y RCD+ (sobre los modelos de RoAb)	- 104 -
Tabla 21. Enriquecimiento de RCD+ para H1 en CRR con y sin mapa de restricción.	- 108 -
Tabla 22. Enriquecimiento de RCD+ para H2 en CRR con y sin mapa de restricción.	- 111 -
Tabla 23. Enriquecimiento de RCD+ para L1 en CRR con y sin mapa de restricción.	- 113 -
Tabla 24. Enriquecimiento de RCD+ para L2 en CRR con y sin mapa de restricción.	- 115 -
Tabla 25. Enriquecimiento de RCD+ para L3 en CRR con y sin mapa de restricción.	- 117 -
Tabla 26. Valores de RMSD en la predicción del anticuerpo 4hpy del Top10 con y sin mapa de restricción para cada CDR.	- 119 -
Tabla 27. Enriquecimiento de RCD+ para H3 en CRTh con y sin mapa de restricción.	- 124 -
Tabla 28. Enriquecimiento de RCD+ para H1 en CRTh con y sin mapa de restricción.	- 128 -
Tabla 29. Enriquecimiento de RCD+ para H2 en CRTh con y sin mapa de restricción.	- 131 -
Tabla 30. Enriquecimiento de RCD+ para L1 en CRTh con y sin mapa de restricción.	- 133 -

Tabla 31. Enriquecimiento de RCD+ para L2 en CRTh con y sin mapa de restricción.	- 135 -
Tabla 32. Enriquecimiento de RCD+ para L3 en CRTh con y sin mapa de restricción.	- 138 -
Tabla 33. Comparación del enriquecimiento de RCD+ con y sin mapa de restricción en 3nps y 4dn3-	- 143 -
Tabla 34. Tamaño medio de cada CDR para los subgrupos con ligando (A+) y sin ligando (A-) de las estructuras de ambos conjuntos de referencia.	- 146 -
Tabla 35. Resultados en función de la presencia de antígeno en la estructura cristalográfica.	- 146 -
Tabla 36. Casos menos fiables de los otros métodos de predicción de anticuerpos.	- 147 -
Tabla 37. Lista de estructuras descartadas y su motivo.	- 147 -
Tabla 38. RMSD medio de los anclajes de los bucles CDR para los métodos que predicen la estructura completa.	- 148 -
Tabla 39. RMSD promedio en H3 para todos los métodos.	- 151 -
Tabla 40. RMSD promedio en H3 para todos los métodos por subconjuntos de tamaños.	- 152 -
Tabla 41. RMSD promedio en H1 para todos los métodos.	- 155 -
Tabla 42. RMSD promedio en H2 para todos los métodos.	- 159 -
Tabla 43. RMSD promedio en L1 para todos los métodos.	- 162 -
Tabla 44. RMSD promedio en L2 para todos los métodos.	- 165 -
Tabla 45. RMSD promedio en L3 para todos los métodos.	- 168 -

V. Resumen

La gran versatilidad y especificidad de los anticuerpos para reconocer y unirse a una amplia variedad de antígenos los convierte en componentes esenciales de la respuesta inmunitaria. Estas propiedades han consolidado a los anticuerpos como herramientas clave en múltiples aplicaciones biotecnológicas y biomédicas, que abarcan desde biosensores y plataformas de diagnóstico hasta el desarrollo de terapias avanzadas. Sin embargo, el diseño experimental de anticuerpos sigue siendo un proceso complejo, laborioso y costoso. En este contexto, las herramientas bioinformáticas permiten optimizar y acelerar dicho proceso, aunque la predicción de las seis regiones tipo bucle que se unen al antígeno, conocidas como CDR (Regiones Determinantes de la Complementariedad), continúa representando un desafío computacional considerable. En particular, el bucle H3, principal determinante de la especificidad destaca por su elevada variabilidad en secuencia y longitud, lo que lo convierte en el más difícil de modelar.

Esta tesis presenta una mejora sustancial de la herramienta **RCD+** para el cierre *ab initio* de bucles CDR en anticuerpos. La nueva versión incorpora: (i) un muestreo exhaustivo del espacio conformacional mediante la generación de bucles restringidos por mapas derivados de conformaciones conocidas; (ii) un sistema de cribado estructural basado en el potencial orientacional KORP; y (iii) un refinamiento final utilizando la última versión de PyRosetta. Estas mejoras permiten una predicción más precisa, especialmente en el bucle H3, donde se observan mejoras superiores a 1 Å al incorporar restricciones basadas en su conformación distintiva en los extremos, conocida como *kink*.

El rendimiento de RCD+ se evaluó frente a herramientas de referencia, incluyendo predictores generales de estructura (AlphaFold2), métodos especializados en el diseño completo de anticuerpos (DeepAb, ABodyBuilder, ABlooper) y enfoques específicos para el modelado del bucle H3 (Rosetta-NGK). Los resultados demuestran que RCD+ alcanza niveles altamente competitivos, superando a la mayoría de los métodos en la predicción de H3. A diferencia de otros enfoques, RCD+ genera múltiples soluciones estructurales, lo que permite identificar conformaciones alternativas más cercanas a la estructura

nativa. Por ejemplo, aunque la mejor predicción presenta un error medio de 2 Å, se encuentran soluciones con errores de 1.5 Å e incluso 1.3 Å al considerar las cinco o diez primeras conformaciones generadas, respectivamente.

En conjunto, estos resultados posicionan a RCD+ como una herramienta computacional robusta, eficiente (con tiempos de ejecución de pocos minutos) y precisa (errores sub-ångström para bucles de menos de 12 residuos), con aplicaciones potenciales en diagnóstico, desarrollo de terapias y bioingeniería.

Adicionalmente, se ha desarrollado KORPM, un método para la predicción del cambio de estabilidad en mutaciones de sustitución aminoacídica basado en el potencial KORP. Destaca por su sencillez al depender solo de la posición y orientación relativa de tres átomos de la cadena principal, por su eficacia en cuanto a velocidad y por su precisión al obtener resultados altamente competitivos frente a los métodos existentes.

VI. Summary

Antibodies are essential components of the immune response due to their remarkable versatility and specificity in recognizing a wide range of antigens. These properties have established antibodies as key tools in biotechnology and biomedicine, from biosensors and diagnostics to advanced therapies. However, experimental antibody design remains complex, time-consuming, and costly. Computational approaches can accelerate this process, yet predicting the six antigen-binding loops, known as complementarity-determining regions (CDRs), remains a major challenge—particularly the highly variable H3 loop, the main determinant of specificity.

This work introduces a substantially improved version of **RCD+** for *ab initio* CDR loop modeling. The new implementation integrates: (i) exhaustive conformational sampling guided by maps derived from known structures; (ii) structural screening using the KORP orientation-based potential; and (iii) final refinement with the latest PyRosetta release. These enhancements significantly improve accuracy, especially for H3, achieving >1 Å improvement when incorporating kink-based constraints.

Benchmarking against state-of-the-art methods—including general structure predictors (AlphaFold2), full-antibody design tools (DeepAb, ABodyBuilder, ABlooper), and H3-specific approaches (Rosetta-NGK)—shows that RCD+ delivers highly competitive performance, often outperforming alternatives for H3 prediction. Unlike most methods, RCD+ generates multiple structural candidates, enabling the identification of near-native conformations (e.g., 1.3 Å error within the top 10 models).

Overall, RCD+ emerges as a robust, efficient (runtime of a few minutes), and accurate tool (sub-ångström errors for loops <12 residues), with strong potential for applications in diagnostics, therapeutic development, and bioengineering.

Additionally, KORPM has been developed, a method for predicting stability changes in amino acid substitution based on the KORP potential. It stands out for its simplicity, since it only relies on the position and relative orientation of three backbone atoms, for its efficiency in terms of speed, and for its accuracy in producing highly competitive results compared to existing methods.

VII. Lista de abreviatura

ABB1	ABodyBuilder1
ABB1	ABodyBuilder2
ABL	ABlooper
ACC	Exactitud (del inglés, <i>Accuracy</i>)
ADN	Ácido Desoxiribonucleico
AF2	Alphafold2
AID	Desaminasa inducida por activación (del inglés, <i>Activation Induced Deaminase</i>)
BCR	Receptor de células B (del inglés, <i>B-Cell Receptor</i>)
CASP	Evaluación Crítica de Técnicas para la Predicción de la Estructura de las Proteínas (del inglés, <i>Critical Assessment of Techniques for Protein Structure Prediction</i>)
CCD	Descenso de Coordenadas Cíclico (del inglés, <i>Cyclid Coordinate Descent</i>)
CDR	Región Determinante de la Complementariedad (del inglés, <i>Complementarity Determining Region</i>)
CNN	Redes Neuronales Convolucionales (del inglés, <i>Convolutional Neural Networks</i>)
CRR	Conjunto de Referencia de Rosetta
CRTh	Conjunto de Referencia de Terapéutico
DAB	DeepAB
DL	Aprendizaje profundo (del inglés, <i>Deep Learning</i>)
IMGT	InMunoGeneTics
KIC	Cierre Cinemático de inspiración robótica (del inglés, <i>robotic-inspired KInematic Closure</i>)
KORP	Potencial orientacional basado en el conocimiento (del inglés, <i>Knowledge-base ORientational Potential</i>)
LAT	Transformación de anclaje de bucle (del inglés, <i>Loop Anchor Transform</i>)
MAE	Error Medio Absoluto (del inglés, <i>Mean Absolute Error</i>)
MCC	Coeficiente de Correlación de Matthews

MSA	Alineamiento Múltiple de Secuencia (del inglés, <i>Multiple Sequence Alignment</i>)
NGK	KIC de siguiente Generación (del inglés, <i>Next Generation KIC</i>)
NMR	Resonancia Magnética Nuclear
PCC	Coeficiente de Correlación de Pearson
PDB	Base de Datos de Proteínas (del inglés, <i>Protein Data Bank</i>)
PPV	Valor Predictivo Positivo o Precisión
RCD	Descenso de coordenadas aleatorias (del inglés, <i>Random Coordinate Descent</i>)
RMSD	Desviación cuadrática media (del inglés, <i>Root-Mean-Square Deviation</i>)
RMSE	Error de Raíz Cuadrática Media (del inglés, <i>Root Mean Square Error</i>)
RNN	Redes neuronales recursivas (del inglés, <i>Recursive Neural Networks</i>)
RoAb	Rosetta Antibody
SabDab	Structural Antibody Database
TCR	Receptor de células T (del inglés, <i>T-Cell Receptor</i>)
TNR	Ratio de Verdaderos Negativos o Especificidad
TPR	Ratio de Verdaderos Positivos o Sensibilidad

1. Introducción

1.1 Bucles de proteínas

Los bucles son segmentos de las proteínas que conectan dos elementos de estructura secundaria (e.g. hélices alfa y laminas beta), que se encuentran generalmente expuestos en proteínas globulares y que presentan una mayor variabilidad de secuencia. Aunque representan un tercio del total de las secuencias de las proteínas, el 50% de los residuos de los centros activos suelen pertenecer a estos bucles (Bartlett et al., 2002) y suelen jugar un papel importante en funciones como señalización, reconocimiento molecular o regulación alostérica.

Cerca del 70% de estructuras conocidas disponibles en el *Protein Data Bank* (PDB) contienen regiones no resueltas experimentalmente, las cuales suelen corresponder a zonas con alta flexibilidad o movilidad, localizadas típicamente en bucles o en las colas terminales (Petoukhov et al., 2002). Por tanto, para completar la caracterización atómica de las proteínas es necesario poder reconstruir estas regiones bucle. Además, dada la importancia de estas regiones en interacciones proteína-ligando y proteína-proteína su predicción es clave en el diseño de nuevas proteínas. Esta importancia resalta en los anticuerpos ya que su especificidad de unión a antígenos recae en los bucles de la denominada región determinante de la complementariedad (en inglés *complementarity determining region* o CDR). Por consiguiente, el diseño y la predicción estructural de nuevos anticuerpos pasa inevitablemente por una modelización precisa de sus bucles.

La exploración del espacio conformacional de los bucles constituye un desafío computacional considerable. Este espacio crece exponencialmente con la longitud del bucle, y está condicionado por la secuencia y por las restricciones geométricas impuestas por los residuos contiguos. Aunque se han desarrollado múltiples metodologías para abordar este problema, la predicción de bucles sigue siendo un reto abierto, especialmente en el caso de aquellos que son largos (más de 8 residuos) y/o altamente flexibles.

1.2 Métodos de predicción de estructura de bucles

Aunque los protocolos de predicción emplean estrategias mixtas, en general podemos clasificar los métodos de modelado de bucles en dos grandes grupos: basados en conocimiento y *ab initio* (Barozet et al., 2021).

Los **métodos basados en conocimiento**, también llamados “basados en homología” o “basados en plantillas”, se fundamentan en la premisa de que secuencias similares tienen conformaciones similares. De forma general, primero buscan estructuras de bucles lo más parecidos en secuencia al bucle diana que se quiere predecir y luego utilizan estas estructuras como modelo para generar sus predicciones. Estos métodos suelen presentar la ventaja de ser más rápidos, ya que no necesitan realizar simulaciones costosas. Sin embargo, están limitados a la disponibilidad de estructuras de bucles de proteínas resueltas.

Existen multitud de aproximaciones que siguen esta filosofía, cada una con sus particularidades. ModLoop (Fiser & Sali, 2003), ArchPRED (Fernandez-Fuentes et al., 2006) o FREAD (Choi & Deane, 2010a) son aproximaciones pioneras. Esta última, por ejemplo, selecciona bucles a partir de una base de datos de fragmentos de proteínas según: la similitud de secuencia, la distancia entre extremos del bucle, la distancia relativa entre los átomos de los extremos de la proteína con los del fragmento y la ausencia de colisiones al insertar el fragmento. Otros métodos más recientes, como LoopIng (Messih et al., 2015), selecciona bucles compatibles estructuralmente desde una base de datos utilizando un método basado en aprendizaje automático de tipo *Random Forest*: considerando variables como la similitud de secuencia, la distancia entre los anclajes o la geometría de los extremos del bucle. DaReUS-Loop (Karami et al., 2018) explora estructuras remotas o no relacionadas: analiza las regiones que flanquean al bucle y realiza una búsqueda de estructuras con regiones flanqueantes similares. Para posteriormente filtrar las regiones seleccionadas teniendo en cuenta su similitud de secuencia y perfil conformacional frente al bucle objetivo

Los **métodos *ab initio*** buscan reconstruir la estructura de los bucles proteicos sin apoyarse en estructura conocidas, generalmente a través un proceso de modelado que explora el espacio conformacional computacionalmente hasta encontrar un bucle

cerrado y estereoquímicamente correcto (sin colisiones estéricas y ángulos/longitudes de enlaces/diedros adecuados). Su gasto computacional es bastante variable y depende del método de muestreo y del tamaño del bucle, pero generalmente requiere de más recursos computacionales que los métodos basados en conocimiento. Al igual que los anteriores, sufren la limitación del crecimiento del espacio conformacional con el tamaño del bucle, pero de forma más acusada al ser más costosos.

El primer paso que los métodos *ab initio* deben solventar es el problema de cierre del bucle: encontrar el conjunto de posibles conformaciones del bucle que conecten geométricamente los extremos de la cadena de proteína. Existe un método analítico que permite resolver este problema, pero está limitado a un segmento de cadena con 6 ángulos de torsión (Coutsias et al., 2004): transforma el problema en la búsqueda de raíces reales de un polinomio de grado 16, inspirado en la cinemática de sistemas robóticos. KIC (*robotic-inspired kinematic closure*) (Mandell et al., 2009) es una extensión de este método analítico que permite flexibilidad en ángulos de enlace, no requiere torsiones consecutivas, y admite segmentos rígidos intermedios; lo que le ha hecho muy popular como motor de búsqueda conformacional en los métodos de predicción.

Alternativamente a las aproximaciones analíticas, los métodos iterativos permiten una mayor flexibilidad de grados de libertad. Entre estos métodos destaca CCD (de *Cyclid Coordinate Descent* Descenso de coordenadas cíclico) (Canutescu & Dunbrack, 2003). En este método primero se une el bucle (la secuencia de aminoácidos a predecir) con una conformación aleatoria al extremo N-Terminal dejando el extremo C-terminal libre (sin cerrar). La distancia entre el extremo C-terminal del bucle y su zona de anclaje se va reduciendo de forma iterativa, perturbando los ángulos diedros ϕ y ψ . La perturbación se va haciendo secuencialmente desde el primero hasta el último de los aminoácidos que componen el bucle y se repite cíclicamente hasta que la distancia esté lo suficientemente cerca como para considerarse que el extremo Ct-terminal está conectado, i.e. cerrado. La eficiencia y eficacia de este método fue mejorado en nuestro laboratorio mediante la selección aleatoria de los ángulos diedros y la incorporación de técnicas de álgebra geométrica, dando lugar al método RCD (*Random Coordinate*

Descent) (Chys & Chacón, 2013), que permite modelar bucles en ambas direcciones (de N-terminal a C-terminal y viceversa).

Independientemente del algoritmo que se emplea para cerrar el bucle, existen múltiples aproximaciones para generar bucles *ab initio* como, por ejemplo: LoopWeaver (Holtby et al., 2013), SuperLooper (Hildebrand et al., 2009), MODELLER (Martí-Renom et al., 2000), Loopy (Xiang et al., 2002), OSCAR-loop (Liang et al., 2012), Rosetta-NGK (Stein & Kortemme, 2013), LEAP (Liang et al., 2014) o M-DiSGro (Tang et al., 2015). También existen enfoques híbridos como CODA (Deane & Blundell, 2001), GalaxyLoop-PS2 (Park et al., 2014) o Sphinx (Marks et al., 2017) que combinan elementos de métodos *ab initio* y basados en conocimiento. El más popular es NGK (next generation KIC) que cambia un motor de búsqueda KIC con el entorno de modelado Rosetta.

Por otro lado, la aparición y gran éxito de AlphaFold2 (AF2) como método de predicción de proteínas completas (Jumper et al., 2021; Stevens & He, 2022) ha provocado que se vuelva un referente también en la predicción de regiones específicas como son los bucles. La estimación de fiabilidad de AF2 (pLDDT) es un buen indicador de flexibilidad y desorden. No es de extrañar que en las regiones de bucles flexibles baje y por extensión la precisión de la predicción. Además, la aplicación del aprendizaje automático en el campo de la predicción de bucles tiene un gran potencial como: HyLooper2 (Nguyen et al., 2019) o Karmalooop (T. Wang et al., 2024). En una reciente comparación de métodos específicos de predicción de bucles y AF2 se demostró que, para bucles inferiores a 8 aminoácidos, métodos *ab initio* como Rosetta-NGK obtenía mejores resultados y solo con bucles superiores a 16 aminoácidos AF2 era superior (T. Wang et al., 2023). También se observó mejores predicciones de los métodos *ab initio* con estructuras poco representadas en las bases de datos o con modelos no cristalográficos.

En esta tesis, se empleará como método de referencia para modelar bucles a RCD+, que combina el algoritmo *ab initio* para cerrar bucles RCD como motor para la búsqueda conformacional, con un refinado que incluye las cadenas laterales con Rosetta. Comparaciones con Rosetta-NGK han demostrado que RCD+ ofrece una precisión similar, pero con una eficiencia computacional significativamente superior, al ser un orden de magnitud más rápido (López-Blanco et al., 2016).

1.3 Anticuerpos

Los anticuerpos, también denominados inmunoglobulinas, son glicoproteínas solubles producidas y liberadas por las células especializadas del sistema inmune: los linfocitos B. Su principal característica es la capacidad de reconocer y unirse de forma específica a una amplia variedad de antígenos, entendidos como cualquier molécula capaz de inducir una respuesta inmune.

Los anticuerpos constituyen uno de los componentes esenciales de la respuesta inmune adaptativa de los vertebrados y tienen tres funciones principales (Charles A Janeway et al. 2001):

- **Neutralización de agentes patógenos y toxinas:** pueden unirse directamente a la superficie de virus o bacterias, así como a sus toxinas, impidiendo su interacción con las células del organismo e inhibiendo su capacidad de infección o efecto nocivo.
- **Activación de otras células del sistema inmunológico:** mediante su unión a la superficie de agentes extraños, facilitan el reconocimiento y la respuesta de otras células del sistema inmune, como las células fagocíticas, que pueden eliminar de forma más eficiente los patógenos recubiertos por anticuerpos.
- **Activación del sistema del complemento:** desencadenan la activación de proteínas del sistema del complemento, un conjunto de proteínas plasmáticas que cooperan en la destrucción de microorganismos y en la amplificación de la respuesta inmunitaria.

1.3.1 Estructura 3D y la importancia de sus bucles

La estructura tridimensional de los anticuerpos, así como su patrón de plegamiento de los dominios individuales y las características fundamentales de los sitios de combinación con el antígeno, han sido objeto de numerosos estudios y revisiones (Amzel & Poljak, 1979; Chiu et al., 2019; Davies & Metzger, 1983; Padlan, 1977; Wilson & Stanfield, 1994).

En seres humanos los anticuerpos son grandes complejos proteicos compuestos por dos cadenas pesadas idénticas (*heavy chains*, H) y otras dos cadenas ligeras también idénticas (*light chains*, L). Una cadena L se asocia a una cadena H para formar un

heterodímero HL, y dos heterodímeros se enlazan mediante un puente disulfuro entre las cadenas H en una región conocida como “bisagra”, adoptando una estructura en forma de Y. Las cadenas L tienen una masa molecular aproximada de 24 KDa y puede ser de dos clases: κ (kappa) y λ (lambda). Ambas tienen una región constante (C_L) y una región variable (V_L). Por su parte, las cadenas H en humanos tienen una masa molecular entre 50-70 KDa y pueden clasificarse en 5 isotipos: IgA, IgD, IgE, IgG e IgM; cada uno con un rol diferente en el sistema inmune. IgA, IgD e IgG poseen una región variable (V_H) y tres regiones constantes (C_{H1} , C_{H2} , C_{H3}). IgE e IgM presentan una región constante adicional (C_{H4}). IgA e IgM tienen además una cadena J que les permite formar dímeros y pentámeros respectivamente. El resto de los isotipos son monoméricos (definido en cuanto a 2 cadenas H y 2 cadenas L). La Figura 1 ilustra este esquema descrito para IgG, el isotipo más abundante en humanos y el más utilizado como modelo estructural.




Figura 1. Esquema estructural de los anticuerpos. Modificado desde (*Antibody | Definition, Structure, Function, & Types | Britannica*, n.d.)

Un anticuerpo funcional cuenta con tres dominios: dos Fab (fragmento de unión a antígeno o *fragment antigen binding*) y un Fc (fragmento cristalizante o *fragment crystallizable*). Los dominios Fab están compuestos por la pareja de regiones variables

de H y L (región también conocida como F_v), junto con la región constante de L (C_L) y la primera de H (C_{H1}). El extremo N-terminal tanto de la cadena H como de la L se encuentran en F_v . El dominio F_c está compuesto por el resto de las regiones constantes de ambas cadenas H. Este dominio está glicosilado y también se le denomina región efectora, puesto que es la encargada de interactuar con otros componentes del sistema inmune que realizarán su función contra el antígeno ligado, como puede ser la activación de macrófagos (IgG), la iniciación de cadenas de respuesta de linfocitos B (IgD) o unión al complemento (Arnaout et al., 2011; Charles A Janeway et al., 2001b; Cohen, 1975).

Cada dominio estructural de las cadenas L y H, está compuesto por 110 aminoácidos aproximadamente y adoptan una conformación conocida como *plegamiento de inmunoglobulinas*, que consiste en dos láminas β antiparalelas muy compactas (Figura 2B). Para las regiones C una de las láminas β está formada por 4 hebras β ($\downarrow A \uparrow B \downarrow E \uparrow D$) y la otra por 3 ($\downarrow C \uparrow F \downarrow G$). A esta conformación también se la conoce como barril de llave griega. Las 2 láminas están unidas por un puente disulfuro intracadena entre 2 cisteínas localizadas en las hebras $\uparrow B$ y $\uparrow F$. Estas regiones C son generalmente compactas con bucles pequeños entre cada hebra β .




Figura 2. Plegamiento de las regiones de los anticuerpos. A) Disposición de las hebras de lámina β en la región V con los bucles CDR representados en rojo y el resto en azul. B) Disposición de las hebras de lámina β en la región C. Figura obtenida de (Chiu et al., 2019).

Por otro lado, las regiones V son similares a las regiones C, pero con unas pequeñas diferencias. La primera lámina β es igual, con 4 hebras ($\downarrow A \uparrow B \downarrow E \uparrow D$), sin embargo, la segunda lámina contiene 5 hebras ($\downarrow C'' \uparrow C' \downarrow C \uparrow F \downarrow G$), como se puede apreciar en la Figura 2A. Mantiene el puente disulfuro intracadena, pero es menos compacto debido a la incorporación de estas 2 hebras y a la mayor longitud de los bucles que las conectan.

Entre estos bucles de la región V, encontramos 3 que se sitúan de forma más expuesta, tanto para la cadena H (H1, H2 y H3) como para la cadena L (L1, L2 y L3). Al conjunto de estos 6 bucles se les denomina **región determinante de la complementariedad** (*complementarity determining region, CDR*) y presentan una alta variabilidad en longitud y secuencia, frente a lo conservado del resto de la estructura, lo que se traduce también en una elevada diversidad conformacional. En la Figura 3 se muestra un ejemplo de la disposición espacial de los bucles CDR. Dentro de cada región V, L1 y H1 unen $\uparrow B$ con $\downarrow C$; L2 y H2 unen $\uparrow C'$ con $\downarrow C''$; y L3 y H3 unen $\uparrow F$ con $\downarrow G$.




Figura 3. Localización espacial de los bucles CDR en Fv. Figura obtenida de (Chiu et al., 2019).

Estudios conformacionales iniciales propusieron que todos los bucles CDR, a excepción de H3, tendrían un número limitado de posibles conformaciones, conocidas como **estructuras canónicas**, y que esta vendría condicionada por la longitud y secuencia del bucle (Al-Lazikani et al., 1997; Chothia & Lesk, 1987a). Según han ido

creciendo el número de estructuras de anticuerpos resueltas, esta idea se ha ido confirmando y ampliando el número de estructuras canónicas reconocidas (North et al., 2011). Estos estudios han llevado a la identificación de aminoácidos específicos en posiciones definidas como determinantes de la conformación de los bucles (Nowak et al., 2016). Las estructuras canónicas se encuentran registradas y definidas en la base de datos PylgClassify2 (Kelow et al., 2022).

Estas estructuras canónicas agrupan conformaciones exclusivamente de la misma longitud, sin embargo, se han encontrado algunas conformaciones de diferentes longitudes más parecidas entre ellas que a otras de la misma longitud. Por ello se han hecho también aproximaciones en las que se generan agrupaciones con estructuras parecidas de diferentes longitudes, aprovechando que residuos en posiciones equivalentes toman la misma disposición (Nowak et al., 2016). Un ejemplo ilustrativo de este fenómeno se muestra en la Figura 4: el panel A representa el bucle CDR-L1 de 4JO2 (en azul) alineado con el bucle más cercano de su misma longitud (13 residuos), 3BDX (en rojo), a una distancia de 2.8 Å; mientras que el panel B representa el mismo bucle 4JO2 alineado con un bucle más corto (12 residuos), 3LHP (en verde), a una distancia de 1.4 Å.




Figura 4. Similitud entre bucles L1 de diferentes estructuras y longitudes. (A) CDR-L1 de 4JO2 (azul, 13 residuos) alineado con CDR-L1 de 3BDX (rojo, 13 residuos), el bucle estructuralmente más cercano de su misma longitud. (B) CDR-L1 de 4JO2 (azul, 13 residuos) alineado con CDR-L1 de 3LHP (verde, 12 residuos), el bucle estructuralmente más cercano de cualquier longitud. Figura obtenida de (Nowak et al., 2016)

➤ La importancia y cualidades únicas de H3

El bucle H3 es el CDR con mayor longitud media y mayor variación de tamaño como se puede apreciar en la Figura 5. Su longitud suele oscilar entre 3 y 20 aminoácidos, aunque en ciertos casos puede llegar a ser muy superior: en anticuerpos bovinos se han descrito casos de 50 o 60 residuos (F. Wang et al., 2013). Esto provoca que sea el único CDR sin estructuras canónicas completamente descritas.

Esta elevada variabilidad en longitud y secuencia que caracteriza a los CDRs (y que afecta en mayor medida a H3) viene causada por el exclusivo sistema de recombinación V(D)J y de hipermutación somática que se explica en más detalle posteriormente en el apartado 1.3.2.




Figura 5. Distribución de longitudes de los seis bucles CDR. Figura tomada de (Marks & Deane, 2017a).

Además, H3 está situado en el centro del sitio de unión, provocando que sea el CDR que tiene más contactos con el antígeno. Esto lo convierte en un pilar fundamental, siendo el CDR de mayor aportación en el reconocimiento del antígeno (Kuroda et al., 2012; MacCallum et al., 1996).

Estudios computacionales sugieren que H3 es un bucle altamente flexible debido a su longitud y a su reducido número de enlaces estabilizantes (Babor & Kortemme, 2009). Sin embargo, análisis más detallados en los que se analiza de forma sistemática el factor de temperatura normalizado llegan a la conclusión de que son igual de flexibles

que los bucles de proteínas estándar (Regep et al., 2017). En este mismo estudio analizan otras características de H3 y muestran que se trata del bucle con mayor porcentaje de conformaciones únicas con mucha diferencia sobre el resto. Para ello dividen los CDRs en conjuntos de fragmentos de 4 aminoácidos consecutivos, incluyendo todas las combinaciones solapantes (e.g. un bucle de 6 residuos tendría 3 fragmentos). Para comparar, aplicando el mismo criterio, obtuvieron cerca de 12 millones de fragmentos de los bucles (mas 2 residuos de los anclajes) de todas las proteínas no redundantes disponibles y no pertenecientes a la familia de inmunoglobulinas (no-IG). Calculan la distancia entre dos fragmentos tras alinearlos con Kabsch (Kabsch, 1978). Agrupan los fragmentos no-IG en aproximadamente 65.000 conjuntos únicos con una diferencia de 0.5 Å como límite; y consideran un fragmento externo como único cuando el fragmento más próximo en todos los conjuntos no-IG supera 1 Å (esto supone una sobreestimación de conformaciones únicas, pero permite eliminar falsos positivos). Los resultados del análisis comparativo entre los conjuntos de fragmentos de los CDRs y de las 18 superfamilias de proteínas más abundantes se representan en la Figura 6. El 30 % de fragmentos de H3 cumple las características de considerarse único estructuralmente, mientras que el mayor valor en el resto de los conjuntos supone un 5.6% y la media ronda el 3%. También se ha identificado que la mayor parte de los fragmentos únicos de H3 se encuentran en la zona del vértice del bucle, es decir, el residuo más alejado de ambos anclajes.

Debido a su elevada diversidad estructural, el bucle H3 no puede definirse mediante estructuras canónicas como el resto de CDRs. No obstante, se han llevado a cabo estudios estructurales que han identificado dos conformaciones específicas en la región del *torso* de la cadena principal (los residuos próximos a los anclajes N- y C-terminales): una conformación extendida y una conformación denominada *kink* (Morea et al., 1998). Esta conformación *kink* es la mayoritaria y consiste en una protuberancia- β (*β -bulge*) en la región C-terminal.




Figura 6. Similitud estructural de los bucles CDR y de 18 conjuntos de bucles control respecto a los conjuntos de fragmentos no redundante no-IG. Histogramas para cada conjunto de fragmentos correspondiente a cada CDR y a las 18 superfamilias más pobladas del PDB, de la distribución de RMSDs al fragmento estructural más cercano de los conjuntos de fragmentos no-IG. Los 18 grupos control tienen como título el ID de la superfamilia. Se indica también el porcentaje de fragmentos únicos (RMSD > 1 Å). Imagen tomada de (Regep et al., 2017).




Figura 7. Conformaciones de H3: extendida (a) y kink (b). Figura obtenida de (Marks & Deane, 2017a).

En el trabajo de (Weitzner et al., 2015) se analiza en detalle la geometría estructural del *kink*, la frecuencia con la que aparece en anticuerpos, si aparece en otro tipo de proteínas y con qué frecuencia, y cuáles pueden ser las causas de su diversidad. Definen el bucle H3, con la variación North del formato de numeración Chothia (los formatos se explican más adelante en el apartado 1.3.4), como los residuos comprendidos entre el inmediatamente posterior a la cisteína conservada (posición 93) y el anterior al triptófano conservado (posición 102).

En primer lugar, definen LAT (*Loop Anchor Transform*) como la transformación 3D de 6 grados de libertad que es necesaria para alinear los extremos o anclajes N y C terminales de un conjunto de bucles. En la Figura 8A se representa LAT para el caso de los bucles H3, basándose en los residuos 93 y 102. Los valores de LAT que presentan los bucles H3 son mucho más restringidos que los que presentan el conjunto general de proteínas del PDB. Los autores identifican cerca de 46.000 estructuras comparten los mismos parámetros LAT que H3, de ellas se seleccionan 16.000 que tienen una longitud entre 9 y 20 residuos (conjunto LAT no-IG) para posteriormente comparar si contienen *kink* en igual o diferente frecuencia que H3.

Para definir la geometría del *kink* emplean 2 ángulos. El primero (τ_{101}) es un pseudo ángulo de enlace entre los C_{α} de los tres residuos C-terminales (100x, 101 y 102). El segundo (α_{101}) es un ángulo diedro que considera los C_{α} de los mismos residuos que τ_{101} e incluye la posición 103. La representación geométrica de ambos ángulos se muestra en la Figura 8B. La distribución de τ_{101} (Figura 8C) se puede modelar con precisión como una mezcla de dos gaussianas, donde la mayor abarca aproximadamente el 80% de las estructuras. Mediciones adicionales confirmaron que la mayor corresponde con estructuras *kink*, mientras que la pequeña corresponde con una conformación de lámina β extendida. La distribución de α_{101} (Figura 8D) tiene picos separados de densidad sobre 0° y 180° y de igual manera, la distribución mayor corresponde a un 85% de las estructuras, coincidiendo con el *kink*. Empleando exclusivamente estos dos ángulos, concluyen que un 79% de los anticuerpos no redundantes poseen conformación *kink*.




Figura 8. (A) Ejemplo de un bucle H3 con la construcción de LAT. Los marcos de coordenadas (negros) se construyen a partir de los átomos C, C α y N de los anclajes N-terminal (verde) y C-terminal (magenta). Los seis grados de libertad (tres traslacionales y tres rotacionales) necesarios para superponer perfectamente los marcos de coordenadas se representan mediante una línea discontinua que los conecta. (B) **Geometría del kink definido por los dos ángulos:** τ_{101} , entre los C α de los tres residuos C-terminales y α_{101} , diedro entre los C α de los tres residuos C-terminales y el residuo de anclaje. (C) **Histograma de τ_{101} .** (D) **Histograma de α_{101} .** Figura obtenida de (Weitzner et al., 2015)

En el conjunto LAT no-IG únicamente un 6% de las estructuras presentaron una conformación similar al *kink*. Esto indica que, aunque no es tan común como en anticuerpos, es una conformación que si se puede encontrar en otro tipo de proteínas. También se analizó si existe alguna secuencia conservada relacionada con esta conformación, y aunque en anticuerpos si aparecen ciertos residuos conservados en los anclajes (ya que la cisteína 92 y el triptófano 103 definen el inicio y fin del bucle), en las proteínas no-IG no aparece ninguno aminoácido conservado en ninguna posición. Esto sugiere que no es dependiente de secuencia

En (North et al., 2011) definen el *kink* únicamente con distribuciones específicas de Ramachandran, por lo que (Weitzner et al., 2015) deciden representar los valores de los ángulos diedros correspondientes a las posiciones base de H3 y compararlos frente a las mismas posiciones en las estructuras LAT no-IG (Figura 9). Las estructuras con *kink* tienen una distribución de Ramachandran mucho más reducida tanto en los anclajes del bucle como en los 3 primeros residuos de cada extremo.




Figura 9. Distribuciones de Ramachandran para las posiciones los anclajes de bucle CDR-H3 (92 y 103) y las 3 posiciones más cercanas del bucle a cada anclaje (93-95 y 100x-102) y para sus correspondientes posiciones en el conjunto de bucles que cumplen los mismo parámetros LAT. En verde se representa la conformación kink, en rojo la conformación extendida y en azul una conformación que cumple características de ambas. Figura modificada del material suplementario de (Weitzner et al., 2015).

(Weitzner et al., 2015) argumentan que la presencia del *kink* se debe a que el plegamiento de la cadena H estabiliza su conformación y que se trata de un mecanismo permite incrementar la diversidad estructural con el mismo número de residuos (puesto que cuando la conformación es extendida, las láminas β continúan de forma más rígida). El motivo de que predomine la conformación *kink* en H3 y no en otros se atribuye a la necesidad evolutiva que han presentado los anticuerpos para poderse unir con gran especificidad a nuevos antígenos.

1.3.2 Como se produce un anticuerpo

Un humano adulto posee entre 3 y 9 millones de secuencias únicas para H3 en el sistema circulatorio (Arnaout et al., 2011), a pesar de que el genoma humano contiene únicamente alrededor de 60.000 genes (Nurk et al., 2022). Para poder alcanzar esta cifra tan elevada de diversidad de secuencia, los anticuerpos se generan a través de un proceso denominado recombinación somática o **recombinación V(D)J**.

Como se ha descrito previamente un anticuerpo se forma por una cadena pesada (H) y una ligera (κ o λ). Los segmentos genéticos que codifican para estas cadenas están organizados en tres loci: κ , λ y H. Mientras que las regiones constantes (C) de cada cadena se codifican en un único segmento de ADN, las regiones variables (V) se forman con la unión de 2 o 3 segmentos diferentes: V, D y J para la cadena H; y V y J para la cadena L. En la Tabla 1 se muestra la cantidad de variantes típicas que hay en el ser humano de cada segmento para cada locus. Como resultado del polimorfismo genético, los números varían para diferentes individuos, existiendo además un número variado de pseudogenes (versiones mutadas y no funcionales de una secuencia genética) intercalados.

Tabla 1. Número de segmentos de genes funcionales en loci de inmunoglobulina humana. Tabla adaptada de la Fig. 5.4 de (Duan & Mukherjee, 2016).

<i>Segmento</i>	<i>Cadena L</i>		<i>Cadena H</i>
	κ	λ	H
V	31-35	29-32	38-46
D	0	0	23
J	5	4-5	6
C	1	4-5	9

Cada locus esta codificado en un cromosoma diferente y su organización interna se muestra en la Figura 10. El locus λ se encuentra en el cromosoma 22, todos los segmentos V se encuentran agrupados y a continuación cada fragmento J se encuentra emparejado con un fragmento C (toda la región constante junta). El locus κ se localiza en el cromosoma 2, y en este tenemos el conjunto de segmentos V, seguidos de los segmentos J y una única copia del segmento C. Por último, el locus de la cadena H, localizado en el cromosoma 14, tiene en primer lugar también sus segmentos V, seguidos del conjunto de segmentos D, posteriormente los J y cerrando 9 diferentes

versiones del segmento C (esto se corresponde a los diferentes isotipos que pueden tomar los anticuerpos).




Figura 10. Organización de las líneas germinales de los loci de las cadenas H y L de inmunoglobulinas humanas. Segmentos V (rojos), D (verde), J (amarillo) y C (Azul) para el locus λ (cromosoma 22), κ (cromosoma 2) y H (cromosoma 14). Figura tomada de (Duan & Mukherjee, 2016).

Durante el desarrollo de los linfocitos B, las líneas germinales contienen la información completa, y mediante procesos de delección génica se selecciona únicamente un segmento V(D)J, generando células B especializadas. Permitiendo así que cada linfocito B maduro produzca en gran cantidad un mismo tipo de anticuerpo, pero cada uno tenga una combinación diferente. Solo a partir de la combinación de los diferentes segmentos se obtiene unas 200 combinaciones para la cadena L y 8000 combinaciones para la cadena H; por lo tanto, lo que da lugar a un total de 1.6×10^6 combinaciones únicas. Cada segmento está flanqueado por unas secuencias

conservadas, asegurando que solo estas regiones sean las que se recombinan en el proceso y protegiendo la linealidad, por ejemplo, un segmento V solo podrá unirse a un segmento D o J y no a otro segmento V. En la mayoría de las ocasiones la recombinación es precisa, pero hay un pequeño porcentaje de situaciones en las que durante la recombinación se eliminan o añaden ciertos nucleótidos en las zonas de unión. Esta ganancia o pérdida se denomina **diversificación de unión** (*junctional diversification*) e incrementa considerablemente la diversidad de secuencias generadas. Este proceso puede alterar el marco de lectura, lo que produce secuencias no viables en dos de cada tres casos. Los linfocitos B afectados, detendrán su proceso y se eliminarán en la médula ósea (Alberts et al., 2002; Jung et al., 2006). Es importante destacar que la información del bucle CDR H3 se reparte entre los segmentos V, D y J; lo que le explica su papel clave en el reconocimiento antigénico y su elevada variabilidad en comparación con los demás CDRs.

La recombinación V(D)J origina un repertorio inicial de anticuerpos con capacidad para detectar una amplia variedad de antígenos. Estos anticuerpos suelen presentar afinidades iniciales moderadas, lo que garantiza una eliminación eficiente de patógenos. Tras una primera exposición al patógeno, las células dendríticas que lo han fagocitado exponen material antigénico en la superficie y lo transportan a los órganos linfoides secundarios. Para incrementar esta afinidad se produce el mecanismo denominado **hipermutación somática**: proceso en el que se acumulan mutaciones puntuales en las regiones variables del anticuerpo con ratios 10^6 veces superiores que en los estándares observados en otros genes. Esta acumulación de mutaciones ocurre en la etapa de centroblasto, durante la diferenciación de células B en los centros germinales de estos órganos linfoides secundarios. Las células B expresan la enzima AID (Desaminasa inducida por activación) después de reconocer el antígeno a través de un anticuerpo de superficie que actúa como receptor de células B (BCR). Esta AID accede al loci de inmunoglobulina en el núcleo al asociarse con la maquinaria de transcripción y desamina algunas citosinas, convirtiéndolas en uracilos. Estos uracilos fuera de lugar serán reconocidos por la maquinaria de corrección de errores (la enzima uracil-DNA glycosylasa o el heterodímero MutS α) y se revertirá el cambio a citosinas en la mayoría

de los casos, sin embargo, en otros, la base nitrogenada introducida será una diferente a la existente previamente (Methot & Di Noia, 2017).

La hipermutación somática no distingue entre mutaciones favorables y desfavorables, pudiendo producir anticuerpos con mayor afinidad al antígeno, menor afinidad, ninguna variación en afinidad o incluso no funcionales al no plegarse correctamente. Sin embargo, el proceso de selección de anticuerpos ocurre en la zona clara del centro germinal donde se seleccionan las células B que producen los anticuerpos de mayor afinidad a los antígenos presentes (Martin et al., 2015).

1.3.3 Bases de datos de anticuerpos

Actualmente el **Protein Data Bank** (PDB), contiene con un total de 215.000 estructuras 3D de proteína obtenidas de forma experimental (Berman et al., 2000). Sin embargo, existen bases de datos más especializadas con el fin de facilitar búsqueda y uso de anticuerpos. Entre ellas, cabe destacar, la base de datos de estructuras de anticuerpos (Structural Antibody Database: SabDab) recoge todas las estructuras de anticuerpos existentes en el PDB (Dunbar et al., 2014a). Por ser la base de datos más completa y sencilla es la que se ha tomado como referencia en esta tesis. Dentro del propio SabDab existe una sección denominada Thera-SabDab en el que se almacena y se puede acceder a aquellas estructuras de anticuerpos que han sido oficialmente reconocidas para uso terapéutico (Raybould et al., 2020). También hay otras bases de datos con una finalidad similar, aunque menos empleadas, como son Abysis (Swindells et al., 2017), IMGT/3D-Structure-DB (Kaas et al., 2004) o Abdb (Ferdous & Martin, 2018). Existen también bases de datos más específicas como puede ser PyigClassify2, que almacena y agrupa las estructuras canónicas (conformaciones más frecuentes) de los principales bucles CDR (Adolf-Bryfogle et al., 2015; Kelow et al., 2022) o PCLICK que recoge las interacciones entre antígenos y anticuerpos (Cao et al., 2021).

1.3.4 Esquemas de numeración de anticuerpos

Debido a la conservación en estructura y longitud de los anticuerpos en las zonas constantes de F_V, frente a la variabilidad en las zonas CDR, se han ido generando una serie de esquemas de numeración de estos para mantener una numeración consistente en las zonas conservadas independientemente de la longitud de los bucles CDR. Se han

ido generado y empleando diferentes esquemas de numeración de forma simultánea (Dondelinger et al., 2018). Los principales esquemas de numeración son:

➤ **Kabat**

Es el primer esquema estandarizado, se empieza a desarrollar en 1970 (Kabat et al., 1979). Se origina desde un alineamiento de secuencias limitado de anticuerpos y de receptores de células T (TCR). Este esquema marca las inserciones con letras (por ejemplo, 101A, 101B, 101C en H3) y deja espacio en la numeración en caso de bucles más cortos o deleciones. Al ser limitado a unas estructuras con longitudes más estándar, resulta en un esquema poco flexible para estructuras menos convencionales. Otra carencia que muestra es que, al ser obtenido desde un alineamiento de secuencias, no tiene en cuenta la topología o estructura tridimensional a la hora de definir las regiones de los bucles.

➤ **IMGT (InMunoGeneTics)**

Esquema generado por la empresa IMGT®, que se origina desde el grupo de inmunogenética molecular de la universidad de Montpellier y es la principal referencia para inmunogenética e inmunoinformática. Esquema basado en el alineamiento de secuencia de genes toda la superfamilia de inmunoglobulinas de dominio tipo V (Lefranc et al., 2003). Numera desde las posiciones 1 a 128 de forma continua, haciendo únicamente una inserción para H3 entre las posiciones 111 y 112 cuando el bucle excede los 13 aminoácidos. Se salta un número cuando un residuo falta en una determinada secuencia. Este sistema es más robusto al originarse de una base de datos completa. Sin embargo, su método de numeración continua no permite una visualización más intuitiva de las posiciones de inserción, incluso para los bucles más comunes. Convirtiéndose en un esquema poco flexible para adaptarse a posibles nuevos puntos de inserción.

➤ **Chothia**

Es un esquema creado a partir de la alineación de la región V de estructuras cristalográficas (Chothia & Lesk, 1987b). Corrigen la posición de inserción de los bucles H1 y L1 respecto a Kabat, cambiando el punto de inserción de H35 a H31 y de L27 a L30. Inicialmente localizaron el punto de inserción de L1 en L30, pero 2 años más tarde lo movieron a L31 (Chothia et al., 1989), para que en 1997 retornara al L30 original. Su

principal limitación, al igual que Kabat, consiste en su limitación ante secuencias de longitudes menos comunes, ya que se describió desde una serie de estructuras más canónicas.

➤ **Martin/AbM – Enhanced Chothia**

Mejora el sistema Chothia al incorporar ciertos puntos de inserción en puntos fuera de los bucles CDR. Lo consiguen al analizar tanto secuencias como estructuras e incluir longitudes no canónicas (Abhinandan & Martin, 2008). Definen posiciones de delección donde encuentran un patrón de ausencia de aminoácido en ciertas familias, mientras que se conserva en otras. Con toda la información nueva, y junto con el software *Abnum*, describen un nuevo esquema denominado “Chothia mejorado”.

Variación North: Pequeña variación que afecta solo a el bucle H3. Chothia original comienza en la posición H95, tres aminoácidos después de una cisteína muy conservada. Sin embargo, posteriormente se describió que los dos aminoácidos que hay entre la cisteína y el inicio del bucle definido forman parte de la región susceptible de ser *kink*, pero, aunque se consideraba como una estructura muy conservada se fueron encontrando anticuerpos que no presentaban esta estructura (expuesto previamente en Figura 7). De esta forma el inicio del bucle H3 queda muy separado espacialmente con o sin la presencia de *kink* y la estructura del bucle depende de ello. Para tener en cuenta esta diferenciación estructural, se definió el inicio justo después de la cisteína en la posición H93 (North et al., 2011). Durante esta tesis se trabajará con esta variación de numeración.

En la Tabla 2 se muestra el esquema de numeración empleado por cada uno de los métodos anteriormente descritos.

Tabla 2. Esquema de numeración de anticuerpos. Posiciones en las cadenas L y H de cada bucle CDR según la definición de los métodos Kabat, Martin-AbM, Chothia e IMGT. (Valores obtenidos de (Bioinf.Org.Uk - Prof. Andrew C.R. Martin’s Group at UCL))

CDR	Kabat	Martin - AbM	Chothia	IMGT
L1	L24-L34	L24-L34	L26-L32	L27-L32
L2	L50-L56	L50-L56	L50-L52	L50-L51
L3	L89-L97	L89-L97	L91-L96	L89-L97
H1	H31-H35	H26-H35	H26-H32	H26-H33
H2	H50-H65	H50-H58	H52-H56	H51-H56
H3	H95-H102	H95-H102	H96-H101	H93-H102

A su vez también hay métodos más complejos que atienden a elementos diferentes y no únicamente diferencian por la numeración, como son los dos siguientes:

➤ **Gelfand**

Esquema más complejo y por lo tanto menos usado. Divide la cadena en 21 fragmentos, que coinciden con elementos de estructura secundaria. Las láminas y hélices son definidas con una letra (A, B, C ...) y los bucles son definidos con las letras de las estructuras que les rodea (AB, BC ...). Este esquema no incluye huecos o puntos de delección, pero permite una comparación precisa de estructuras secundarias. La definición de los CDRs no coincide con otros esquemas.

➤ **Honneger (AHO's)**

Esquema que numera de forma homogénea los variados dominios de la superfamilia de inmunoglobulinas. Se basa en un alineamiento estructural de la de la región V de las inmunoglobulinas. El esquema permite definir las posiciones conservadas de C α (Honnegger & Plückthun, 2001). Define una serie de residuos conservados (C23, W43, C106, G140, etc) y los huecos de los bucles en posiciones específicas (#27-28, #36, #63, #123). Al estar basado en alineamiento estructurales, coincide mejor con las características tridimensionales de los anticuerpos, de manera similar al esquema Chothia. Por otro lado, al igual que IMGT puede saltarse la numeración de algún residuo dando lugar a una mayor complicación para seguir la numeración de la secuencia. Se genera también un problema para incluir anticuerpos con nuevas o más largas inserciones.

1.3.5 Métodos de predicción de Anticuerpos

Los métodos experimentales de determinación de la estructura cristalográfica no tienen la capacidad y velocidad de cubrir el número de candidatos necesarios para el desarrollo de anticuerpos en programas terapéuticos. Esto provoca una necesidad de generar modelos computacionales suficientemente precisos y fiables para potenciar la resolución de estructuras de anticuerpos de forma eficiente. Debido a su complejidad estructural, métodos estándar de predicción de estructura de proteínas no han logrado resolver de forma correcta la región de los CDR, en especial de H3, obteniendo siempre resultados alejados (Teplyakov et al., 2014). Para intentar resolver este desafío se han

ido desarrollando diferentes métodos de predicción de estructura enfocados únicamente en anticuerpos, especializados en predecir las conformaciones que toman los bucles CDR. Aunque si se ha mejorado la precisión, todavía H3 sigue siendo un caso excepcional que trae complicaciones incluso para estos métodos. A continuación, se explicarán los métodos más relevantes hasta el momento.

1.3.5.1 RosettaAntibody (RoAb)

Rosetta es un paquete de software integral para el modelado estructural de macromoléculas. Originalmente estaba programado en Fortran y se centraba en la predicción *ab initio* de estructuras de proteínas pequeñas. Posteriormente pasó a codificarse en C++, ya que le daba más versatilidad y ha desarrollado métodos de predicción de proteínas tanto *ab initio* como por homología. Ha participado desde su inicio en los ejercicios de predicción de *Critical Assessment of Techniques for Protein Structure Prediction* (CASP) (Evaluación crítica de las técnicas para la predicción estructural proteica), siendo el método más competitivo en todas sus convocatorias desde que formó parte, hasta la aparición de AlphaFold. Se han ido desarrollando y añadiendo nuevas funcionalidades, protocolos y algoritmos a sus sistemas, como son funciones de puntuación de estructuras, *docking* con proteínas y ligandos, análisis de mutaciones o diseño de enzimas (Gray et al., 2003; Kuhlman et al., 2003; Rohl et al., 2004; Simons et al., 1997; C. Wang et al., 2007).

En este contexto, se desarrolló un protocolo específico para la predicción de los bucles CDR de anticuerpos, denominado RosettaAntibody (Weitzner et al., 2017), basado en su método de cerrado de bucles (NGK) junto con modelado por homología. Este protocolo está disponible en su distribución en C++, en Python mediante PyRosetta y en su servidor online ROSIE (<https://r2.graylab.jhu.edu/apps/submit/antibody>) (Lyskov et al., 2013). La entrada de este protocolo es la secuencia de ambas cadenas del anticuerpo en formato fasta. En una primera etapa se genera una estructura completa del anticuerpo por homología. Buscan estructuras conocidas con secuencia similares usando BLASTP para utilizarlos como plantillas para los diferentes elementos estructurales de F_v . Primero genera una plantilla para la orientación alineando las cadenas completas de F_L - F_H . Seguidamente incorpora las plantillas parciales sobre la general, probando diferentes configuraciones y seleccionando aquellas donde los

aminoácidos encajen mejor hasta obtener el primer modelo inicial. Este proceso se repite hasta tener 10 modelos iniciales diferentes que parten de distintas plantillas de orientación. Como es previsible que los bucles de los CDR queden ligeramente abiertos, se realizan ajustes estructurales a través de ciclos de minimización con CCD para cerrarlos. Posteriormente se realiza una relajación completa de la estructura para situar correctamente las cadenas laterales restringiendo el movimiento de la cadena principal. Desde este punto en el que se tienen los bucles cerrados es donde empieza el refinado de la estructura. Para ello se remodela los bucles con técnicas KIC de nueva generación (NGK) (Stein & Kortemme, 2013), de forma iterativa hasta tener múltiples candidatos que se ordenan según su energía y que posteriormente serán seleccionados por el usuario.

Como hemos comentado anteriormente, dado que los bucles H3 tienen la estructura característica de *kink*, también han desarrollado otro protocolo para la predicción de este CDR considerando esta singularidad (Weitzner & Gray, 2017). Para ello, se añaden una serie de restricciones angulares a su algoritmo de NGK de generación de bucles para que adopten preferencialmente la conformación del *kink*.

1.3.5.2 Alphafold 2 (AF2)

Alphafold2 es un método revolucionario basado en aprendizaje profundo (*Deep Learning*, DL), que ha permitido dar una solución práctica al problema del plegamiento de proteínas a partir de su secuencia (Jumper et al., 2021). Debuta su primer prototipo en las evaluaciones de CASP13 (2018), con resultados muy similares al resto de métodos punteros; y es en CASP14 (2020), con el método pulido, cuando revoluciona el campo de la predicción de estructuras al sobrepasar de forma rotunda al resto de métodos. Las estructuras de AF2 tuvieron una precisión de 0.85-1.16 Å con un 95% de confianza, frente a 2.7-4.0 Å de su competidor más cercano (Kryshtafovych et al., 2021). Desde entonces, AF2 se ha convertido en el nuevo estándar en predicción estructural, junto con RosettaFold (Baek et al., 2021), al permitir el acceso a información estructural de las proteínas en minutos a partir de su secuencia.

Además de la predicción 3D, AF2 proporciona un valor de confianza por residuo llamado pLDDT. Un pLDDT >90 indica alta fiabilidad, valores entre 70 y 90 sugieren una

buena predicción de la cadena principal, mientras que valores <50 suelen corresponder a regiones desordenadas o poco fiables. Aunque de forma general los modelos de AF2 son muy buenos, en ocasiones presentan regiones de menos fiabilidad, muchas veces localizadas en la superficie en regiones flexibles como bucles.

La entrada principal para la red neuronal de AF2 es la secuencia, a partir de la cual se genera un alineamiento múltiple (MSA) con secuencias homólogas. La calidad de este MSA determina en gran medida la precisión de la predicción: MSAs profundos y diversos, con cientos o miles de secuencias alineadas, permiten detectar señales coevolutivas más robustas. Entre las limitaciones del método destacan su dificultad para modelar cambios conformacionales e interacciones proteína-proteína.

Aunque no es un método especializado en anticuerpos, pero al tener una alta precisión con cualquier tipo de estructuras se convirtió en un método muy válido para usar para su predicción.

1.3.5.3 ABodyBuilder (ABB1)

ABodyBuilder es un algoritmo de predicción de anticuerpos por homología compuesto por 4 etapas (Leem et al., 2016):

1. Selección de plantillas: se escoge una única plantilla para ambas cadenas (F_H y F_L) si la identidad de secuencia sobre la estructura ya resuelta es superior al 80%, de lo contrario se eligen una plantilla para cada cadena.
2. Predicción de orientación: se mantiene la orientación entre cadenas de la plantilla única o se toma la de la subunidad con mayor identidad.
3. Modelado de bucles: se utiliza FREAD (Choi & Deane, 2010b), que emplea bibliotecas específicas de estructuras CDR. Si no encuentra coincidencias por tamaño y/o identidad de secuencia, recurre al modelado *ab initio* mediante MODELLER (Šali & Blundell, 1993).
4. Predicción de cadenas laterales: utiliza la herramienta SCWRL4 (Krivov et al., 2009). Tienen 2 aproximaciones: la primera es la predicción parcial, en la que mantienen la misma orientación que en la plantilla original para las cadenas laterales de los aminoácidos que coinciden en la misma posición y predicen el

resto; y la segunda es la predicción completa de todas las cadenas laterales. Si hay colisiones, se aplica una relajación estructural con MODELLER.

1.3.5.4 ABlooper (ABL)

ABlooper es una herramienta de predicción de bucles CDR basada en DL equivariante de extremo a extremo. Se diseñó para mejorar los resultados obtenidos por ABB1, por lo que parte de una estructura tridimensional en formato IMGT, sobre la que elimina los bucles CDR y los genera de nuevo en base a su red neural entrenada (Abanades et al., 2022).

Está compuesto por 5 redes neuronales gráficas equivariantes (E(n)-EGNN), cada una con 4 capas. Se entrenaron en paralelo con un total de 3438 estructuras de anticuerpos, teniendo solo en cuenta los átomos de la cadena principal de los aminoácidos de los bucles y sus anclajes. Cada una de las 5 redes dará una predicción diferente, y el resultado final consiste en una estructura media del resto de resultados. Como solo se modela la cadena principal, se necesita hacer un paso de relajación de los bucles, minimizando de energía a través del integrador de Langevin contenido en el paquete de Python de OpenMM. Aunque este paso reduce ligeramente la precisión del RMSD, garantiza estructuras físicamente plausibles.

Tras comprobar que mejoraban notablemente los resultados previos de ABB1, decidieron incorporarlo dentro de este, sustituyendo el paso de modelado de bucles de FREAD; junto con la sustitución de la predicción de cadenas laterales de SCWRL4 a PEARS (Leem et al., 2018)(Abanades et al., 2023a).

1.3.5.5 AbodyBuilder2 (ABB2)

Aunque comparte nombre con ABB1, ABB2 es un método completamente distinto, desarrollado tras el éxito de AF2. Emplean como base la estrategia de AF-multimer y modifican algunos de sus parámetros y características para centrarse solo en estructuras de anticuerpos y sus CDRs, basándose en las técnicas que han desarrollado previamente (Abanades et al., 2023b). El sistema cuenta con cuatro modelos DL entrenados independientemente que generaran cuatro predicciones estructurales. Se

alinean y se selecciona la más representativa, la cual es posteriormente relajada en OpenMM (Eastman et al., 2017).

1.3.5.6 DeepH3 y DeepAB (DAB)

DeepH3 es una red neuronal entrenada para predecir las distancias y orientaciones entre residuos de las cadenas H y L. Se genera un conjunto de probabilidades de distribución para las distancias y orientaciones entre pares de residuos, con las que se construye un potencial que se emplea para discriminar entre los modelos generados por el método anteriormente explicado de RoAb (Ruffolo et al., 2020).

DeepAB es una evolución de DeepH3 que incorpora información evolutiva de la secuencia junto a un procesamiento y minimización final de la estructura con Rosetta (Ruffolo et al., 2022). Es importante reseñar que se ha entrenado con un conjunto reducido de 1433 estructuras de anticuerpos.

1.3.6 Diseño estructural computacional como futuro de la ingeniería de anticuerpos

Gracias a su alta especificidad frente a los antígenos, los anticuerpos se han consolidado como herramientas fundamentales en diversos campos, como la bioquímica, la biología molecular o la medicina. Su aplicación abarca desde el diagnóstico hasta el tratamiento de múltiples enfermedades, donde actúan mediante la activación del sistema inmune (Ducancel & Muller, 2012). Es por esto, que la mayoría de las proteínas terapéuticas que están clínicamente aprobadas o en fase de ensayos clínicos son, en grado variable, inmunogénicas (Baker, 2009; Van Walle et al., 2007). Muchas de las herramientas giran alrededor de la creación de anticuerpos monoclonales (mABs): anticuerpos idénticos generados en laboratorio a partir un único linfocito B maduro clonado. Estos mABs se han desarrollado para un amplio abanico de enfermedades y tratamientos, siendo pilares básicos en enfermedades como el cáncer o trastornos autoinmunes, entre otras patologías.

La ingeniería de proteínas consiste en la edición o modificación de la función de una proteína a través de la alteración de su secuencia genética (Wilkinson et al., 1984).

En particular, la ingeniería de anticuerpos busca mejorar las propiedades bioquímicas y biofísicas de los anticuerpos de interés. Metodológicamente existen dos estrategias para lograrlo: racionales y empíricos (Chiu et al., 2019). Los métodos racionales están basados en el conocimiento de la estructura, obtenida por métodos experimentales o modelos *in silico*. Los métodos empíricos se basan en generar grandes librerías de mutantes y hacer un cribado sobre el antígeno con el que se quiere dirigir, atendiendo a cualidades como la especificidad de unión.

Hasta el momento, la ingeniería de anticuerpos se ha basado en estrategias experimentales *in vivo* prácticamente en su totalidad, las cuales requieren múltiples rondas de optimización y validación experimental. Sin embargo, los recientes avances en predicción de estructuras están revolucionando este campo, permitiendo el desarrollo de enfoques computacionales, tanto parciales como totalmente *in silico*, con cada vez más protagonismo (Chaves et al., 2025; Dreyer et al., 2024; Hummer et al., 2022; Joubbi et al., 2024; Norman et al., 2020; Wilman et al., 2022).

2. Objetivos

El objetivo principal es el desarrollo de un método *ab initio* para la predicción estructural de bucles CDR de anticuerpos y en particular de H3 por su variabilidad e importancia funcional. Para ello se plantean los siguientes objetivos específicos:

1. Actualizar y mejorar el algoritmo de RCD+.
 - 1.1. Optimización del término de Ramachandran en la formula del potencial KORP.
 - 1.2. Actualización de la etapa de refinamiento de PyRosetta.
2. Adaptar RCD+ a la predicción de bucles CDR de anticuerpos.
 - 2.1. Recopilación y curación de conjuntos de referencia para la predicción de anticuerpos.
 - 2.2. Diseño de mapas de Ramachandran específicos para bucles CDR, con el fin de restringir el muestreo conformacional y aumentar la precisión de predicción.
 - 2.3. Validación sistemática de los mapas de restricción desarrollados.
3. Comparar el rendimiento del método desarrollado con otros métodos de predicción.
 - 3.1. Comparación con RosettaAntibody como método *ab initio* en la predicción específica del bucle H3.
 - 3.2. Comparación con otros métodos de referencia: AlphaFold2, DeepAB, AntiBodyBuilder y ABlooper.

3. Materiales y métodos

3.1 Desarrollo e implementación de RCD+

El primer objetivo de esta tesis consiste en la actualización y mejora del algoritmo RCD+. Este es un método diseñado para predecir la estructura completa de un bucle de proteína en tres etapas (Figura 11):




Figura 11. Esquema de las etapas para la predicción completa de un bucle en RCD+.

1. Etapa de **muestreo**: consiste en la generación de un gran número de conformaciones cerradas del bucle a través del algoritmo RCD para cubrir la mayor parte posible del espacio conformacional. Para simplificar el problema solo trabaja con los átomos de la cadena principal (C, C_α , O y N) junto al C_β .

2. Etapa de **filtrado**: se evalúan todas las conformaciones generadas con el potencial KORP para seleccionar las de menor energía (consideradas como las más probables estructuralmente).

3. Etapa de **refinado**: a partir de las estructuras seleccionadas, se genera un modelo completo incluyendo las cadenas laterales con PyRosetta, aplicando protocolos de minimización eliminar colisiones y optimizar la estructura final. Se seleccionan las conformaciones de menor energía del conjunto refinado.

A continuación, se explicará con mayor detalle la metodología de cada una de estas etapas.

3.1.1 Muestreo de bucles → RCD

La primera etapa consiste en resolver el problema del cerrado de bucles. RCD funciona de una manera similar al método de CCD, pero con incorporaciones clave que lo hacen más robusto. El CCD es un algoritmo iterativo que primero coloca todos los aminoácidos del bucle desde el aminoácido N-terminal (o de anclaje) con ángulos diedros ϕ (phi) y ψ (psi) aleatorios para luego optimizarlos secuencialmente hasta conseguir superponer el último aminoácido del bucle con el de anclaje en el extremo C-terminal (Canutescu & Dunbrack, 2003).

Entre las modificaciones que incorpora RCD frente a CCD se encuentran:

- La selección aleatoria de los ángulos: en lugar de seguir una optimización secuencial, se escoge aleatoriamente los diedros a modificar en cada iteración, lo que contribuye a una exploración más amplia y diversa del espacio conformacional.
- La selección aleatoria del extremo desde donde se inicializará la construcción del bucle: mientras que CCD siempre es el extremo N-terminal, en RCD los bucles también se pueden comenzar desde el extremo C-terminal.
- Una actualización de conformaciones más rápida (Chys & Chacón, 2012) gracias a la utilización de una aproximación matricial basada en spinors para calcular las rotaciones.
- La incorporación de una serie de filtros geométricos para evitar colisiones y generar bucles con estereoquímica más realista (Chys & Chacón, 2013).

3.1.1.1 Proceso de cerrado de bucles

El proceso completo de cerrado de un bucle se detalla en la Figura 12 y consta de los siguientes pasos:

1. Definición de datos de entrada: Se especifica la secuencia del bucle y las regiones Nt y Ct de anclaje dentro de la estructura de la proteína.
2. Definición del espacio 3D accesible: Se construye una rejilla en 3D, centrada en los anclajes, con un tamaño acorde a la longitud del bucle, en la que se define de forma binaria la presencia (1) o ausencia (0) de los átomos de la proteína. Utilizando esta rejilla podemos detectar de forma eficiente las posibles colisiones de los átomos del bucle que estamos generando con su entorno dentro de la proteína.
3. Inicialización del bucle: Se selecciona la dirección de cierre de bucle de forma aleatoria ($Ct \rightarrow Nt$ o $Nt \rightarrow Ct$). Se van colocando el resto de los aminoácidos de manera que queda un extremo del bucle unido a su anclaje y el otro en una posición aleatoria sin colisiones dentro de la rejilla. Se coloca el residuo del anclaje opuesto al final del bucle abierto, manteniendo sus distancias y ángulos de enlace originales. La distancia entre este residuo anclaje del bucle abierto respecto a su posición real en la proteína define nuestra función de coste en la minimización.
4. Iteraciones de minimización: Se escoge aleatoriamente uno de los ángulos diedros del bucle y se le calcula la rotación óptima que minimiza RMSD entre el residuo de anclaje del bucle y su posición real en la proteína. Se acepta la nueva conformación siempre que todos los aminoácidos cumplan con los filtros geométricos intermedios (explicados más adelante en 3.1.1.2). En caso contrario, se descarta y se retoma la conformación anterior a la rotación. De esta forma las conformaciones intermedias que se van formando en el cierre del bucle generando son estereoquímicamente razonables.
5. Se repite sucesivamente el paso anterior eligiendo aleatoriamente entre los ángulos diedros restantes (evitando repetir el mismo ángulo en dos pasos consecutivos) hasta que el RMSD sea inferior a un umbral (e.g. 0.1 Å) y pase por

los filtros finales. Si no los supera, se descarta y comienza una nueva iteración desde el paso 3.

6. Se repite desde el paso 3 hasta al 5 hasta obtener el número requerido de bucles cerrados válidos. Con la intención de cubrir la mayor parte del espacio conformacional, se recomienda generar entre 20.000 y 50.000 bucles, atendiendo a la longitud del bucle objetivo. Aunque como veremos más adelante, para bucles muy largos, el número de bucles necesario podría ser mucho mayor.




Figura 12. Diagrama de flujo del proceso de cerrado de bucles mediante RCD.

3.1.1.2 Filtros geométricos

Para mejorar la eficiencia de búsqueda, RCD incorpora una serie de filtros para descartar configuraciones geométricamente no válidas.

- **Filtro de colisiones de la rejilla:** Este filtro comprueba si el bucle no colisiona con la proteína original (i.e. la proteína sin el bucle a modelar). Este filtro se usa durante la fase de inicialización, las iteraciones de minimización y también como filtro final para asegurar que en todo momento el bucle se encuentra en una región válida del espacio de búsqueda. En particular, se utiliza una máscara binaria cúbica cuyas celdas son de 0.25 Å de lado y toman valores de 1 en las zonas ocupadas por proteína y de 0 en las zonas libres mediante la proyección esferas de *van der Waals* en las posiciones de los átomos de la proteína original. Aunque sería más exacto utilizar radios de *van der Waals* según el tipo de átomo particular, se ha comprobado que utilizar un mismo valor de 3 Å (el doble del radio medio de 1.5 Å) es una buena solución de compromiso para generar una máscara suave y tener en cuenta que la estructura de la proteína experimental no suele incluir los átomos de hidrógeno. Finalmente, basta con comprobar directamente si todos los átomos del bucle están en las zonas libres de la máscara 3D para determinar que no tiene colisiones, evitando el elevado coste computacional que implicaría comprobar todas las distancias átomo a átomo.
- **Filtro de colisiones internas:** Detecta las colisiones entre los átomos del bucle. Este filtro opera como filtro intermedio durante los movimientos del bucle abierto y como filtro final para comprobar que el bucle cerrado tiene una geometría válida. Para ello se calcula la distancia interatómica de todos los átomos que forman la cadena principal del bucle y tomando distancia límite valores estándar (Fersht, 1985).
- **Filtro adaptativo de Ramachandran:** Restringe los ángulos diedros phi (ϕ) y psi (ψ) de acuerdo con los rangos de Ramachandran. Este filtro opera como filtro inicial y como filtro intermedio justo antes de aplicar el filtro de colisiones externas, y simplemente acepta o rechaza el bucle abierto. Originalmente se empleaba un filtro sencillo generado a partir de una distribución estándar de Ramachandran, pero con la publicación del servidor web RCD+ se decidió

actualizar este filtro y utilizar distribuciones más específicas (López-Blanco et al., 2016). Se trata de distribuciones de probabilidad dependientes de vecino, extraídas mediante un análisis estadístico no paramétrico bayesiano sobre un conjunto de datos de bucles de proteínas de alta resolución (Ting et al., 2010).

3.1.2 Filtrado y selección de estructuras

3.1.2.1 Introducción de potenciales de energía

La segunda etapa de RCD+ es cribar el elevado número de bucles cerrados por RCD, seleccionando los más cercanos a la estructura nativa del bucle. Para ello se utiliza un filtro de energía, seleccionando aquellas conformaciones que están más cerca del mínimo energético. El cálculo o estimación de energía se puede hacer a partir de potenciales físicos o estadísticos. Los potenciales físicos, como puede ser el cálculo de campos de fuerza de mecánica molecular son más precisos, pero requieren un gran esfuerzo computacional. Por otro lado, los potenciales estadísticos o basados en el conocimiento (*knowledge-based*) obtenidos desde estructuras de proteínas son una alternativa muy útil, ya que sus resultados se acercan bastante a los de los potenciales físicos, pero sin requerir el elevado esfuerzo computacional de estos últimos. Además, también son muy versátiles, pues permiten adaptar el nivel de detalle con el que se representan las estructuras a cada aplicación particular para encontrar el equilibrio adecuado entre velocidad y calidad.

Los primeros potenciales basados en el conocimiento consideraban únicamente los contactos entre átomos, y se fueron desarrollando diferentes aportaciones para mejorarlos como la influencia de la distancia entre los aminoácidos o la inclusión de términos de orientación (Poole & Ranganathan, 2006). La posición y orientación relativa entre dos objetos 3D (en este caso dos aminoácidos) se puede describir a partir de seis grados de libertad, por ejemplo, con tres translaciones y tres rotaciones o con una distancia y cinco variables angulares. En un inicio, hubo métodos que optaron por asumir independencia entre los parámetros angulares, como es el caso de GOAP (Zhou & Skolnick, 2011) y otros optaron por una reducción de las dimensiones con las que operar, como es el caso de ORDER_AVE que tuvieron en cuenta solo cuatro dimensiones (Liu et al., 2014). En nuestro laboratorio se desarrolló un potencial específico denominado

KORP (Knowledge-base ORientational Potential), un potencial orientacional basado en el conocimiento (López-Blanco & Chacón, 2019), en el que se considera la dependencia en seis grados de libertad. Este potencial se mostró muy competitivo en especial para el cribado de bucles y se incorporó como potencial de predicción de RCD+. También se ha empleado con éxito para evaluar interacciones proteína-ligando (KORP-PL) (Kadukova et al., 2021) y para predecir estabilidad y cambio de energía con mutaciones puntuales (KORPM) (Hernández et al., 2023). Nosotros hemos utilizado este potencial para el cribado de bucles, por esta razón se describe en detalle a continuación.

3.1.2.2 KORP

➤ Posición relativa y orientación de los marcos de referencia

KORP es un potencial aproximado (*coarse-grained*) definido por una probabilidad 6D que depende de la posición y orientación relativa de 3 átomos de la cadena principal (C, C $_{\alpha}$ y N). Este potencial es independiente de las cadenas laterales. La posición y orientación relativa entre dos aminoácidos i y j viene definido por una distancia y cinco parámetros angulares, tal como se ilustra en la Figura 13. La distancia (r_{ij}) corresponde al módulo del vector que conecta los átomos C $_{\alpha}$ de ambos aminoácidos. La orientación relativa viene dada por los siguientes cinco ángulos: θ_i , φ_i , θ_j , φ_j and ω_{ij} .




Figura 13. Variables que definen la relación 6D entre dos aminoácidos.

El sistema de referencia de cada aminoácido consiste en tres vectores:

$$V_Z = (r_{CC_\alpha} + r_{NC_\alpha}) / |r_{CC_\alpha} + r_{NC_\alpha}| \quad (1)$$

$$V_Y = (V_Z \times r_{NC_\alpha}) / |V_Z \times r_{NC_\alpha}| \quad (2)$$

$$V_X = (V_Y \times V_Z) \quad (3)$$

En la ecuación (1) se obtiene V_Z : el vector unitario de la suma de r_{CC_α} y r_{NC_α} , los cuales son los vectores definidos desde el átomo C_α a los átomos N y C respectivamente. En la ecuación (2) se obtiene V_Y : vector unitario del producto vectorial entre V_Z y r_{NC_α} . Y en la ecuación (3) se obtiene V_X : vector resultante del producto vectorial entre V_Z y V_Y .

Con estos vectores se obtienen los dos ángulos polares de cada aminoácido: θ es el ángulo entre el radio r_{ij} y el vector V_Z ; mientras que ϕ es el ángulo entre V_X y la proyección de r_{ij} en el plano definido por V_X y V_Y . Mientras que el ángulo de torsión ω_{ij} es el diedro definido por los vectores V_{Zi} , r_i y V_{Zj} .

➤ Definición del potencial

El potencial de KORP se obtiene de un conjunto de proteínas no redundantes (explicado más adelante en este mismo apartado), usando una ecuación clásica de Boltzmann inversa:

$$E_{ij} = -RT \ln \frac{P_{ab}^{obs}(r_{ij}, \phi_i, \theta_i, \phi_j, \theta_j, \omega_{ij}) + z}{P^{ref}(r_{ij}, \phi_i, \theta_i, \phi_j, \theta_j, \omega_{ij}) + z} \quad (4)$$

Donde P_{ab}^{obs} es la probabilidad conjunta en 6D que depende de la distancia y orientación relativa entre dos aminoácidos i y j de tipo a y b , respectivamente. La constante z se añade para prevenir valores infinitos o muy altos cuando las probabilidades de referencia (P^{ref}) son muy bajas, y además contribuye a mejorar la estabilidad del potencial. La probabilidad de referencia se define siguiendo la forma clásica de (Samudrala & Moult, 1998) en la que simplemente se hace la media sobre los 20 tipos de aminoácidos. Al tratarse de un potencial *coarse-grained*, se divide el espacio de cada variable en intervalos o compartimentos. El radio r_{ij} se divide en 10 intervalos iguales y el ángulo de torsión ω_{ij} en 8 intervalos de 45°. Los ángulos polares de cada aminoácido (θ y ϕ) se dividen mediante una teselación esférica que produce 36 regiones

con superficie equivalente (Figura 14), consistente en 2 áreas circulares polares y 34 regiones cuasi cuadradas (Beckers & Beckers, 2012). Finalmente, para todos los compartimentos pertenecientes a cada intervalo de r , se normalizan las energías obtenidas desplazando la media al valor 0. Con esta acción se suavizan las diferencias dependientes de distancia y favorecen las dependientes del tipo de aminoácido y orientación.




Figura 14. Teselación del espacio circular para los ángulos θ y ϕ .

Dado que $P_{ab}^{obs} \neq P_{ba}^{obs}$, puesto que tienen diferencias sutiles, aunque significativas, ya que las preferencias evolutivas para la orientación y disposición de aminoácidos a y b no conmutan (i.e. no es lo mismo una prolina precediendo a una alanina en términos de secuencia, que al revés), se consideran 400 mapas 6D (en lugar de 200), uno para cada par de aminoácidos. Cada mapa tiene dimensiones 36x36x8x10, lo que lleva a un total de dimensiones 36x36x8x10x400.

➤ **Términos del potencial**

$$E = f_l \sum_{n < s}^{n=2} E_{ij}^{local} + \sum_{n > s}^{n=s} E_{ij}^{non-local} + f_r \sum_{n=1} E_i^{rama} \quad (5)$$

Originariamente, al igual que en otros potenciales basados en conocimiento los dos primeros términos diferencian entre interacciones locales y no locales. Donde n es la separación entre el índice de secuencia ambos aminoácidos y s el límite de distancia entre dos residuos para considerarse en un término u otro. El termino local contiene el factor de ajuste (f_l).

Posteriormente se añadió un tercer término adicional para tener en cuenta las interacciones entre aminoácidos consecutivos en secuencia dependiente de las distribuciones de Ramachandran (6). En el que la $P_{ab}^{obs}(\phi, \psi | L, C, R)$ es la probabilidad condicional de que cualquier residuo central C con los vecinos L y R (izquierda y derecha) tenga los ángulos diedros ϕ y ψ . Y $P^{ref}(\phi, \psi | C)$ es probabilidad condicional de que cualquier residuo central C tenga los ángulos ϕ y ψ . Para obtener las distribuciones de Ramachandran de aminoácidos dependientes de vecino se emplea las mismas distribuciones que en el filtro geométrico (Ting et al., 2010). Estas distribuciones se discretizan en intervalos de 5° para cada ángulo diedro, formando compartimentos de 5x5. En total se forma una matriz de 72x72 para cada mapa, que se corresponde con unas dimensiones totales de 72x72x20x20x20. Este término de rama tiene también su propio factor de ajuste (f_r).

$$E_i^{rama} = -RT \ln \frac{P_{ab}^{obs}(\phi, \psi | L, C, R)}{P^{ref}(\phi, \psi | C)} \quad (6)$$

El primer objetivo específico de esta tesis consistió en la optimización de la inclusión de este término, explicado en el apartado 4.1.1 y donde tras un análisis de diferentes configuraciones de parámetros se definió como óptimos los siguientes valores:

- **Radio (r_{ij}):** Los límites para considerar las interacciones comprende entre 3 y 14 Å, dividido en 10 intervalos iguales.
- **Ángulos polares (θ y ϕ):** Teselación esférica de 36 regiones.
- **Angulo de torsión (ω):** 8 divisiones de 45°.
- **Límite entre termino local y no local (s):** Valor óptimo de 5.
- **Factor local (f_l):** 1.8.
- **Factor rama (f_r):** 6.
- **Constante z:** 10^{-8} .

➤ **Conjunto de entrenamiento de KORP**

Para generar el potencial KORP se obtuvieron inicialmente 36.851 cadenas de proteínas no redundantes del servidor web PISCES (G. Wang & Dunbrack, 2005). Los criterios para seleccionar dichas cadenas fueron: i) identidad de secuencia inferior al 90

%, ii) resolución mejor que 3.0 Å, y iii) Factor-R inferior a 0.25. Para evitar efectos de sobre ajuste se eliminaron las estructuras con una identidad de secuencia igual o superior al 50% con las estructuras seleccionadas para el conjunto de referencia de evaluación (se expone en el apartado 3.5.1), empleando CD-HIT (Fu et al., 2012). Por lo que el conjunto final de entrenamiento incluyó 35.929 cadenas de proteína.

3.1.2.3 Detalles de ejecución de RCD + KORP

➤ KORP

La generación del potencial KORP se realiza en dos etapas:

1. Generación del **mapa de contactos**:

Primero, KORP procesa todos los átomos de los PDBs listados en `ListaPISCES.txt` y anota en un archivo binario (`mapacontactos`) aquellos contactos dentro de los rangos descritos mediante las opciones `-c` (distancia máxima) y `--minr` (distancia mínima):

```
korp ListaPISCES.txt -c 18 --minr 1 --stride .stride -o
mapacontactos
```

2. Generación del **potencial** desde un mapa de contactos:

```
korp asdf -l mapacontactos -d 6 -c 14 --minr 3 --nr 10 -n 36 --nc 8
--nb 1 --bnb 4 --izero 1e-8 --bf 1.8 -o potencialKORP
```

Es necesario incluir `asdf` como primer argumento para diferenciarlo del comando anterior. Con `-l` introducimos el archivo de contactos `mapacontactos`. La opción `-d` especifica las dimensiones (en este caso 6, ya que en otros contextos se ha experimentado con un menor número de dimensiones). Con `-c` y `--minr` indicamos distancia máxima y mínima de interacción otra vez (esta vez algo más reducida). En `-nr`, `-n` y `--nc` se definen el número de divisiones para el radio r , para los ángulos diedros θ y φ y para el ángulo de torsión ω . Las opciones `--nb` y `--bnb` establecen el rango de separación en secuencia para considerar una interacción como local (de `--nb` sin incluir hasta `--bnb` incluido). En `--nb` se indica el residuo de inicio del término local sin incluir hasta el valor de `--bnb` incluido. Con `--izero` se introduce la constante z de la fórmula de Boltzmann. `--bf` es para el factor del término local. Por último, en `-o` se indica el nombre que se le pone al potencial generado.

Una vez generado el potencial este se puede emplear para evaluar estructuras con el comando *korpe*. La forma más sencilla evalúa una estructura completa tan solo indicando su nombre y especificando el potencial tras *--score_file*:

```
korpe proteina --score_file KORP.bin -o output
```

La opción *--loops* permite evaluar la precisión de la predicción de bucles de proteínas. Para ello se le añade el archivo Multi-PDB que se genera de RCD con los bucles cerrados generados para una proteína o el sufijo de este archivo para las estructuras de la lista. La opción *--rmsd* indica que existe la estructura nativa y se calcula el RMSD. Con *--score_file* se vuelve a poner el potencial de KORP. Otra diferencia entre ambos comandos es que el primero emplea la versión original de KORP con solo dos términos, mientras el segundo incorpora el termino de rama siendo necesario especificar los valores de *-e* y *--rama_model*; además de especificar el archivo de distribuciones de Ramachandran (*dunbrack.bin*) tras *--rama_file*.

```
korpe proteina --loops proteina_closed.pdb --rmsd --score_file  
KORP.bin -o output
```

```
korpe lista_ids.txt --loops _closed.pdb --rmsd --score_file  
KORPmap.bin -e 56 --rama_model 3 --rama_file dunbrack.bin --rf 6 -o  
output
```

La versión de KORP empleada en esta tesis es la 1.25. La parte de evaluación de estructuras (*korpe*) se puede descargar en el GitHub del grupo:

<https://github.com/chaconlab/Korp.git>

➤ RCD

Comando de RCD para generar 50.000 bucles de una lista de proteínas:

```
rcd lista_ids.txt -r -e 56 --energy_file potencialKORP.bin -n 50000  
--loco_best 1000 -x dunbrack.bin --linear -d 0.5 --linear -t 0.99 -  
o output
```

El archivo de entrada donde se definen las estructuras y los bucles se indica en el primer argumento (*lista_ids.txt*) y debe tener el siguiente formato para cada caso:

PDB1.pdb	96	104	H	ARRDITTFY
PDB2.pdb	89	97	L	HQSSSLpFT

Cada caso se pone en una línea diferente, sin líneas en blanco. En orden se deben especificar el archivo estructural, la posición de residuo de inicio del bucle, la posición del final, la cadena y la secuencia de aminoácidos en código de una letra en mayúscula.

Si el bucle contiene una prolina es necesario cerciorarse si es CIS o TRAN para que RCD no de error. Para indicar esta diferencia se anota en mayúscula para el primer caso y en minúscula para el segundo, como se puede observar en la 2ª línea del ejemplo.

Con la opción `-r` se activa una pequeña aleatorización al seleccionar longitudes de enlace entre átomos al cerrar el bucle. Y con la opción `-e` se especifica el modelo del potencial de energía: con un `1` se usa potencial básico, con `5` se usa el KORP original, con `6` solo el termino de Ramachandran y con `56` ambas opciones; también existe la opción `0` donde no se seleccionan bucles, tan solo se generan. Tras esto es necesario indicar el archivo del potencial (*potencialKORP.bin*) con la opción `--energy_file`. Con la opción `-n` se indica el número total de bucles a generar y con `--loco_best` el número de ellos seleccionados por el potencial escogido. La opción `-x` especifica el archivo de distribuciones de Ramachandran dependiente de vecinos (Ting et al., 2010), empleado tanto en el proceso de cierre de bucles como en la evaluación si se especifica emplear el termino de Ramachandran en el potencial. Con `--linear` se activa el método aproximación lineal para el último paso del cerrado de bucles y con `-d` se indica el valor en Å a partir del cual se considera el bucle cerrado. `-t` indica el límite en porcentaje de la región a tener en cuenta de la distribución de Ramachandran: por ejemplo, con 99% se tienen en cuenta casi la totalidad de la distribución, pero se omite el 1% menos denso con fin de eliminar los casos aislados. El programa genera una carpeta con el nombre indicado en `-o` y en su interior archivos para cada PDB de la lista de entrada con los siguientes sufijos:

- *_loop1.pdb* → Archivo PDB con el bucle nativo cortado y que se emplea para calcular el RMSD con los generados de forma sencilla.
- *_native.txt* → Archivo de texto con los ángulos diedros (ϕ y ψ) de cada residuo del bucle nativo.
- *_closed.pdb* → Archivo Multi-PDB con todos los bucles cerrados seleccionados.
- *_rmsd.txt* → Archivo donde se listan los bucles cerrados ordenados según la energía obtenida y que muestra su RMSD frente al nativo.
- *_len.txt* → Archivo con las longitudes de enlace entre cada átomo de la cadena principal de los bucles cerrados.

Se puede descargar una versión precompilada de RCD estándar (vs 1.40) en el enlace del grupo. Aunque todas las incorporaciones y adaptaciones que se explicaran (vs 1.60) posteriormente no están disponibles todavía:

<https://chaconlab.org/modeling/rcd/rcd-download/item/rcd-linux64>

3.1.3 Refinado con PyRosetta

Para efectuar el último paso de refinado con bucles generados mediante RCD y filtrados por KORP se ha utilizado la herramienta PyRosetta (Chaudhury et al., 2010). Es una implementación en Python de la conocida plataforma de modelado Rosetta (*Documentation – Rosetta Commons*, n.d.). En primer lugar, se les añaden todas las cadenas laterales a los bucles seleccionados desde una biblioteca de rotámeros. Estas cadenas pueden tener colisiones entre ellas o con el resto de la estructura; o bien pueden adoptar conformaciones con altos estreses de energía. Por ello posteriormente se le realizan una serie de ciclos de minimización para relajar las estructuras en el campo de fuerzas *ref2015*.

3.1.3.1 Escenarios de predicción

El origen de la proteína y el motivo por el que se quiere predecir el bucle pueden tener características variadas, por lo que dependiendo de ellas se han definido dos escenarios diferentes en los que se realizaran estas relajaciones:

➤ **Nativo**

La estructura de la proteína es de confianza, tiene resolución atómica. El objetivo es rellenar posibles huecos que no se han resuelto bien experimentalmente (algo que ocurre en mayor medida en zonas más expuestas como son los bucles en cristalografía) o explorar conformaciones alternativas de la misma secuencia. En este caso, se restringe el movimiento del resto de la proteína, permitiendo únicamente la relajación del bucle que se desea modelar. El refinamiento se aplica exclusivamente sobre dicha región flexible.

➤ **Modeling**

La proteína es obtenida mediante un programa de modelado, pudiendo ser de homología de alta calidad o de AlphaFold, pero su resolución no es atómica. En este

escenario se quiere modelar regiones de las que se tiene menos confianza. Para este escenario se define una región esférica de hasta 15 Å de radio alrededor del bucle. Todos los residuos que contengan algún átomo dentro de esta región serán relajados junto al propio bucle, aunque con restricciones mayores, para que sean menos móviles que los bucles pero que se les permita reajustarse.

3.1.3.2 Detalles de ejecución

Esta etapa se realiza con PyRosetta y esta codificada en Perl y en Python. Tan solo es necesario lanzar un único comando dentro de la carpeta generada por RCD+ donde se encuentran los bucles cerrados y es completamente obligatorio que los parámetros se especifiquen en el siguiente orden:

```
refine_loops.pl lista_ids.txt escenario sufijosalida np "--energy ref2015"
```

En primer argumento consiste en la misma lista de bucles que se usó para lanzar RCD, seguido del escenario. Este solo admite *native* o *modeling*, cualquier otro valor generará un error. A continuación, se especifica el sufijo con el que se generarán los archivos resultantes y posteriormente el número de procesadores (*np*) con el que se quiere paralelizar el proceso. Por último, tal como aparece entre comillas, se especifica el nombre del sistema de referencia de energía empleado en PyRosetta, en nuestro caso el *ref2015*.

Refine_loops.pl depende de 5 archivos de código:

- *refine_loops.pl* → Script principal que coordina el proceso de refinamiento y realiza diferentes acciones según los parámetros que se le den según y el escenario especificado.
- *insertpdb.pl* → Código en Perl encargado de insertar el primer bucle cerrado generado en la estructura nativa. Ya que PyRosetta requiere una estructura cerrada para iniciar como punto de partida.
- *loops_energy13.py* → Script con el protocolo de refinamiento de los bucles. Toma diferentes parámetros de inicio para cada escenario a través de *refine_loops.pl*. Es el encargado de paralelizar la ejecución y mandar de forma individual diferentes bucles cerrados a los procesadores que se hayan indicado.

- *monrelax4.py* → Archivo con el protocolo para la relajación inicial alrededor del bucle en el escenario *modeling*.
- *monfuncs.py* → Archivo Python donde están codificadas las funciones.

3.1.4 Servidor online

Se dispone de un servidor web donde se puede realizar el proceso completo sin necesidad de descargar o instalar ningún software localmente (López-Blanco et al., 2016). Este servidor dispone de la última versión de KORP, con el termino de Ramachandran incorporado. Sin embargo, todavía no tiene implementado las funcionalidades de la predicción específica de anticuerpos para RCD+, manteniéndose en la versión 1.40. Permite también escoger escenario para la etapa de refinado. En la Figura 15 se muestra la interfaz de este servidor, en donde se puede ver todas las opciones disponibles.

<https://rcd.iqf.csic.es/>

RCD+ Fast loop closure modeling

Start here Queue status Results Benchmarks Gallery Help

RCD+ server (New version 2019) is a fast loop modeling tool based on an improved version of our loop-closureRCD method. Accurate all-atom loop predictions and ensembles can be easily generated in a few minutes for loops of 12 or less residues. Once your job is completed you can interactively check and download the predicted models.

Please, upload a **only protein** PDB file with the atomic coordinates and introduce the following parameters: chain id, indices of the start/end residues, **sequence**, and select the prediction scenario between Native (if the loop environment is reliable) or Modeling (to also include the side-chains of the loop neighborhood in the refinement). The coordinates must **avoid any non standard aminoacids/atoms**, contain a valid **chain id**, and include at least the backbone of the **two N- and two C-terminal anchor residues** (indices Start-2, Start-1, End+1, and End+2). All residues from "Start" to "End" indices (inclusive) will be modeled from scratch.

Test case: Either fetch by ID 2CMD or upload [2cmd.pdb](#) file, and input Chain: A, Start: 270, End: 277, and Sequence: LGKNGVEE.

Upload a PDB file Chain Start End Scenario Loop sequence

Browse... PDB ID A 0 0 Native ...otherwise it is taken from PDB. (lc case 'p' indicates cis-Proline)

Submit

Options

Job name and description (optional) Email (optional)

Type here your favourite job name and description email@example.com

Advanced options ...

#Loops	#Refined	%Rama.	Atomic model	RCD method	Expert options
25000	560	95	N,Ca,C,O,Cβ	Dunbrack	Type here any rcd command line option

*If you would like to refer our work use:

Server and improved method López-Blanco JR, and Chacón P (2020). Improving the accuracy of protein loop structure prediction (To be submitted)

López-Blanco JR, Canosa-Valls AJ, Li Y, and Chacón P (2016). RCD+: Fast loop modeling server. NAR (DOI: 10.1093/nar/gkw395). [\(Use this reference, please\)](#)

Original method Chys P and Chacón P (2013). Random coordinate descent with spinor-matrices and geometric filters for efficient loop closure. J. Chem. Theory Comput. 9:1821-1829. [\(Use this reference, please\)](#)

Figura 15. Interfaz del servidor online de RCD+.

3.2 Aplicación de KОРP a predicción de mutaciones

El potencial KОРP desarrollado para evaluación de modelos y bucle puede ser aplicado en distintos contextos. En (Kadukova et al., 2021) se adaptó el potencial para evaluar interacciones de proteína-ligando. Siguiendo una estrategia muy similar, gracias a mi familiarización con dicho potencial, durante la tesis nos propusimos aplicar el potencial a la predicción de estabilidad de mutaciones en proteínas (Hernández et al., 2023). Experimentalmente se estudia si una mutación es estabilizante o desestabilizante mediante el cálculo de $\Delta\Delta G$ por desnaturalización química o térmica, definida por:

$$\Delta\Delta G = \Delta G_{mut} - \Delta G_{wt} \quad (7)$$

Donde G es la energía libre de Gibbs de una estructura; ΔG es la diferencia de esta energía entre la misma proteína plegada y desnaturalizada, y *wt* corresponden a la estructura nativa y *mut* a la mutada. En la ecuación (8), los valores positivos de $\Delta\Delta G$ corresponden con mutaciones estabilizantes.

Para estimar los valores de $\Delta\Delta G$ entre una proteína nativa y la misma proteína con un residuo mutado viene definida por:

$$\Delta\Delta G = \Delta G_{mut} - \Delta G_{wt} = \sum_i^N aa_i aa_{mut} E_{i,mut}^{KORP} - \sum_i^N aa_i aa_{wt} E_{i,wt}^{KORP} \quad (8)$$

Los valores estimados de ΔG se calculan con el potencial KОРP (ecuación (4)) a partir de la estructura nativa y de la mutada, donde *i* recorre todos los residuos vecinos al residuo nativo (*wt*) y mutado (*mut*). Los factores de ponderación *aa* dependen del tipo de aminoácido (20 variables) se ajustaron con datos $\Delta\Delta G$ experimentales de forma equivalente descrita en Kadukova et al., 2021 para proteína-ligando. Este ajuste se realizó con el conjunto de referencia balanceado de valores $\Delta\Delta G$ experimentales recopilados de bases de datos (véase 3.2.1), dividiéndolo en un subconjunto de entrenamiento y otro de validación complementario y no redundante (identidad de secuencia <50%). La optimización o ajuste se ha realizado minimizando el MAE entre los valores experimentales y los estimados con la ecuación (8). Para evitar sobreajustes, se realizó una validación cruzada con 5 y 10 K-folds y se repitió 100 veces para reducir el error. Obtuvimos valores muy robustos y prácticamente idénticos para k=5 o 10: los valores absolutos que oscilaron entre ~0.7 y 2.5 con desviaciones estándar entre ~0.1

y 0.2. Adicionalmente y sin pérdida de rendimiento logramos reducir los factores de 20 a 12 mediante la agrupación de algunos aminoácidos con tipos químicos similares: negativos (DE), hidrofóbicos pequeños (VIL), hidrofóbicos grandes (FY), polares no cargados (STNQ) y positivos (KH). Dado que la reducción del número de variables es preferible para limitar posibles problemas de sobre ajuste, adoptamos estos pesos reducidos como referencia. Los valores exactos para cada aminoácido pueden encontrarse en la Tabla S 1 (material suplementario). Los detalles de la optimización se pueden encontrar en Hernández et al., 2023)

3.2.1 Conjuntos de datos de entrenamiento, de validación y evaluación

➤ Conjunto de entrenamiento y validación

Se recopiló un nuevo conjunto de datos curado a partir del cribado de las dos bases de datos más extensas, ThermoMutDB (Xavier et al., 2021) y ProTherm (Nikam et al., 2021), con el fin de identificar mutaciones puntuales no redundantes con valores de $\Delta\Delta G$ determinados experimentalmente que cumplen las siguientes condiciones:

- Temperatura experimental entre 10 y 40°C y pH entre 5 y 9.
- Ante múltiples experimentos para la misma mutación se selecciona aquel más cercano a condiciones estándar (pH 7 y 25°C).
- Para evitar distorsiones estadísticas se descartan valores extremos de $\Delta\Delta G$ (< -7 o > 5.0 kcal/mol).
- Estructura monomérica disponible en el PDB con resolución mejor o igual a 2,5 Å (se evitan interacciones con otras proteínas).
- No hay interacciones directas con ligandos (la distancia entre cualquier par de átomos pesados entre el residuo mutado y el ligando debe ser superior a 5 Å.)
- Se descartan estructuras con coordenadas incompletas en algún átomo de la cadena principal.
- Se descartan las 684 mutaciones del conjunto S^{sym} .

El conjunto de datos inicial incluyó 3.824 mutaciones pertenecientes a 139 familias proteicas (identidad de secuencia $< 25\%$), con un valor promedio de $\Delta\Delta G$ de -1.0 kcal/mol y una desviación estándar de 1.6 kcal/mol. El 73% de las mutaciones eran

desestabilizantes y el 27% estabilizantes, siendo más de un tercio de ellas sustituciones hacia alanina. Para obtener un conjunto de datos más equilibrado, se limitó el número de entradas a un máximo de 15 mutaciones para cada pareja de aminoácidos, eliminando principalmente mutaciones desestabilizadoras que involucraban alanina. Con esta reducción de datos se buscó atenuar la sobrerrepresentación de alanina, evitando al mismo tiempo la pérdida de mutaciones estabilizadoras y de familias proteicas. El **conjunto balanceado** resultante resultó en 2.371 mutaciones pertenecientes a 129 familias proteicas, de las cuales el 58% son desestabilizantes y el 42% estabilizantes, con un valor promedio de $\Delta\Delta G$ de -0.7 kcal/mol y una desviación estándar de 1.6 kcal/mol.

➤ **Conjunto de evaluación: S^{sym}**

Para la evaluación del rendimiento y comparación con otros métodos de predicción de estabilidad se empleó el **conjunto balanceado S^{sym}** , compuesto por 342 mutaciones en 15 cadenas de proteínas, para las cuales está disponible los valores de ΔG de la estructura de la proteína tanto nativa como la mutante (Pucci et al., 2018). Las mutaciones directas (de nativa a mutante) y las mutaciones inversas (de mutante a nativa) tienen signo opuesto, lo que trae en consecuencia que el conjunto contenga también las 342 en sentido contrario (684 en total), lo que implica el mismo número de mutaciones estabilizantes como desestabilizantes.

El KORP original cuenta con cerca de 250 millones de contactos obtenidos de un conjunto no redundante de proteínas (explicado anteriormente). Como precaución para evitar cualquier tipo de sobre ajuste se repitió el mismo procedimiento omitiendo las estructuras presentes en los conjuntos explicados anteriormente y sus correspondientes homólogos.

3.2.2 Comparación con otros métodos

Se compararon nuestra aproximación con los 8 métodos más representativos de las diferentes estrategias existentes: FoldX (v3.0) (Schymkowitz et al., 2005) y EvoFF (Huang et al., 2020) como potenciales de campos de fuerza; Rosetta Cartesian ddG (CartddG) (Frenz et al., 2020) con uso de potenciales físicos-empíricos híbridos más sofisticados; DDgun3D (Montanucci et al., 2019) integra información estructural con

secuencias y características evolutivas; PopMusic-Sym (Pucci et al., 2018) como método empírico; y Dynamut2 (Rodrigues et al., 2021), ThermoNet (Li et al., 2020) y ACDCNN (Benevenuta et al., 2021) como enfoques de aprendizaje automático. Para todos los métodos se emplearon las mismas estructuras 3D y sus parámetros predefinidos y asumiendo condiciones estándar. Las métricas empleadas se detallan en posteriormente en el apartado 3.3.1.2.

3.3 Métricas y tratamientos

3.3.1 Métricas

Se pueden distinguir dos conjuntos de métricas según evaluemos predicciones de estructuras de bucles o de estabilidad de sustituciones de aminoácidos.

3.3.1.1 Para la evaluación de estructura de bucles

- **RMSD:** *Root Mean Square Deviation* (raíz de la desviación cuadrática media) es la medida más común para evaluar la desviación estructural entre dos conjuntos de átomos equivalentes (9). En esta tesis, salvo que se indique lo contrario, se realizara sobre los átomos C, C_α, N y C_β.

$$RMSD(v, w) = \sqrt{\frac{\sum_{i=1}^N ((v_{ix} - w_{ix})^2 + (v_{iy} - w_{iy})^2 + (v_{iz} - w_{iz})^2)}{N}} \quad (9)$$

- **TopN:** Mejor valor de RMSD de N estructuras seleccionadas. Estas estructuras suelen ser ordenadas por energía como es en caso de los resultados finales de RCD+.
- **Enriquecimiento:** Porcentaje de estructuras por debajo de varios umbrales de RMSD para un conjunto de estructuras seleccionadas. Esta métrica es útil para analizar el rendimiento de potenciales al seleccionar estructuras desde un conjunto más amplio.

3.3.1.2 Para la evaluación de predicción de estabilidad por sustituciones de aminoácidos

En cuanto a valores absolutos entre el valor de energía predicho y el real se usó:

- **RMSE:** *Root Mean Square Error* (raíz del error cuadrático medio). Es equivalente al RMSD, usando la misma fórmula (9), con solo un valor o punto en vez de coordenadas 3D.
- **MAE:** Mean Absolute Error (error medio absoluto). Equivale a la medición de RMSE sin realizar la raíz cuadrada.
- **PCC:** Coeficiente de Correlación de Pearson. Mide la correlación lineal entre valore predicho y valor real para el conjunto total de predicciones.

De forma estándar se trata de una clasificación binaria entre mutaciones estabilizantes (positivas) y desestabilizantes (negativas), por lo que se emplearon las medidas comunes en el campo:

- **Sensibilidad (TPR):** Ratio de mutaciones estabilizantes acertadas (TP) sobre el total de mutaciones estabilizantes (P).
- **Especificidad (TNR):** Ratio de mutaciones desestabilizantes acertadas (TN) sobre el total de mutaciones desestabilizantes (N).
- **Precisión (PPV):** Ratio de mutaciones estabilizantes acertadas (TP) sobre el total de mutaciones estabilizantes predichas (TP+TR).
- **Exactitud (ACC):** Ratio de mutaciones acertadas (TP+TN) sobre el total de mutaciones (P+N).
- **Coeficiente de correlación de Matthews (MCC):** Evaluador de calidad de clasificadores binarios que sigue la formula (10):

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (10)$$

- **Área bajo la curva ROC:** Relación entre la sensibilidad (TPR) y el ratio de falsos positivos, FPR (1- Especificidad) según se varía el umbral de clasificación.
- **Área bajo la curva PRC:** Similar a la curva ROC, pero representando la sensibilidad (TPR) frente a la precisión (PPV).

Por otra parte, también se clasificó la naturaleza de las mutaciones de forma ternaria, donde diferenciamos entre estabilizantes ($\Delta\Delta G \geq 1$ kcal/mol), desestabilizantes ($\Delta\Delta G \leq -1$ kcal/mol) y neutras (valores intermedios). A las mutaciones, tanto

experimentales como predichas, se les asigna un valor de 0 para desestabilizantes, 1 para neutrales y 2 para estabilizantes y se evalúan con las siguientes 3 opciones:

- **Sc:** Misma clase. Se acierta a que grupo pertenece la mutación.
- **Of1:** Se falla en un grupo de distancia, es decir mutaciones desestabilizantes o estabilizantes se clasifican como neutras o a la inversa.
- **Of2:** Se falla en dos grupos de distancia, se clasifican mutaciones estabilizantes como desestabilizantes o a la inversa.

Por último, se evaluó también la capacidad de un método para ser simétrico, es decir predecir con la misma exactitud una mutación en un sentido y en el contrario a través de:

- **r^{Sym}:** Correlación entre mutaciones directas e inversas. El valor ideal es 1.
- **δ:** suma media de mutaciones directas e inversas. El valor ideal es 0.

3.3.2 Procesamiento de estructuras de anticuerpos

Todas las estructuras cristalográficas de anticuerpos se obtienen directamente desde la base de datos SabDab (Dunbar et al., 2014b) con formato y numeración Chothia. Antes de utilizarlas en los procesos de modelado, es necesario realizar un preprocesamiento que garantice su validez estructural y su compatibilidad con los programas empleados, que se describe a continuación:

- 1) Script `AB_SabDab_sumarize.pl`: Realiza la primera serie de acciones necesarias para poder ser utilizadas por RCD+.
 - Procesa todos los archivos `.pdb` contenidos en el directorio desde el que se ejecuta.
 - Lee el archivo `sabdab_summary_all.tsv`, obtenido al descargar todas las estructuras de SabDab, con metainformación extra sobre cada estructura (especie, genero, fecha de obtención, método experimental, resolución, tipo de antígeno o especie del antígeno).
 - Lee las líneas `REMARK` en la cabecera de cada archivo para identificar el tipo de anticuerpo, el número de unidades presentes y el nombre de las cadenas H, L y del antígeno (en caso de estar presente).

- Lee las líneas `ATOM` para identificar el inicio y final de cada bucle CDR. Luego renumera todos los átomos y residuos de manera secuencial, eliminando huecos e inserciones, ya que es un requisito para poder ser entrada en RCD+. Y guarda el nuevo valor que toma el inicio de y fin de cada bucle.
- Genera un archivo nuevo (`*_2.pdb`) con todas las cadenas renumeradas.
- Comprobación de discontinuidades: Calcula la distancia entre residuo consecutivos, considerando un salto en la cadena si esta supera los 4.2 Å, permitiendo identificar y descartar aquellas estructuras que tengan un salto dentro de los bucles.
- Genera el archivo de entrada para RCD+ con todos los bucles registrados sin salto en la cadena (`AB_loop_RCD.txt`).
- Genera un archivo de aviso de que estructuras tienen un salto de cadena dentro de los bucles CDR y en específico en cuál de ellos se encuentra (`GAP.txt`).
- Genera un archivo `.json`, con los datos recopilados, útil para su posterior análisis y visualización en R.

```
perl AB_SabDab_sumarize.pl sabdab_summary_all.tsv
```

- 2) Se hace una comprobación de las estructuras ya renumeradas para que sean compatibles con PyRosetta a través del script de Python: `open_and_close.py`. Se abre cada `.pdb` y se carga como objeto `pose` de PyRosetta. El propio PyRosetta analiza que la estructura este correcta, es decir que no haya discontinuidades en las cadenas, colisiones entre residuos o cadenas laterales y añade átomos que faltan (generalmente de hidrogeno).

```
for i in *_2.pdb; do open_and_close.py $i ${i:0:4}_3.pdb ; done
```

- 3) Se eliminan los H de las estructuras ya que no son necesarios para RCD+ y reduce considerablemente el tamaño del archivo.

```
for c in *_3.pdb ; do echo $c; d=${c:0:4}; echo $d;
exit4=${d}_4.pdb'; grep -v "ATOM.....H....." $c > $exit4; done
```

- 4) Se eliminan los heteroátomos. Con esto se elimina cualquier tipo de molécula que no sea propiamente proteína, ya que la mayoría de los programas no los procesan

correctamente, y pueden producir errores o que se termine la ejecución antes de haber terminado el cálculo.

```
for c in *_4.pdb ; do echo $c; d=${c:0:4}; echo $d;  
exit5=$d'_5.pdb'; grep -v "HETATM" $c > $exit5; done
```

- 5) Se calcula la estructura secundaria de cada aminoácido junto a los valores de los ángulos phy, psi y omega para posteriores análisis.

```
for i in *_5.pdb; do pdb $i kk 0 0 0 0 0 0 --dihedral ; done
```

3.4 Bases de datos de anticuerpos: SabDab

El SabDab recoge la totalidad de estructuras obtenidas experimentalmente de anticuerpos disponibles en el PDB (Dunbar et al., 2014a). Cada estructura registrada es anotada junto con sus propiedades estructurales, nomenclatura de anticuerpos, sus datos de afinidad y las secuencias correspondientes a cada una de las regiones CDR. El SabDab puede ser empleado para analizar estructuras de forma individual, para crear y descargar diferentes conjuntos de estructuras atendiendo a diferentes filtros, para buscar estructuras con secuencias similares o para monitorizar la evolución general del conjunto de anticuerpos.

Las estructuras anotadas se pueden descargar en formato PDB bajo diferentes esquemas de numeración: la numeración original del PDB (tal como fue publicada), en formato Chothia o en formato IMGT.

El repositorio dispone de diferentes secciones para realizar las búsquedas:

1. Búsqueda estructural: La sección principal de búsqueda permite descargar todas las estructuras contenidas, realizar una búsqueda por identificador del PDB o filtrando según ciertos atributos, como puede ser el tipo de anticuerpo, el método experimental, la especie, etc. También permite la búsqueda del conjunto de estructuras con un límite máximo de porcentaje de identidad de secuencia.
2. Búsqueda por secuencia: Permite buscar todas las estructuras que contengan una secuencia con una mínima identidad con la secuencia objetivo, tanto en la cadena ligera como en la cadena pesada. Además, permite otros filtros para elegir la cadena o sólo un tipo de región CDR.

3. Búsqueda de CDR: Búsqueda muy similar a la sección de búsqueda estructural pero restringida a aquellas que tienen una anotación completa de sus regiones CDR. Sin embargo, no dispone de la opción de búsqueda de un conjunto único acorde a un máximo de identidad de secuencia.

A fecha de 7 de abril de 2022, se comprobó que el número de estructuras disponibles era 5998. Las estructuras depositadas hasta esta fecha son las empleadas para esta tesis. Como los datos contenidos en el SabDab son heterogéneos, se ha realizado un análisis previo para caracterizar su composición atendiendo a diferentes características. En la Figura 16 se muestran los valores y la proporción de estructuras clasificadas según la especie, la presencia o ausencia de antígeno en el PDB, el tipo de anticuerpo y el método experimental de obtención.




Figura 16. Distribución de las especies, de la presencia/ausencia de antígeno, del tipo de anticuerpo y del método experimental sobre el total de estructuras depositadas en SabDad.

➤ **Especie**

El 92 % (5.518) de los anticuerpos contenidos en SabDab pertenecen a tan solo siete especies, mientras que el 8 % restante corresponde a una mezcla de hasta 75 especies distintas. La especie más representada es *Homo sapiens*, con 2.705 estructuras, dado que la mayoría de los estudios en inmunoterapia y biotecnología están centrados en anticuerpos humanos. Le sigue *Mus musculus* (ratón común), con 1.866 estructuras, como principal organismo modelo en estudios de inmunidad adaptativa. El grupo de los camélidos también está ampliamente representado: *Lama glama* (llama) con 457 estructuras, *Vicugna pacos* (alpaca) con 146, y *Camelus dromedarius* (dromedario) con 79. Asimismo, se identifican 151 estructuras pertenecientes a constructos sintéticos, y otras 115 correspondientes a uniones químicas entre *Homo sapiens* y *Mus musculus*.

➤ **Presencia de antígeno**

El 75 % de las estructuras (4.490) contienen el antígeno asociado al anticuerpo, mientras que el 25 % restante (1.508 estructuras) corresponden a anticuerpos en estado aislado, sin su antígeno presente.

➤ **Número de unidades antigénicas**

Se define una unidad antigénica como el conjunto formado por las cadenas pesada (H), ligera (L) y, cuando está presente, la cadena correspondiente al antígeno. En la Figura 17, se muestra el número de unidades antigénicas por PDB. La mayoría de los archivos PDB contienen una única unidad antigénica, como ocurre en 3.000 estructuras. No obstante, 1.949 contienen dos unidades y 1.049 presentan tres o más.

Además, SabDab clasifica las unidades antigénicas según su composición en tres categorías: tiene tan solo una cadena, como puede ser solo la H o solo la L (individual); posee ambas cadenas (emparejado); y contiene una combinación de unidades individuales y emparejadas (dual). Aunque la mayoría entran dentro de la categoría *emparejado* (4874), al menos 1.085 estructuras pertenecen a la categoría *individual*, y en 39 casos se encuentran unidades de tipo *dual*.




Figura 17. Distribución del número de unidades antigénicas por PDB en las estructuras de anticuerpos del SAbDab.

➤ Método experimental

La técnica predominante para la obtención de estructuras es la cristalografía por difracción de rayos X, empleada en 4.854 casos. Le sigue la microscopía electrónica de transmisión, con 1.120 estructuras. Aunque en menor medida, también se han identificado estructuras determinadas mediante otras técnicas, como la resonancia magnética nuclear (RMN), aunque apenas representados.

➤ Distribución de resolución

Prácticamente todas las estructuras presentan una resolución inferior a los 5 Å, con una resolución media de 2.68 Å, lo cual indica una calidad estructural aceptable para estudios de modelado y análisis detallado (Figura 18).




Figura 18. Distribución de la resolución en las estructuras de anticuerpos del SAbDab.

➤ Distribución de los CDR

La ausencia de alguna de las cadenas o la falta de resolución en regiones específicas provoca que no todos los bucles CDR estén presentes en todas las estructuras. La Figura 19 muestra la frecuencia de aparición de cada uno de los seis bucles CDR en el conjunto de estructuras analizadas.




Figura 19. Apariciones de cada bucle CDR en el total de estructuras de anticuerpos del SAbDab.

➤ Tamaño

En la Figura 20 se puede comprobar con los datos de las estructuras presentes en SabDab como esta variabilidad de tamaño ocurre en diferente medida en cada uno de los bucles. Los bucles H1, H2, L2 y L3 son bastante uniformes en tamaño, ya que la mayoría (más del 80-90 %) poseen 7, 6, 7 y 9 aminoácidos, respectivamente. En muy pocas ocasiones se aprecian bucles H2 con 5 aminoácidos o bucles L3 con 8, 10 u 11 aminoácidos. Sin embargo, los bucles L1 y H3 muestran una amplia variación en el número de aminoácidos que lo componen. En particular, H3 con una distribución de bucles de 4 a 30 aminoácidos.




Figura 20. Variabilidad de longitud para cada de bucle CDR en el total de estructuras de anticuerpos del SAbDab.

3.5 Conjuntos de evaluación y de referencia

3.5.1 Conjunto de evaluación de KORP

Para la optimización del término de Ramachandran de KORP se empleó un conjunto de evaluación estándar ya empleado en la evaluación del método original (López-Blanco & Chacón, 2019). Está compuesto por cuatro subconjuntos, cada uno de 100 estructuras de bucles de 6, 8, 10 y 12 aminoácidos de longitud, seleccionadas de forma aleatoria. Como se ha explicado previamente todas las cadenas con un segmento con al menos un 50% de identidad con estas estructuras fueron eliminadas en el conjunto de entrenamiento del potencial. La distribución de cadenas de proteínas de alta resolución generadas por el servidor PISCES indica que el 94% de los bucles tienen 12 residuos o menos (G. Wang & Dunbrack, 2005). Por este motivo se consideró que las longitudes escogidas eran suficientemente representativas para evaluar un método de predicción de bucles general.

3.5.2 Conjuntos de referencia para la predicción de anticuerpos

Para poder evaluar la capacidad de predicción de las diferentes configuraciones y variaciones desarrolladas sobre RCD+ y compararlo frente a otros métodos se han empleado varios conjuntos de referencia estandarizados. Estos conjuntos están definidos por estructuras nativas de anticuerpos que han sido seleccionadas utilizando criterios de calidad estructural. Los principales parámetros considerados han sido:

➤ Resolución

La resolución es una medida de la capacidad de resolubilidad en el mapa de densidad electrónica de una molécula, originada en cristalografía de rayos X y expresada en angstroms. Cuanto menor sea este valor, mayor será el grado de resolución atómica. El mejor valor que se puede alcanzar es de 1 Å, donde se permite visualizar los átomos de hidrogeno de forma individual y mapear átomos más pesados con mucha precisión. La mayoría de las estructuras resueltas tienen valores entre 1.5 Å y 2.5 Å, donde los átomos de hidrogeno ya no son visibles (pero se pueden inferir por geometría de enlaces sobre el resto de los átomos) y empieza a aparecer cierta incertidumbre sobre la ubicación precisa de alguno de los átomos pesados. Con estructuras con valores superiores a 2.5 Å aumentan las imprecisiones de coordenadas y comienzan a aparecer ligeros problemas estructurales. Y para estructuras con valores superiores a 3.5 Å existen ya incertidumbres considerables en la ubicación de átomos y pueden empezar a aparecer incertidumbre en la identidad de algunos aminoácidos de forma individual.

➤ Valor R

Es la medida de la calidad del modelo atómico obtenido a partir de los datos cristalográficos. Al resolver la estructura de una proteína, el investigador primero construye un modelo atómico a partir del patrón de difracción experimental y luego calcula un patrón de difracción simulado basado en ese modelo para validarlo. El valor R mide el ajuste entre el patrón de difracción simulado y el observado experimentalmente. Un conjunto de átomos totalmente aleatorio dará un valor R de aproximadamente 0.63, mientras que un ajuste perfecto tendría un valor de 0. El valor

de R utilizado habitualmente como criterio de calidad es ≤ 0.20 (Kleywegt & Jones, 1997).

➤ Factor B

También conocido como factor de temperatura o desplazamiento, cuantifica la movilidad atómica dentro de la red cristalina.

En las estructuras obtenidas por difracción de rayos X, el factor B es un parámetro que mide el efecto que tienen los movimientos de los átomos de un sólido cristalino en la difracción de una onda electromagnética. En una red cristalina, los átomos fluctúan debido a vibraciones térmicas. Estas variaciones en la posición generan un cambio de fase de la onda difractada que depende del ángulo de difracción y difumina la señal. Un valor bajo de factor B indica una posición atómica bien definida, mientras que valores altos reflejan mayor incertidumbre posicional. Se considera como umbral de calidad un valor medio de factor B inferior a 80.

3.5.2.1 Conjunto de referencia de Rosetta (CRR)

Este conjunto de referencia es el más utilizado para evaluar la predicción de bucles H3 y se ha convertido en el estándar. Consta de 49 estructuras recopiladas por (Weitzner & Gray, 2017). Partiendo de la base de datos de anticuerpos PylgClassify (Adolf-Bryfogle et al., 2015), utilizaron las siguientes restricciones: i) resolución máxima de 2.5 Å, ii) Valor-R inferior a 0.2, iii) factor B < 80.0 Å², iv) solo una copia de la Fv en la unidad simétrica, v) H3 longitudes entre 9 y 20 residuos, vi) estructuras exclusivas de humano o de ratón, vii) ausencia de aminoácidos no canónicos o modificados. En la Tabla 3, se pueden ver las características descriptiva de CRR: su identificador PDB, si presenta ligando (A+) o no (A-), y la longitud y secuencia de cada bucle CDR.

Tabla 3. CRR: Conjunto de referencia de Rosetta.

PDB	A	H1L	H1 S	H2L	H2 S	H3L	H3 S	L1L	L1 S	L2L	L2 S	L3L	L3 S
1dlf	-	7	GFTFSDA	8	RNKANNHA	12	TGIYYHYPWFAY	16	RSSQSLVHSGNGTYLH	7	KVSNRFS	9	SQSTHVpFT
1fns	-	7	GFSLTDY	5	WGDGS	16	VRDPADYGNVDYALDY	11	SASQDINKYLN	7	YTSSLHS	9	QQYEKLpWT
1gig	-	7	GFLNISN	5	WAGGN	16	ARDFYDYDVFFYAMDY	14	RSSTGAVTTSNYAN	7	GTNNRAP	9	ALWYSNHWV
1jfq	-	7	GYTFTSN	6	NPGNGY	14	ARSEYGGSYKFDY	11	RASQDINNFLN	7	FTSRQS	9	QQGNALpRT
1jpt	-	7	GFNIKEY	6	DPEQGN	10	ARDTAAYFDY	11	RASRDIKSYLN	7	YATSLAE	9	LQHGESpWT
1mfa	+	7	GYTFTNY	6	YPGNSA	11	TRGGHGYGYDY	14	RSSTGTVTSGNHAN	7	DTNNRAP	9	ALWSNNHWI
1mlb	-	7	GYTFSTY	6	LPGSGS	9	ARGDGNVGY	11	RASQISNNLH	7	YVSQSSS	9	QQSNSWpRT
1mqk	-	7	GFTFSSY	6	NNGGGR	11	VRHEYYAMDY	11	RASENIYSYLA	7	NAKTLGE	10	QHHYGTpLT
1nlb	-	7	GYTFTDF	6	NTETGE	11	ARFLLRQYFDV	17	KSSQSLLSNRTRKNYLA	7	WASTRES	9	KQAYIPpLT
1oaq	-	7	GYTFTSY	6	DPNGGG	13	ARMWYYGTYFFDY	14	RSSTGAVTTSNYAN	7	GTNNRAP	9	ALWYSNHLV

1seq	-	7	GFTFSTY	6	SKGGGS	16	ARGAMFGNDFKYPMDR	10	SASSSVSYM	7	TTSNLAS	9	HQWSSYpWT
1x9q	+	7	GFTFGHY	8	RNKPYNIE	9	TGASYGMEY	16	RSSQSLVHSNGNTYLR	7	KVSNRVS	9	SQSTHVpWT
2adf	-	7	GYTFINY	6	NTNTGE	11	ARDNPYYALDY	11	KASQDINKYIA	7	YTSTLQP	8	LQYDNLRT
2d7t	-	7	GYFTGN	6	NPKSGD	9	ATGWWGMDV	11	RASQINNNYLH	7	AASNLCQ	9	LQTHAYpLT
2e27	+	7	GYFTTY	6	YPGNGD	9	ARSDYGGDY	11	KANQDIKKKIA	7	YTSTLKS	9	LQYDNFTWT
2fb4	-	7	GFISSY	6	WDDGSD	19	ARDGGHGFCSSASCfGPDY	13	SGTSSNIGSSTVN	7	RDAMRPS	11	AAWDVSLNAYV
2fbj	-	7	GDFFSKY	6	HPDSGT	11	ARLHYGYNAY	10	SASSSVSSLH	7	EISKLAS	9	QQWTYpLIT
2r8s	-	7	GFNLYSS	6	SSSYGY	14	ARRAAGMSTYGFYD	11	RASQSVSSAVA	7	SASSLYS	9	QQSYSSpIT
2v17	-	7	GFTFTDY	8	RNKAKGYT	13	ARDNGAARATFAY	11	RASKSIRKFLA	7	SGSTLQS	9	QQHNDYpLT
2vxv	-	7	GYVTTSY	6	YPGDSE	14	ARVSGWYYPYTFDI	11	RASESISSNLA	7	TASTRAT	10	QQYNNWpSIT
2w60	-	7	GYFTDY	6	NTETGE	11	ARATTATELAY	16	KSSQSLLDSDGKTYLN	7	LVSKLDS	9	WQGTfHfLT
2xwt	+	7	GYSILDN	6	YPGDS	12	VGLDWNYNPLRY	13	SGSSSDIGSNYVS	7	DNNKRPS	11	GTWDSRLGIAY
2ypv	+	7	GYSFSDY	6	DPKYGT	12	VRDYYGSSYFDY	11	KASQDIHNYLN	7	RANRLVD	9	LQYDEFPPT
3e8u	-	7	GYFTTHY	6	NTHTGE	10	TRSHRFGLDY	15	KASQSVDYNGDSYLN	7	AASNLES	9	QQSNEDpFT
3eo9	-	7	GYSFTGH	6	HPDSE	14	ARGIYFYGTTFYDY	11	RASKTISKYLA	7	SGSTLQS	9	QQHNEYpLT
3g5y	+	8	GYSITSDY	5	SYSAN	9	ATAGRGFPY	11	HSSQDISSNIG	7	HGTNLED	9	VQYGQFPWT
3giz	-	7	GFTFNDY	6	SWNSGS	15	AKDIQYGNYYGMDV	11	RASQSVSSYLA	7	DASNRAT	9	QQRSNWpIT
3gnm	-	7	GYFTTY	6	SPNTDY	11	ARSHFYGNFDF	16	RSSQTIVSYNGNTYLE	7	KVSNRFS	9	FQGSHPpFT
3go1	+	7	GGPINNA	5	YHTGV	16	AREWAEDGDFGNAFHV	11	SAEALSNQYAY	7	KDTRKPS	10	QSADSSGDYV
3hc4	-	7	GYFTTY	6	YPGNHG	9	ARSWEGFDY	11	KASQNVGINVA	7	SASYRYS	9	QQYDTYpFT
3hnt	+	7	GYSFTNY	6	YPGNSD	11	TRFGNYVPFAY	11	RASQDIGSYLN	7	YTSRLHS	9	HQDTKPpYT
3i9g	+	7	GYFIDH	6	SPRHDI	14	ARGGFYGSTIWFDY	11	ITTTDIDDDMN	7	EGNILRP	9	LQSDNLpFT
3ifl	+	9	GFSLSGSM	5	WWDDD	12	ARRTTTADYFAY	16	RSSQSIHVHNGNTYLE	7	KVSNRFS	9	FQSSHVPpLT
3liz	+	7	GFTFSS	6	NSNGAS	12	TRDPAGRAWFAY	11	KASQDINNLYS	7	RADRLVD	9	LQYDELpYT
3lmj	-	7	GFTLTGL	6	GPEENE	18	ATGGNYYNLWTGYPLAY	13	SGSSSNIGKNYVS	7	DDTQRPS	12	GTWDSLSSTGQL
3m8o	-	7	GFTLSGS	8	KRNAESDA	10	VIRGDVYNRQ	16	RSSQSLLRDGHNDLE	7	LGSTRAS	9	MQNKQTpLT
3mlr	+	7	GYNFLDS	6	YPDDSD	17	TRLYLFEQAQSSNAFDL	11	SGDKLDDKYVS	7	QDFKRPS	19	QAWDASTGVSGGGTKLTVL
3mxw	+	7	GYTFIDE	6	RPYSGE	12	ARDWERGDFDY	11	KASQSVSNDLT	7	YASNRYT	9	QQDYGSpPT
3nps	+	7	GGTFSSY	6	IPIFGT	19	ARTFHIRYRSGYYDKMDH	13	SGSSSNIGSNYVS	7	DNNQRPS	9	QSRDISQYV
3oz9	-	7	GYRFSSY	6	LPGIGS	12	ARGYYGPTWFAY	10	SASSSVSYM	7	STSNLAS	8	HQWSGFYT
3p0y	+	7	GFTLSGD	6	SAAGGY	14	ARESRSFEAAMDY	11	RASQDLATDVA	7	SASFLYS	9	QQSEpEpYT
3t65	+	7	GFTFTDY	8	RNKANGYT	13	ARDHDGYERFSY	17	KSSQSLNRSRTRKNYLA	7	WASTRES	8	KQSYNLRT
3umt	+	7	GYTFEY	6	NPNNGG	12	ARDDRYPAWFAY	11	RASQDIGSNLN	7	ATSSLDS	9	LQYASSpPT
3v0w	+	7	GFTFSDY	8	RNKRNGDT	11	VRQGRGYTLDY	11	RASQININIWLS	7	KASNLHT	9	LQGSQYpRT
4f57	-	7	GFSFSDF	6	PFDRRI	18	AKHRSQWNFWPREGGLDH	14	TGTSSDVGGYNYVS	7	DVTNRPS	10	AAYTVASTLL
4h0h	+	7	GYSFTDY	6	NPYYGS	12	ARKNYYGSSLDY	16	RSSQSLVHSNGNTYLH	7	KVSNRFS	9	SQSTHVpYT
4h20	-	7	GYFTDY	6	IPSNNG	12	ARRGLTGALFAY	11	KASQDVTSAVA	7	SASYRYT	9	QQHYGTpLT
4hpy	+	7	GFTFDDG	6	SWNSNI	13	AKDSPRGELPLNY	11	SGDALPKNYAY	7	EDSKRPS	11	YSTSSSGNHRV
4nzu	-	7	GFTFGSY	6	SYNGSS	18	ARAPDCADADCHKGAFGY	11	QASQDIKFLD	7	DASNLAI	9	QHYDDFPIS

3.5.2.2 Conjunto referencia anticuerpos terapéuticos (CRTh)

Conjunto de referencia construido con mABs que están en fase de desarrollo clínico. Al tratarse de un conjunto de referencia obtenido durante el desarrollo de fármacos y tratarse de estructura añadidas al PDB de forma más reciente, es más difícil que los métodos de predicción de estructuras hayan podido entrenarse con ellas. Originalmente se seleccionan 56 estructuras desde una preselección de 137 posibles (Marks & Deane, 2017b). Las estructuras 3eo9 y 3giz están presentes en CRR por lo que no se tienen en cuenta para este, quedándose en 54. En la Tabla 4 se puede ver las características descriptivas de CRTh al igual que en el conjunto anterior.

Tabla 4. CRTh: Conjunto de referencia de Terapéutico.

PDB	A	H1L	H1 S	H2L	H2 S	H3L	H3 S	L1L	L1 S	L2L	L2 S	L3L	L3 S
1bey	-	7	GFTFTDF	8	RDKAKGYT	12	AREGHTAAPFDY	11	KASQNIIDKYL	7	NTNNLQT	9	LQHISRpRT
1cz8	+	7	GYDFTHY	6	NTYTGE	16	AKYPYYGTSWYFDV	11	SASQDISNYLN	7	FTSSLHS	9	QQYSTVpWT
1mim	-	7	GYSFTRY	6	YPGNSD	10	SRDYGYVDF	10	SASSRSYMQ	7	DTSKLAS	7	HQRSSYT
1sy6	+	7	GYTFTRY	6	NPSRGY	12	ARYDDHYCLDY	10	SASSSVSYM	7	DTSKLAS	9	QQWSSNpFT
1yy8	-	7	GFSLTNY	5	WSGGN	13	ARALTYDYEFAY	11	RASQSIGTNIH	7	YASESIS	9	QQNNNWpTT
2hwz	-	9	GFSLTSGM	5	WWDDK	12	ARSMITNWYFDV	10	KCQLSVGYMH	7	DTSKLAS	9	FQGSYGpFT
3b2u	+	9	GGSISSGDY	5	YYSGS	13	ARVSIFGVGTFDY	11	RASQSVSSYLA	7	DASNRRAT	9	HQYGSTpLT
3c08	-	-	-	6	NPSNGR	14	ASRDYDYGRYFDY	-	-	7	DTSNLAS	9	QQWSSSHIFT
3eo0	-	7	SGYTFSS	6	IPIVDI	13	ASTLGLVLDAMDY	12	RASQSLGSSYLA	7	GASSRAP	9	QQYADSpIT
3gkw	-	7	GYFTTNY	6	NPTSGG	16	TRQGLWFDSDGRGDFD	16	RSSQNIVHSNGNTYLD	7	KVSNRFS	9	FQYSHVpWT
3hmw	-	7	GYSFTTY	6	SPVDS	12	ARRRPQQGYDF	11	RASQGISSWLA	7	AASSLQS	9	QQYNIYpYT
3nfs	-	7	GYFTSY	6	NPSTGY	9	ARGGGVFDY	10	SASSSISYMH	7	TTSNLAS	9	HQRSTYpLT
3o2d	+	7	GYFTSY	6	NPYNDG	15	AREKDNATYATGAWFAY	17	KSSQSLLYSTNQKNYLA	7	WASTRES	8	QQYYSYRT
3pp3	-	7	GYAFSYS	6	FPDGD	12	ARNVFDGYWLVY	16	RSSKSLHSNGITYLY	7	QMSNLVS	9	AQNLELpYT
3qwo	+	9	GFSLSTAGM	5	WWDDK	12	ARDMIFNFYFDV	10	SASSRVGYMH	7	DTSKLAS	9	FQGSYGpFT
3s34	-	7	GFTFSSY	6	SSSSY	9	ARVTDAFDI	11	RASQGDINWLG	7	DASNLD	9	QQAKAFpPT
3u0t	+	7	GYTEAY	6	DPATGN	9	ASLYSLPY	16	KSSQSLLYSDAKTYLN	7	QSRDLP	9	LQGTHYpVL
4cni	+	7	GFNFNDY	8	RNKNYQYG	11	ARESYYGFTSY	11	QASQDIGISLS	7	NANNLAD	9	LQHNSApYT
4d9q	+	7	GYFTTNY	6	NTYTGE	8	EREKGVNN	11	ITSTDIDDDMN	7	GGNTLRP	9	LQSDSLpYT
4dn3	-	7	GGTFSSY	6	IPIFGT	12	ARYDGIYELDF	12	RASQSVSDAYLA	7	DASSRAT	10	HQYIQLHSFT
4edw	+	7	GFSLIGY	5	WGDGT	15	ARGGYWYATSYFYDY	11	RASQISNNLN	7	YTSRFS	9	QQEHTLpYT
4g5z	-	7	GFTFSVY	6	WYDGD	11	ARDLRTGPFY	11	RASQSIGSSLH	7	YASQFS	9	HQSSSLpFT
4g6k	-	9	GFSLTSGM	5	WWDGD	12	ARNRYDPPWFVD	11	RASQDISNYLS	7	YTSKLHS	9	LQGKMLpWT
4hkz	+	7	GFNIKDT	6	YPTNGY	13	SRWGGDGFYAMDY	11	RASQDVNTAVA	7	SASFLYS	9	QQHYTTPPT
4i77	+	7	GFSLSAY	5	WGDGK	12	AGDGYPPYAMD	15	RASKSVDSYGNFSMH	7	LASNLES	9	QQNNEDpRT
4irz	+	7	GFNIKDT	6	DPANGY	16	AREGYGNYGYVAMDY	11	KTSQDINKYMA	7	YTSALQP	8	LQYDNLWLT
4k3j	+	7	GYFTSY	6	DPSNSD	12	ATYRSYVTPLDY	17	KSSQSLLYTSSQKNYLA	7	WASTRES	9	QQYYAYpWT
4kaq	-	7	GYFTSY	6	YPGNGD	14	ARSTYGGDWYFNV	10	RASSSVSYH	7	ATSNLAS	9	QQWTSNpPT
4m6n	-	7	GYSFSNY	6	DPSNSY	10	ARWYKPFVD	14	TGSSSNIGSGYDVH	7	GNSKRPS	11	ASWTDGLSLVV
4nyl	-	7	GFTFDDY	6	TWNSGH	14	AKVSYLTASSLDY	11	RASQGIRNYLA	7	AASLTQS	9	QRYNRApYT
4o02	+	7	GYTFSSY	6	NPSRGY	11	ASFLGRGAMDY	11	RASQDISNYLS	7	YTSKLHS	9	QQGNTFPYT
4od2	+	7	GFTFDDY	6	NWQGGG	14	AKILGAGRWYFDY	11	SGDSLRSYAS	7	GANNRPS	11	NSADSSGNHVV
4ojf	+	7	GFTFSNY	6	RSGGGR	12	VRYDHYSGSSDY	16	KSSQSLLDSDGKTYLN	7	LVSCLDS	9	WQGTHTpRT
4qyg	-	7	GYIFTNY	6	YPGDS	10	ARHDEGFDY	12	RASQSVSSFFA	7	GASSRAT	9	QQYDSSAIT
4x7s	-	8	GYITSY	5	TYDGS	14	ARGSHYFGWHFAV	15	RASQSVSDYDGDYMYN	7	AASYLES	9	QQSHEDpYT
4ypg	+	7	GYFTSY	6	SVYNGN	9	ARDPIAAGY	12	RASQSVSSTYLA	7	GASSRAT	9	QQYGSSPRT
5csz	+	7	GFTFSSY	6	NASGTR	-	-	12	RASQSVSSYLA	7	GASSRAT	9	LQIYNMpIT
5dk3	-	7	GYFTTNY	6	NPSNGG	13	ARRDYRFDMGFDY	15	RASKGVSTSGYSYLH	7	LASYLES	9	QHSRDLpLT
5ggq	-	7	GITFSNS	6	WYDGSK	6	ATNDY	11	RASQSVSSYLA	7	DASNRRAT	9	QQSSNWpRT
5ggu	-	7	GFTFSSY	6	WYDGSN	18	ARDPRGATLYYYYGMDV	11	RASQSINSYLD	7	AASSLQS	9	QQYYSTpFT
5i5k	+	7	GYIFSNY	6	LPGSGS	15	ARYFFGSSPNWYFDV	11	GASENIYGALN	7	GATNLAD	9	QNVNLTPLT
5jxe	+	7	GYFTTNY	6	NPSNGG	13	ARRDYRFDMGFDY	15	RASKGVSTSGYSYLH	7	LASYLES	9	QHSRDLpLT
5kmv	-	7	GFTFSSY	6	NSNGGS	5	ASGDY	16	RSSQSLVSYNGDITYLH	7	KVSNRFS	9	QSSTHVpWT
5l6y	+	7	GYFTTNY	6	SANNGD	15	ARDSSSSWARWFFDL	11	GGNIIGSKLVH	7	DDGDRPS	11	QVWDTGSDPVV
5n2k	-	7	GFTFSSY	6	RYDGSN	8	KTHGSHDN	13	SGSRNSIGSNTVK	7	YNDQRPS	12	QSYDRYTHPALL
5nhw	-	7	GYFTSS	6	NPVSGS	8	ARGGWFDY	14	TGTSSDVGSYNYVN	7	GVSKRPS	11	GTFAGGSYYGV
5sx4	+	9	GGSVSSGDY	5	YYSNG	11	VRDRVTGAFDI	11	QASQDISNYLN	7	DASNLET	9	QHFHDLpLA
5tru	+	7	GFTFSSY	6	SYDGNN	11	ARTGWLGPFDY	12	RASQSVGSSYLA	7	GAFSRAT	9	QQYGSSpWT
5vh3	-	7	GFIFSNH	8	RSKSINSA	11	SRNYGGSYDY	11	RASQFVGSSIH	7	YASESMS	9	QQSHSWpFT
5vkk	-	7	GYFTSY	6	NPRNDY	9	ARRDITTFY	17	KSSQSVLYSANHKNYLA	7	WASTRES	8	HQYLSSWT
5wuv	-	7	GYVFTDY	6	NTYIGE	11	ARGYRSYAMDY	11	KASQNVGTNVA	7	SASFLYS	9	QQYNIYpLT
5xxy	+	7	GFTFSDS	6	SPYGGG	11	ARRHWPGGFDY	11	RASQDVSTAVA	7	SASFLYS	9	QQYLYHpAT
5y9k	-	7	GGTFNNN	6	IPMFGT	16	ARSRLLLFPHHALSP	11	QGDLSRYYAS	7	GKNRPS	11	SSRDSGNNHVV
6and	+	7	GYEFSRS	6	YPGDGD	13	ARDGSSWDYFDV	-	-	7	KVSNRFS	9	FQGSQFpYT

3.6 Generación de mapas de restricción para CDRs

3.6.1 Composición

Como se ha explicado anteriormente el *kink* está presente en la mayoría de los bucles H3. Este *kink* genera una restricción estructural muy específica que tiende a estructuras secundarias. Esto provoca que a la amplia mayoría de predictores les cueste obtener esa estructura en esa región. En el método general de predicción de estructura de bucles con RCD+ se incorpora la información de los mapas de Ramachandran estándares para cada aminoácido. Sin embargo, estos mapas generales tienen a omitir (y por tanto se descarta con mayor frecuencia) los ángulos diedros necesarios para el *kink*.

Con el objetivo de favorecer la selección de estos ángulos en las posiciones de *kink* se decidió generar unos mapas específicos de Ramachandran para cada una de las posiciones implicadas e introducir esta información junto con los mapas generales. De esta forma a la hora de predecir un bucle H3, se generará un mapa de Ramachandran mixto entre el mapa específico de posición y el mapa específico de aminoácido. Se hará en las posiciones 92 (anclaje), 93, 94 y 94 en el extremo N-terminal y en las posiciones 100, 101, 102 y 103 (anclaje) según la nomenclatura Chothia. Se incluyen los mapas de los anclajes ya que en la predicción de bucles se emplean también para seleccionar los ángulos entre los aminoácidos del extremo y sus anclajes.

Para realizar los mapas se accedió a las estructuras ya resueltas disponibles en la base de datos del Sabdab que cumplieran ciertos criterios. El proceso empieza el 19 abril de 2021 y se realizan varios ensayos y experimentos para optimizar los mapas, sin embargo, al consultar otra vez el Sabdab en el 7 de abril de 2022 el total de estructuras había aumentado cerca de un 20% al subir de 4824 a 5997 en el plazo de un año. Dado que este incremento aportaba una mejora significativa a la robustez estadística de los mapas, se decidió tomar como base las estructuras disponibles en esta fecha para el resto de la tesis.

Para construir los mapas se seleccionaron las estructuras que cumplieran una serie de características: dos conjuntos con estructuras con una resolución inferior a 3 Å y a 3.5 Å; 3 conjuntos de estructuras con unas identidades menores a 99%, 95% y 90%.

Previamente se habían eliminado las estructuras que conforman CRR y CRTh. El número de estructuras disponibles en cada conjunto es el siguiente:

- Total → 5.997
- No redundantes 99% → 3.217
- No redundantes 95% → 2.388
- No redundantes 90% → 2.090
- Resolución inferior a 3 Å → 4.101
- Resolución inferior a 3.5 Å → 4.982

Se generaron combinaciones de conjuntos entre resolución y no redundantes, con las que se construyeron mapas con diferente estadística. También realizó el procesamiento de estructuras explicado en apartado 3.3.2, para eliminar aquellas con los bucles CDR incompletos. Cada subconjunto se compone finalmente del número de estructuras mostradas en la Tabla 5, resaltado en negrita el cual fue seleccionado para los resultados finales de esta tesis:

Tabla 5. Número de estructuras que componen cada subconjunto con valores de resolución y no redundancia (NR).

	NR 99%	NR 95%	NR 90%
Resolución < 3 Å	2.208	1.600	1.406
Resolución < 3.5 Å	2.656	1.957	1.714

El espacio de 360° de los ángulos phi (ϕ) y psi (ψ) se divide en intervalos de 5°, formando una matriz que cubre el espacio 2D de 72x72. Con esto se mantiene la misma estructura y se asegura la compatibilidad con los mapas rama generales de RCD+.

En cada celda de la matriz se contabiliza el número de ocurrencias observadas de un par ϕ/ψ , filtradas por diferentes características, como el tipo de CDR o la posición relativa dentro del bucle. Posteriormente se normaliza la matriz, pasando de tener una matriz de frecuencias a una matriz de probabilidad. Este procedimiento, en el que cada celda refleja directamente las observaciones del conjunto de entrenamiento se denomina “**no suavizado**”.

3.6.2 Suavizados

Dada la limitación en el número de datos se decidió suavizar los mapas para evitar discontinuidades.

El primer método de suavizado, que denominamos “gaussiano” o **S1**, consiste en generar el mapa no suavizado y a cada celda aplicarle una matriz gaussiana de 3x3 para redistribuir su valor entre ella misma y las 8 celdas que la rodean (11). La distribución del valor es mayor en la casilla central (original) y menos según esta más alejada. De esta forma cada casilla tiene información mayoritariamente suya, pero con aportación de las casillas adyacentes. Los bordes del mapa de Ramachandran son solo a la hora de representarlos, puesto que al ser un espacio tridimensional cuando se sale por un borde, se aparece por el opuesto. Estos bordes de los mapas se tienen en cuenta a la hora de suavizar para no perder información.

$$\begin{pmatrix} 1/16 & 2/16 & 1/16 \\ 2/16 & 4/16 & 2/16 \\ 1/16 & 2/16 & 1/16 \end{pmatrix} \quad (11)$$

El segundo método de suavizado se realiza a la hora de construir el propio mapa y lo denominamos “interpolado” o **S2**. Esta forma de construir el mapa no pone la totalidad del valor en la casilla en la que cae, si no que se distribuirá entre las cuatro celdas más próximas de forma inversamente proporcional a la distancia. Como ejemplo podemos observar el caso de la Figura 21. En este caso simplificado tendríamos cuatro celdas de 2x2, cuyos centros son I (-1,1), J (1,1), K (-1,-1) y L (1,-1) y el punto que se tendría que repartir entre estas celdas cae en la posición M (-0.38, 0.5). En el reparto sin suavizado quedaría todo el valor en la casilla superior izquierda, sin embargo, al no estar totalmente centrado en el punto I, también debería tener una pequeña influencia en las otras 3 celdas que se encuentran más cerca. Para resolver este suavizado se realiza de reparto de proporcionalidad inversa teniendo en cuenta la distancia del punto M a cada uno de los centros de celda. Las distancias son e=0.79, f=1.47, g=1.62 y h=2.04 respectivamente. Para saber el valor correspondiente de cada celda se seguirá la formula (12), donde x representa la distancia desde el punto al centro de la celda considerada. Tomando como ejemplo el valor que corresponde a la celda I (V_e), con su distancia e; se resolvería de la siguiente manera: $V_e = \frac{1}{\frac{1}{0.79} + \frac{1}{1.47} + \frac{1}{1.62} + \frac{1}{2.04}} : 0.79 \cong 0.414$.

Igualmente resolviendo esta fórmula quedaría $V_f=0.223$, $V_g=0.202$ y $V_h=0.161$, como se puede ver, a mayor distancia al punto, su influencia es menor u por lo tanto el valor resultante también.

$$V_x = \frac{T}{\frac{1}{e} + \frac{1}{f} + \frac{1}{g} + \frac{1}{h}} : x \quad (12)$$




Figura 21. Ejemplo de suavizado por interpolación.

3.6.3 Pasos de formación de mapas

Para formar los mapas se siguió un protocolo que incluye diferentes scripts. A continuación, se explican en orden sucesivo cómo funciona cada uno y qué acciones realiza:

➤ Selección de estructuras

Cada mapa a generar requiere que las estructuras seleccionadas se almacenen en un directorio independiente, y sobre este realizar el protocolo que se expone a continuación. Por ejemplo, para seleccionar el mejor suavizado y el mejor subconjunto de resolución y redundancia se realizó los mapas de H3 (explicados en 3.6.4) para cada combinación de forma independiente.

Para el resto de CDRs, se empleó únicamente el suavizado y el subconjunto elegido, pero fue necesario dividir las estructuras seleccionadas por la longitud del

mismo, ya que se requiere hacer un mapa específico para cada longitud (véase sección 3.6.5).

➤ **Extracción de los ángulos diedros de los bucles** → *AB_CDRloop_angles.pl*

Este script toma todos los archivos PDB presentes en el directorio de estructuras seleccionadas y saca los ángulos diedros en un intermedio archivo con terminación *.ss* con el siguiente comando:

```
pdb $pdb kk 0 0 0 0 0 0 --dihedral
```

Posteriormente realiza un barrido de este archivo y según el CDR en cuestión leerá los ángulos diedros correspondientes a la región del bucle. Y por último genera varios ficheros donde resume los diedros de las estructuras analizadas para hacer los mapas de cada CDR. El formato del archivo de salida consiste en separar los ángulos de cada estructura en una línea diferente. Los campos se separan por un espacio en blanco: siendo el primero el nombre de la estructura y el segundo la secuencia de la que se han tomado los ángulos en formato de una única letra y el resto los valores de los ángulos.

De forma general se generan dos ficheros. El primer fichero corresponde a los valores de los ángulos phi (ϕ) y psi (ψ). Los campos de los ángulos alternan los valores de estos al ir en parejas, quedando los ángulos phi en posición impar en la línea y los ángulos psi en posición par. El segundo fichero es similar pero solo con los ángulos omega (Ω).

Además, dependiendo del CDR, se generan diferentes ficheros acordes a los mapas que se van a realizar. Para H3 son tres ficheros extra: uno con los cuatro residuos del extremo N-terminal, otro con los cuatro aminoácidos del extremo C-terminal y el tercero con los aminoácidos restantes entre eso 8 (a esta región la denominamos *interkink*). Para el resto de los CDR se generan archivos específicos de longitud, donde solo se recogen los valores correspondientes a un mismo tamaño. Excepcionalmente, para bucles L3, es capaz de detectar aminoácidos con conformación cis y trans y generar dos archivos diferentes para cada longitud (la importancia de esta característica a la hora de realizar los mapas se verá más adelante en el apartado 3.6.5.5).

El archivo de los ángulos omega se ideó por si era necesario realizar algún mapa para este ángulo, pero tras analizarlos se vio que no había muchas variaciones

específicas por posición y se descartó hacer el mapa, pero se ha mantenido como salida por si es necesario usar los datos para alguna otra situación.

➤ **Generación de los mapas individuales** → *Ramachandran.pl*

Toma el archivo de texto generado en el paso anterior y contabiliza las ocurrencias en cada una de las celdas de la matriz de 72x72 celdas (previamente descrita). Tras contabilizar todos los casos, normaliza el mapa a una frecuencia total de 1 y lo escribe en un archivo de texto. A continuación, se muestra de ejemplo alguna de las líneas que componen estos archivos y el formato que siguen:

47	57.5	39	17.5	1	0.0128205128205128
47	57.5	40	22.5	2	0.0256410256410256
47	57.5	41	27.5	3	0.0384615384615385
47	57.5	42	32.5	4	0.0512820512820513
47	57.5	43	37.5	2	0.0256410256410256
47	57.5	44	42.5	1	0.0128205128205128

El primer campo de cada línea corresponde a el número de celda para el ángulo phi (ϕ), teniendo valores entre 0 y 71 para cubrir todas las celdas. El segundo campo es el valor central de ángulo phi (ϕ) para esa celda. El tercer campo es el número de celda para el ángulo psi (ψ), teniendo de igual manera posible valores entre 0 y 71. Y el cuarto es el valor central de ángulo psi (ψ). El quinto valor es el número absoluto de ocurrencias encontradas para ese mapa en esa celda. Y el ultimo campo es el valor relativo normalizado sobre los casos totales en tanto por 1.

Se emplean variantes específicas de este script según el tipo de mapa y región:

- *Ramachandran.pl* → Para la región *interkink* de H3. Genera 21 mapas: uno por cada aminoácido estándar y uno general. De esta forma se refleja en los valores que suelen tomar cada uno de los aminoácidos en posiciones de bucle, pero no específicas de estructuras constantes como es el *kink*.
- *RamachandranNT.pl* → Para la región N-terminal de H3. Genera un mapa por posición (4 en total).
- *RamachandranCT.pl* → Similar al anterior, pero para la región C-terminal.
- *Ramachandran_CDR.pl* → Para el resto de CDRs. Toma un archivo correspondiente a una longitud específica y genera los X mapas necesarios para cada posición.

Además de cada uno de ellos hay dos versiones, una para cada tipo de suavizado.

➤ **Unión de mapas** → *Mergemaps.pl*

En determinadas situaciones (particularmente en CDRs que no son H3), es necesario unificar varios mapas individuales. Este script, lee los mapas individuales, y teniendo en cuenta las repeticiones genera un mapa donde respeta la proporcionalidad de cada mapa de entrada.

➤ **Generación del mapa binario** → *Binario.pl* y *creador_fichero_bin*

El primer script, *Binario.pl*, es simplemente un agregador de archivos. En un directorio vacío se copian todos los archivos de mapas que hemos podido ir generando para los diferentes CDRs y según un esquema definido en el código los ordena e imprime en un único archivo de texto.

El segundo, esta codificado en C++ a diferencia que el resto. Este coge el archivo creado por *Binario.pl* y va a generar el mismo mapa, pero codificado de formato binario. De esta forma ocupan bastante menos espacio y es el formato que tiene RCD+ para leer mapas de Ramachandran.

3.6.4 Mapas de H3

Como se ha explicado anteriormente, los bucles H3 disponen de una conformación bastante conservada tanto al inicio como al final del bucle que recibe el nombre de *kink*. Este *kink* tiene unos valores de los ángulos diedros que son poco comunes y hace que su conformación apenas se mueva. Para favorecer un aumento de muestreo de bucles y mejorar la capacidad de predicción se hizo unos mapas específicos para cada posición dentro del bucle. Para este objetivo se decide dividir el bucle en 3 secciones:

- i) Zona N-terminal: Corresponde al anclaje y los 3 primeros residuos (posiciones 92, 93, 94 y 95 según nomenclatura chothia respectivamente).
- ii) Zona C-terminal: Corresponde a los 3 últimos residuos y el anclaje (posiciones 100, 101, 102 y 103 según nomenclatura chothia respectivamente).
- iii) Zona intermedia: zona de longitud variable que corresponden al resto de residuos no incluidos en las dos zonas de *kink*.

Para las zonas Nt y Ct se elabora un mapa específico de posición, donde solo se seleccionan los valores de los diedros de esas mismas posiciones desde el conjunto de estructuras seleccionadas. Resultando en un total de 8 distribuciones de Ramachandran. La zona intermedia, sin embargo, recoge todos los valores de los residuos que también estén en zona intermedia en el conjunto de estructuras seleccionadas y se harán mapas específicos por aminoácido. De esta forma se obtendrá 20 mapas específicos de aminoácido y otro extra que une de forma proporcional los datos de estos 20 mapas (*ALL*). El mapa final para H3 tiene los 29 mapas específicos en el siguiente orden:

ALA – CYS – ASP – GLU – PHE – GLY – HIS – ILE – LYS – LEU – MET – ASN – PRO – GLN – ARG – SER – THR – VAL – TRP – TYR – ALL – N92 – N93 – N94 – N95 – C100x – C101 – C102 – C103

En la Figura 22 se representan para una misma posición del bucle H3 (94), los diferentes mapas de Ramachandran resultantes del uso de los diferentes métodos de suavizado. En primer lugar, se encuentra los datos brutos, sin emplear ningún suavizado. Se pueden apreciar cambios notables de color que indican valores diferentes entre celdas contiguas, generándose discontinuidades provocadas por la limitación de las estructuras empleadas. Estas discontinuidades le han supuesto que en ciertas estructuras se quede atascado al descartar ángulos centrales en la distribución. En segundo lugar, el suavizado gaussiano (S1), el cual muestra como homogeniza celdas contiguas. Y en tercer lugar el suavizado por interpolación (S2). Los resultados de los mapas suavizados no difieren significativamente, como se verá más adelante (apartado 4.3), se optó por S2 por mínimas ventajas en H3.




Figura 22. Mapas Ramachandran de restricción para la posición 94 de H3 con diferentes suavizados. De izquierda a derecha: sin suavizado, suavizado gaussiano (S1) y suavizado interpolado (S2).

En la Figura 23 se representan los mapas de restricción específicos con suavizado S2, finalmente seleccionados, para las posiciones del *torso* de H3 (donde se encuentra

el *kink*). La distribución es muy similar a la previamente mostrada para las mismas posiciones (Figura 9) con la especificación que con estos mapas se aprecia mejor la densidad de cada región.




Figura 23. Mapas de restricción S2 para las posiciones del torso de H3.

3.6.5 Mapas del resto de CDRs

Para formar los mapas del resto de los CDRs se escogió el subgrupo de estructuras con el que se han hecho los mapas finales de H3: el de resolución $\leq 3 \text{ \AA}$, con identidad inferior a 90%. Teniendo un total de 1406 estructuras, pero sujetas a estudio y optimización para cada caso.

Estos mapas son ligeramente diferentes a los que se hicieron para H3, pero para todos ellos se llevaron a cabo los mismos pasos. Primero se mira que longitudes de bucle son las que tienen suficientes casos para hacer unos mapas representativos. Sobre ellos, se obtienen los ángulos y se forman mapas para cada posición. Se representan los mapas de forma gráfica y se comprueba que distribución tienen, incluyendo los aminoácidos de anclaje. Se da una nomenclatura a cada tipo de distribución obtenida y se comprueba si en posiciones equivalentes las distribuciones son similares a los de otras longitudes. En aquellas distribuciones en las que se identifica esta similitud se combinan los datos de ambos mapas para generar uno único con mayor estadística, ya que incluye datos de más estructuras.

Los mapas finales en los que se aplica una misma distribución a diferentes posiciones (ya sea de una misma longitud o de diferentes longitudes) se comparan frente a un mapa más estricto con el mapa individual por posición midiendo el enriquecimiento de RCD+ sobre los bucles de CRR de dichas longitudes. Se descartan las uniones de mapas en los que el enriquecimiento baja drásticamente. Con esto se obtienen mapas específicos para cada CDR más sencillos, con resultados similares a tener un mapa por posición por cada longitud y con un mayor respaldo estadístico para nuevas estructuras.

3.6.5.1 H1

Para este CDR solo había estadística suficiente para hacer mapas con la longitud de 7 aminoácidos (1227 estructuras). Para los H1 de longitud 8 (68 estructuras) y 9 (90 estructuras) se utilizó los mapas de longitud 7 en aquellas posiciones equivalentes con distribuciones similares. La nomenclatura adoptada para indicar el mapa de restricción generado para una única posición es el siguiente: *(CDR)_(longitud del bucle)/(posición)*, donde la posición va desde 0 (anclaje N-terminal) hasta longitud del bucle +1 (anclaje C-

terminal). En las posiciones donde no se aplica ningún mapa de restricción se indica con un (-1). La asignación exacta de mapas de restricción para cada posición de los bucles H1 de longitud 7, 8 y 9 se muestra en la Tabla 6. A cualquier otra posible longitud no se le aplica restricción a ninguna posición.

Tabla 6. Mapas de restricción específicos aplicados a cada posición de los bucles H1.

Posición	Longitud 7	Longitud 8	Longitud 9
0	H1_7/0	H1_7/7	H1_7/0
1	H1_7/1	H1_7/1	H1_7/1
2	H1_7/2	H1_7/2	H1_7/2
3	H1_7/3	(-1)	H1_7/0
4	H1_7/4	(-1)	H1_7/4
5	H1_7/5	H1_7/4	H1_7/5
6	H1_7/6	H1_7/6	(-1)
7	H1_7/7	(-1)	(-1)
8	H1_7/8	(-1)	(-1)
9	-	(-1)	H1_7/7
10	-	-	H1_7/7

3.6.5.2 H2

Para los mapas H2 se definieron longitudes de 5, 6 y 8 aminoácidos, descartando 7 puesto que solo se disponía de 21 estructuras. En este CDR nos encontramos ya varias longitudes que muestran distribuciones similares varias posiciones. Diferenciamos con una nomenclatura propia aquellas distribuciones similares (i.e. X o X_F para distribuciones similares encontradas en los anclajes o H para distribuciones en zona típica de hélices). Tras esta primera agrupación, identificamos distribuciones únicas de forma numérica dentro de cada grupo. Las distribuciones que identificamos para cada longitud y el número de estructuras que las componen se muestran en la Tabla 7:

Tabla 7. Número de estructuras y distribución de cada posición para bucles H2.

Longitud	Nº estructuras	Distribución
5	311	X - Y ₁ - H ₁ - H ₂ - L ₀ - Z ₁ - X _F
6	982	X - Y ₂ - H ₁ - H ₁ +H ₂ - L ₁ - L ₂ - Z ₂ - X _F
7	21	No hay suficientes estructuras
8	78	X - Y ₁ - Y ₁ - H ₁ - H ₁ - H ₂ - L ₃ - L ₃ - Z ₁ - X _F

Aquellas posiciones con misma nomenclatura se consideran equivalentes y se decidieron juntar para obtener distribuciones con mayor estadística. Tras los análisis y comprobaciones, el diseño final para el mapa de H2 consta de 13 mapas individuales. El orden, la cantidad de estructuras empleadas para ese mapa específico, a que longitud

de bucles y posición afectan quedan reflejadas en la Tabla 8. En la Figura S 1 (material suplementario) se ejemplifica, para las conformaciones X e Y₁, las distribuciones originales de cada longitud y posiciones y la distribución final obtenida.

Tabla 8. Esquema del mapa de restricción total de H2.

Posición	Nomenclatura	Nº estructuras	Posiciones específicas referidas
0	X	1.371	H2_5/0, H2_6/0, H2_8/0
1	Y ₁	467	H2_5/1, H2_8/1, H2_8/2
2	Y ₂	982	H2_6/1
3	H ₁	1.449	H2_5/2, H2_6/2, H2_8/3, H2_8/4
4	H ₂	389	H2_5/3, H2_8/5
5	H ₁ + H ₂	982	H2_6/3
6	L ₀	311	H2_5/4
7	L ₁	982	H2_6/4
8	L ₂	982	H2_6/5
9	L ₃	156	H2_8/6, H2_8/7
10	Z ₁	389	H2_5/5, H2_8/8
11	Z ₂	982	H2_6/6
12	X _F	1.371	H2_5/6, H2_6/7, H2_8/9

El bajo número de casos para longitud 7 (21) impide la generación de mapas. Únicamente se vio que todos los valores en las posiciones de los anclajes y en el primer aminoácido del bucle estaban dentro de los valores representados en el mapa general para las mismas posiciones. Por lo que se decidió que para las posiciones 0, 1 y 8 de los bucles de 7 residuos se emplearían los mapas 0, 1 y 12 respectivamente.

Un ejemplo de las comprobaciones realizadas sobre el enriquecimiento de RCD+ para verificar el efecto del uso de mapas más generales sobre las longitudes y asegurarse de que no se perdía mucho rendimiento frente a usar uno específico para cada longitud se puede ver en la Tabla 9, para el caso de bucles de 8 residuos de H2. Aunque los mapas específicos muestran un rendimiento algo superior, la pérdida de precisión es mínima. Se consideró que el beneficio estadístico y la robustez general justificaban el uso de mapas generalizados.

Tabla 9. Enriquecimiento de RCD+ en los bucles H2 de 8 aminoácidos de CRR, sin usar mapa, con solo el mapa específico de su longitud (propio) y con el mapa general.

	Mejor caso	<0.5 Å	<1.0 Å	<1.5 Å	<2.0 Å	<2.5 Å	<3.0 Å
Sin mapa	1.285	0.00	0.00	0.33	0.50	3.00	13.83
Mapa propio	0.720	5.00	45.33	73.50	88.00	90.83	93.00
Mapa general	0.801	2.83	40.33	71.67	84.33	88.83	91.50

3.6.5.3 L1

L1 es el caso más complicado de todos los CDRs, puesto que es el que (sin contar H3) tiene una media de longitud más elevada, y también presenta más variación en tamaño. Las longitudes de bucle con mayor población en el conjunto de estructuras seleccionado son: 11 (589), 12 (109), 13 (91), 14 (116), 15(79), 16 (197) y 17 (83).

Al tener tantas posiciones entre todas las longitudes, la identificación de distribuciones comunes entre longitudes resultó especialmente compleja. Sin embargo, debido a la amplia distancia entre los anclajes, se vio que tanto al inicio como al final de todas las longitudes se mantenían distribuciones muy similares. Se decidió generar mapas generales para estas posiciones y específicos de cada longitud para las posiciones más centrales. El mapa total de L1 consta con un total de 58 mapas individuales, ordenados como se puede ver en la Tabla 10. Los mapas que afectan a más de una longitud son 14 y se indican con una g.

Tabla 10. Esquema del mapa de restricción total de L1.

Pos. general	Pos. especificas	Pos. general	Pos. especificas	Pos. general	Pos. especificas
0	0g	20	5(13/14)	40	12(15)
1	1g	21	6(13)	41	6(16)
2	2g	22	7(13)	42	7(16)
3	3g	23	8(13)	43	8(16)
4	4g	24	9(13)	44	9(16)
5	5g	25	10(13)	45	10(16)
6	6(11)	26	11(13)	46	11(16)
7	7(11)	27	6(14)	47	12(16)
8	8(11)	28	7(14)	48	13(16)
9	9g	29	8(14)	49	6(17)
10	10g	30	9(14)	50	7(17)
11	11g	31	10(14)	51	8(17)
12	12g	32	11(14)	52	9(17)
13	6(12)	33	12(14)	53	10(17)
14	8(12)	34	6(15)	54	11(17)
15	9(12)	35	7(15)	55	12(17)
16	10(12)	36	8(15)	56	13(17)
17	2(13/14)	37	9(15)	57	14(17)
18	3(13/14)	38	10(15)		
19	4(13/14)	39	11(15)		

Como hay bastantes posiciones, a continuación, se detalla que mapas toma cada longitud:

- Longitud 11: toman las posiciones 0-5 de los mapas generales (mapas 0-5). Luego tiene 3 mapas únicos de su longitud (mapas 6-8). Y vuelve a tomar los mapas generales para las últimas 4 posiciones (mapas 9-12).
- Longitud 12: toman las posiciones 0-5 de los mapas generales (mapas 0-5). Tiene un mapa propio para las posiciones 6, 8, 9 y 10, con la curiosidad de que la posición 7 es muy similar a la posición general 5, así que en vez de mapa propio toma el general (mapas 13, 5, 14, 15, 16 en orden). Y para terminar toma los tres últimos mapas generales (mapas 10-12).
- Longitud 13: toman las 2 primeras posiciones generales (mapas 0 y 1). Las siguientes 4 posiciones no se toman de los generales, sino que son un poco más específicas y se compartirán con los bucles de 14 residuos (mapas 17-20). A continuación, tienen 6 posiciones de mapas únicos propios (mapas 21-26). Y vuelve a tomar los mapas generales para las últimas 3 posiciones (mapas 10-12).
- Longitud 14: comienzan igual que los de 13. Los dos primeros mapas son las 2 primeras posiciones generales (mapas 0 y 1) y las 4 siguientes son específicas de estas 2 longitudes (mapas 17-20). Continúa con 7 posiciones propias específicas (mapas 27-33) y termina con las 3 posiciones generales finales (mapas 10-12).
- Longitud 15: toman las posiciones 0-5 de los mapas generales (mapas 0-5). Continúa con 7 posiciones propias específicas (mapas 34-40) y termina con las 4 posiciones generales finales (mapas 9-12).
- Longitud 16: de manera muy similar toman las posiciones 0-5 de los mapas generales (mapas 0-5). Continúa con 8 posiciones propias específicas (mapas 41-48) y termina con las 4 posiciones generales finales (mapas 9-12).
- Longitud 17: toman las posiciones 0-5 de los mapas generales (mapas 0-5). Continúa con 9 posiciones propias específicas (mapas 49-57) y termina con las 4 posiciones generales finales (mapas 9-12).
- Por último, para el resto de las longitudes se decidió emplear ciertos mapas de las posiciones generales, ya que se veía que este CDR tendía a coincidir en todas las longitudes para los aminoácidos cercanos a los anclajes. Para ello tanto para los bucles de 10 residuos como superiores a 18 se decidió tomar las primeras 5 posiciones generales (mapas 0-5) y las últimas 4 (mapas 9-12). Para los de 9 residuos

se toman las primeras 4 posiciones y ultimas 3 (mapas 0-3 y 10-12). Para los de 8 residuos se toman las primeras 3 posiciones y ultimas 3 (mapas 0-2 y 10-12). Para los de 7 residuos se toman las primeras 2 posiciones y ultimas 2 (mapas 0-1 y 11-12). Y para posibles bucles más pequeños no se toma ningún mapa. Además, para las posiciones que no se les otorga mapa específico se les da total libertad.

3.6.5.4 L2

En el bucle L2 ocurre una situación similar a H1: la amplia mayoría de estructuras tiene únicamente 7 residuos, siendo en este caso 1318, mientras que para otras longitudes apenas hay representación para poder hacer un mapa. Por lo tanto, el mapa específico cuanta con 9 mapas únicos, los 7 residuos y sus anclajes. Para cualquier otra longitud de bucles se decidió no emplear ningún mapa de restricción específico.

3.6.5.5 L3

L3 es también un bucle con una variabilidad alta, con longitudes comprendidas mayoritariamente entre 8 y 13 residuos. Se emplea una estrategia similar a H2 y las distribuciones identificadas junto al número de estructuras que las componen quedan reflejadas en la Tabla 11:

Tabla 11. Número de estructuras y distribución de cada posición para bucles L3.

Longitud	Nº estructuras	Distribución
8	117	$X_1 - X_2 - X_3 - D_1 - H_1 - -1 - G_1 - X_{F3} - X_{F2} - X_{F1}$
9 (con P cis)	724	$X_1 - X_2 - X_3 - D_1 - H_1 - X_7 - B_1 - B_2 - B_3 - X_{F2} - X_{F1}$
9 (sin P cis)	133	$X_1 - X_2 - X_3 - -1 - -1 - -1 - -1 - -1 - -1 - X_{F2} - X_{F1}$
10	144	$X_1 - X_2 - X_4 - X_6 - -1 - H_2 - H_3 - L_0 - X_8 - X_{F3} - X_{F2} - X_{F1}$
11	124	$X_1 - X_2 - X_5 - X_6 - B_0 - H_2 - H_2 - H_4 - L_1 - X_9 - X_{F4} - X_{F2} - X_{F1}$
12	42	$X_1 - X_2 - X_5 - X_6 - B_0 - H_2 - -1 - -1 - H_3 - L_0 - -1 - X_{F3} - X_{F2} - X_{F1}$
13	23	$X_1 - X_2 - X_5 - X_2 - -1 - -1 - -1 - -1 - -1 - -1 - -1 - X_{F4} - X_7 - X_{F3} - X_{F2} - X_{F1}$

Se realizan mapas con las longitudes desde 8 hasta 11, puesto que hay más de 100 de ellas, para las de 12 y 13 se descarta hacer mapas propios e incluirlos en caso de mezclarse, pero se representan para ver que tendencia tienen y por si se pueden clasificar con alguno de los del resto de longitudes. Otra de las características especial en este CDR es que un gran número de bucles de 9 aminoácidos presentan una prolina cis en la posición 7 (84% de los casos). Mientras que en el 16% de estructuras restantes presentan otros aminoácidos. En las estructuras con prolina, los mapas son regulares y definidos, mientras que las de sin prolina son ruidosos.

Tras los análisis y comprobaciones, el diseño final para el mapa de L3 consta de 25 mapas individuales. El orden y a que longitud de bucles y posición afectan quedan reflejadas en la Tabla 12.

Tabla 12. Esquema del mapa de restricción total de L3.

Posición	Nomenclatura	Nº estructuras	Posiciones específicas referidas
0	X ₁	1.242	Posición 0 para cualquier L3
1	X ₂	1.242	Posición 1 para cualquier L3, L3_13/3 ³
2	X ₃	974	L3_8/2, L3_9/2 ¹
3	X ₄	144	L3_10/2
4	X ₅	124	L3_11/2, L3_12/2 ³ , L3_13/2 ³
5	X ₆	268	L3_10/3, L3_11/3, L3_12/3 ³
6	B ₀	124	L3_11/4, L3_12/4 ³
7	D ₁	840	L3_8/3, L3_9/3 ² *
8	H ₁	840	L3_8/4, L3_9/4 ² *
9	H ₂	392	L3_10/5, L3_11/5, L3_11/6, L3_12/5 ³
10	X ₇	724	L3_9/5 ² *, L3_13/11 ³
11	G ₁	117	L3_8/6
12	H ₃	144	L3_10/6, L3_12/8 ³
13	H ₄	124	L3_11/7
14	B ₁	724	L3_9/6 ² *
15	B ₂	724	L3_9/7 ² *
16	B ₃	724	L3_9/8 ² *
17	L ₀	144	L3_10/7, L3_12/9 ³
18	L ₁	124	L3_11/8
19	X ₈	144	L3_10/8
20	X ₉	124	L3_11/9
21	X _{F4}	124	L3_11/10, L3_13/10 ³
22	X _{F3}	261	L3_8/7, L3_10/9, L3_12/11 ³ , L3_13/12 ³
23	X _{F2}	1.242	Posición penúltima para cualquier L3
24	X _{F1}	1.242	Posición ultima para cualquier L3

¹ Se incluyen todas las estructuras de bucles de 9 residuos

² Se incluyen solo las estructuras de bucles de 9 residuos con P cis.

³ Posiciones a las que se le aplica ese mapa, pero cuyas estructuras no se han incluido para generarlo.

3.6.6 Implementación de los mapas

3.6.6.1 Orden final del archivo de mapas

Los 143 mapas generados se integran en un único archivo binario, denominado *CDRS.bin*, que constituye el único fichero requerido por RCD+ para la predicción de cualquiera de los CDR. El orden en que se almacenan los mapas sigue la disposición indicada para cada CDR, organizada de la siguiente forma:

H3 (29) – H1 (9) – H2 (13) – L1 (58) – L2 (9) – L3 (25)

3.6.6.2 Sistema de mezcla de mapas en RCD+

Como se ha mencionado anteriormente en la sección 3.1.1.2, el algoritmo de cierre de bucles de RCD+ aplica un filtro adaptativo de Ramachandran. Este filtro depende del tipo de aminoácido considerado y de sus dos residuos adyacentes. El objetivo de realizar estos mapas de restricción específicos es para sustituir este filtro general por uno específico de CDR, longitud y/o posición. Realizar, una sustitución completa genera complicaciones al restringir tanto el espacio disponible. En cambio, una mezcla entre el mapa estándar y el mapa de restricción específico resulta en unas distribuciones más reales al combinar información específica de la posición interesada con información específica del tipo de aminoácido. Para parametrizar esta unión, se genera una variable de nombre *merge* que cuantifica la proporción de cada mapa, y que se debe indicar como dato de entrada del comando. Dentro del código de RCD+ se genera una rutina que recorre las celdas de ambos mapas y realiza la siguiente operación:

$$mapb[i][j]=factor*map[k][i][j]+(1-factor)*map2[i][j]$$

Donde el primer mapa es el de restricción para esa posición y se multiplica el valor de la celda por el valor de *merge*; y el segundo mapa es el estándar de aminoácido que se multiplica por $(1 - merge)$. La suma de ambos valores da el resultado final de cada celda.

Debido a que los bucles H3 presentaban diferentes regiones en cuanto a comportamiento se describieron tres variables diferentes de *merge*:

- *kink_mergeA* → Afecta tan solo a los anclajes del bucle de H3. Lo que corresponde a los mapas H3-N92 y H3-C103.
- *kink_merge* → Afecta al resto de posiciones del kink de H3: H3-N93, H3-N94, H3-N95, H3-C100, H3-C101 y H3-C102.
- *nokink_merge* → Afecta el resto de los aminoácidos que no están dentro del *kink*.

En el resto de CDRs, al no definirse *kink* tan solo se emplea la variable *nokink_merge*.

También se definieron las correspondientes variables para definir el % umbral de Ramachandran del mapa (*threshold o -t*) para los mapas resultantes de los *merge* del

kink. De esta forma se descarta las zonas menos densas. Para la zona sin *kink* se emplea la misma variable que para bucles normales.

Asimismo, se definieron variables adicionales para ajustar el umbral de Ramachandran ($threshold - t$) que se aplica tras la mezcla para descartar regiones de baja densidad. En las posiciones del *kink*, se utilizan valores específicos (t_{kink} , t_{kinkA}), mientras que para las regiones sin *kink* se aplica el mismo umbral que en los bucles estándar.

En la Figura 24 se ilustran dos casos que ejemplifican el proceso de elaboración del mapa final empleado en cada posición. En primer lugar, se muestra el mapa de restricción generado para posiciones específicas (N93 y C100 en bucles H3). En segundo lugar, se muestra el mapa de la distribución general de Ramachandran para el aminoácido que lo compone (alanina y tirosina respectivamente) obtenido de (Ting et al., 2010). En tercer lugar, el resultado de combinar la distribución específica de posición con la específica de residuo, a través de la variable de *merge* descrita (para esa ocasión 0.7 supone el 70% de peso para la posición y 30% para el aminoácido). Por último, el mapa resultante al aplicar el umbral de *threshold* seleccionado, eliminando los casos aislados (los valores de estos parámetros definidos para cada situación se muestran en la Tabla 13).




Figura 24. Distribuciones de Ramachandran en el sistema de mezclado de mapas.

3.6.6.3 Especificaciones comandos para CDRs

Con la incorporación de los mapas se introducen una serie de novedades sobre el comando original de RCD para el cerrado de bucles mostrado en la sección 3.1.2.3. A continuación, se muestra un ejemplo para H3 y otro para cualquier otro CDR:

```
rcd lista_H3.txt --ABmap CDRS.bin --H3 --kink_merge 0.9 --kink_mergeA 0.9 --nokink_merge 0.5 --tkink 0.70 --tkinkA 0.70 --nterm_rama 0 -r -e 56 --energy_file potencialKORP.bin -n 50000 --loco_best 1000 -x dunbrack.bin --linear -d 0.5 -t 0.99 -o output
```

```
rcd lista_L2.txt --ABmap CDRS.bin --L2 --nokink_merge 0.9 --nterm_rama 0 -r -e 56 --energy_file potencialKORP.bin -n 50000 --loco_best 1000 -x dunbrack.bin --linear -d 0.5 -t 0.99 -o output
```

Tras múltiples análisis y estudios paramétricos de las diferentes variables, se determinaron los valores óptimos para cada CDR, los cuales se resumen en la Tabla 13. Estos parámetros serán utilizados para los análisis comparativos del rendimiento del método en las siguientes secciones.

Tabla 13. Parámetros de RCD+ específicos para el cierre bucles CDR.

	Bucles cerrados	Selección KORP	nokink_merge	kink_merge	kink_mergeA	t	tkink	tkinkA	d
H1	20000	200	0.4	-	-	0.99	-	-	0.2
H2	20000	200	0.9	-	-	0.99	-	-	0.5
H3	50000	1000	0.5	0.9	0.9	0.99	0.7	0.7	0.5
L1	20000	200	0.9	-	-	0.99	-	-	0.5
L2	20000	200	0.9	-	-	0.99	-	-	0.5
L3	20000	200	0.9	-	-	0.99	-	-	0.5

3.7 Comparación con otros métodos

Para evaluar el rendimiento de nuestro método se comparó con varios de los métodos del estado del arte más punteros explicados anteriormente. En las publicaciones de estos métodos muestran los resultados que se han obtenido en condiciones similares con las que se evalúa nuestra metodología, pero no idénticas. Por consistencia y para asegurar igualdad en los criterios de medición se replicaron sus resultados sobre los conjuntos de referencia y se midieron los valores de RMSD.

3.7.1 RoAb

Todos los protocolos de Rosetta se pueden realizar de forma local instalando y compilando su programa, aunque los protocolos más importantes están también

disponibles a través del servidor ROSIE2 (*Rosetta Online Server that Includes Everyone*) (Lyskov et al., 2013).

Debido a las complicaciones que supone el formateo de las estructuras y el tiempo computacional necesario tanto para la preparación como para realizar el protocolo de H3, se decidió emplear el servidor online y su aplicación de generación de modelos de anticuerpos (Jeliazkov et al., 2021). RoAb, como se explicó anteriormente, no parte de una estructura cristalina, si no que genera un modelo por homología de la región Fv y sobre este modela de forma *ab initio* el bucle H3 únicamente.

Adicionalmente, los datos obtenidos para la comparación específica de solo la parte de modelado de H3 se tomaron directamente de la tabla presente en su artículo (Weitzner & Gray, 2017).

3.7.2 AF2

Debido a los elevados requerimientos computacionales para ejecutar AF2 en local, se decidió emplear la versión disponible en *colab* de Google. Los *colab*, son unos servicios que pone a disposición Google de forma totalmente abierta y gratis. Permite a cualquier usuario emplearlo con facilidad sin necesidad de tener recursos locales, aunque con ciertas limitaciones de potencia de cálculo. En este caso el enlace con el método original de AF2 en su versión v2.3.2 sería:

<https://colab.research.google.com/github/deepmind/alphafold/blob/main/notebooks/AlphaFold.ipynb>

El primer paso es la generación del alineamiento múltiple de secuencia (MSA) y requiere de una gran cantidad de recursos. Para ser más eficaces se sustituyó el alineamiento original por MMseq2 y recibe el nombre de ColabFold (Mirdita et al., 2022):

<https://colab.research.google.com/github/sokrypton/ColabFold/blob/main/AlphaFold2.ipynb>

En esta tesis se ha empleado la versión v1.5.5. Una de las dificultades encontradas es que las estructuras generadas por AF2 contienen los átomos de O y de C β en orden diferente a la estructura nativa. Otra fue que una de las limitaciones, intrínsecas con

colab, es que solo se pueden mandar casos a mano de uno en uno (puesto que para usar el servicio es necesario identificarse) y que el navegador debe permanecer conectado durante todo el proceso. Ralentizando mucho el completar los conjuntos de referencia.

3.7.3 ABB1

Desgraciadamente el método original no está disponible, solo una versión que ya incluye ABL como generador de los bucles CDR. La herramienta se puede encontrar en el siguiente servidor web:

<https://opig.stats.ox.ac.uk/webapps/newsabdab/sabpred/abodybuilder/>

ABB1 permite introducir una lista negra de estructuras, las cuales no se tendrán en cuenta para buscar como referencias. Esto nos permite evitar el sobreajuste eliminando la estructura que utilizamos en el conjunto de prueba.

Las estructuras de salida vienen en formato IMGT por lo que es necesario reformatearlas. Dentro de los problemas encontrados a la hora de obtener las predicciones se encuentra que ha sido necesario introducir a mano cada una de las secuencias de los aminoácidos y lanzarlas de una en una. Para la estructura 2adf, en ABB1, daba error obtenerla si se ponía a sí misma en la lista negra, así que finalmente es la única que se sacó sin poder omitirse como plantilla. También en varias de las estructuras, el método considera que el primer aminoácido no es necesario y en la estructura final lo omite. Haciendo que para comparaciones posteriores y solo para mantener la numeración tuviera que añadir un primer aminoácido por inferencia en el inicio de las cadenas donde faltaba.

3.7.4 ABL

Aunque sus resultados están incorporados en los de ABB1; puesto que se podía instalar en local y ejecutar de forma sencilla; y que las estructuras de entradas necesarias (formato IMGT) estaban disponibles; se decidió comprobar si al no realizar una etapa de refinado más exhaustiva como ABB1, obtenían sus mismos resultados o si había alguna variación. Se instala y ejecuta el programa codificado en Python en la última versión (10 noviembre 2022) según las instrucciones de su GitHub:

<https://github.com/oxpig/ABlooper>.

3.7.5 ABB2

El interfaz y el método de introducción de datos es muy similar a ABB1. Sin embargo, para ABB2 no tienen disponibilidad de una opción de lista negra debido a la diferencia técnica de cada método. Por ello no se puede asegurar que no se hayan entrenado con la estructura objetivo y haya casos de sobreajuste. La herramienta se puede encontrar en el siguiente servidor web:

<https://opig.stats.ox.ac.uk/webapps/newsabdab/sabpred/abodybuilder2/>

3.7.6 DAB

Por los motivos similares a los mencionados con AF2, se optó por usar la versión del *colab* disponible, donde al igual que el resto de los métodos calculados desde un servidor online es necesario lanzarlo de uno en uno:

<https://colab.research.google.com/github/RosettaCommons/DeepAb/blob/main/DeepAb.ipynb>

3.7.7 Cálculo de RMSD y generación de modelos de alta calidad

Al tratarse de estructuras generadas de forma completa desde la secuencia y no únicamente sus CDR desde un esqueleto cristalográfico, es necesario realizar ciertos ajustes para obtener una medición de RMSD correcta. Si se alinearan directamente la estructura cristalográfica con la generada es muy probable que un pequeño desvío en la parte central provocara que todo el bucle estuviera desplazado, afectando a la comparación de resultados de RMSD. Para reducir estas posibles desviaciones se alinean los residuos cercanos al anclaje pero que no forman parte del bucle y se calcula el RMSD sobre los residuos del bucle.

Se desarrolló el script `RMSD_hib.pl` que realiza en un mismo proceso dos acciones principales de forma simultánea:

1. Calcular el RMSD entre cada bucle de la estructura original y de la estructura predicha, junto con el RMSD entre los anclajes para comprobar el desvío inicial del que se parte.

2. Generar una estructura híbrida con los CDRs de la estructura cristalográfica y el núcleo de la estructura del método de predicción: Esta estructura puede servir para conocer el rendimiento de nuestro método en escenario modelling sobre estos modelos de mayor precisión.

Antes de ejecutar el script es necesario preparar las estructuras de los diferentes métodos de igual forma que se han prepararon las estructuras cristalográficas para mantener numeración y orden de anotación de los átomos de cada aminoácido. Esto se realiza con los pasos explicados en el apartado 3.2. Posteriormente ya se ejecuta `RMSD_hib.pl` para cada CDR, quedando algo parecido a lo siguiente (ejemplo con ABB1):

```
perl AB_numbering_reverse.pl
for i in *_cl1.pdb; do open_and_close.py $i ${i:0:5}cl2.pdb ; done

for c in *_cl2.pdb ; do echo $c; d=${c:0:4}; echo $d;
exit4=${d}'_ABB1.pdb'; grep -v "ATOM.....H....." $c > $exit4;
done

perl RMSD_hib.pl AB_loop_RCD_H1.txt H1
perl RMSD_hib.pl AB_loop_RCD_H2.txt H2
perl RMSD_hib.pl AB_loop_RCD_H3.txt H3
perl RMSD_hib.pl AB_loop_RCD_L1.txt L1
perl RMSD_hib.pl AB_loop_RCD_L2.txt L2
perl RMSD_hib.pl AB_loop_RCD_L3.txt L3
```

El pseudocódigo de `RMSD_hib.pl` es:

1. Toma la lista de entrada de RCD y va procesando cada caso 1 a 1.
2. Recorta el bucle nativo (1) y el bucle del modelo (2).
3. Recorta los anclajes de los bucles nativo (3) y modelo (4).
4. Se busca el valor mínimo de RMSD entre los anclajes (3) y (4) desplazando (3) sobre (4). Se guarda el valor de RMSD entre anclajes.
5. Desplazamiento del bucle nativo (1) con la misma transformación obtenida en el paso anterior, generando el bucle nativo desplazado sobre el modelo (5).
6. Cálculo del RMSD entre el bucle nativo desplazado (5) y el bucle del modelo (2).
7. Genera una estructura híbrida entre el núcleo del modelo con el bucle nativo desplazado correspondiente (5) y renumera los átomos para que tengan un orden lineal sin saltos (6). Habrá 6 estructuras de este tipo ya que se hace con cada uno de los 6 CDRs por separado.

8. Generación de una estructura similar a la del paso anterior, pero en la que se insertan todos los bucles nativos desplazados en la estructura modelada (7).
9. Se repite desde el paso 4 pero de forma inversa, desplazando los bucles del modelo sobre el núcleo cristalográfico (8) y se genera una estructura inversa a la del paso 8, con todos los bucles del modelo sobre la estructura cristalográfica (9).

4. Resultados

4.1 Actualización y mejora de RCD+

4.1.1 Optimización del término de Ramachandran en el potencial KORP

El potencial original de KORP estaba compuesto únicamente por los dos primeros términos mostrados en la ecuación (5), los cuales distinguen entre interacciones locales y no locales. Cada uno de ellos siguiendo la fórmula de la ecuación (4). Por otra parte, el término de Ramachandran para las interacciones entre aminoácidos consecutivos mostrado en la ecuación (6), estaba desarrollado pero no implementado. Con el objetivo de incorporarlo y mejorar la precisión de KORP en la evaluación de estructuras se llevó a cabo un barrido sistemático de parámetros para identificar la combinación óptima.

La Tabla 14 resume los valores iniciales del método, los valores probados y los valores que finalmente se seleccionaron como óptimos tras incorporar el término de Ramachandran. Ciertos parámetros, como el umbral para clasificar una interacción como local (límite de interacción local) y el número de divisiones utilizadas para discretizar el espacio 6D, se mantuvieron constantes y no fueron objeto de análisis en esta optimización

Tabla 14. Parámetros examinados en la optimización del potencial KORP.

<i>Parámetros</i>	<i>Valor original</i>	<i>Valores probados</i>	<i>Valor óptimo</i>
Radio máximo (Å)	16	12, 13, 14, 15, 16, 17	14
Radio mínimo (Å)	3	2, 3, 4	3
Nº divisiones para el radio	10	-	10
Nº divisiones para Θ y φ	36	-	36
Nº divisiones para ω	8	-	8
Límite interacción local	4	-	4
Factor local (f_l)	1.8	1.5, 1.8, 2	1.8
Factor rama (f_r)	-	3, 4, 5, 6, 8, 10, 15, 20	6

Para la selección de los valores óptimos se generaron potenciales para cada combinación de parámetros. Estos potenciales se emplearon sobre los conjuntos de referencia de longitudes estándar de bucles explicados en 3.5.1. Para intentar cubrir la mayor parte del espacio conformacional de cada longitud de bucle se generaron 10.000, 20.000, 50.000 y 100.000 bucles cerrados con RCD para los conjuntos de 6, 8 10 y 12

aminoácidos de longitud respectivamente. Para evaluar el rendimiento y evolución de la discriminación que realiza cada potencial se obtuvo el Top RMSD medio respecto a la estructura nativa para varios umbrales de selección (%): 1, 2, 5, 10, 20, 50, 100, 200, 500 y 1000. Dada la gran cantidad de combinaciones posibles, el análisis se centró en estudiar las tendencias de cada parámetro de forma aislada, seleccionando aquellos valores que ofrecían mejoras consistentes en todas las longitudes analizadas.

Los resultados mostraron que, a partir de un radio máximo de 14 Å, los mapas no ofrecían mejoras significativas adicionales. Por tanto, se adoptó este valor para reducir el número total de contactos y disminuir el tiempo de cálculo sin sacrificar precisión. Para el radio mínimo se observó que variaciones si afectan negativamente y se mantuvo 3 Å. Con el factor local no se apreciaron cambios significativos. Para el factor Rama se realizó un barrido más amplio y se encontró valores óptimos entorno al valor 6.

Dado que el cierre de bucles en RCD es un proceso estocástico, repetimos el proceso de RCD+KORP 10 veces, tanto con el conjunto de parámetros original (sin el termino Rama), como con el conjunto nuevo optimizado. La Figura 25 reflejada en una reducción sistemática del Top RMSD medio en todas las longitudes analizadas. Esta reducción es más importante es en el Top1 donde vemos como se baja desde 0.91 Å, 1.11 Å, 1.37 Å y 1.60 Å con el conjunto de parámetros original sin el termino de Rama, a 0.82 Å, 1.07 Å, 1.34 Å y 1.53 Å con la nueva optimización para cada longitud de bucle respectivamente.




Figura 25. Mejora en la discriminación de bucles cercanos a la estructura nativa por el potencial KORP tras incorporar el termino de Ramachandran.

4.1.2 Actualización y optimización de PyRosetta

El protocolo original de RCD+ (2014) utilizaba una versión temprana de PyRosetta desarrollada en Python 2.1. Con el fin de mantener la compatibilidad con entornos actuales y beneficiarse de las mejoras del software, se decidió actualizar a la versión moderna de PyRosetta 4 y migrar todo el código a Python 3.7.

Esta actualización requirió una serie de modificaciones en el protocolo de refinamiento y parametrización en las etapas de *repacking* y minimización de cadenas laterales. En términos propios de Rosetta, *pack* es un protocolo que emplean para predecir la posición de las cadenas laterales de los residuos partiendo de la cadena principal con métodos de Monte Carlo intentando encontrar las conformaciones con menor energía desde un conjunto fijo de rotámeros. *Repacking* es una variante orientada al refinamiento de dichas conformaciones laterales ya posicionadas. Dado el carácter estocástico del proceso, se realizan cinco repeticiones completas del proceso y se escoge el mejor resultado. En el código original, en cada repetición se ejecutaban cuatro ciclos de *repacking* y minimización, con un peso en las fuerzas de repulsión Lennard-Jones (*fa_rep*) entre átomos creciente: 0.02, 0.25, 0.550 y 1.0, y con una tolerancia en la minimización de 0.01, 0.01, 0.01 and 0.00001 respectivamente:

```
repeat 5
  ramp_repack_min 0.02 0.01
  ramp_repack_min 0.250 0.01
  ramp_repack_min 0.550 0.01
  ramp_repack_min 1 0.00001
  accept_to_best
endrepeat
```

La nueva versión del protocolo mantiene la misma estructura de cinco repeticiones, pero introduce varias novedades: Incorporación progresiva de una restricción sobre las coordenadas atómicas (*coord_cst_weight*) que disminuye progresivamente (1.0, 0.5, 0.0 y 0.0) a lo largo de los ciclos; y separación de los valores de *fa_rep* para el *repacking* (0.040, 0.265, 0.559 y 1) y la minimización (0.051, 0.28, 0.581 y 1), siendo ligeramente su valor en esta última en cada ciclo.

```

repeat 5
-----
coord_cst_weight 1.0                #repack + min 1
scale:fa_rep 0.040
repack
scale:fa_rep 0.051
min 0.01
-----
coord_cst_weight 0.5                # repack + min 2
scale:fa_rep 0.265
repack
scale:fa_rep 0.280
min 0.01
-----
coord_cst_weight 0.0                # repack + min 3
scale:fa_rep 0.559
repack
scale:fa_rep 0.581
min 0.01
-----
coord_cst_weight 0.0                # repack + min 4
scale:fa_rep 1
repack
min 0.00001
accept_to_best
endrepeat

```

Para comprobar si genera alguna mejora en tiempo o resultados sobre la predicción de bucles, se realizaron tres réplicas de predicciones completas (RCD + Rosetta), tanto para la versión antigua como para la nueva versión; sobre el CRR en el bucle H3. El valor de RMSD corresponde al Top10 y tiene en cuenta los átomos C, C α , N y O; a diferencia de los valores mostrados en el resto de la tesis que se sustituye el átomo de O por el átomo C β . Esto es debido a que esta sección fue una de las primeras acciones que se realizaron y todavía no se había definido con qué átomos se iba a realizar todas las métricas. En la Tabla 15 se resumen los resultados. El valor de RMSD del Top10 para ambas versiones es el mismo. También se analizaron los resultados dividiendo el conjunto de referencia en 3 grupos según la longitud de los bucles (<12, 12 – 15 y >15 residuos). La actualización del código trae una pequeña mejora de 0.05 Å en el grupo más pequeño, mantiene los resultados en el grupo intermedio y empeora muy ligeramente en el grupo más largo. Estas diferencias no son significativas y se puede afirmar que la actualización no supone un perjuicio en los resultados.

Tabla 15. Comparación de RMSD (Top10) entre el protocolo de refinamiento original y el nuevo de RCD+ en CRR para el bucle H3.

	<i>Total</i>	<i>< 12</i>	<i>12 - 15</i>	<i>> 15</i>
<i>Antiguo protocolo</i>	1.20	0.85	1.00	2.11
<i>Nuevo protocolo</i>	1.20	0.80	1.02	2.14

Debido a que la diferencia entre el protocolo antiguo y el nuevo reside principalmente en la diferencia de unos valores fijos, pero se mantiene el mismo número de ciclos de minimizaciones, tampoco se observó una diferencia significativa en el tiempo empleado por cada uno.

4.2 KORPM: Korp en la predicción de estabilidad en la sustitución de aminoácidos

En la Tabla 16 se muestran los resultados obtenidos para el conjunto de evaluación estándar S^{sym} . Como se puede apreciar, KORPM tiene una excelente correlación de 0.69 entre los valores predichos y los experimentales de $\Delta\Delta G$, con un error de RMSE de 1.33 kcal/mol. Las métricas de rendimiento de clasificación binaria, como sensibilidad, especificidad, VPP, VPN y ACC, obtiene valores superiores a 0.77. Otra métrica que corrobora los buenos resultados en un amplio rango de especificidades es la que proporciona la curva ROC (Figura 26) y el área correspondiente bajo ella, que es igual a 0.86. Si analizamos la clasificación ternaria, KORPM identifica correctamente el grupo al que pertenecen en el 65.9% de los casos, falla a un grupo adyacente en un 33.7% y tan solo confundió estabilizantes con desestabilizantes en el 0.4%.

Tabla 16. Resultados de todos los métodos de predicción de estabilidad en sustitución de aminoácidos para el conjunto de dato de evaluación simétrico S^{sym} . Resaltado el mejor valor de cada columna.

Método	Valor absoluto			Clasificador binario								Ternario			Simetría	
	RMSE	MAE	PCC	Sen	Spe	PPV	NPV	ACC	MCC	AUC ^{ROC}	AUC ^{PRC}	Sc	Of1	Of2	r ^{sym}	δ
KORPM	1.33	0.95	0.69	0.77	0.79	0.79	0.78	0.78	0.56	0.86	0.86	65.9	33.7	0.4	0.88	-0.15
Cartddg	3.44	2.63	0.63	0.58	0.88	0.83	0.68	0.73	0.48	0.81	0.82	52.3	41.1	6.6	0.41	-3.12
FoldX	1.86	1.29	0.54	0.55	0.78	0.71	0.63	0.66	0.33	0.74	0.75	60.1	34.5	5.4	0.27	-1.25
EvoFF	1.56	1.12	0.54	0.61	0.70	0.67	0.64	0.66	0.31	0.74	0.75	61.7	34.9	3.4	0.58	-0.36
PopMusic	1.58	1.15	0.52	0.67	0.71	0.70	0.68	0.69	0.38	0.76	0.74	56.6	42.4	1.0	0.77	-0.06
Dynamut2	1.88	1.37	0.38	0.21	0.88	0.64	0.53	0.53	0.13	0.62	0.62	54.4	38.2	7.4	0.11	-1.56
DDGun3D	1.43	1.04	0.63	0.68	0.69	0.69	0.69	0.69	0.37	0.75	0.76	61.8	37.5	0.7	0.99	-0.04
ThermoNet	1.53	1.09	0.55	0.65	0.70	0.69	0.67	0.68	0.35	0.75	0.74	58.2	40.9	0.9	0.96	-0.01
ACDCNN	1.38	1.01	0.69	0.70	0.79	0.70	0.70	0.70	0.40	0.80	0.80	61.5	38.5	0.0	0.98	-0.05




Figura 26. Curvas ROC para todos los métodos de predicción de estabilidad en S^{sym} .

El método es prácticamente simétrico por construcción; es decir, la predicción para el cambio de la proteína nativa al mutante y para la sustitución inversa presenta una magnitud similar pero con signo opuesto. Esto se confirma con los valores obtenidos en las métricas de simetría como la alta correlación de 0.88 o la baja diferencia media entre mutaciones directas e inversas. Las desviaciones existentes se deben a diferencias estructurales entre la proteína nativa y la mutante, que modifican las orientaciones relativas del residuo mutado y de sus vecinos.

La comparación entre métodos de predicción de estabilidad es difícil debido a las diferencias en los conjuntos de entrenamiento/prueba y validación que utiliza cada uno, así como a las incertidumbres inherentes de los datos experimentales. A excepción de DDGun3D, que es un método no entrenado, y ThermoNet y PoPMusicS, que emplearon el mismo conjunto como prueba ciega, no se puede asegurar que el resto de los métodos no tengan alguno de los casos en su conjunto de entrenamiento.

En la Tabla 16 como KORPM obtiene el menor RMSE y MAE junto con el PCC más alto. Esta tendencia se mantiene en la mayoría de las métricas del clasificador binario, destacando como tanto en ROC (Figura 26) y PRC, como en el área bajo ellas se obtienen los mejores valores. Esto evalúa de forma global el método, independientemente del

umbral elegido para la clasificación, mostrando que nuestro enfoque tiene mejores resultados en todos los rangos prácticos. Cartddg se sitúa en segundo lugar, obteniendo también buenos resultados en las áreas bajo las curvas, e incluso superando a KORPM en especificidad y precisión (PPV), sin embargo, es el que peor RMSE obtiene (3.44 kcal/mol) ya que tiende a predecir valores de $\Delta\Delta G$ extremadamente altos para algunas mutaciones desestabilizantes, probablemente debido a colisiones fuertes (aunque intentamos reducir este comportamiento anómalo limitando los valores predichos a un máximo de -8 kcal/mol).

En cuanto a la comparación dentro de los errores en la clasificación ternaria encontramos que KORPM lidera acertando un $\sim 66\%$ de los casos, le siguen de cerca los métodos basados en energía con valores entre 60-62% y en último lugar se encuentra Cartddg con un $\sim 52\%$. Además, el porcentaje de predicciones totalmente erróneas fue de menos de un 1% para ACDCNN, KORPM, PopMusicS, DDgun3D y ThermoNet, mientras que superiores al 5% para CartddG, Dynamut2 y FoldX.

Si comparamos las predicciones sobre mutaciones directas frente a mutaciones inversas, ACDCNN, DDgun3D y ThermoNet logran una simetría casi perfecta, con valores de r^{Sym} muy próximos a 1 y valores de δ cercanos a 0. KORPM y PopmusicS les siguen de cerca, con la correlación entre mutaciones directas e inversas también es elevada (0.88 y 0.77, respectivamente), con valores de δ bajos (-0.15 y -0.06 , respectivamente). Por el contrario, las predicciones de EvoFF2, CartddG, FoldX y Dynamut2 son significativamente mejores para las mutaciones directas que para las inversas. Este sesgo en la simetría se evidencia en la baja correlación de r^{Sym} (0.58, 0.41, 0.27 y 0.11, respectivamente).

4.3 Resultados con los mapas de restricción para H3 y selección de suavizado

Con el objetivo de evaluar el impacto de los mapas de restricción en la predicción estructural del bucle H3, y que tipo de suavizado realiza una mejor predicción, se analizaron las distintas configuraciones sobre el conjunto CRR. Se realizaron tres réplicas independientes de RCD y para cada una de ellas se aplicaron cinco réplicas de refinamiento con Rosetta, dando un total de 15 predicciones para cada estructura. En la

Tabla 17 se muestran los valores de enriquecimiento medios de las tres réplicas de RCD. Estos valores corresponden a: el valor más bajo de RMSD de los 1000 bucles seleccionados por KORP sobre los 50.000 generados antes del refinamiento; al porcentaje de esto bucles seleccionados por debajo de los umbrales de 0.5 Å, 1 Å, 1.5 Å, 2 Å, 2.5 Å y 3 Å; y al tiempo total necesario en todo este proceso en un entorno de paralelización equitativo de 10 procesadores. En primer lugar, se ve como se consigue bajar considerablemente el valor del bucle generado más cercano a la solución de 1.8 Å de media en la predicción sin mapas de restricción específicos hasta valores inferiores a 1.3 Å en las predicciones con mapa. Destaca también, como hay un gran enriquecimiento en los umbrales de los mapas seleccionados. Mientras se obtiene tan solo un 7.47% de los bucles generados por debajo de 3 Å sin usar mapas, se llega a valores en torno al 48% al emplear mapas. Esta mejora es notable en umbrales más bajos como en el caso de los 2 Å, donde sin mapa no se supera el 1 % y con mapa se acerca al 20%, obteniendo valores mejores por debajo de 1 Å con mapa que por debajo de 2 Å sin mapa. El enriquecimiento de bucles generados y seleccionados más cercanos a la solución supone una ventaja muy significativa, ya que el último paso de refinamiento se dedica a introducir las cadenas laterales y realizar pequeños movimientos de relajación de la estructura para evitar colisiones. Esto significa que, aunque en ciertas ocasiones se desplace considerablemente el bucle inicial y se obtenga uno más cercano a la solución por motivos estéricos, y en otras ocasiones ocurra lo contrario, es mucho más sencillo llegar a la solución correcta si los bucles que se refinan se encuentran en mayor proporción más cercanos a esta solución.

Tabla 17. Enriquecimiento de RCD+ en H3 de CRR sin mapa y para cada tipo de suavizado (S1 y S2).

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
<i>Sin mapa</i>	1.816	0.00	0.00	0.12	0.90	3.19	7.47	101.45
<i>S1</i>	1.292	0.00	0.92	8.24	19.69	33.70	47.96	69.17
<i>S2</i>	1.277	0.00	1.00	8.40	19.89	33.98	48.22	67.43

Además de la mejora en la discriminación, se observa una reducción significativa en el tiempo medio de ejecución cuando se emplean mapas de restricción. La comparación entre los dos tipos de suavizado revela que ambos proporcionan resultados similares, aunque S2 presenta una ligera ventaja tanto en la discriminación como en tiempo.

En la Tabla 18 se muestran los promedios de RMSD, para el Top1, Top5 y Top10, tras las cinco réplicas de refinamiento en cada replica de RCD (15 en total). Ambos mapas de restricción mejoran considerablemente los valores respecto a las predicciones sin mapa, y entre ellos, S2 aporta una pequeña mejora. Por tanto, debido a la pequeña, pero consistente ventaja que proporciona el suavizado S2 frente a S1 observada en tanto en el enriquecimiento de RCD+ como en los RMSDs finales, será el empleado por defecto.

Tabla 18. Comparación del suavizado de mapas en el CRR en el bucle H3 tras el refinamiento. Se muestran los valores de RMSD para cada tipo de suavizado (S1 y S2) y para los Top10, Top5 y Top1 respectivamente.

	<i>Top1</i>	<i>Top5</i>	<i>Top10</i>
Sin mapa	2.95	2.08	1.81
S1	2.05	1.49	1.33
S2	2.03	1.45	1.29

En la Figura 27 y en la Figura 28 se representan los resultados medios obtenidos para cada caso con y sin mapa ordenados de menor a mayor longitud de bucle (de 1mlb con 9 residuos a 3nps con 19 residuos) para el Top1 y Top10 respectivamente. Se puede observar que, usando el mapa, excepto en 4 casos, se obtienen valores mejores.




Figura 27. Resultados Top1 en H3 de CRR con (verde) y sin mapa (naranja). Los anticuerpos están ordenados por tamaño del bucle, desde 9 residuos en el 1mlb hasta 19 residuos en el 3nps.

Para comprobar comportamientos más generales se dividen los casos en 3 grupos: > 15 residuos (10 estructuras), entre 12 y 15 residuos (21 estructuras) y < 12 residuos (18 estructuras). En los bucles > 15, la mejora es más evidente. Centrándonos en los valores del Top10 destacan los casos de 3mlr (17 residuos) que baja de 5.02 Å a

3.61 Å, 4f57 (18 residuos) que baja de 5.15 Å a 3.44 Å o 3nps (19 residuos) que baja de 5.15 Å a 3.44 Å. El RMSD más bajo corresponde a 1fns (16 residuos) con 1.47 Å. Los RMSDs finales son altos si se comparan de forma absoluta con el resto del conjunto, y es debido a que al poseer una longitud tan grande su espacio conformacional es varios ordenes de magnitud mayor. Sin embargo, la mejoría general refleja que al restringir ese espacio conformacional conseguimos acercarnos mucho más hacia las soluciones nativas.

También se observa una mejora significativa en el grupo de entre 12 y 15 residuos. Se pueden destacar los casos de mayor mejora de 3i9g (14 residuos) que baja de 2.40 Å a 1.20 Å, 3t65 (13 residuos) que baja de 3.28 Å a 1.67 Å o 3mxw (12 residuos) que baja de 2.67 Å a 1.16 Å. También hay varios casos que salían con resultados decentes en torno a 1 Å, que tras aplicarle los mapas de restricción no se han estropeados, y ha mejorado muy a valores en torno a 0.50 Å, como son los casos de 2xwt, 3ifl o 4h0h. Este último, de 12 residuos, obteniendo el resultado más bajo del grupo con 0.39 Å. Sin embargo, también se encuentran ciertos anticuerpos en los que el mapa les perjudica. Ocurre de forma ligera en los casos 1dlf, 2ypv, 3liz, 4h2o y 2r8s. Y destacan un par de casos donde la predicción empeora de forma notable frente a realizarla sin mapas de restricción: 2ypv (12 residuos) que aumenta de 0.64 Å a 1.21 Å y el peor caso con 3liz (12 residuos) que aumenta de 1.47 Å a 3.49 Å.




Figura 28. Resultados Top10 en H3 de CRR con (verde) y sin mapa (naranja). Los anticuerpos están ordenados por tamaño del bucle, desde 9 residuos en el 1mlb hasta 19 residuos en el 3nps.

Atendiendo a los bucles < 12 , se observa que tan solo 5 de 18 tenían valores superiores a 1 Å sin emplear los mapas, y que tan solo 2 tenían un valor superior a 2 Å. Por lo que el punto de partida es bastante más cercano a la solución y la posible mejora es menos. Se encuentran mejoras significativas en los casos de 1mlb (9 residuos) que baja de 1.91 Å a 0.66 Å, 1mkq (11 residuos) que baja de 1.31 Å a 0.52 Å y 3gnm (11 residuos) que baja de 2.17 Å a 1.36 Å. La mayoría de casos tienen ciertas mejoras ligeras. Aunque hay casos en los que también el mapa le provoca pequeños empeoramientos, como son 2e27, 1mfa, 2fbj, 3hnt. Hay que destacar dos casos en los que parece que los mapas no terminan de funcionar bien. En primer lugar, 3m8o (10 residuos): originalmente era uno de los dos casos con valores superiores a 2 Å y tras usar el mapa ni mejora o empeora, se queda con los mismos valores, siendo el caso con el peor valor de este grupo tras usar los mapas. En segundo lugar, 3hc4 (9 residuos): sin mapa tenía resultados buenos con 0.47 Å, pero tras usar los mapas este empeora a 1.32 Å.

En la Figura 29 se representan 6 ejemplos ilustrativos de las estructuras destacadas anteriormente, incluyendo los casos más críticos. Se ha representado la estructura nativa en gris y los bucles del Top10 más cercanos en RMSD al valor medio de entre las 15 réplicas con el mapa de restricción en verde y sin el mapa en naranja.

El caso 1x9q de 9 residuos (Figura 29A) es un claro ejemplo de bucle < 12 que se predecía bien sin mapa y que al introducir el mapa hay una pequeña variación positiva de 0.43 Å a de 0.35 Å. Difícil de observar a simple vista.

La estructura 1mlb de 9 residuos (Figura 29B) es un caso ilustrativo de gran mejora en bucles < 12 al pasar de 2.21 Å a 0.66 Å tras emplear mapas. Tiene un kink bastante marcado, sin embargo, la predicción sin mapa se aleja bastante de la conformación nativa en la zona cercana al anclaje C-Terminal.

De igual manera, el caso 3mlr de 17 residuos (Figura 29C) mejora significativamente de 6.16 Å a 1.52 Å con mapa. En este caso el espacio conformacional es muy amplio, sin mapa se pueden llegar a conformaciones muy desviadas, sin embargo, al restringir el kink, el bucle predicho con mapa sigue la estructura nativa en ambas zonas cercanas a los anclajes, y no es hasta mitad de bucle cuando se empieza a desviar un poco, pero manteniendo una conformación muy parecida al bucle nativo.

En el caso más crítico, 3liz de 12 residuos (Figura 29D), la predicción con mapa obtiene un valor de RMSD de 3.81 Å y sin mapa de 1.47 Å. En este caso se trata de una de las pocas estructuras que no tiene kink, si no que la cadena sigue recta. El bucle sin mapa, al tener más libertad en esas posiciones si encuentra la orientación más parecida, pero en el bucle con mapa, al forzarle una conformación con kink se impide poder encontrar el camino nativo. Siendo este un ejemplo de que como puede perjudicar el mapa a aquellos poco caso en los que el kink no está presente.




Figura 29. Casos representativos de H3 Top10 con y sin mapas de restricción con RCD+ en CRR. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

El caso 1mfa de 11 residuos (Figura 29E) se trata de una estructura con kink en la que tanto sin mapa como con mapa se observa una pequeña desviación (1.26 Å) en la zona C-terminal a la salida del kink. En la estructura nativa está presente el ligando y en

nuestro método se hace sobre la proteína APO, por lo que es posible que el ligando fuerce a la estructura a tener una conformación menos relajada.

En el caso 2ypv de 12 residuos (Figura 29F) la predicción empeora ligeramente de 0.64 Å a 1.21 Å al emplear mapa. Al analizarlo más en detalle se comprobó que para las predicciones sin mapa siempre se obtenía la conformación más cercana a la nativa, sin embargo, con el mapa se obtuvieron conformaciones similares (en torno a 0.65 Å) en 11 de las 15 réplicas y valores superiores a 2.5 Å en las 4 réplicas restantes. Por lo que parece que el uso del mapa provoca el desplazamiento hacia otro mínimo local de energía diferente al nativo. También se trata de una de las estructuras que contiene ligando, por lo que este también puede ser el causante que esta conformación sea bien predicha unas veces y otras veces no, al poder forzar que alguno de los ángulos este en el borde de los restringido por los mapas. Una posible solución para este tipo de casos es realizar un mayor muestreo para reducir las posibilidades de no tener en cuenta las estructuras límites.

4.4 Comparación de RCD+ con RoAb en H3

4.4.1 RoAb NGK-kink

Para modelar H3, RoAb parte de estructuras relajadas en su potencial. Afortunadamente contamos con las mismas estructuras relajadas del artículo original y proporcionadas por sus autores. Por esta razón, podemos compararnos exactamente en las mismas condiciones. El RMSD se calcula con los átomos C-C α -N-O a diferencia del resto de la tesis y nos comparamos con los valores del Top1 publicados (Weitzner & Gray, 2017).

El resultado medio para CRR que obtiene RoAb en el Top1 es de 2.19 Å, mientras que RCD+ obtiene un valor más reducido de 2.00 Å. Se puede apreciar en la Figura 30, que de forma general hay bastantes estructuras con resultados similares. Aunque RCD+ obtiene predicciones notoriamente más cercanas al nativo con bucles < 12 residuos. Por ejemplo, los casos 1mlb, 1x9q, 2e27 o 3m8o rebajan considerablemente los valores obtenidos por RoAb. En bucles entre 12 y 15 residuos solo encontramos dos casos donde RCD+ se desvía claramente. En especial el caso 3liz fue comentado previamente en la Figura 29D como un caso con ausencia de *kink*. Por otro lado, 3t65 si pudimos observar

en la Figura 28 que esta desviación se corrige si atendemos al Top10. Por último, ambas aproximaciones muestran sus limitaciones en bucles largos de más de 15 residuos.




Figura 30. Comparación de RMSD Top1 para los bucles H3 de CRR entre RCD+ (verde) y RoAb (morado) sobre estructura cristalográfica. Los anticuerpos están ordenados por tamaño del bucle CDR, desde 9 residuos en el 1mlb hasta 19 residuos en el 3nps.

4.4.2 Resultados servidor Rosie (2025)

En la plataforma Rosie se encuentra el protocolo completo de RoAb. Genera un modelo basado en homología desde la secuencia de aminoácidos para posteriormente aplicar sobre estos modelos el protocolo *ab initio* para H3 NGK-kink. Se han producido errores recurrentes en las estructuras 1mqk, 1x9q, 3eo9 y 3ifl y no se ha podido obtener sus predicciones. Por lo que en esta sección solo se compararan sobre las restantes 45 estructuras de CRR.

Generando el mismo número de predicciones para cada caso de H3, RCD+ es más de un orden de magnitud más rápido que RoAb lanzado en Rosie. Este es el principal motivo por el que, aunque RoAb posee una naturaleza estocástica en la generación de los bucles tan solo se pudo realizar una réplica. El tiempo medio requerido para un único caso de H3 para cada método se muestra en la Tabla 19.

Tabla 19. Tiempo medio empleado en horas:minutos por caso en CRR, para el protocolo completo de cada método.

	<i>RoAb (Rosie)</i>	<i>RCD (nativo)</i>	<i>RCD (modeling)</i>
Tiempo (h:m)	14:39	00:09	00:29

Mientras que con RCD+ se obtienen los resultados con una media de entre 8 y 9 minutos por caso en escenario nativo y entre 25 y 30 minutos en escenario de modeling, RoAb lanzado en Rosie tarda de media entre 13 y 16 horas. Estos valores se obtienen tras lanzar RCD+ en un cluster con 50 procesadores, mientras que Rosie lo manda en 64 (y aunque no se sabe cuáles son, por recursos económicos de cada organización se le presuponen de mayor capacidad de cálculo). Además, el servidor online dispone de una serie de mecanismos de protección al bloqueo en la que cuando un usuario manda más de 5 casos simultáneos reduce su prioridad y estos se quedan esperando a que no haya ningún otro usuario usando el sistema, suponiendo una media final para CRR de 18 horas por caso.

Para calcular el RMSD los bucles de RoAb se empleó el proceso explicado en el apartado 3.7.7, donde a su vez se obtiene el RMSD correspondiente a la zona de anclaje del mismo bucle, permitiendo evaluar la fiabilidad del modelo generado en esa región. Estos modelos de Rosie obtuvieron un valor medio de RMSD de los anclajes de 0.14 Å, lo que indica que son cercanos a la estructura nativa y las métricas obtenidas son fiables. Tan solo 2 estructuras han obtenido un valor superior a 0.3 Å: 3umt con 0.43 Å y 3nps con 0.33 Å. Lo que sugiere pequeños cambios de la cadena principal en la estructura predicha frente a la nativa e impide obtener valores más bajos.

Para comprar los resultados, en RCD+ se utilizan los mismos modelos de Rosie y se predice H3 con escenario *modeling*. Se realizaron 9 réplicas totales (tres réplicas de generación de bucles con RCD y tres réplicas de refinamiento en cada replica anterior).

Tal como se resume en la Tabla 20, el promedio de RMSD obtenido por RoAb es de 3.45 Å en el Top1 y 2.10 Å en el Top10, mientras que RCD+ obtiene valores de 2.77 Å y 2.01 Å respectivamente. Atendiendo a los valores por grupos de tamaños, vemos que, aunque RCD+ obtiene valores más bajos en todos ellos, es en el grupo de bucles > 15 residuos para el Top1 donde se obtiene la principal diferencia para el Top1, mientras en el Top10 se igualan.

Tabla 20. Resultados de RMSD en H3 para RoAb y RCD+ (sobre los modelos de RoAb)

		Total	< 12	12 - 15	> 15
RCD+	Top1	2.77	1.92	2.60	4.46
	Top10	2.01	1.56	1.92	2.92
RoAb (Rosie)	Top1	3.45	2.20	2.90	6.50
	Top10	2.10	1.46	2.13	3.08

Los valores individuales para cada caso se encuentran representados en la Figura 31 para el Top1 y en la Figura 32 para el Top10. Si nos centramos en el Top1 y lo comparamos con ambos métodos en un escenario cristalográfico (sección 4.4.1) se puede apreciar como hay un empeoramiento de la predicción generalizado en todos los casos, ya que pequeñas modificaciones en la zona del anclaje pueden condicionar el resto de la conformación seleccionada. Partiendo del mismo margen de error podemos apreciar como RCD+ obtiene unos resultados más consistentes. Aunque en la mayoría de los casos obtiene valores similares a RoAb, hay hasta 9 casos en los que RCD+ obtiene valores de RMSD mucho más bajos, mientras que de forma inversa solo ocurre en 2 casos. Mientras que RCD tan solo tiene 3 casos por encima de 5 Å y el máximo es 2fb4 (19 residuos) con un valor de 5.76 Å; RoAb tiene 8 casos por encima de 5 Å, de los cuales 4 son superiores a 9 Å, siendo el máximo 1fns (16 residuos) con 10.99 Å. Esto expone como RCD+ tiene una mayor consistencia incluso en situaciones dudosas de modelado y que RoAb cuando falla lo hace de forma más marcada. También hay que recordar que en hasta 4 casos Rosie no pudo generar predicciones.




Figura 31. Comparación de RMSD Top1 para los bucles H3 de CRR entre RCD (dorado) y RoAb (morado) sobre modelo de homología. Los anticuerpos están ordenados por tamaño del bucle CDR, desde 9 residuos en el 1mlb hasta 19 residuos en el 3nps.




Figura 32. Comparación de RMSD Top10 para los bucles H3 de CRR entre RCD (dorado) y RoAb (morado) sobre modelo de homología. Los anticuerpos están ordenados por tamaño del bucle CDR, desde 9 residuos en el 1mlb hasta 19 residuos en el 3nps.

Si atendemos a los valores del Top10, RCD+ mantiene todas las estructuras por valores inferiores a 4 Å, a excepción de 3liz (12 residuos) que obtiene 4.46 Å, mientras que RoAb tiene hasta 5 casos por encima de este valor incluyendo la misma 3liz. RCD+ destaca en hasta 8 casos de forma notoria sobre RoAb, resaltando 3mxw (12 residuos) con un RMSD de 1.01 Å frente a 4.18 Å frente a RoAb, representada en la Figura 33B; o 3m8o (10 residuos) con 1.86 Å frente a 4.48 Å. De forma inversa, RoAb obtiene mejor resultado de forma destacada en 6 ocasiones. Las diferencias más notorias son en el caso de 2w60 (12 residuos) donde RoAb obtiene un resultado de 0.55 Å, mientras que RCD+ obtiene un valor de 3.88 Å, representada en la Figura 33C; o en el caso de 2ypv (12 residuos) con 1.58 Å frente a 2.86 Å.

Además, en la Figura 33A, se ejemplifica un caso como 3oz9 de 12 residuos, donde ambos métodos obtienen predicciones sub-ángstroms; y en la Figura 33D, el caso excepcional de 3mlr de 17 residuos: ambos métodos predicen correctamente la región del *kink*, sin embargo, pero debido a su gran longitud y la conformación estilizada tras el *kink*, ambos métodos fallan, optando por una conformación redondeada (aunque RCD+ tiene cierta ventaja 3.20 Å frente a casi 5 Å).




Figura 33. Comparación de predicciones de Top1 de RoAb y RCD+ en cuatro casos ilustrativos. RoAb obtenido del servidos Rosie (morado) y RCD+ ejecutado sobre las estructuras de Rosie en escenario modeling (dorado).

En la Figura 34 se representa la evolución del valor de Top RMSD medio para todos los casos del CRR según avanza el número de estructuras seleccionadas. Podemos observar cómo RCD+ obtiene valores de Top más bajos en región inicial y según se incrementa el número de predicciones seleccionadas ambos métodos se igualan. Esto indica que RCD+ genera una discriminación más efectiva hacia el bucle nativo entre las primeras estructuras seleccionadas.




Figura 34. Evolución del RMSD mínimo medio por Top para CRR desde los modelos de RoAb para RCD+ (amarillo) y RoAb (morado).

4.5 Estudio de los mapas de restricción en el resto de CDRs en CRR




Figura 35. RMSD medio de RCD+ ejecutado con y sin mapa en todos los bucles CDR en CRR.

La incorporación de los mapas de restricción específicos para los distintos CDRs reducen la distancia de las predicciones con la conformación nativa como se puede ver en la bajada general de los valores de RMSDs, con la excepción de H1 en las que no se aprecia diferencias (Figura 35). En el caso de H1, independientemente de aplicar restricciones o no con los mapas, las mejores predicciones y la estructura nativa son prácticamente indistinguibles desviándose solo 0.3-0.4 Å. Con H2 y L3 la mejora con los

mapas es más significativa en torno a 0.3-0.1 Å, alcanzando 0.6Å y 0.4 Å para el Top1 y Top10, respectivamente. L1 y L2 presentan la mejora más destacable cuando se usan los mapas acercándose a la estructura nativa 0.47 Å y 0.38 Å en el Top1 y 0.38 Å y 0.31 Å en el Top10, partiendo de valores por encima de 1 Å sin mapas (1.60 y 1.33 Å en el Top1 y 1.08 Å y 1.05 Å en el Top10). Aunque la mejora es general, en las siguientes secciones se detallan caso por caso los resultados obtenidos.

4.5.1 Resultados de los mapas de restricción de H1

Aunque con H1 no se aprecia mejoría en RMSD, si analizamos el enriquecimiento en la primera fase de generación de bucles con RCD y selección del 1% con KORP (i.e. sin el refinamiento de Rosetta), si se observa una mejora (Tabla 21). A umbrales más bajos, por ejemplo, conseguimos doblar la cantidad de estructuras < 1 Å desde 25% sin mapa a 57% con mapa o a obtener 10 veces más estructuras < 0.5 Å al aumentar de 0.16% a 1.6%. Esa mejora no se traduce posteriormente en la etapa de refinamiento porque el espacio configuracional es relativamente pequeño, 7 residuos, y se puede explorar exhaustivamente sin necesidad de mapa restricción. En cuanto a tiempo medio empleado por caso no aparece ninguna variación.

Tabla 21. Enriquecimiento de RCD+ para H1 en CRR con y sin mapa de restricción. En todos los casos se han generado 20.000 bucles con RCD y se seleccionaron los 200 con menor energía KORP.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
<i>Sin mapa</i>	0.696	0.16	24.94	81.36	91.58	94.38	96.68	26.45
<i>Con mapa</i>	0.592	1.60	57.30	90.85	94.65	96.55	98.09	26.89

Si atendemos a los resultados individuales tras el refinamiento mostrados en la Figura 36, podemos observar que tan solo 5 de las 49 estructuras tienen un resultado superior a 0.5 Å en RMSD sin mapas. Independientemente de la consideración de restricciones, la mayoría de las predicciones coincide con la estructura real. En la Figura 37A, se muestra un ejemplo ilustrativo (2adf) de cómo tanto con o sin mapa se obtiene un resultado prácticamente indistinguible de la estructura nativa.

De las 5 estructuras que se encontraban con soluciones más alejadas, tres de ellas no varían apenas (1dif, 2xwt, 3g5y), sin embargo, las otras dos (3pns, 4hpy) en vez de mejorar, empeoran con el mapa.




Figura 36. Resultados Top10 en H1 de CRR con (verde) y sin mapa (naranja).

En la Figura 37A se muestra un ejemplo ilustrativo (2adf) en la que con y sin mapa la predicción coincide con la conformación nativa.

En el caso de 3g5y, la Figura 37B, tiene una pequeña desviación en la zona central tanto con mapa como sin mapa con un valor de RMSD de 0.94 Å en ambos casos. En este caso la estructura nativa está unida al antígeno lo que podría explicar este pequeño desvío. Aunque este caso es anómalo por su longitud de 8 residuos, otros casos con longitudes incluso mayores no presentaban desviaciones significativas (3ifl, 9 residuos, 0.45 Å a 0.48 Å con y sin mapa). Entre los dos casos que empeoran destaca 3nps (Figura 37C) que partiendo de una estructura cercana a la nativa sin mapa 0.51 Å se desvía a 2.03 Å con mapa. Si nos fijamos en la estructura el desvío de la estructura con el mapa se produce en entre el primer y segundo aminoácido (2 glicinas) de la zona N-Terminal del bucle, lo que sugiere un camino conformacional diferente a la mayoría de los bucles H1 como la Figura 37A. También hemos observado que en 2 de las 15 réplicas sin mapa también se selecciona como mejor solución a esta conformación a distancia de 2 Å. En este caso las restricciones del mapa hacen que esta conformación minoritaria con mapa desplace a las conformaciones más cercanas a la nativa. La estructura nativa de referencia está unida a la proteína MT-SP1 (Membrane-Type Serine Protease 1) (MT-SP1) que también puede afectar conformacionalmente.




Figura 37. Casos representativos de H1 Top10 con y sin mapas de restricción con RCD+ en CRR. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

Por último, en la Figura 37D corresponde a la estructura 4hpy (7 residuos) en la que la inclusión de mapa empeora ligeramente el RMSD de 1.38 Å a 1.60 Å con mapa. En este caso, hay una desviación de la estructura nativa en el C-Terminal del bucle que es ligeramente mayor con mapa. Esta proteína también ha sido cristalografiada con su antígeno.

Coincide que los 3 casos estudiados con peor resultado son casos en los que en la estructura cristalográfica contiene un antígeno y a la hora de predecir con RCD+ este no se tiene en cuenta. Se analizará cómo afectan los mapas restricción a predicción de estructuras con y sin antígeno p más adelante en el apartado 4.7.

4.5.2 Resultados de los mapas de restricción de H2

H2 también se trata de un bucle pequeño, con generalmente 6 aminoácidos de longitud. En este caso, incluso sin mapa también los modelos están cerca de las estructuras nativas (0.62 Å), aunque se aprecia una ligera mejoría cuando se restringe con mapas (0.41 Å). El enriquecimiento obtenido cuando generamos los bucles con mapas, Tabla 22, al contrario que ocurría con H1, se traduce una mejoría en el siguiente paso refinamiento con Rosetta. Este enriquecimiento se observa a umbrales inferiores, con los mapas se obtienen 4 veces más bucles a <0.5 Å y duplica los bucles a <1 Å (65%).

Tabla 22. Enriquecimiento de RCD+ para H2 en CRR con y sin mapa de restricción.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
<i>Sin mapa</i>	0.728	3.01	31.46	62.98	76.46	82.50	87.09	22.66
<i>Con mapa</i>	0.436	14.18	65.65	85.54	89.79	92.13	95.87	22.57

Atendiendo a los resultados individuales tras el refinamiento en la Figura 38 se puede ver que la mayoría de las estructuras obtienen valores inferiores a 1 Å excepto en 6 casos. Entre estas excepciones, el empleo de mapas reduce el RMSD de 2.06 Å, 3.19 Å y 1.41 Å a 0.39 Å, 0.26 Å y 0.31 Å, los casos 1dlf, 1x9q y 2v17 respectivamente; en 3lmj y 3m8o no se aprecia variación siendo los dos peores casos con valores de RMSD 1.5 Å y 3 Å, respectivamente. Por otro lado, 4hpy es único caso en el que se aparecía un empeoramiento con el mapa.

En la Figura 39A, se muestra el caso con mayor mejora, 1x9q (8 residuos). En este caso la divergencia es notable de 3.35 Å a 0.26 Å sobre todo en la zona central. Para la Figura 39B, 3m8o, las predicciones con y sin mapa está muy alejadas de la nativa 3.8 Å. Se trata de una estructura muy singular, con una vuelta de hélice en la parte central del bucle. Curiosamente 4 de las 15 réplicas con mapa si se encuentra una estructura cercana a la nativa como resultado del Top10 (en torno a 0.4 Å), mientras que en el resto se obtienen valores cercanos a 4 Å. En el caso de las predicciones sin mapa, en ninguna de las réplicas se consigue bajar de 3 Å.

En la Figura 39C, 3hnt corresponde a un caso ilustrativo de un bucle de 6 residuos (el tamaño más frecuente en H2). Se puede ver como para el caso sin mapa se tiene una estructura bastante similar a la nativa, pero con una cierta separación en la zona central (0.57 Å) que queda completamente corregida con el uso de mapas (0.19 Å).




Figura 38. Resultados Top10 en H2 de CRR con (verde) y sin mapa (naranja).




Figura 39. Casos representativos de H2 Top10 con y sin mapas de restricción con RCD+ en CRR. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

En la Figura 39D, 4hpy, independientemente del uso del mapa, el modelo más cercano a la media es coincidente con la estructura nativa (0.3 Å). Cuando se usan las restricciones del mapa, en 12 de las 15 réplicas se obtienen bucles cercanos a los nativos (0.3 Å), pero en las tres restantes se obtiene bucles muy alejados 3.3 Å, de ahí la desviación de más de 1 Å observada en los valores medios de RMSD de la figura 25.

4.5.3 Resultados de los mapas de restricción de L1

L1 es el bucle CDR más largo y variable de la cadena L, entre 10 y 17 residuos, con una media de 12.39 aminoácidos en el conjunto. Al contrario que H3, este bucle es mucho más predecible, ya que sin mapa se obtiene 1.08 Å en el Top10 y con mapa se reduce a 0.37 Å. En los enriquecimientos de la Tabla 23 se puede ver que casi la mitad de los bucles están <1 Å de la nativa cuando utilizamos mapas, y sin mapa no llega ni al 1 % de estructuras. En cuanto a tiempo también se observa una pequeña mejora.

Tabla 23. Enriquecimiento de RCD+ para L1 en CRR con y sin mapa de restricción.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
<i>Sin mapa</i>	1.463	0.00	0.73	7.91	29.80	49.09	59.06	55.33
<i>Con mapa</i>	0.624	2.01	45.01	64.35	71.75	78.12	86.08	50.25

En la Figura 40 podemos analizar los casos individuales tras el refinamiento ordenados por tamaño. Se observan dos regiones claramente diferenciadas. En la primera región con bucles con 12 residuos o menos, en general, el empleo de mapas reduce el RMSD a valores inferiores a 0.3 Å, con la excepción de 4hpy (0.94 Å). Para bucles más largos, la aplicación de los mapas reduce considerablemente los valores de RMSD. Destacan por ejemplo los casos 3lmj, 3nps o 4f57, que bajan sus valores de 3.11 Å, 2.71 Å y 2.64 Å respectivamente a 0.36 Å, 0.28 Å y 0.27 Å. El único caso donde no hay mejora es 3gnm cuyo valor no baja de los 2 Å.

En la Figura 41A se muestra un ejemplo ilustrativo (1seq) de bucles cortos donde con y sin mapa coinciden con la solución nativa (0.19 Å). El bucle 2r8s de 11 residuos (Figura 41B) se tiene una pequeña desviación (0.61 Å) sin mapas mientras que con las restricciones de los mapas alcanza la estructura nativa (0.28 Å). En la Figura 41C, 3lmj de 13 residuos, se presenta la mayor mejora de 3.13 Å sin mapa a 0.36 Å con él, y en la Figura 41D, 3gnm de 16 residuos, es el único caso en el que los bucles predichos están a una distancia superior a 2 Å de la nativa. En la Figura 41E, 4f57 (14 residuos), es otro caso de mejora con mapa de 2.89 Å a 0.27 Å. Al igual que C, tienen una vuelta de hélice característica en la zona central. Curiosamente, el caso de mayor longitud (Figura 41F), 1nbl de 17 residuos, también se llega a conformaciones muy cercanas a la nativa (0.49) a pesar de su tamaño.




Figura 40. Resultados Top10 en L1 de CRR con (verde) y sin mapa (naranja). Se encuentra ordenados por tamaño creciente de izquierda a derecha (de 10 a 17 residuos).




Figura 41. Casos representativos de L1 Top10 con y sin mapas de restricción con RCD+ en CRR. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

4.5.4 Resultados de los mapas de restricción de L2

L2 es en media el bucle más corto de la cadena L, siendo mayoritariamente de 7 residuos de longitud, y al igual que en los casos anteriores se alcanza la estructura nativa 0.31 Å. La mejora ya se ver reflejada en el primer paso con los enriquecimientos de RCD+, Tabla 24. Se observa cómo sin mapas de restricción el bucle más cercano al nativo está a 1.3 Å; tan solo un 1% de los bucles a < 1 Å y menos de un cuarto del total de los seleccionados a < 3 Å. Tras aplicar los mapas, el bucle más próximo al nativo se reduce a 0.38 Å, con un 15% de los bucles generados < 0.5 Å, el 90% < 1 Å y se prácticamente el 100 % < 2 Å.

Tabla 24. Enriquecimiento de RCD+ para L2 en CRR con y sin mapa de restricción.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
Sin mapa	1.302	0.12	1.23	4.37	12.04	18.74	23.19	26.46
Con mapa	0.384	15.09	89.00	97.18	99.85	100.00	100.00	25.83

Atendiendo a los casos individuales tras el refinamiento, se puede ver en Figura 42, que hasta 23 estructuras tienen un valor superior a 1 Å sin el uso de mapas; y 7 de ellas incluso por encima de los 2 Å. Tras el empleo de los mapas solo 3 casos están por encima de 0.5 Å y tan solo 1 (1gig) supera por muy poco 1 Å (1.07 Å).




Figura 42. Resultados Top10 en L2 de CRR con (verde) y sin mapa (naranja).

En la Figura 43 se pueden observar los casos más representativos de este conjunto de referencia para L2. En la Figura 43A se muestra el único caso, 1gig, que la mejora con los mapas es reducida, de 1.27 Å a 1.07 Å, localizada cerca del anclaje N-Terminal. En la

Figura 43B se presenta el caso con mayor mejora, de 3.3 Å a 0.23 Å. En la Figura 43C se representa el caso de bucle 3i9g en el que ya sin mapa es coincidente con la estructura nativa (0.27 Å) y con mapa mantiene el resultado. Finalmente, el panel D, se presenta el caso de la proteína 2vxv, que, aunque mejora considerablemente de 3.24 Å a 0.98 Å, mantiene una desviación en el C-Terminal. Es interesante reseñar que las tres estructuras con peor RMSD (2vxv, 1gig, 3go1), coinciden en la misma desviación que se producen en esa zona C-terminal.




Figura 43. Casos representativos de L2 Top10 con y sin mapas de restricción con RCD+ en CRR. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

4.5.5 Resultados de los mapas de restricción de L3

A diferencia de los otros bucles CDR de la cadena L, sin mapa obtienen bucles muy cercanos al nativo (0.50 Å) y mejora ligeramente con mapas (0.42 Å). Recuérdese que el tamaño de este bucle estaba distribuido entre 8 y 12 residuos con un pico mayoritario en 9 (Figura 11). Al igual que en los CDRs anteriores el de enriquecimiento de RCD es evidente (Tabla 25) y en particular a umbrales bajos. También es interesante observar que al igual que con H3 al emplear los mapas hay una reducción del tiempo en la generación de los bucles.

Tabla 25. Enriquecimiento de RCD+ para L3 en CRR con y sin mapa de restricción.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
Sin mapa	0.838	0.00	1.00	15.00	45.67	59.50	87.50	46.75
Con mapa	0.727	4.48	45.25	65.49	75.14	82.23	87.17	36.13

En la Figura 44 se muestran los valores medios del Top10 con y sin mapa de restricción para L3 tras el refinamiento. Al usar los mapas específicos se puede observar que en todas las estructuras hay una ligera mejora, a excepción de 3hnt (9 residuos) que aumenta de 0.48 Å a 0.56 Å y 4hpy (11 residuos) que empeora de 1.16 Å a 1.46 Å. Por otro lado, destaca visiblemente la gran mejora en la estructura 3lmj (12 residuos) de 2.84 Å a 1.27 Å con el empleo de mapas.




Figura 44. Resultados Top10 en L3 de CRR con (verde) y sin mapa (naranja). Se encuentra ordenados por tamaño creciente de izquierda a derecha (de 8 y 12 residuos).

En la Figura 45A, en el caso 3g5y de 9 residuos, se observa una mejora de 0.35 Å a 0.82 Å curiosamente localizada en un par de residuos de la zona central del bucle. En

los paneles B y C se muestran las 2 únicas estructuras (3hnt y 4hpy) con mayor desviación respecto al bucle nativo cuando se utiliza el mapa. En el caso de 3hnt esta desviación es pequeña de 0.45 Å a 0.56 Å y apenas es significativa estructuralmente. En el caso de 4hpy, aunque casi la totalidad de la estructura del bucle es correcta, la desviación que ocurre en la zona central provoca que sea el caso con peor valor de RMSD tras emplear mapas. De forma opuesta, en 3lmj (Figura 45D), siendo el único bucle de 12 residuos del conjunto, se observa la mayor disminución de RMSD. Sin mapa se aprecia una predicción completamente distinta, pero con mapa se observa una desviación tan en un par de aminoácidos centrales.




Figura 45. Casos representativos de L3 Top10 con y sin mapas de restricción con RCD+ en CRR. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

4.5.6 Estudio del caso de 4hpy

La proteína 4hpy no ha obtenido buenos resultados en al menos 4 de los 6 CDRs. En la Tabla 26 se pueden ver resumidos los datos de RMSD Top10 para cada bucle CDR. Aumenta el valor de RMSD en los CDRs H1, H2 y L3 tras emplear mapas de restricción. En L1 y L2 tiene una mejora bastante buena, acorde con el resto de los casos en CRR. Y en H3, siendo un bucle de tamaño mediano, aunque si presenta una mejora aceptable, tan solo hay 2 casos con un valor final de RMSD superior en su grupo de tamaño.

Tabla 26. Valores de RMSD en la predicción del anticuerpo 4hpy del Top10 con y sin mapa de restricción para cada CDR.

4HPY	H1	H2	H3	L1	L2	L3
Tamaño	7	6	13	11	7	11
Sin mapa	1.35	0.30	1.66	1.98	1.03	1.16
Mapa	1.55	1.12	1.36	0.94	0.25	1.46

Una de las posibles causas es el efecto del antígeno en la estructura cristalografiada. Este anticuerpo se une a un fragmento de glicoproteína de la cubierta de VIH con secuencia KKQKVHALFYK (Liao et al., 2013), numerados del residuo K168 al K178. Destaca la presencia de aminoácidos con cadenas laterales con cargas positivas como 4 lisinas (K) o 1 histidina (H). También contiene 3 aminoácidos con elementos aromáticos como son la propia histidina, la tirosina (Y) y la fenilalanina (F). Según el estudio cristalográfico original 4 de los residuos son esenciales para la unión al anticuerpo: K169, H173, F176 y Y177. Al hacer un barrido de mutaciones de un solo punto en cada una de las posiciones por una alanina, estas 4 posiciones perdían completamente la unión al antígeno. Además, identificaron la presencia de puentes salinos y puentes de hidrogeno con el anticuerpo en estos residuos, y en Q170 y K171. En la Figura 46 se representan estos residuos clave junto a sus interacciones descritas.




Figura 46. Aminoácidos clave del antígeno en su interacción con el anticuerpo en la estructura 4hpy. Se muestran las cadenas laterales de los residuos clave del antígeno (cian), junto con los enlaces de puentes salinos y de hidrogeno a los bucles CDR: H1(rojo), H2 (amarillo), H3 (verde), L1 (magenta), L2 (azul oscuro) y L3 (naranja).

En la Figura 47 se representan como se localizan cada uno de los bucles CDR predichos por nuestro método con y sin mapa frente al bucle nativo y en relación con el antígeno. Mostrando también las cadenas laterales de los aminoácidos del bucle que interaccionan o se encuentran más próximos al antígeno.

H1 (Figura 47A), con secuencia GFTFDDG, es uno de los 2 bucles que peor salían en CRR y que además empeoraban un poco al emplear el mapa. La zona C-Terminal es la más cercana a antígeno. El lugar donde se produce la gran diferencia entre el bucle nativo y los predichos es en el segundo aminoácido de ácido aspártico (D), del cual se muestra la cadena lateral. El ácido aspártico es uno de los 2 aminoácidos con carga negativa a pH fisiológico y suele estar presentes en interacciones intermoleculares debido a su carga. Se encuentra localizado frente a uno de los residuos clave descritos en la unión del antígeno: la tirosina Y177. H1 Podría tomar tomaría una conformación estructural condicionada a su presencia puesto que en ambas predicciones lo vemos las alejado del antígeno.




Figura 47 Estructura de 4hpy junto a su antígeno en los 6 bucles CDR. Se muestra la posición de cada bucle nativo en gris junto al antígeno y una superficie semitransparente en azul del espacio que ocupa. Se muestra en verde los bucles generados con el mapa de restricción y en naranja sin el mapa, ambos sin haber tenido en cuenta la posición del antígeno.

H2 se predijo de forma correcta sin mapas y se tuvo ciertos problemas con los mapas. Este bucle tiene la secuencia SWNSNI, sin aminoácidos cargados. En este CDR el problema no parece consistir en un cambio de conformación, ya que la estructura nativa y la obtenida sin mapa coinciden. La conformación no es común puesto que con el mapa se acierta en 11 de las 15 réplicas mientras que en los 4 restantes obtenían valores superiores a 3 Å; aunque sin mapa se acierta siempre la conformación nativa (es lo que hace la diferencia en la media final). Esto queda confirmado al representar los ángulos diedros sobre los mapas de restricción específicos para bucles H2 de 8 aminoácidos (Figura 48). Los ángulos se encuentran en el límite de la distribución o completamente

fuera para todas las posiciones menos dos. Aun así, es interesante destacar que en las pocas ocasiones que, si se muestrea un bucle similar al nativo, el método es capaz de seleccionarlo y refinarlo correctamente.




Figura 48. Ángulos diedros de 4hpy (rojo) sobre los mapas de restricción para bucles H2 de 8 aminoácidos. El orden de las posiciones es de izquierda a derecha la fila superior y posteriormente de la misma forma la fila inferior.

En H3 tiene la secuencia AKDSPRGELPLNY con 13 aminoácidos y no destaca por haber hecho una mala predicción en CRR dentro de lo complicado que suele resultar este CDR, ya que sin mapa se obtiene una media de 1.63 Å y mejora ligeramente a 1.36 Å al usar mapas. En la Figura 47E podemos observar que se predice con gran precisión con ambas aproximaciones el *kink* y ácido aspártico (D) cerca del extremo N-Terminal, que interacciona con el residuo H173 de antígeno. Tan solo se desvía en el vértice del bucle, siendo lo más notorio la arginina (R) representada. Aunque el bucle nativo si parece ciertamente más cerca del antígeno, con las interacciones descritas no se puede terminar de justificar una interacción tan fuerte, y el error puede deberse a que el vértice tenga unos ángulos pocos comunes que ninguna de las aproximaciones cubre correctamente.

En la Figura 47B se representa a L1, con secuencia SGDALPKNYAY, donde el bucle tome forma de hélice. Sin el uso del mapa no se consigue predecir, obteniendo un valor medio de 1.98 Å. Con uso de mapas si se consigue recrear, quedándose a una distancia media de 0.94 Å. Este bucle tiene el mismo comportamiento que los casos analizados en el apartado 4.5.3 de 3lmj y 4f57, los cuales muestran una mejora en RMSD con unas hélices similares.

En L2, con secuencia EDSKRPS, sin mapa se desvía bastante y que tras usar mapa se consigue corregir. Mientras que sin mapa se falla en los dos residuos (ácido glutámico (E) y ácido aspártico (D)) con interacciones clave de puentes salinos con K169 y K171 del antígeno, con mapa se aciertan la conformación nativa hasta de las cadenas laterales. Este puede ser uno de los puntos de sujeción más estables que tenga el antígeno en este anticuerpo.

En L3 cuenta con la secuencia YSTDSSGNHRV. Es uno de los bucles más largos en CRR para este CDR, el que peor resultados obtiene tras usar los mapas y el único que empeora (pasa de 1.16 Å a 1.46 Å). En primer lugar, ambas aproximaciones predicen correctamente la tirosina de la zona N-terminal, clave en por su interacción con H173 del antígeno. En el apartado anterior (Figura 45C) se vio que el error se localizaba en el vértice del bucle, que no corresponden a aminoácidos muy grandes o cargados: 2 serinas (S) contiguas, una glicina (G) y una asparagina (N). En la Figura 47F, además vemos como las 2 serinas participan con puentes de hidrógenos en la interacción con Q170. Estos puentes pueden ser estabilizar el vértice del bucle en esta posición y que ambas predicciones, al no poderlos tener en cuenta generan predicciones oscilantes en esta región tan móvil.

4.6 Resultados de los mapas de restricción en CRTh.

CRTh es otro conjunto de validación que ha sido empleado como conjunto de evaluación. Tiene la particularidad de que las estructuras son más recientes y de usos terapéuticos. Se observa una bajada de los valores de RMSD consistente en todos los CDR como se puede apreciar en la Figura 49. En general se mantiene un comportamiento similar a lo visto previamente en CRR. En todos los CDRs menos en H3 se obtienen valores medios muy bajos: 0.5 Å, 0.52 Å, 0.59 Å, 0.41 Å y 0.78 Å en los Top1 de H1, H2, L1 y L2 y L3 respectivamente tras emplear los mapas. Reduciéndose hasta 0.34 Å, 0.39 Å, 0.42 Å, 0.41 Å y 0.56 Å si nos fijamos en el Top10. Las mayores mejoras ocurren en los bucles L1 y L2 que sin mapa obtuvieron de valores 1.71 Å y 1.33 Å en el Top1, y 1.12 Å y 1.04 Å en el Top10. En H3, aunque tiene valores de RMSD más altos, se obtienen también buenas mejoras: reduciendo el Top1 de 2.43 Å a 1.78 Å y el Top10 de 1.52 Å a

1.26 Å. Estos valores medios son más bajos que los que se observaron en CRR con mapa para el mismo CDR (2.03 Å en el Top1 y 1.29 Å en el Top10).




Figura 49. RMSD medio de RCD+ ejecutado con y sin mapa en todos los bucles CDR en CRTh.

4.6.1 Resultados en H3

En H3 se consigue reducir el RMSD de 2.43 Å a 1.78 Å en el Top1 y de 1.52 Å a 1.26 Å en el Top10 con la utilización de mapas. Para las estructuras 5kmv y 5ggq es inviable el uso de los mapas diseñados para H3 debido a su corta longitud (<7 residuos) y se ha empleado la predicción sin mapa. Los valores obtenidos son más bajos que para CRR al tener una longitud media más pequeña (12.0 frente a 12.8).

Se obtuvo un considerable en el enriquecimiento de RCD+ (Tabla 27), al igual que en al CRR. Destacando la reducción del valor mínimo de RMSD entre las estructuras generadas de 1.65 Å a 1.20 Å, el aumento de estructuras < 1 Å de menos de 0.05% a más de 1.5% o el aumento de estructuras < 2 Å de menos de 3% hasta un 24%. En cuanto al tiempo medio requerido para generar la misma cantidad de bucles cerrados se observa también una ligera mejoría al pasar de 73 a 58 segundos por caso.

Tabla 27. Enriquecimiento de RCD+ para H3 en CRTh con y sin mapa de restricción.

	Min RMSD	<0.5 Å	<1.0 Å	<1.5 Å	<2.0 Å	<2.5 Å	<3.0 Å	Tiempo (s)
Sin mapa	1.647	0.00	0.04	0.72	2.90	7.19	13.49	73.25
Con mapa	1.198	0.01	1.55	10.50	23.91	38.56	52.98	58.38

Los resultados individuales tras el refinamiento se muestran en la Figura 50. Al igual que para CRR, los organizamos en tres grupos por tamaño: < 12 residuos (21 estructuras), entre 12 y 15 residuos (27 estructuras) y > 15 residuos (5 estructuras).

Los bucles > 15 tienen todas las predicciones sin mapa por debajo de 4 Å. Sin embargo, tras el uso de mapas de restricción mejoran tan solo 3 de las 5 estructuras, dejando dos de ellas por debajo de los 2 Å. Pero empeoran de manera muy notable las: 3gkw pasa 3.75 Å a 4.92 Å; y 5y9k pasa de 3.44 Å a 4.16 Å.

Atendiendo a los bucles de 12-15 residuos encontramos un comportamiento similar a CRR con una mejora significativa. Encontramos 8 casos con valores superiores a 2 Å sin mapas, tras usar mapa 5 de ellos mejoran considerablemente, destacando 1yy8 (13 residuos) que baja de 2.25 Å a 0.66 Å. En los otros tres casos el uso de mapa es irrelevante: 1bey se mantiene sobre los 2 Å, 4i77 con una pequeña mejora de 2.52 Å a 2.35 Å y 4edw con un pequeño empeoramiento también alrededor de los 2 Å. Por otro lado, 3co8 (14 residuos) que empeora de 1.51 Å a 4.23 Å.




Figura 50. Resultados Top10 en H3 de CRTh con (verde) y sin mapa (naranja). Los anticuerpos están ordenados por tamaño del bucle CDR, desde 5 residuos en el 5kmv hasta 18 residuos en el 5ygu.

Para los bucles <12 10 de 19 estructuras obtienen predicciones superiores a 1 Å sin usar mapa, aunque dentro de esas 10, tan solo 2 por encima de 2 Å. Al usar mapas, en 6 de ellas se reduce significativamente su valor de RMSD. Destacando el caso 4mn6 (10 residuos) que mejora de 2.70 Å a 0.87 Å y 4mn6 (10 residuos) que mejora de 2.70 Å a 0.87 Å. En cuanto a los casos negativos encontramos 3 (3u0t, 4ypg y 5tru) que tenían

RMSD altos sin mapa y que con mapas se alejan un poco más. 5vkk (9 residuos), que tiene el mayor empeoramiento del grupo, al pasar de 0.68 Å a 1.19 Å.

En la Figura 51 se muestran las características estructurales de alguno de los casos más destacados mencionados anteriormente. De igual manera que para el CRR, a la hora de realizar estas figuras si ha escogido el bucle más cercano al valor medio representado en la gráfica dentro de sus 15 réplicas.

El caso 4m6n de 10 residuos (Figura 51A) es la estructura que presenta la mayor mejora del conjunto: de 2.73 Å a 0.69 Å. Hay que destacar que con mapa se observa varianza en sus valores de RMSD entre las diferentes replicas, aunque siempre sale mejor que sin mapa: sin mapa todos los valores se encuentran entre 2 y 3 Å, mientras que con mapa hay 3 casos en torno a 1.8 Å, 1 caso en 1.4 Å y el resto entre 0.5 Å y 0.8 Å. Esto indica que hay al menos dos distribuciones conformacionales. El caso 1yy8 de 13 residuos (Figura 51B) es otro ejemplo de gran mejora, esta vez en el grupo de entre 12 y 15 residuos, pasando de 2.09 Å a 0.67 Å. En este caso apenas hay variación en las predicciones con mapa, pero si la encontramos sin mapa: donde se observan distribuciones cercanas a la nativa (1/15) junto a otras muy alejadas (5-6.56 Å).

El caso 4ypg de 9 residuos (Figura 51C) se trata de un bucle > 12 residuos en que tanto sin mapa (2.75 Å) como con mapa (2.51 Å) se desvía en la región central, donde el bucle nativo muestra una zona retorcida que las predicciones no registran, elevado los valores RMSD. Este error aparenta originarse desde la zona N-Terminal, donde el bucle se desvía impidiendo realizar el giro nativo en la zona central. En este caso, el antígeno podría ser el causante de tomar una conformación más forzada en la zona central, que la predicción sin la presencia de este no priorice la solución cristalográfica al encontrar otras conformaciones con menor energía.

El caso más crítico de CRTh corresponde a 3co0 de 14 residuos (Figura 51D), la predicción con mapa obtiene un valor de RMSD de 4.18 Å y sin mapa de 1.55 Å. La estructura nativa mantiene una estructura secundaria de lámina alejada de una estructura *kink*. El caso 5i5k de 15 residuos (Figura 51E) es un caso ilustrativo de mejora en bucles largos al pasar de 3.67 Å sin mapa a 1.62 Å con mapa. Sin mapa vuelve a tratarse de resultados muy variables y con mapa, al restringirse correctamente el *kink* en ambos extremos, predice la zona central de forma más próxima a la nativa. El caso

3gkw de 16 residuos (Figura 51F) expone un caso de bucles >15 residuos que empeora con el uso de mapa de 3.75 Å a 5.45 Å, de forma similar a la figura D pero para un bucle más largo. En esta ocasión nos encontramos con una estructura secundaria de tipo lamina en la zona N-Terminal del bucle y otra de tipo hélice en la zona C-Terminal (no *kink*). Ambas predicciones aciertan en la zona N-Terminal, pero la predicción con mapa erra en la zona C-terminal al intentar forzar el kink y desviarse considerablemente. También hay que puntualizar que, aunque sin mapa no se llega a separar tanto, tampoco se consigue predecir la estructura de la hélice, aunque tome un recorrido más cercano.




Figura 51. Casos representativos de H3 Top10 con y sin mapas de restricción con RCD en CRTh. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

Por último, en la Figura 52 está representado el caso de 5kmv de 5 residuos. Se ha predicho únicamente sin mapa de restricción con un valor de RMSD de 0.21 Å. Como se ha expuesto anteriormente, al ser un bucle tan pequeño no tiene espacio suficiente para poder contener el kink. También al ser tan pequeño su espacio conformacional es muy reducido y el método original sin mapas consigue resultados muy precisos.




Figura 52. Bucle H1 Top10 de 5kmv sin mapa de restricción (naranja).

4.6.2 Resultados en H1

Al igual que con CRR, no hay diferencia de predicción con mapa que sin mapa, aunque si se encontró mejora en el enriquecimiento de RCD+ (Tabla 28).

Tabla 28. Enriquecimiento de RCD+ para H1 en CRTh con y sin mapa de restricción.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
<i>Sin mapa</i>	0.703	0.17	21.97	72.36	86.14	91.29	94.87	45.00
<i>Con mapa</i>	0.590	1.96	51.65	82.48	91.67	96.21	98.03	41.37

El valor medio del bucle de menor RMSD disminuye más de 1 decima de Å. Aunque se aumenta el número de estructuras generadas < 1 Å a más del doble, desde 22 % sin mapa hasta 52% con mapa o se incrementa más de 10 veces las estructuras < 0.5 Å al aumentar desde 0.17% a 1.96% tras emplear mapas; como podemos observar en la Figura 53, la mayoría de los casos tras el refinamiento tienen un valor sin mapa ya inferior a 0.5 Å. Dentro de estas estructuras, no hay variaciones importantes al emplear el mapa. A excepción de 4edw que obtiene una mejora desde 0.46 Å a 0.27 Å tras usar los mapas o 1bey que empeora desde 0.65 Å a 0.84 Å. Los únicos casos con valores superiores a 1 Å (3eo0, 3uot y 4nd3), consiguen mejorar desde 1.06 Å, 1.75 Å y 1.28 Å a 0.64 Å, 0.91 Å y 0.96 Å respectivamente.




Figura 53. Resultados Top10 en H1 de CRTh con (verde) y sin mapa (naranja).

Aunque H1 son bucles mayoritariamente de 7 aminoácidos, hay presente una estructura de 8 residuos (4x7s) que se mantiene en valores de 0.5 Å, y 5 estructuras con 9 residuos: 2hwz, 3b2u, 3qwo, 4g6k y 5sx5. De estos casos, las 4 primeras estructuras comienzan con valores inferiores a 0.5 Å y se mantienen, destacando la pequeña mejora de 4g6k que pasa de 0.35 Å a 0.26 Å; y 5sx5 se mantiene en torno a 0.90 Å. Estos resultados validan el empleo de mapas con longitudes menos estándares.

En la Figura 54 se representan 4 casos representativos de este conjunto. El caso 1bey de 7 residuos (Figura 54A) es el único que sufre un empeoramiento en todo el conjunto de referencia al pasar de 0.63 Å sin mapa a 0.83 Å con mapa. Sin embargo, a simple vista es difícil percibir donde se produce esa diferencia. En el caso 1cz8 de 7 residuos (Figura 54B) llega a la estructura nativa con y sin mapa con valores de 0.14 Å.

Por otro lado, 3u0t de 7 residuos (Figura 54C) es el peor resultado sin mapa y a su vez la mayor mejora registrada en el conjunto: de 1.86 Å a 0.80 Å. Sin mapa toma una conformación completamente diferente y con mapa se puede ver cómo se corrige excepto en un aminoácido que se separa levemente. Este es el mismo error que se observó en varias estructuras en CRR.

Por último, en la Figura 54D se representa 5sx4 de 9 residuos que obtiene resultados similares tanto con restricción como si ella (0.94 Å y 0.87 Å respectivamente). En ambos casos se puede ver cómo se desvían en el mismo punto cerca ambos anclajes

y luego oscilan alrededor de la estructura nativa sin llegar a coincidir con ella, pero sin alejarse tampoco.




Figura 54. Casos representativos de H1 Top10 con y sin mapas de restricción con RCD en CRTh. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

4.6.3 Resultados en H2

En este conjunto de referencia, H2 mantiene un comportamiento similar mostrado en CRR: obtienen una mejora constante al reducir el RMSD medio del Top10 de 0.60 Å sin mapa a 0.39 Å con mapas. Esta mejora viene apoyada por un mayor enriquecimiento de RCD con el empleo de mapas como se puede observar en la Tabla 29. Destaca el aumento de los umbrales más pequeños: donde se mejora de 7.66% a

19.54% de estructuras seleccionadas $< 0.5 \text{ \AA}$; e incrementa en hasta un 28% alcanzando casi los 70% por debajo de $1 \text{ \AA}$.

Tabla 29. Enriquecimiento de RCD+ para H2 en CRTh con y sin mapa de restricción.

	<i>Min RMSD</i>	$<0.5 \text{ \AA}$	$<1.0 \text{ \AA}$	$<1.5 \text{ \AA}$	$<2.0 \text{ \AA}$	$<2.5 \text{ \AA}$	$<3.0 \text{ \AA}$	<i>Tiempo (s)</i>
Sin mapa	0.582	7.66	41.96	79.03	89.43	92.92	95.15	26.10
Con mapa	0.408	19.54	69.92	95.83	98.03	99.46	99.92	25.50

Como se puede apreciar en la Figura 55, únicamente 6 casos tienen un valor superior a $1 \text{ \AA}$ al realizar la predicción sin mapas. Con el empleo de mapas se observa una mejora significativa en aquellos casos con RMSDs más altos. Destacando 4cni y 5vhe que mejoran su RMSD de Top10 desde $2.52 \text{ \AA}$ y $4.19 \text{ \AA}$ a $0.19 \text{ \AA}$ y $0.71 \text{ \AA}$ respectivamente. Tan solo 4ojf permanece por encima de este valor al usar mapas: bajando de $1.76 \text{ \AA}$ a $1.44 \text{ \AA}$. Entre las estructuras con predicción acertada sin mapa, únicamente aparece una estructura que le perjudica el uso del mapa (5i5k), que aumenta de $0.33 \text{ \AA}$ a $0.71 \text{ \AA}$.




Figura 55. Resultados Top10 en H2 de CRTh con (verde) y sin mapa (naranja).

En cuanto a las longitudes, predominan los bucles de 6 residuos, aunque también los hay presentes de 5 y 8 residuos. Los casos de 5 residuos tienen valores muy cercanos al nativo sin mapa. En los casos de 8 residuos la mejora es muy notable, incluso en los que han obtenido peores resultados sin mapas (1bey, 4cni y 5vh3). Esto indica que la estructura 4hpy, que daba problemas en CRR para este CDR y que se analizó en el apartado 4.5.6, es un caso excepcional.

En la Figura 56A se muestra el caso 2hwz de 5 residuos donde las predicciones con y sin mapa divergen tan solo $0.1 \text{ \AA}$ de la nativa. En cambio, 4ojf de 6 residuos (Figura

56C), es el único caso con el valor de RMSD por encima de 1 Å, consiguiendo bajar de 1.77 Å a 1.09 Å. En la imagen se aprecia como hay un par de residuos que se desplazan y no llegan a la conformación nativa.

Los casos de 4nci y de 5vh3, ambos de 8 residuos, son las dos mayores mejoras del conjunto: reduciendo de 2.53 Å y 4.80 Å a 0.19 Å y 0.79 Å respectivamente. En el primero (Figura 56B) se mejora más de 2 Å, pasando de error completamente el camino tras el anclaje C-Terminal a acertar la conformación nativa. En el segundo (Figura 56D), siendo la mayor mejora en valor absoluto, llegar a una conformación muy cercana a la nativa con unas desviaciones pequeñas en los residuos centrales.




Figura 56. Casos representativos de H2 Top10 con y sin mapas de restricción con RCD en CRTh. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

4.6.4 Resultados en L1

Para L1, el valor medio de RMSD se reduce de 1.12 Å sin mapa a 0.42 Å obtenido con mapa. Esta gran mejora en la predicción se ve reflejada en el enriquecimiento de RCD+ (Tabla 30). Sin mapa, el valor medio del bucle generado más cercano se encuentra a 1.4 Å de distancia. Se consigue reducir hasta 0.63 Å tras aplicar los mapas de restricción. El porcentaje de estructuras inferiores a 1 Å aumenta de 1.16% sin mapas hasta 40.8 % con mapas; o inferiores a 2 Å aumenta de un 21.08 % hasta un 79.58%.

Tabla 30. Enriquecimiento de RCD+ para L1 en CRTh con y sin mapa de restricción.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
Sin mapa	1.405	0.00	1.16	9.54	29.08	48.54	60.90	100.19
Con mapa	0.627	1.97	40.80	66.44	79.58	86.79	92.33	76.37

En CRR se pudo distinguir dos regiones separadas de bucles donde el límite eran los 13 residuos. Los bucles cortos obtenían buenos resultados sin mapas e incluso mantenían una mejora constante y significativa. Por otra parte, los bucles largos obtenían resultados alejados sin mapa, pero con mapa se obtenían mejoras todas las estructuras y la mayoría conseguían valores muy cercanos en RMSD a la nativa. Como se observa en la Figura 57, CRTh mantiene el mismo comportamiento.




Figura 57. Resultados Top10 en L1 de CRTh con (verde) y sin mapa (naranja). Se encuentra ordenados por tamaño creciente de izquierda a derecha (de 10 a 17 residuos).

En el grupo de bucles ≤ 12 residuos todos los casos menos 5l6y de 11 residuos (Figura 58B) obtienen valores de RMSD inferiores a 1 Å en la predicción sin mapa. Tras usar los mapas se obtienen valores mejores en prácticamente todas las estructuras,

incluso 5l6y baja de 2.14 Å a 0.62 Å. La única excepción sería 1bey de 11 residuos que empeora de 0.81 Å a 0.99 Å tras usar los mapas. Tanto con mapa como sin mapa (Figura 58A), hay una región de 2 aminoácidos de longitud en la zona superior izquierda de la imagen que se desvía de la nativa, siendo el desvío mayor con mapa.




Figura 58. Casos representativos de L1 Top10 con y sin mapas de restricción con RCD en CRTh. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

En el grupo de bucles > 12, todos los casos obtienen valores superiores o alrededor de 2 Å sin mapas y mejora de forma muy notable al emplear mapa. Únicamente queda por encima de 1 Å el caso de 5n2k de 13 residuos (Figura 58C). Se trata de un caso con gran varianza de resultados en las 15 réplicas con mapa: en 5 casos se obtuvieron valores inferiores a 0.33 Å, en otros 3 valores entre 0.7 Å y 1 Å y en los 7 restantes valores en torno a 3.3 Å; indicando diferentes conformaciones o mínimos

locales. Por otro lado, en las predicciones sin mapa todo fueron valores superiores a los 2 Å. Esto expone que es una conformación muy complicada de muestrear, prácticamente inaccesible sin restricción, y cuando hay restricción solo se muestrea en 5/15 ocasiones. Por otro lado, es interesante destacar que la conformación que toma este bucle de 13 residuos es similar a las encontradas para 13 y 14 residuos en las imágenes B) y C) de la Figura 41 en CRR. Otro caso notable es 3o2d de 17 residuos (Figura 58D) que mejora de 3.14 Å sin mapa a 0.28 con mapa. Resaltando el valor tan bajo de RMSD para un bucle tan largo, y de igual forma tomando una conformación similar a los casos acertado D) y F) de la Figura 41.

4.6.5 Resultados en L2

L2 tiene una longitud de 7 residuos en todos los casos de ambos conjuntos de referencia. Aun siendo bucle de pequeño tamaño, presentaba ciertos problemas para predecirse sin mapa en CRR. Pero tras aplicar las restricciones conseguía corregirse en gran medida y obtener resultados muy buenos. En CRTh se obtienen un resultado muy similar: sin mapa, la media de RMSD alcanza los 1.04 Å en el Top10 y consigue reducirse hasta 0.33 Å tras aplicarse los mapas.

Esta mejora se ve reflejada también en los valores de enriquecimiento de RCD+ de la Tabla 31. El RMSD medio del bucle generado más cercano al nativo es de 1.23 Å sin mapa hasta los 0.42 Å con mapa. Prácticamente el 100% de las seleccionadas está por debajo de los 2 Å con mapa cuando sin mapa solo se obtenía el 18.72% o incluso un 31.69% por debajo de los 3 Å. En el umbral de bucles < 1 Å aumenta de tan solo un 1.02 % hasta un 90.29%.

Tabla 31. Enriquecimiento de RCD+ para L2 en CRTh con y sin mapa de restricción.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
<i>Sin mapa</i>	1.230	0.02	1.02	6.73	18.72	27.78	31.69	26.44
<i>Con mapa</i>	0.421	16.11	90.29	95.26	99.92	100.00	100.00	26.35

En la Figura 59 se puede comprobar como en la mayoría de los casos se produce una mejora visible, exceptuando en dos. El caso de 1cz8 (Figura 60A) corresponde a la mejora más significativa, de 3.25 Å a 0.29 Å, en la que sin mapa toma una dirección completamente desviada y con mucha varianza (casos con valores superiores a 4 Å) y con mapa se ajusta a la nativa en todas las réplicas.




Figura 59. Resultados Top10 en L2 de CRTh con (verde) y sin mapa (naranja).

El caso de 4o02 (Figura 60C) tiene el segundo peor valor de predicción sin mapa y se mejora con el mapa, de 2.73 Å a 0.86 Å. La predicción con mapa se desvía exclusivamente en el primer aminoácido de la parte inferior (C-Terminal), a diferencia de la predicción sin mapa que se desvía más en esa región y además también en la parte superior (N-Terminal).

Por el contrario, 4d9q (Figura 60B), es el único caso que empeora significativamente, de 0.24 Å a 1.04 Å (tanto de CRTh como de CRR para este CDR si nos fijamos en los resultados del apartado 4.5.4). Viendo el resto de las estructuras representadas parece que el mapa tiene a forzar una conformación más común y evita la nativa que sin mapa si encuentra.

Por último, 4od2 (Figura 60D) no mejora al poner restricciones quedándose como uno de los más alejados: 0.86 Å. Ambas predicciones fallan ligeramente en la parte superior (N-Terminal), donde encontramos que la estructura nativa no gira como en las imágenes A o C.




Figura 60. Casos representativos de L2 Top10 con y sin mapas de restricción con RCD en CRTh. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

4.6.6 Resultados en L3

En CRR ya se obtenían buenos resultados sin mapa, con una media de RMSD del Top10 de 0.5 Å y de 0.42 Å con mapa. En CRTh se obtienen valores similares de RMSD sin mapa para el Top10 de 0.62 y con mapas se consigue bajar a 0.56 Å.

En el enriquecimiento de RCD+, mostrado en la Tabla 32, se observa: una reducción notable en el bucle con menor RMSD generado; la aparición de un 3.86% de estructuras por debajo de 0.5 Å con mapas cuando sin mapas no había ningún caso; o la mejora de tan solo 2.77% de estructuras por debajo de 1 Å sin mapas a 46.13% con mapas. También se mantiene la mejora en el tiempo medio necesario para cerrar los bucles.

Tabla 32. Enriquecimiento de RCD+ para L3 en CRTh con y sin mapa de restricción.

	<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
<i>Sin mapa</i>	0.945	0.00	2.77	31.37	60.78	75.44	83.10	49.14
<i>Con mapa</i>	0.623	3.86	46.13	71.46	82.71	89.11	93.47	27.83

Hasta 7 estructuras tiene un valor superior a 1 Å en la predicción sin mapa (Figura 61). De ellas, 4o02 (9 residuos), 4ypg (9 residuos) y 5i5k (9 residuos) obtienen un resultado muy parecido con mapa: 1.40 Å, 1.73 Å y 1.80 Å respectivamente; 3co8 (9 residuos) mejora ligeramente de 1.32 Å sin mapa a 1.19 Å con mapa; 4irz (8 residuos) y 5nhw (11 residuos) obtienen una mejora más significativa, al reducir desde 1.09 Å y 1.87 Å sin mapa a 0.45 Å y 1.09 Å respectivamente; y 5n2k (12 residuos) empeora considerablemente al aumentar su resultado medio de 1.40 Å sin mapa a 1.84 Å con mapa. En el resto hay varios casos con una mejora visible como son 3o2d, 3b2u o 4ojf. Podemos observar que muchos de ellos apenas presentan variación entre la predicción con mapas y sin mapa, algunos con ligeras mejoras, pero hasta 6 casos con empeoramientos pequeños de valores en torno a 0.05 Å. Por el contrario, el caso de 4m6n (11 residuos), aunque comienza con valores medios sin mapa de 0.62 Å, empeora considerablemente al usar mapas hasta los 1.39 Å.




Figura 61. Resultados Top10 en L3 de CRTh con (verde) y sin mapa (naranja). Se encuentra ordenados por tamaño creciente de izquierda a derecha (de 7 y 12 residuos).

En CRTh los resultados son algo más variados frente a los obtenidos en CRR. Presentan un resultado ligeramente más alto en valores absolutos de RMSD, pero sigue

mostrando una mejora general. Al contrario que en CRR, CRTh ha casos de ≤ 9 residuos con valores altos sin mapa y que no se consiguen mejorar.

Los tamaños complicados por poca representación muestral a la hora de hacer los mapas son 11, 12 y 13 residuos como se expuso en el subapartado 3.6.5. Tanto en CRR como en CRTh presentan un comportamiento algo variable, donde de media empiezan con valores de RMSD más altos que los bucles de menor tamaño y tras el empleo de mapas hay tanto casos en los que se mejora de forma destacada (5nhw baja de 1.90 Å a 1.20 Å), casos que no varían o casos que empeoran (4m6n sube de 0.62 Å a 1.40 Å).




Figura 62. Casos representativos de L3 Top10 con y sin mapas de restricción con RCD en CRTh. Se representa la estructura nativa (gris) junto a un caso representativo del Top10 obtenido con mapas de restricción (verde) y sin mapa (naranja).

En la Figura 62A, 4irz, se muestra un caso de mejora para bucles de 8 residuos de 1.03 Å a 0.46 Å. En el que se corrige la pequeña desviación de la zona central del bucle. Es interesante destacar que esta estructura fue cristalografiada con antígeno y a diferencia de otras vistas anteriormente este no parece perjudicar la predicción con el uso de mapas.

En Figura 62B, 3eo0 de 9 residuos, se muestra el caso con mejor resultado tanto con mapa como sin él (0.18 Å). También con 9 residuos se muestra en Figura 62C el caso 4ojf, que corresponde a un acercamiento a la conformación nativa de 1.05 Å a 0.32 Å. Con mapa es una predicción muy regular, mientras que sin mapa la mitad de las réplicas corresponde a la conformación nativa y la otra mitad tiene valores superiores a 1 Å. En la Figura 62D, 5i5k, se representa el peor resultado para un caso de la misma longitud. Tanto sin mapa como con mapa hay una desviación localizada en dos residuos (1.81 Å).

5nhw de 11 residuos (Figura 62E) ilustra un caso de gran mejora para bucles más largos, pasando de 1.95 Å a 1.19 Å. Es un bucle que sin restricción tiene varianza y solo consigue muestrear la conformación nativa sin mapa en 2 de las 15 réplicas con valores inferiores a 1 Å. Con mapa se corrige la zona central del bucle de forma constante, pero se desvía sistemáticamente de la nativa cerca del anclaje C-Terminal.

El caso 5n2k de 12 residuos (Figura 62F) empeora de 1.41 Å a 1.87 Å. Tanto con mapa como sin mapa tienen con mucha varianza. Toman una conformación similar a la nativa cerca de los anclajes, sin embargo, ambas se desvían en el mismo punto.

4.6.7 Comparación de H1 entre 3nps y 4dn3

En CRR se encontró una única estructura en H1 que obtenía resultados mucho peores al usar mapas de restricción (3nps) y que tenía un comportamiento muy diferente al resto de estructuras del conjunto (Figura 36). En CRTh, sin embargo, no se encontró una estructura que tuviera y comportamiento similar. Con la intención de intentar comprender mejor porque ese caso no funciona y cuáles son las posibles debilidades de los mapas H1 se buscaron similitudes con el resto de H1. Se encontró que 4dn3, en CRTh, tiene exactamente la misma secuencia para este CDR: GGTFSSY. Esta estructura también coincide con el peor valor absoluto tras usar mapas para este

conjunto, pero, al contrario que en 3nps, se obtienen mejoras al usar mapas y valores más cercanos al nativo.

Al analizar el bucle nativo de ambas estructuras (Figura 63) se observa una diferencia conformacional que toma la misma secuencia. En la perspectiva frontal vemos como la mitad izquierda (Nt) no asciende tanto para la estructura de 3nps mientras que en 4dn3 sube para en la zona central bajar y volver a subir. En la perspectiva cenital se observa como 4dn3 serpentea, pero se queda más cerca del plano que une ambos anclajes, mientras que 3nps se separa nada más salir del anclaje N-terminal para luego ir más líneal de vuelta. Por último, en la perspectiva lateral, vemos como confluyen las vistas anteriores y nos permite entender como 3nps hace primero un giro hacia la izquierda para luego ascender y bajar en el anclaje C-Terminal y 4dn3 toma una conformación más retorcida, pero se mantiene más en un mismo plano. Atendiendo a los anclajes encontramos que tienen diferente orientación ya de partida, en especial el del extremo N-Terminal: mientras que para 3nps dirige el comienzo del bucle hacia el interior en 4nd3 comienza apuntando hacia el exterior. Además, difieren en la distancia entre ellos mientras que para 3nps es de 14.60 Å, para 4nd3 son 12.50 Å.




Figura 63. Estructura nativa de H1 para los bucles 3nps (A) y 4dn3 (B) en 3 orientaciones: frontal, cenital y lateral ordenadas de arriba a abajo. En beige los átomos de los anclajes, en gris los carbonos y en azul los nitrógenos. El extremo N-T a la izquierda y el C-t a la derecha. En rojo marcada la línea recta entre el ultimo átomo de cada aminoácido de anclaje y la distancia que los separa.

En la Figura 64 se muestra de la misma forma que antes, pero con los bucles predichos tras emplear mapas de restricción. En esta ocasión podemos comprobar como para 4dn3 (B) se obtienen imágenes parecidas a la estructura nativa con ligeras variaciones en alguna de las posiciones. Para 3nps (A) mientras que en la vista frontal toma un perfil similar, en las vistas lateral y cenital se observan grandes diferencias (véase también la Figura 37C).




Figura 64. Estructura predicha con mapas de restricción de H1 para los bucles 3nps (A) y 4dn3 (B) en 3 orientaciones: frontal, cenital y lateral ordenadas de arriba a abajo. En beige los átomos de los anclajes, en verde los carbonos y en azul los nitrógenos. El extremo N-T a la izquierda y el C-t a la derecha. En rojo marcada la línea recta entre el ultimo átomo de cada aminoácido de anclaje y la distancia que los separa.

Otra diferencia de comportamiento es la que queda reflejada en la Tabla 33: se muestra los resultados de enriquecimiento de RCD+ para cada caso con y sin mapa antes del refinamiento con PyRosetta. Para H1, como se ha explicado anteriormente se generan 20.000 estructuras con RCD y se seleccionan las 200 de menor energía de Korp. Sin mapa, el menor RMSD de las 200 seleccionadas es una décima mejor en 4dn3 que en 3nps y se observan mayores porcentajes de estructuras seleccionadas por debajo de los umbrales pequeños. Al aplicar mapas, para 4dn3 se incrementa el porcentaje de estructuras más cercanas a la nativa, mientras que para 3nps ocurre lo contrario.

Tabla 33. Comparación del enriquecimiento de RCD+ con y sin mapa de restricción para 3nps y 4dn3. Se muestra el valor mínimo de RMSD y el porcentaje de estructuras por debajo de cada umbral del total de las seleccionadas por KORP antes del refinamiento (200). También se muestra el tiempo en segundos empleado para la generación de todas las estructuras de RCD (20.000).

		<i>Min RMSD</i>	<i><0.5 Å</i>	<i><1.0 Å</i>	<i><1.5 Å</i>	<i><2.0 Å</i>	<i><2.5 Å</i>	<i><3.0 Å</i>	<i>Tiempo (s)</i>
3nps	Sin mapa	0.936	0.00	0.83	9.17	31.00	62.50	97.17	26.80
	Con mapa	1.252	0.00	0.00	2.67	12.17	49.67	98.67	27.12
4dn3	Sin mapa	0.838	0.00	1.00	15.00	45.67	59.50	87.50	46.75
	Con mapa	0.791	0.00	2.00	30.50	83.67	94.00	99.00	38.68

Por otro lado, es interesante ver que para la misma secuencia los tiempos son también diferentes. Para 3nps es hasta 20 segundos más rápido realizar los 20.000 bucles cerrados sin mapas que para 4dn3. Sin embargo, el uso de mapas sienta de forma contraria: a 3nps los empeora un poco, aunque sigue siendo más rápido y 4dn3 mejora hasta 8 segundos.

Para comprobar cómo afectan las restricciones a cada uno de los bucles, en la Figura 65 se representan los mapas empleados junto a la pareja de ángulos diedros en cada posición en amarillo para 3nps y en rojo para 4nds. Como era de esperar, ambos casos corresponden a valores fuera de las regiones más pobladas en casi todas las posiciones para los mapas de longitud 7 de H1 (longitud mayoritaria). Lo que justificaría que sean los 2 peores casos cuando se les aplican la restricción.




Figura 65. Ángulos diedros de 3nps (amarillo) y 4dn3 (rojo) sobre los mapas de restricción para cada posición de bucles H1 de 7 residuos.

En la Figura 66 se puede observar como ante una misma orientación el resto de los CDRs de 3nps son más grandes y provocan que H1 esté restringido espacialmente en comparación con 4dn3.




Figura 66. Representación del bucle H1 de 3nps y 4dn3 junto con el resto del anticuerpo. En verde el bucle predicho, en amarillo el bucle nativo y en gris el resto del anticuerpo.

Mientras que 3nps está cristalografiada con antígeno, 4dn3 no lo tiene presente en su estructura resuelta. Por lo que finalmente se decidió analizar como interacciona el antígeno con el H1 de 3nps y si su presencia puede afectar. El antígeno es un fragmento proteico perteneciente a la enzima transmembrana “*membrane-type serine protease*” (MT-SP1). En la Figura 67 se representan el espacio ocupado por el antígeno junto al bucle H1 nativo y el predicho. Aunque la zona de interacción esta es la opuesta a la zona N-t más desviada en nuestra predicción, en esta zona C-t se aprecia una incompatibilidad espacial con el antígeno. En concreto las dos serinas (superficie verde) potencialmente ocupan el mismo espacio que la fenilalanina del antígeno (superficie cian).

En resumen, es bastante probable que el bucle H1 de 3nps sufra alguna variación de conformación por la presencia del antígeno. además, el empleo de mapas de restricción es contraproducente en este caso porque los valores de los diedros tienen muy baja o nula probabilidad en los mapas generados.




Figura 67. Interacción entre el bucle H1 de 3nps nativo (gris), predicho (verde) y el antígeno (azul). El antígeno se muestra siempre con la cadena lateral del aminoácido más cercano (fenilalanina). Los paneles superiores muestran las cadenas principales y los inferiores incorporan las superficies del antígeno y del bucle predicho junto con las cadenas laterales de sus 2 serinas.

4.7 Presencia de antígeno vs ausencia

Se ha observado que algunos de los errores en las predicciones coinciden con casos en los que la estructura de anticuerpo fue resuelta en presencia del antígeno (como 4hpy analizado en la Figura 47 o 3nps analizado en la Figura 67). Esta coincidencia nos hace plantearnos cómo afecta la presencia del antígeno a las conformaciones de los anticuerpos que hemos tomado como referencia en nuestros conjuntos de prueba. Para investigar esto, hemos agrupado ambos conjuntos (CRR y CRRH) y los hemos clasificado por la presencia de antígeno (A+) o ausencia de antígeno (A-) con un total de 45 y 59 estructuras, respectivamente. La Tabla 34 muestra que el tamaño medio de cada bucle

CDR es muy similar entre los dos grupos, por lo que no se esperan sesgos debidos al tamaño de los bucles.

Tabla 34. Tamaño medio de cada CDR para los subgrupos con ligando (A+) y sin ligando (A-) de las estructuras de ambos conjuntos de referencia.

	<i>Nº Estructuras</i>	<i>Tamaño H1</i>	<i>Tamaño H2</i>	<i>Tamaño H3</i>	<i>Tamaño L1</i>	<i>Tamaño L2</i>	<i>Tamaño L3</i>
A+	45	7.20	6.00	12.48	12.34	7.00	9.36
A-	59	7.09	6.07	12.29	12.31	7.00	9.22

En la Tabla 35 se presentan los resultados obtenidos para cada tipo de CDR en función de la presencia del antígeno. Como se puede observar, la presencia o ausencia del antígeno no parece afectar significativamente la media de las predicciones. Aunque H1 o L3 obtienen valores más bajos en los casos sin antígeno, las estructuras predichas son prácticamente indistinguibles de las nativas en ambos grupos.

Tabla 35. Resultados en función de la presencia de antígeno en la estructura cristalográfica. Comparación y cálculo de la mejora resultante de usar mapas de restricción en cada grupo en cada CDR para las métricas Top1 y Top10.

		Top1					
		H1	H2	H3	L1	L2	L3
A+		0.54	0.53	1.96	0.53	0.40	0.82
A-		0.39	0.57	1.86	0.54	0.39	0.68
		Top10					
		H1	H2	H3	L1	L2	L3
A+		0.41	0.38	1.27	0.39	0.33	0.56
A-		0.29	0.41	1.28	0.40	0.33	0.48

4.8 Resultados comparativos con otros métodos

4.8.1 Casos descartados

Para obtener un conjunto comparable y aplicable a todos los métodos se han descartado aquellas estructuras con discontinuidades en algún CDR; que algún método es incapaz de predecir; o en las que el RMSD de las zonas de anclaje es superior a 0.5 Å entre la estructura cristalográfica y los modelos en la mayoría de los métodos.

Al aplicar el protocolo explicado en el apartado 3.7.7, para obtener el RMSD de bucle también se obtiene el RMSD de la zona de anclajes (los 3 residuos anteriores a cada extremo del bucle). Aquellos casos en los que el RMSD fuera cercano a 0 Å indica que la zona previa de la proteína está predicha de forma fiable y por lo tanto los valores

de RMSD del bucle son acordes a la capacidad del método para predecirlo. Aquellos casos en los que el valor de RMSD de los anclajes sea superior a 0.5 Å genera de inicio una desviación suficiente para desconfiar del valor obtenido para el bucle. Aunque es posible que el espacio conformacional sea reducido y forzado por el resto de la estructura y pueda corregir el bucle predicho, es muy probable que la desviación inicial acabe formando un bucle diferente al nativo. En la Tabla 36 se muestran todos los casos en los que al menos uno de los métodos obtiene valores superiores a los 0.5 Å en todos los CDR. Los valores individuales para cada bucle, para todos los métodos, se pueden encontrar en material suplementario (Tabla S 2 para la cadena H y Tabla S 3 para la cadena L).

Tabla 36. Casos menos fiables de los otros métodos de predicción de anticuerpos. Casos con RMSD de los anclajes mayores a 0.5 Å destacados en todos los CDRs.

CDR	PDB	AF	ABB1/ ABL	ABB2	DAB	CDR	PDB	AF	ABB1/ ABL	ABB2	DAB
H1	3nps	0.71	0.58	0.50	1.90	H2	3ifl	0.25	0.13	0.92	3.06
	3gkw	1.36	1.45	1.20	1.24		3lmj	0.48	0.81	0.55	1.02
	3lmj	0.28	1.16	1.00	0.99		3nps	0.25	0.37	0.22	0.63
	1oaq	0.11	1.12	0.15	0.13		3gkw	0.20	0.60	0.28	0.24
	3eo0	0.92	0.96	1.00	0.90		3poy	0.18	0.25	0.54	0.25
	4dn3	0.75	0.95	0.89	0.81	H3	3gkw	1.86	1.93	1.87	1.84
	3m8o	0.52	0.51	0.40	0.75	L1	5i5k	0.53	0.49	0.56	0.55
	5y9k	0.67	0.44	0.30	0.44	L2	1jfq	0.21	0.63	0.26	0.25
	4edw	0.44	0.66	0.37	0.44		2vxv	0.28	0.61	0.27	0.32
	5l6y	0.27	0.59	0.33	0.44		3nps	0.30	0.60	0.36	0.46

Para estos métodos que predicen la estructura de forma completa, el error en un bucle puede forzar errores en el resto de CDRs. En H1 es el CDR donde más casos con estas características aparecen. La lista final de estructuras omitidas y su razón quedan reflejadas en la Tabla 37:

Tabla 37. Lista de estructuras descartadas y su motivo.

	Conjunto	CDR	Motivo
2adf	CRR	Todos	ABB1 y ABL no pueden dar una solución
3c08*	CRTh	H1, L1	Discontinuidades
3eo0	CRTh	H1	Desviación general en los anclajes
3gkw	CRTh	H1, H2, H3	Desviación general en los anclajes
3mlr*	CRR	L1, L2, L3	Bucle L3 excepcionalmente largo que impide predicción de cadena L en todos los métodos menos AF2
4dns	CRTh	H1	Desviación general en los anclajes
5csz*	CRTh	H3	Discontinuidad
6and	CRTh	L1, L3	Discontinuidades

*Estructuras descartadas también en el estudio de mapas de restricción.

El hecho de descartar las estructuras que otros métodos generan erróneamente de forma general supone una desventaja para RCD+, puesto que, si ha sido capaz de predecir todas ellas, destacando por ejemplo en H3 en 2adf donde se obtuvieron valores de 0.71 Å y 0.42 Å para el Top1 y Top10.

4.8.2 Valores de desviación: RMSD de los anclajes

Para compararnos con el resto de los métodos, RCD+ se ha ejecutado sobre estructuras cristalográficas a las que se le ha sometido una relajación con Rosetta. Esto iguala en condiciones y genera unas pequeñas perturbaciones en la región de los anclajes, aunque en ningún momento supera los 0.1 Å. Los valores medios de RMSD cada método en cada CDR, una vez eliminadas las estructuras descartadas y para ambos conjuntos de referencia unidos; se muestran en Tabla 38.

Tabla 38. RMSD medio de los anclajes de los bucles CDR para los métodos que predicen la estructura completa.

	<i>H1</i>	<i>H2</i>	<i>H3</i>	<i>L1</i>	<i>L2</i>	<i>L3</i>
<i>AF2</i>	0.24	0.17	0.15	0.19	0.20	0.15
<i>ABB1/ ABL</i>	0.30	0.23	0.20	0.21	0.28	0.18
<i>ABB2</i>	0.26	0.22	0.18	0.20	0.23	0.17
<i>DAB</i>	0.28	0.22	0.19	0.17	0.22	0.16

ABB1 y ABL están agrupados, ya que la entrada de ABL es la salida de ABB1 que solo modifica los CDRs (apartado 3.7.4). Los valores obtenidos muestran unos promedios en torno a 0.2 Å. Si comparamos entre métodos, vemos que AF, tiende a encontrarse más cerca del nativo que el resto de los métodos en todos los CDRs, ya que ha demostrado ser el mejor método de predicción completa de proteínas hasta la fecha. Esto no indica que sus predicciones de los bucles vayan a ser mejores, pero si que vaya a tener más facilidad al partir de una posición más fiable. Por el contrario, el que parece que el modelado del núcleo de la proteína falla ligeramente un poco más es para ABB1/ABL. Si nos fijamos entre CDRs, L3 y H3 son los que obtienen valores más bajos, por debajo de 0.2 Å.

4.8.3 Comparación general de los CDRs

En sección 4.4 se ha comparado RCD+ con Rosetta (NGK-kink, Rosie) que es la mejor aproximación *Ab Initio* disponible que también explota las restricciones de kink

del H3. En esta sección se extiende la comparación a otros métodos más alejados metodológicamente, como son: ABB1 (homología) y ABB2, ABL, AF2 y DAB (aprendizaje profundo). Para ellos, se ha utilizado los mismos conjuntos de prueba omitiendo los casos expuestos previamente en el apartado 4.8.1.

Es importante destacar que ABB1 es el único método que permite eliminar la estructura de referencia en el proceso de modelado, para el resto de los métodos no se ha podido asegurar que se haya empleado la estructura referencia como plantilla, con la consiguiente fuga de datos y la sobreestimación de sus métricas. ABB1 tiene también la particularidad de no disponer del método original, si no que los datos disponibles se obtienen con una versión que utiliza ABL en sus primeras etapas. Además, a excepción de RCD+, estos métodos rinden una sola predicción o varias prácticamente idénticas, con lo que solo podremos comparar valores Top1.

En la Figura 68 se puede observar que a excepción de H3 el resto de los métodos obtienen valores inferiores a 1 Å. Al contrario que H3, en el resto de los bucles el espacio conformacional es lo suficientemente pequeño y/o característico que hace más factible su predicción con distintas aproximaciones.

En términos generales, RCD+ obtiene valores más bajos de RMSD al resto de métodos y con valores muy cercanos a AF2. Lógicamente, para RCD+, encontramos bucles mucho más cercanos al nativo en todos los CDRs en el Top5 y Top10. ABL obtiene resultados muy similares a ABB1 de forma lógica. ABB2 mejora los resultados de ABB1 en todos los CDRs sin embargo muestra comportamientos diferentes según el conjunto de referencia: en CRR es generalmente 4º método y nunca mejora a AF2 ni RCD+; y en CRTh es mejor o igual que AF2, incluso siendo el mejor de los métodos de forma muy destacada en H3. Hemos constatado que ABB2 utiliza a CRR como conjunto de validación y se entrena con todas las estructuras disponibles a fecha de 31 de Julio de 2021 exceptuando las estructuras del CRR (Abanades et al., 2023b). Hemos podido comprobar que, en consecuencia, todas de las estructuras presentes en CRTh se incluyen en el conjunto de entrenamiento accesible en:

https://github.com/oxpig/ImmuneBuilder/blob/main/data/antibody_data.csv

Esto explica la diferencia de resultados en H3 entre CRR (2.21 Å) y CRTh (0.99 Å), un valor el doble más bajo que cualquier otro método. Con DAB observamos un comportamiento similar, aunque no tan marcado. En este caso obtiene mejores resultados en CRR que en CRTh. DAB fue entrenado con todos los anticuerpos disponibles hasta su fecha de desarrollo (incluyendo los que componen CRR), y al evaluarlos con las estructuras posteriores a esa fecha (la mayoría de CRTh) sus métricas de predicción bajan.




Figura 68. Comparación de los diferentes métodos de predicción de CDRs en el CRR y CRTh. Se representan: el Top1, Top5 y Top10 de RCD+ en verde; AF en rojo; ABB1 en azul claro; ABB2 en morado claro; DAB en azul oscuro y ABL en rosa.

Es interesante también observar cómo RCD+ (tanto con mapas como sin mapas) se obtienen mejores resultados en H1, aun siendo un bucle pequeño. Esta diferencia puede estar condicionada a que es el CDR donde el RMSD de los anclajes es ligeramente

mayor en el resto de los métodos. Adicionalmente, en H3, y omitiendo ABB2 en CRTh, el Top1 supera al resto de métodos en igualdad de condiciones, pero además el Top5 y Top10 consiguen reducir en gran medida el valor de RMSD y asegurar que entre las primeras opciones de RCD+ hay estructuras mucho más precisas que las del resto de los métodos.

A continuación, comentaremos los resultados caso por caso, empezando por H3 por su dificultad e importancia biológica.

4.8.4 Resultados en H3

La variabilidad conformacional y el mayor tamaño medio hace que sea el bucle más difícil de predecir. En CRR, RCD+ se aleja de RMSD 2.06 Å de las estructuras nativas, seguido de cerca (2.2 Å) por los métodos basados en aprendizaje profundo (AF/DAB/ABB2), y con valores más alejados de 2.45 Å, se encuentran ABB1/ABL (Tabla 39). Además, RCD+ encuentra bucles mucho más cercanos a la nativa, 1.5 y 1.3 Å, entre las 5 y 10 primeras predicciones.

En el caso de CRTh, con valores 0.3-0.4 Å más bajos, se mantiene el comportamiento favorable a RCD+ con la excepción de ABB2 que obtiene valores extraordinariamente bajos (debido al sobre ajuste explicado previamente). Además, mientras que ABB1 permite poner una lista negra de estructuras a evitar, ABB2 no dispone de esta opción, por tanto, en el proceso de predicción se puede emplear estructuras del conjunto de validación. De igual forma, AF2 puede utilizar las estructuras de validación como plantillas. Para ser totalmente imparciales habría que utilizar el mismo conjunto de entrenamiento, validación y prueba en todos los métodos, sin embargo, esto está fuera de nuestro alcance.

Tabla 39. RMSD promedio en H3 para todos los métodos.

<i>Conjunto referencia</i>	<i>Longitud media</i>	<i>Nº casos</i>	<i>Top10</i>	<i>Top5</i>	<i>Top1</i>	<i>AF2</i>	<i>ABB1</i>	<i>ABL</i>	<i>ABB2</i>	<i>DAB</i>
CRR	12.83	48	1.31	1.48	2.06	2.19	2.46	2.45	2.21	2.21
CRTh	11.87	52	1.19	1.32	1.70	1.86	1.70	1.77	0.99	2.19

En la Tabla 40 se muestran los resultados obtenidos agrupando los casos de ambos conjuntos de validación en función de la longitud del bucle para todos los métodos con la excepción de ABB2. RCD+ es significativamente mejor al resto de métodos tanto con bucles <12 residuos (con valores sub-ångstroms en el Top5) como

con bucles entre 12-15 residuos con valores ~ 0.4 Å más cercanos al nativo. Por el contrario, con bucles >15 residuos (el 15% del total) los métodos de aprendizaje profundo están prácticamente 1Å más cerca que RCD+, de 4.1 Å a 2.9 Å (AF2). RCD+ predice modelos similares a 2.9 Å en el top5, y ligeramente más bajos en el Top10 (2.6 Å).

Tabla 40. RMSD promedio en H3 para todos los métodos por subconjuntos de tamaños.

Tamaño	Longitud media	Nº casos	Top10	Top5	Top1	AF2	ABB1	ABL	DAB
< 12	9.74	38	0.82	0.92	1.20	1.38	1.56	1.59	1.56
12-15	13.00	48	1.19	1.32	1.76	2.28	2.17	2.17	2.35
> 15	17.07	14	2.62	2.94	4.08	2.88	3.10	3.23	3.41

En las Figura 69 y Figura 70 se muestran los valores individuales de CRR y CRTh ordenadas según el tamaño del bucle de menor a mayor.




Figura 69. RMSD en H3 de cada método para cada caso del CRR.

En CRR, RCD+ obtiene resultados sensiblemente menores que el resto en casos como: 1x9q (9 residuos), 1nlb (11 residuos), 2w60 (11 residuos), 3ifl (12 residuos) o 3p0y (14 residuos), y solo hay dos casos donde ocurre lo contrario: 3hc4 (9 residuos, 1.6 vs 0.7 Å) o 4f57 (18 residuos, 5.5 vs 1-2 Å). También hay casos en que todos los métodos fallan como 3liz (12 residuos), recordar que este era un caso excepcional sin *kink* (véase Figura 29D), y de forma general se observa que las predicciones son peores en los últimos bucles, los más largos.




Figura 70. RMSD en H3 de cada método para cada caso del CRTh.

Los resultados CRTh confirman que en general RCD+ obtiene mejores resultados que el resto, con alguna excepción en bucles muy largos como 5y9k (16 residuos). En el caso 3c08 (14 residuos), comentado e identificado anteriormente por no tener *kink* y

por adoptar una estructura lámina en uno de sus extremos (Figura 51D), ningún método obtiene estructuras similares a la nativa, siendo el peor resultado de AF2 con 8.12 Å.

En la Figura 71 se representan las predicciones ilustrativas para todos los métodos. En la mayoría de los casos se obtienen estructuras decentes, cercanas a la nativa. Entre ellas, destaca el caso 1yy8 de 13 residuos (Figura 71A) donde todos los métodos obtienen valores sub-ángstroms (a excepción de DAB que se desvía algo más). En la Figura 71B se representa el caso de 3p0y de 14 residuos, donde RCD+ obtiene valores de RMSD inferiores a 0.5 Å mientras que el resto se desvía notablemente de la nativa, destacando AF2 con 3.74 Å. El caso de 5y9k de 16 residuos (Figura 71C) es el ejemplo opuesto donde RCD+ es superior a 6 Å en el Top1 y a 4 Å en el Top10, y el resto de los métodos están entre 1 y 2 Å. Por último, 3liz de 12 residuos (Figura 71D), es un caso ilustrativo donde todos los métodos fallan. En este caso todos los métodos predicen una conformación con *kink* que ya habíamos visto que no lo posee (Figura 29D).




Figura 71. Predicciones de todos los métodos en casos representativos de H3.

4.8.5 Resultados en el resto de CDRs

4.8.5.1 H1

En este CDR, los bucles son más fáciles de predecir, independiente del método y del conjunto de validación, los valores de RMSD medios están por debajo de 1 Å (Tabla 41). RCD+ es el único en bajar de forma constante de los 0.5 Å, 0.2 Å mejor que AF2. Los valores de RMSD en CRTh son iguales o mayores a los varones obtenidos con CRR, a excepción de ABB2, que este caso su sobreajuste es menos pronunciado.

Tabla 41. RMSD promedio en H1 para todos los métodos.

<i>Conjunto referencia</i>	<i>Longitud media</i>	<i>Nº casos</i>	<i>Top10</i>	<i>Top5</i>	<i>Top1</i>	<i>AF2</i>	<i>ABB1</i>	<i>ABL</i>	<i>ABB2</i>	<i>DAB</i>
CRR	7.06	49	0.34	0.36	0.41	0.60	0.82	0.83	0.73	0.69
CRTh	7.22	50	0.33	0.35	0.47	0.57	0.66	0.67	0.46	0.60

En CRR (Figura 72), RCD+ obtienen valores más bajos en prácticamente todos los casos, excepto en 3nps y 4hpy para RCD+. En AF2, además de estos 2 casos, falla también en 3go1, 3lmj. Y al resto de métodos se le suman 1oaq, 2xwt, 3go1, 3ifl o 3poy. En el caso de 3nps, identificado también en el apartado 4.6.7 por ser el único caso que empeoraba considerablemente al usar mapas de restricción, ningún método obtiene resultados por debajo de 2 Å. Aunque no podemos descartar algún efecto por la presencia del antígeno en el cristal, hemos observado que la distancia entre anclajes (los extremos Nt y Ct terminales) entre los modelos iniciales y el cristalográfico de referencia son inusualmente altos (Tabla 36). Si los externos terminales donde parte la predicción ya están desviados, el error inicial se propagará naturalmente a lo largo del bucle, aumentando el valor RMSD. Al ver que todos los métodos fallan en los anclajes nos da la pista de que esta estructura en concreto tiene una conformación completamente anormal y que el resto de los métodos tampoco consiguen replicar.




Figura 72. RMSD en H1 de cada método para cada caso del CRR.

Para CRTh el comportamiento es muy similar (Figura 73), con casi todos los casos correctos para todos los métodos y siendo RCD+ ligeramente mejor en la mayoría. Hay 4 casos en los que de forma generalizada las predicciones se desvían $> 1\text{\AA}$. Entre ellos, en 5yk9, aunque RCD+ se encuentra considerablemente más cerca a la solución nativa.




Figura 73. RMSD en H1 de cada método para cada caso del CRRh.

Todos los métodos han obtenido buenos resultados en bucles >7 residuos (longitudes menos estándar) con las excepciones de: 3b2u de CRRh (9 residuos) donde AF2 obtiene un resultado cercano a 2 Å; 3ifl de CRR (9 residuos) donde ABB2 y DAB supera 1 Å mientras que el resto está en torno a 0.5 Å; y 4x5s de CRRh (8 residuos) donde todos los métodos menos RCD+ superan 1 Å y AF2 junto a DAB se acercan a los 2 Å. Esto nos muestra que los mapas de restricción para estas longitudes menos comunes son efectivos mientras otros métodos tienen algún problema.

En la Figura 74 se representan 4 ejemplos ilustrativos, todos ellos de 7 residuos. El primero, 1cz8 (Figura 74A) ejemplifica el comportamiento general donde todos los métodos se acercan a la conformación nativa. 3nps es un caso excepcional (analizado en el apartado 4.6.7- 140 -), donde todos los métodos erran en la predicción (Figura

74B). Aunque en la parte C-Terminal se puede apreciar como RCD+ toma un camino más cercano a la nativa, que le da esa ventaja de RMSD final, luego se desvía igual que el resto.

El caso de 1bey (Figura 74C) muestra también como la conformación escogida por todos los métodos es muy similar, aunque alejada de la nativa. Y el en caso de 3u0t (Figura 74D) se ve como RCD+ tiene un Top1 muy desviado de la nativa (en torno a 3.5 Å) en comparación con el resto de los métodos que se mueven en torno a los 2 Å, pero que con el Top10 ya lo corrige y consigue un valor inferior a 1 Å. Es el único caso donde RCD+ se desvía de más




Figura 74. Predicciones de todos los métodos en casos representativos de H1.

4.8.5.2 H2

Observamos prácticamente las mismas tendencias que el CDR anterior. Aunque por su menor tamaño (6 residuos), las diferencias son lógicamente menores (Tabla 42). Los RMSDs están claramente por debajo de 1 Å con muy pocas excepciones tanto para CRR (Figura 75) como para CRTh (Figura 76).

Tabla 42. RMSD promedio en H2 para todos los métodos.

Conjunto referencia	Longitud media	Nº casos	Top10	Top5	Top1	AF2	ABB1	ABL	ABB2	DAB
CRR	6.14	49	0.41	0.49	0.58	0.69	0.87	0.91	0.69	0.82
CRTh	5.94	53	0.39	0.43	0.52	0.57	0.70	0.74	0.56	0.56




Figura 75. RMSD en H2 de cada método para cada caso del CRR.

En CRR, RCD+ únicamente presenta complicaciones en tres casos: 3m8o, 3mlj y 4hpy. 3m8o (8 residuos) pose una estructura de hélice en mitad del bucle (visto

previamente en la Figura 39B) que complica su predicción. Aunque AF2 también obtiene valores de 4 Å, de forma excepcional, el resto de los métodos consiguen acertar el bucle manteniéndose por debajo de 1 Å. Para el caso de 3mlj (6 residuos), mientras RCD+ tiene valores de 1.71 Å en el Top1 y 1.49 en el Top10, el resto de los métodos están todos por encima de los 4 Å; ya que es un caso con una mayor distancia en las regiones de anclajes. El caso de 4hpy (6 residuos) es el único caso donde el resto de los métodos obtienen mejores resultados que RCD+, como ya se analizó previamente (apartado 4.5.1) la diferencia entre valores Top1, Top5 y Top10 es debido un problema de muestreo para RCD+. Por el contrario, 2r8s (6 residuos) las predicciones están alejadas para todos los métodos a excepción de RCD+. Además, ABB1/ABL tienen 5 casos más en los que ellos solos obtienen resultados superiores a 1 Å. Por último, DAB es el único que se desvía en 3ifl (5 residuos) con un RMSD de 4.63 Å, con una diferencia de 3.06 Å en los anclajes, indicando un fallo general en el modelado de la estructura.

Atendiendo a CRTh, RCD+ tan solo en los casos de 4dn3 y 4ojf obtiene valores superiores a 1 Å en consonancia con los demás métodos. Por el contrario, RCD+ obtiene mejores resultados en los casos 3c08, 3gkw, 3hmw, 5xxy o 5yk9.




Figura 76. RMSD en H2 de cada método para cada caso del CRTh.

En la Figura 77 se muestran las predicciones para 4 casos diferentes, todos de 6 residuos. Con 3hnt (Figura 77A) se muestra el comportamiento mayoritario en que todos los métodos obtienen resultados inferiores a 0.5 Å. La Figura 77B se muestra las complicaciones con la hélice de 3m8o para RCD+ y AF2 previamente comentadas. Con 3hmw (Figura 77C) encontramos un caso donde RCD+ acierta la estructura nativa y el resto fallan en el extremo C-Terminal, condicionándoles el resto del bucle (destaca el error ABB1 con 2.39 Å). Y con 4ojf (Figura 77D) se muestra un caso en el que todos se desvían hasta 1.5 Å. El origen del error es común, el primer residuo del extremo C-Terminal, y después cada método toma una confirmación más abierta y desviándose completamente de la nativa.




Figura 77. Predicciones de todos los métodos en casos representativos de H2.

4.8.5.3 L1

En este CDR todos los métodos obtienen resultados cercanos a la nativa (Tabla 43) a pesar de su mayor longitud. El espacio conformacional está condicionado ya que los extremos Ct y Nt están bastante alejados entre si. RCD+ obtiene resultados similares a AF2, seguidos de cerca por ABB2 y DAB, y con peor desempeño se encuentran ABB1 y ABL.

Tabla 43. RMSD promedio en L1 para todos los métodos.

Conjunto referencia	Longitud media	Nº casos	Top10	Top5	Top1	AF2	ABB1	ABL	ABB2	DAB
CRR	12.42	48	0.36	0.39	0.47	0.45	0.70	0.65	0.53	0.51
CRTh	12.29	52	0.43	0.48	0.61	0.60	0.70	0.67	0.54	0.62

Los valores individuales se muestran en la Figura 78 para CRR y en la Figura 79 para CRTh, con los casos ordenados de menor a mayor longitud del bucle.




Figura 78. RMSD en L1 de cada método para cada caso del CRR.

Como se puede ver en ambos conjuntos, no hay grandes diferencias entre los diferentes métodos. Únicamente encontramos un caso en cada conjunto donde RCD+ falla de forma notoria y los demás aciertan: 3gnm (16 residuos) de CRR y 5n2k (13 residuos) de CRTh. En el caso de 3gnm (mostrado en la Figura 80C), se comprobó previamente (en la Figura 41D) que, aunque si se llegaba a acertar la conformación principal, un pequeño desvío cerca de un anclaje provocaba que la zona media del bucle quedara alejada y obtuviera un RMSD tan alto. Lo sorprendente es que métodos como AF2 obtengan valores de 0.5 Å para una estructura tan larga. Por otro lado, con el caso de 5n2k (mostrada en la Figura 58C), se llegó a la conclusión de que su necesidad era

aumentar el muestreo para que las conformaciones correctas aparezcan y se puedan seleccionar.




Figura 79. RMSD en L1 de cada método para cada caso del CRTh.

Por otro lado, encontramos casos como los de 2fbj (10 residuos), 3go1 (11 residuos), 3nps (13 residuos) o 3m8o (16 residuos) en CRR; y 2hwz (10 residuos), 5csz (12 residuos) o 3gkw (16 residuos) en CRTh; donde RCD+ obtiene resultados mas precisos que el resto de los métodos, estando AF2 a la par en alguno de ellos.

En la Figura 80, además de 3gnm se representan otros 3 casos de este CDR. Con 1seq de 10 residuos (Figura 80C) se ilustra el comportamiento mayoritario en bucles más cortos, donde todos los métodos aciertan. Con 3o2d (Figura 80B) ocurre algo similar, pero esta para uno de los bucles más largos del CDR al tener 17 residuos. Y por último,

3m8o de 16 residuos (Figura 80D), al contrario que 3gnm (Figura 80C), es otro caso largo donde esta vez RCD+ es más preciso y el resto de los métodos se desvían ligeramente en la zona del vértice.




Figura 80. Predicciones de todos los métodos en casos representativos de L1.

4.8.5.4 L2

Al tratarse de un CDR corto y con menos variabilidad en longitud (todos de 7 residuos), la mayoría de los casos obtiene buenos valores de predicción con pocas excepciones, como se puede observar en la Tabla 44 para los valores generales, en las Figura 81 y Figura 82 para cada caso de CRR y CRTH.

Tabla 44. RMSD promedio en L2 para todos los métodos.

<i>Conjunto referencia</i>	<i>Longitud media</i>	<i>Nº casos</i>	<i>Top10</i>	<i>Top5</i>	<i>Top1</i>	<i>AF2</i>	<i>ABB1</i>	<i>ABL</i>	<i>ABB2</i>	<i>DAB</i>
CRR	7.00	49	0.31	0.33	0.38	0.42	0.56	0.50	0.47	0.43
CRTh	7.00	53	0.34	0.35	0.41	0.41	0.54	0.47	0.41	0.44




Figura 81. RMSD en L2 de cada método para cada caso del CRR.

En CRR solo en los casos 1gig y 2vxv, RCD+ tiene un peor resultado que los demás, mientras que en 1jpt, 1oaq, 3eo9, 3hnt o 3i9g obtienen predicciones mas cercanas a la nativa. Aunque de forma menos notoria que en otros CDRs se pueden apreciar algunos valores más altos de RMSD para casos de ABB1 y ABL (e.g. 1oaq, 3poy o 3umt).

En CRTh los resultados son más parejos, con tan solo tres casos destacados. En 4dq9, todos los métodos obtienen valores de RMSD altos, aunque RCD+ toma cierta ventaja al ser el único en bajar de 1 Å (sin contar ABB2). En 4od2 ocurre algo similar, donde todos los métodos están por encima de 1.4 Å y RCD+ se queda en torno a 0.8 Å. Por último, el más destacado es 5y9k, donde RCD+ por debajo de 0.4 Å y el resto de los métodos por encima de 1.2 Å.




Figura 82. RMSD en L2 de cada método para cada caso del CRTh.

En la Figura 83A se muestra 1cz8 como ejemplo ilustrativo donde todos los métodos están cerca de la estructura nativa (0.4 Å). En el caso excepcional de 2vxv (Figura 83B), RCD+ es el único método que se desvía en el extremo C-terminal. Mientras que, de forma opuesta, en 3i9g (Figura 83C), solo RCD+ obtiene la solución nativa (0.3 Å) y el resto de los métodos se desvían en el extremo N-Terminal (zona superior de la imagen) y no bajan de 1.3 Å. Por último, en la Figura 83D se representa a 4d9q, donde todos los métodos se desvían en el extremo N-terminal durante 3 residuos de forma marcada, con excepción de ABB2 que está sobreajustado.




Figura 83. Predicciones de todos los métodos en casos representativos de L2.

4.8.5.5 L3

Los valores medios de RMSD en L3 (Tabla 45) mantienen la tendencia vista en todos los CDRs: RCD+ obtiene los valores más bajos seguido de cerca por AF2. En este bucle volvemos a observar como todos los métodos obtienen un valor igual o ligeramente peor en CRTh que en CRR, con la excepción de ABB2.

Tabla 45. RMSD promedio en L3 para todos los métodos.

Conjunto referencia	Longitud media	Nº casos	Top10	Top5	Top1	AF2	ABB1	ABL	ABB2	DAB
CRR	9.21	48	0.40	0.46	0.58	0.82	0.91	0.89	0.81	0.79
CRTh	9.17	53	0.55	0.59	0.77	0.80	0.93	0.89	0.62	0.97

Los valores específicos de cada caso están representados en la Figura 84 para CRR y en la Figura 85 para CRTh. En CRR se obtienen buenos resultados para RCD+ en todos

los casos; con tan solo valores por encima de 1 Å en los 2 casos más largos: 4hpy (11 residuos) y 3lmj (12 residuos). En ambas estructuras el resto de los métodos obtienen unos valores similares o ligeramente superiores.

Por el contrario, encontramos varios casos donde RCD+ obtiene resultados significativamente mejores: como el bucle 2e27 (9 residuos), donde AF2 también acierta, pero el resto de los métodos obtiene predicciones en torno 1.5 Å; o los casos de 2fbj (9 residuos), 1mqk (10 residuos), 2vxv (10 residuos) y 3go1 (10 residuos), en donde RCD+ es el único con conformaciones prácticamente nativas.




Figura 84. RMSD en L3 de cada método para cada caso del CRR.

En CRTH encontramos mayor homogeneidad. Resaltan los casos de 4ypg (9 residuos) y 5i5k (9 residuos), donde RCD+ obtiene valores elevados mientras el resto de

los casos tiene valores más bajos; o 2hwz (9 residuos) y 3c08 (9 residuos) donde ocurre el comportamiento contrario. Además, en los bucles más largos del conjunto (e.g. 5nhw de 11 residuos), RCD+ tiene valores de RMSD significativamente mejores que el resto. El efecto del sobreajuste de ABB2 también resalta en estos bucles más largos de L3.




Figura 85. RMSD en L3 de cada método para cada caso del CRTh.

En la Figura 86 se muestra las predicciones para 4 casos representativos. El bucle 3eo0 de 9 residuos (Figura 86A) corresponde con el comportamiento general donde todos los métodos tienen precisión sub-ángstroms. De forma opuesta, 4hpy de 11 residuos (Figura 86B), ejemplifica una de las excepciones donde todos los métodos se desvían en posiciones cercanas a los anclajes, con valores de RMSD en torno a 2 Å. El bucle 5nhw de 11 residuos también (Figura 86C), es un caso parecido al anterior, sin embargo, en esta ocasión RCD+ consigue mantenerse cerca de 1 Å en el Top10, AF2

registra el peor valor (5 Å) y el resto de los métodos están entre 2.8 Å y 4 Å; mientras que ABB2 alcanza un valor inferior a 0.6 Å al estar sobre ajustado. Por último, con 4ypg de 9 residuos (Figura 86C), es uno de los pocos casos que RCD+ se desvía de la conformación nativa (1.8 Å) mientras que el resto si acierta (0.6 Å).




Figura 86. Predicciones de todos los métodos en casos representativos de L3.

5. Conclusiones

1. Se ha actualizado y mejorado el algoritmo de RCD+.
 - 1.1. La incorporación y optimización de un término de Ramachandran en el potencial KORP mejora la discriminación de bucles en un conjunto de referencia estándar con longitudes entre 6 y 12 aminoácidos.
 - 1.2. El paso de refinamiento del algoritmo de RCD+ se ha actualizado a la versión de PyRosetta4, modificando el muestreo de las cadenas laterales, manteniendo precisión y velocidad.
2. Adaptación de RCD+ a la predicción de bucles CDR de anticuerpos:
 - 2.1. Diseño de mapas de restricción para la predicción de bucles CDR:
 - En los bucles menos variables y más cortos (H1, H2 y L2), fue posible generar mapas de restricción completos.
 - En L1 y L3, los mapas restringen casi todo el espacio, salvo en longitudes superiores a 11 residuos, donde las posiciones centrales quedan sin restricción debido a su variabilidad.
 - Para H3, dada su alta variabilidad, solo se ha restringen las zonas N- y C-terminal correspondientes a la estructura del *kink*.
 - 2.2. Validación sistemática de los mapas de restricción en los conjuntos de prueba CRR y CRTh:
 - En todos los casos se observó un enriquecimiento hacia la estructura nativa al generar bucles con RCD.
 - En H1, el enriquecimiento no se tradujo en una mejora significativa: sin restricciones, las predicciones y la estructura nativa difieren solo 0.3–0.4 Å. El caso 3nps es una excepción, donde la predicción empeora al aplicar restricciones.
 - Con H2 y L3, se observa una ligera mejora (~0.2–0.1 Å), alcanzando RMSD de 0.6 Å (Top1) y 0.4 Å (Top10).
 - L1 y L2 presentan mejoras más notables: 0.47 Å y 0.38 Å (Top1) y 0.38 Å y 0.31 Å (Top10), partiendo de valores >1 Å sin restricciones.

- En H3, los mapas permiten mejoras sustanciales, excepto en estructuras sin *kink*, como 3liz (12 residuos). Se observan mejoras >1 Å en casos como 1mlb (9 res.), 4mbn (10 res.) o 3mlr (17 res.).
 - Estas conclusiones se mantienen en ambos conjuntos (CRR y CRTh).
- 2.3. En promedio, la presencia del antígeno no afecta significativamente la efectividad de los mapas. Sin embargo, existen casos (como H1 de 3nps) donde las mejores predicciones coinciden con el espacio ocupado por el antígeno.
3. Comparación con otros métodos de predicción:
- 3.1. Comparación con el protocolo de modelado H3 (NGK-kink) de RoAb:
- A partir de estructuras cristalográficas, RCD+ obtiene predicciones 0.2 Å más cercanas a la estructura nativa en el Top1 (~2.00 Å RMSD).
 - Desde modelos por homología de RoAb, RCD+ alcanza 2.77 Å (Top1) y 2.01 Å (Top10), frente a los 3.45 Å y 2.10 Å de RoAb.
 - RCD+ es al menos un orden de magnitud más rápido (minutos vs. horas).
- 3.2. Comparación de predicción en todos los CDRs con métodos de aprendizaje profundo con los conjuntos de referencia CRR y CRTh:
- En H1, H2, L1, L2 y L3;
 - El espacio conformacional es lo suficientemente reducido que todos los métodos alcanzan precisión sub-ångström.
 - RCD+ supera a AF2 (segundo lugar), seguido de ABB1/ABL.
 - En H3:
 - RCD+ es significativamente mejor para bucles <12 residuos (Top5 con RMSD <1 Å) y también para bucles de 12–15 residuos (~0.4 Å más cercanos al nativo).
 - Para bucles >15 residuos (15% del total), métodos de aprendizaje profundo superan a RCD+ (~3.1 Å vs. 4.2 Å). Aun así, RCD+ obtiene modelos similares en el Top5 (~3.1 Å) y mejores en el Top10 (~2.8 Å).
 - En CRR, RCD+ alcanza 2.06 Å de desviación con respecto a la estructura nativa, seguido por métodos de aprendizaje profundo (~2.2 Å) y métodos por homología (~2.4 Å).

- En CRTh hemos encontrado resultados similares, aunque hemos detectado una sobreestimación de resultados de ABB2 por fuga de datos.
 - En todos los casos RCD+ ofrece soluciones más variables, lo que se traduce en la posibilidad de encontrar bucles alternativos más cercanos a la conformación nativa. Por ejemplo, en H3 entre las 5 o las 10 primeras predicciones se encuentran soluciones alejadas 1.5 Å y 1.3 Å, respectivamente.
4. Se ha desarrollado un método para la predicción del cambio de estabilidad en mutaciones de sustitución aminoacídica basado en KORP. Este potencial, que solo depende de la posición y orientación relativa de tres átomos de la cadena principal, ofrece un excelente balance entre precisión y eficacia. A pesar de su sencillez, ha obtenido resultados altamente competitivos frente a los métodos existentes en diferentes métricas (e.g. RMSE, PCC, MCC, ACC, o curva ROC) en conjuntos de evaluación estándar.

6. Apéndices

6.1 Contribuciones

Del trabajo realizado durante la tesis sale dos publicaciones:

1. El potencial de predicción de estabilidad de mutaciones KORPM

Predicting protein stability changes upon mutation using a simple orientational potential (IM Hernández, Y Dehouck, U Bastolla, JR López-Blanco, P Chacón. Bioinformatics 39 (1), 1–7, 2023).

2. Publicación de los resultados generales con mapas de restricción y la implementación de un servidor (en proceso):

Ab initio loop modeling of CDR loops (I Martín-Hernández, P Chacón).

6.2 Programas y código

Los programas y scripts que se han desarrollado durante todo el transcurso de la tesis, tanto los que salen mencionados en la misma como otros más sencillos se pueden encontrar en:

<https://github.com/IvanMartin111/PhDscripts.git>

6.3 Tablas suplementarias

Tabla S 1. Factores de ponderación dependientes del aminoácido de KORPM.

aa _i	K-fold	A	C	D	E	F	G	H	I	K	L
20	5	1.89±0.10	0.73±0.11	0.86±0.09	0.93±0.12	2.37±0.11	0.99±0.21	1.13±0.08	2.50±0.12	0.99±0.12	2.62±0.16
20	10	1.88±0.07	0.73±0.09	0.87±0.07	0.92±0.07	2.37±0.09	0.97±0.13	1.13±0.04	2.51±0.09	0.99±0.09	2.63±0.12
12	5	1.88±0.14	0.72±0.11	0.88±0.08	0.88±0.08	2.44±0.11	0.97±0.25	1.03±0.09	2.51±0.15	1.03±0.09	2.52±0.14
12	10	1.87±0.10	0.73±0.08	0.87±0.05	0.87±0.05	2.45±0.08	0.97±0.18	1.03±0.06	2.52±0.11	1.03±0.06	2.52±0.10
		M	N	P	Q	R	S	T	V	W	Y
20	5	1.66±0.22	1.22±0.08	1.16±0.15	1.00±0.05	1.62±0.13	1.37±0.11	1.16±0.14	2.42±0.19	1.50±0.10	2.55±0.18
20	10	1.67±0.16	1.23±0.06	1.16±0.09	0.99±0.04	1.61±0.11	1.36±0.08	1.16±0.16	2.43±0.14	1.50±0.08	2.57±0.13
12	5	1.65±0.22	1.11±0.07	1.42±0.08	1.11±0.07	1.61±0.13	1.11±0.07	1.12±0.07	2.51±0.14	1.42±0.08	2.44±0.11
12	10	1.66±0.16	1.11±0.05	1.40±0.05	1.11±0.05	1.60±0.10	1.11±0.05	1.12±0.05	2.53±0.10	1.40±0.05	2.45±0.08

Tabla S 2. Valores individuales de RMSD de los anclajes para cada caso de ambos conjuntos de referencia en los bucles de la cadena H (H1, H2 y H3).

	<i>H1</i>					<i>H2</i>					<i>H3</i>				
	AF	ABB1	ABB2	ABlooper	DeepAB	AF	ABB1	ABB2	ABlooper	DeepAB	AF	ABB1	ABB2	ABlooper	DeepAB
<i>1dlf</i>	0,28	0,18	0,33	0,18	0,34	0,18	0,18	0,13	0,18	0,19	0,24	0,25	0,27	0,25	0,28
<i>1fns</i>	0,13	0,24	0,11	0,24	0,25	0,20	0,24	0,21	0,24	0,18	0,08	0,14	0,12	0,14	0,17
<i>1gig</i>	0,18	0,27	0,37	0,27	0,38	0,19	0,20	0,26	0,20	0,18	0,16	0,23	0,18	0,23	0,20
<i>1jfq</i>	0,14	0,20	0,22	0,20	0,29	0,17	0,15	0,28	0,15	0,35	0,13	0,19	0,16	0,19	0,13
<i>1jpt</i>	0,16	0,26	0,19	0,26	0,27	0,16	0,21	0,20	0,21	0,09	0,17	0,20	0,23	0,20	0,20
<i>1mfa</i>	0,14	0,29	0,12	0,29	0,17	0,14	0,15	0,18	0,15	0,14	0,18	0,19	0,20	0,19	0,17
<i>1mlb</i>	0,26	0,38	0,27	0,38	0,19	0,21	0,33	0,26	0,33	0,21	0,18	0,17	0,21	0,17	0,18
<i>1mqk</i>	0,11	0,18	0,18	0,18	0,18	0,13	0,12	0,16	0,12	0,12	0,17	0,30	0,30	0,30	0,21
<i>1nlb</i>	0,17	0,39	0,22	0,39	0,11	0,21	0,28	0,30	0,28	0,21	0,11	0,09	0,20	0,09	0,16
<i>1oaq</i>	0,11	1,12	0,15	1,12	0,13	0,12	0,53	0,14	0,53	0,14	0,13	0,39	0,17	0,39	0,17
<i>1seq</i>	0,25	0,34	0,24	0,34	0,24	0,16	0,15	0,16	0,15	0,16	0,23	0,20	0,27	0,20	0,30
<i>1x9q</i>	0,20	0,43	0,25	0,43	0,26	0,15	0,12	0,19	0,12	0,13	0,25	0,21	0,24	0,21	0,15
<i>2adf</i>	0,14	0,12	0,19	0,12	0,23	0,29	0,27	0,32	0,27	0,18	0,10	-	0,11	-	0,12
<i>2d7t</i>	0,13	0,20	0,23	0,20	0,18	0,25	0,22	0,36	0,22	0,26	0,08	0,18	0,14	0,18	0,09
<i>2e27</i>	0,22	0,14	0,26	0,14	0,22	0,13	0,10	0,23	0,10	0,14	0,14	0,07	0,15	0,07	0,20
<i>2fb4</i>	0,19	0,33	0,31	0,33	0,33	0,17	0,17	0,15	0,17	0,15	0,22	0,37	0,21	0,37	0,18
<i>2fbj</i>	0,19	0,25	0,21	0,25	0,15	0,10	0,14	0,27	0,14	0,14	0,17	0,22	0,22	0,22	0,19
<i>2r8s</i>	0,46	0,54	0,51	0,54	0,43	0,25	0,37	0,33	0,37	0,29	0,19	0,26	0,21	0,26	0,21
<i>2v17</i>	0,10	0,16	0,18	0,16	0,21	0,09	0,19	0,18	0,19	0,18	0,17	0,11	0,18	0,11	0,24
<i>2vxv</i>	0,17	0,29	0,21	0,29	0,22	0,22	0,49	0,39	0,49	0,38	0,13	0,14	0,16	0,14	0,16
<i>2w60</i>	0,18	0,18	0,22	0,18	0,18	0,12	0,22	0,21	0,22	0,14	0,09	0,14	0,13	0,14	0,18
<i>2xwt</i>	0,40	0,28	0,39	0,28	0,28	0,14	0,21	0,20	0,21	0,22	0,12	0,16	0,16	0,16	0,16
<i>2ypv</i>	0,24	0,35	0,27	0,35	0,27	0,15	0,19	0,12	0,19	0,19	0,11	0,28	0,10	0,28	0,13
<i>3e8u</i>	0,16	0,54	0,23	0,54	0,33	0,10	0,27	0,15	0,27	0,11	0,17	0,25	0,16	0,25	0,17
<i>3eo9</i>	0,24	0,36	0,26	0,36	0,32	0,12	0,32	0,17	0,32	0,11	0,11	0,32	0,12	0,32	0,16
<i>3g5y</i>	0,20	0,15	0,14	0,15	0,16	0,12	0,13	0,11	0,13	0,13	0,13	0,17	0,15	0,17	0,21
<i>3giz</i>	0,26	0,27	0,39	0,27	0,30	0,13	0,18	0,14	0,18	0,12	0,16	0,32	0,26	0,32	0,21
<i>3gnm</i>	0,17	0,39	0,23	0,39	0,19	0,10	0,31	0,16	0,31	0,11	0,15	0,47	0,14	0,47	0,14
<i>3go1</i>	0,40	0,45	0,49	0,45	0,48	0,14	0,36	0,28	0,36	0,17	0,20	0,34	0,19	0,34	0,15
<i>3hc4</i>	0,18	0,13	0,23	0,13	0,26	0,10	0,06	0,12	0,06	0,12	0,08	0,06	0,10	0,06	0,10
<i>3hnt</i>	0,11	0,12	0,23	0,12	0,09	0,20	0,24	0,27	0,24	0,16	0,11	0,07	0,10	0,07	0,14
<i>3i9g</i>	0,16	0,21	0,25	0,21	0,22	0,10	0,22	0,27	0,22	0,11	0,11	0,18	0,17	0,18	0,16
<i>3ifl</i>	0,37	0,22	0,25	0,22	0,32	0,25	0,13	0,92	0,13	3,06	0,10	0,08	0,24	0,08	0,23
<i>3liz</i>	0,15	0,24	0,31	0,24	0,24	0,16	0,16	0,10	0,16	0,14	0,22	0,39	0,39	0,39	0,28
<i>3lmj</i>	0,28	1,16	1,00	1,16	0,99	0,48	0,81	0,55	0,81	1,02	0,08	0,31	0,13	0,31	0,11
<i>3m8o</i>	0,52	0,51	0,40	0,51	0,76	0,13	0,14	0,18	0,14	0,18	0,23	0,37	0,35	0,37	0,25
<i>3mlr</i>	0,18	0,34	0,24	0,34	0,21	0,15	0,12	0,28	0,12	0,19	0,16	0,30	0,17	0,30	0,12
<i>3mxw</i>	0,13	0,23	0,22	0,23	0,17	0,11	0,16	0,10	0,16	0,10	0,07	0,07	0,13	0,07	0,11
<i>3nps</i>	0,71	0,58	0,50	0,58	1,90	0,25	0,37	0,22	0,37	0,63	0,11	0,09	0,14	0,09	0,22
<i>3oz9</i>	0,20	0,43	0,19	0,43	0,26	0,10	0,35	0,14	0,35	0,08	0,10	0,25	0,13	0,25	0,12
<i>3p0y</i>	0,26	0,33	0,28	0,33	0,18	0,18	0,25	0,54	0,25	0,11	0,12	0,18	0,18	0,18	0,18
<i>3t65</i>	0,18	0,17	0,29	0,17	0,20	0,11	0,16	0,23	0,16	0,12	0,10	0,14	0,16	0,14	0,16
<i>3umt</i>	0,31	0,32	0,48	0,32	0,38	0,15	0,21	0,20	0,21	0,15	0,11	0,18	0,16	0,18	0,17
<i>3v0w</i>	0,16	0,13	0,18	0,13	0,20	0,15	0,20	0,19	0,20	0,16	0,22	0,15	0,29	0,15	0,27
<i>4f57</i>	0,10	0,12	0,20	0,12	0,20	0,16	0,19	0,18	0,19	0,19	0,13	0,13	0,09	0,13	0,15
<i>4h0h</i>	0,22	0,25	0,21	0,25	0,17	0,20	0,23	0,26	0,23	0,24	0,12	0,13	0,12	0,13	0,14
<i>4h20</i>	0,17	0,19	0,15	0,19	0,12	0,12	0,25	0,15	0,25	0,09	0,12	0,15	0,16	0,15	0,11
<i>4hpy</i>	0,21	0,34	0,36	0,34	0,39	0,12	0,10	0,14	0,10	0,16	0,11	0,21	0,23	0,21	0,13
<i>4nzu</i>	0,13	0,31	0,28	0,31	0,19	0,10	0,14	0,11	0,14	0,23	0,15	0,24	0,30	0,24	0,18
<i>1bey</i>	0,41	0,40	0,41	0,40	0,45	0,28	0,36	0,33	0,36	0,28	0,22	0,23	0,18	0,23	0,20
<i>1cz8</i>	0,22	0,21	0,13	0,21	0,22	0,15	0,16	0,20	0,16	0,20	0,15	0,17	0,14	0,17	0,14
<i>1mim</i>	0,24	0,24	0,20	0,24	0,23	0,21	0,17	0,19	0,17	0,17	0,20	0,21	0,22	0,21	0,21
<i>1sy6</i>	0,23	0,19	0,20	0,19	0,16	0,16	0,20	0,17	0,20	0,21	0,11	0,11	0,14	0,11	0,12
<i>1yy8</i>	0,15	0,13	0,15	0,13	0,22	0,14	0,18	0,24	0,18	0,13	0,13	0,10	0,16	0,10	0,17
<i>2hwz</i>	0,14	0,17	0,15	0,17	0,23	0,28	0,32	0,27	0,32	0,19	0,13	0,11	0,17	0,11	0,17
<i>3b2u</i>	0,40	0,45	0,24	0,45	0,24	0,29	0,27	0,18	0,27	0,27	0,20	0,17	0,18	0,17	0,20

3c08	-	-	-	-	-	0,24	0,14	0,36	0,14	0,18	0,20	0,13	0,17	0,13	0,19
3e00	0,92	0,96	1,00	0,90	0,94	0,13	0,22	0,17	0,22	0,22	0,09	0,12	0,10	0,12	0,07
3gkw	1,36	1,45	1,20	1,45	1,24	0,20	0,60	0,28	0,60	0,24	1,86	1,93	1,87	1,93	1,84
3hmw	0,19	0,32	0,21	0,32	0,20	0,24	0,43	0,25	0,43	0,26	0,15	0,24	0,15	0,24	0,15
3nfs	0,32	0,25	0,27	0,25	0,28	0,14	0,17	0,19	0,17	0,15	0,16	0,15	0,14	0,15	0,16
3o2d	0,27	0,22	0,22	0,22	0,17	0,20	0,32	0,28	0,32	0,24	0,13	0,19	0,15	0,19	0,15
3pp3	0,17	0,20	0,19	0,20	0,21	0,13	0,24	0,21	0,24	0,14	0,15	0,16	0,14	0,16	0,12
3qwo	0,24	0,17	0,14	0,17	0,28	0,12	0,18	0,15	0,18	0,12	0,09	0,12	0,13	0,12	0,19
3s34	0,14	0,21	0,17	0,21	0,15	0,16	0,14	0,16	0,14	0,14	0,10	0,21	0,12	0,21	0,17
3u0t	0,47	0,44	0,23	0,44	0,34	0,13	0,28	0,23	0,28	0,15	0,16	0,28	0,11	0,28	0,23
4cni	0,20	0,28	0,28	0,28	0,22	0,27	0,38	0,11	0,38	0,36	0,18	0,40	0,14	0,40	0,21
4d9q	0,13	0,22	0,20	0,22	0,18	0,20	0,11	0,22	0,11	0,26	0,10	0,11	0,09	0,11	0,16
4dn3	0,75	0,95	0,89	0,95	0,81	0,21	0,29	0,22	0,29	0,25	0,10	0,12	0,11	0,12	0,14
4edw	0,44	0,66	0,37	0,66	0,44	0,17	0,33	0,17	0,33	0,20	0,14	0,20	0,23	0,20	0,22
4g5z	0,08	0,32	0,13	0,32	0,13	0,15	0,11	0,13	0,11	0,09	0,20	0,16	0,11	0,16	0,19
4g6k	0,21	0,28	0,17	0,28	0,31	0,15	0,09	0,24	0,09	0,26	0,12	0,11	0,18	0,11	0,31
4hgz	0,21	0,26	0,17	0,26	0,20	0,08	0,12	0,13	0,12	0,11	0,13	0,14	0,14	0,14	0,12
4i77	0,32	0,41	0,35	0,41	0,49	0,20	0,28	0,11	0,28	0,28	0,10	0,10	0,17	0,10	0,13
4irz	0,26	0,27	0,24	0,27	0,18	0,18	0,28	0,32	0,28	0,16	0,25	0,23	0,22	0,23	0,23
4k3j	0,25	0,46	0,26	0,46	0,32	0,17	0,43	0,20	0,43	0,17	0,24	0,36	0,23	0,36	0,29
4kaq	0,31	0,33	0,25	0,33	0,28	0,14	0,22	0,18	0,22	0,10	0,17	0,20	0,16	0,20	0,15
4m6n	0,16	0,16	0,12	0,16	0,24	0,15	0,09	0,25	0,09	0,17	0,13	0,08	0,14	0,08	0,21
4nyl	0,18	0,15	0,18	0,15	0,19	0,18	0,21	0,16	0,21	0,16	0,19	0,27	0,20	0,27	0,24
4o02	0,38	0,39	0,40	0,39	0,35	0,33	0,35	0,32	0,35	0,32	0,24	0,29	0,23	0,29	0,20
4od2	0,34	0,31	0,35	0,31	0,29	0,22	0,32	0,21	0,32	0,24	0,25	0,32	0,33	0,32	0,29
4oif	0,18	0,15	0,25	0,15	0,20	0,11	0,08	0,12	0,08	0,10	0,20	0,11	0,18	0,11	0,15
4qxx	0,17	0,45	0,17	0,45	0,23	0,20	0,19	0,17	0,19	0,17	0,17	0,22	0,18	0,22	0,10
4x7s	0,40	0,17	0,21	0,17	0,22	0,13	0,19	0,20	0,19	0,20	0,17	0,07	0,16	0,07	0,16
4ypg	0,35	0,25	0,41	0,25	0,31	0,25	0,33	0,22	0,33	0,26	0,19	0,17	0,14	0,17	0,24
5csz	0,15	0,26	0,16	0,26	0,20	0,20	0,31	0,15	0,31	0,23	-	-	-	-	-
5dk3	0,12	0,26	0,23	0,26	0,14	0,11	0,16	0,35	0,16	0,16	0,13	0,11	0,10	0,11	0,13
5ggq	0,24	0,17	0,18	0,17	0,19	0,13	0,10	0,16	0,10	0,12	0,11	0,21	0,15	0,21	0,21
5ggu	0,17	0,15	0,18	0,15	0,16	0,15	0,17	0,18	0,17	0,15	0,11	0,11	0,16	0,11	0,18
5i5k	0,24	0,46	0,22	0,46	0,23	0,34	0,51	0,37	0,51	0,30	0,28	0,32	0,29	0,32	0,27
5jxe	0,17	0,14	0,22	0,14	0,15	0,16	0,13	0,31	0,13	0,25	0,14	0,27	0,13	0,27	0,16
5kmv	0,16	0,29	0,20	0,29	0,22	0,09	0,16	0,12	0,16	0,13	0,19	0,12	0,21	0,12	0,19
5l6y	0,27	0,59	0,33	0,59	0,44	0,14	0,32	0,18	0,32	0,21	0,11	0,25	0,13	0,25	0,21
5n2k	0,10	0,19	0,10	0,19	0,14	0,12	0,21	0,14	0,21	0,19	0,18	0,22	0,19	0,22	0,19
5nhw	0,25	0,16	0,24	0,16	0,30	0,23	0,22	0,22	0,22	0,21	0,10	0,07	0,10	0,07	0,15
5sx4	0,29	0,19	0,23	0,19	0,45	0,18	0,14	0,17	0,14	0,25	0,17	0,14	0,14	0,14	0,17
5tru	0,40	0,34	0,29	0,34	0,35	0,20	0,16	0,15	0,16	0,23	0,27	0,19	0,27	0,19	0,28
5vh3	0,23	0,16	0,15	0,16	0,22	0,12	0,11	0,12	0,11	0,12	0,22	0,11	0,11	0,11	0,19
5vkk	0,24	0,28	0,23	0,28	0,20	0,14	0,29	0,25	0,29	0,17	0,10	0,10	0,11	0,10	0,22
5wuv	0,20	0,25	0,28	0,25	0,17	0,11	0,27	0,23	0,27	0,19	0,10	0,14	0,13	0,14	0,18
5xyy	0,37	0,49	0,39	0,49	0,35	0,20	0,33	0,21	0,33	0,19	0,35	0,36	0,28	0,36	0,33
5y9k	0,67	0,44	0,30	0,44	0,40	0,29	0,38	0,39	0,38	0,19	0,09	0,25	0,12	0,25	0,30
6and	0,15	0,42	0,21	0,42	0,23	0,19	0,36	0,22	0,36	0,20	0,10	0,14	0,17	0,14	0,13

Tabla S 3. Valores individuales de RMSD de los anclajes para cada caso de ambos conjuntos de referencia en los bucles de la cadena L (L1, L2 y L3).

	L1					L2					L3				
	AF	ABB1	ABB2	ABlooper	DeepAB	AF	ABB1	ABB2	ABlooper	DeepAB	AF	ABB1	ABB2	ABlooper	DeepAB
1dlf	0,24	0,21	0,26	0,21	0,24	0,31	0,23	0,35	0,23	0,31	0,15	0,09	0,20	0,09	0,14
1fns	0,15	0,15	0,15	0,15	0,12	0,24	0,21	0,26	0,21	0,17	0,13	0,10	0,12	0,10	0,14
1gig	0,23	0,30	0,30	0,30	0,20	0,28	0,37	0,44	0,37	0,27	0,12	0,14	0,27	0,14	0,23
1jfq	0,15	0,12	0,22	0,12	0,16	0,21	0,63	0,26	0,63	0,25	0,15	0,12	0,14	0,12	0,13
1jpt	0,18	0,17	0,15	0,17	0,13	0,10	0,16	0,29	0,16	0,19	0,14	0,18	0,14	0,18	0,15
1mfa	0,19	0,11	0,27	0,11	0,15	0,29	0,33	0,23	0,33	0,17	0,11	0,16	0,25	0,16	0,18
1mlb	0,21	0,23	0,23	0,23	0,14	0,25	0,20	0,27	0,20	0,28	0,19	0,18	0,14	0,18	0,17

1mqk	0,23	0,19	0,20	0,19	0,17	0,24	0,22	0,16	0,22	0,21	0,12	0,16	0,16	0,16	0,18
1nlb	0,14	0,20	0,11	0,20	0,16	0,18	0,26	0,22	0,26	0,12	0,13	0,10	0,12	0,10	0,10
1oaq	0,27	0,31	0,19	0,31	0,11	0,15	0,59	0,17	0,59	0,26	0,10	0,28	0,18	0,28	0,17
1seq	0,12	0,18	0,14	0,18	0,12	0,09	0,17	0,19	0,17	0,16	0,14	0,20	0,17	0,20	0,14
1x9q	0,11	0,14	0,18	0,14	0,13	0,22	0,46	0,33	0,46	0,22	0,13	0,11	0,21	0,11	0,16
2adf	0,25	0,10	0,20	0,10	0,26	0,18	0,13	0,14	0,13	0,17	0,12	0,08	0,11	0,08	0,18
2d7t	0,19	0,24	0,23	0,24	0,19	0,14	0,23	0,19	0,23	0,21	0,11	0,33	0,19	0,33	0,24
2e27	0,19	0,10	0,16	0,10	0,15	0,11	0,09	0,19	0,09	0,29	0,14	0,17	0,17	0,17	0,20
2fb4	0,18	0,22	0,20	0,22	0,11	0,15	0,38	0,26	0,38	0,16	0,17	0,14	0,21	0,17	0,19
2fbj	0,32	0,25	0,30	0,25	0,24	0,29	0,32	0,39	0,32	0,33	0,13	0,29	0,20	0,29	0,17
2r8s	0,15	0,16	0,17	0,16	0,13	0,35	0,47	0,34	0,47	0,33	0,16	0,16	0,14	0,16	0,13
2v17	0,29	0,31	0,25	0,31	0,23	0,28	0,20	0,37	0,20	0,33	0,17	0,13	0,18	0,13	0,17
2vxv	0,12	0,29	0,21	0,29	0,11	0,28	0,61	0,27	0,61	0,32	0,17	0,22	0,22	0,22	0,20
2w60	0,26	0,27	0,28	0,27	0,26	0,27	0,37	0,31	0,37	0,31	0,13	0,19	0,20	0,19	0,17
2xwt	0,19	0,19	0,21	0,19	0,16	0,15	0,34	0,36	0,34	0,28	0,17	0,15	0,23	0,15	0,21
2ypv	0,19	0,31	0,18	0,31	0,15	0,22	0,19	0,29	0,19	0,25	0,12	0,16	0,14	0,16	0,16
3e8u	0,11	0,23	0,12	0,23	0,08	0,15	0,21	0,16	0,21	0,18	0,22	0,35	0,27	0,35	0,19
3eo9	0,15	0,14	0,13	0,14	0,10	0,20	0,36	0,22	0,36	0,17	0,20	0,39	0,21	0,39	0,20
3g5y	0,18	0,17	0,16	0,17	0,21	0,30	0,25	0,25	0,25	0,25	0,18	0,21	0,14	0,21	0,22
3giz	0,15	0,18	0,18	0,18	0,13	0,13	0,32	0,16	0,32	0,15	0,19	0,18	0,26	0,18	0,20
3gnm	0,13	0,20	0,15	0,20	0,11	0,12	0,25	0,16	0,25	0,12	0,21	0,30	0,21	0,30	0,26
3go1	0,11	0,16	0,14	0,16	0,12	0,34	0,41	0,41	0,41	0,42	0,12	0,21	0,13	0,21	0,15
3hc4	0,12	0,11	0,10	0,11	0,11	0,25	0,29	0,30	0,29	0,21	0,14	0,10	0,20	0,10	0,12
3hnt	0,14	0,08	0,19	0,08	0,15	0,37	0,12	0,43	0,12	0,28	0,26	0,12	0,34	0,12	0,25
3i9g	0,27	0,18	0,23	0,18	0,22	0,12	0,30	0,18	0,30	0,14	0,12	0,18	0,13	0,18	0,15
3ifl	0,18	0,10	0,21	0,10	0,19	0,15	0,27	0,14	0,27	0,17	0,17	0,06	0,17	0,06	0,16
3liz	0,33	0,35	0,33	0,35	0,24	0,20	0,24	0,36	0,24	0,22	0,10	0,15	0,14	0,15	0,16
3lmj	0,17	0,23	0,22	0,23	0,16	0,13	0,32	0,28	0,32	0,13	0,16	0,16	0,18	0,16	0,15
3m8o	0,09	0,14	0,23	0,14	0,15	0,20	0,37	0,19	0,37	0,22	0,27	0,14	0,14	0,14	0,16
3mlr	0,24	0,18	0,20	0,18	-	0,14	0,17	0,17	0,17	-	0,15	-	-	-	-
3mxw	0,11	0,20	0,14	0,20	0,08	0,15	0,17	0,17	0,17	0,14	0,13	0,11	0,16	0,11	0,14
3nps	0,13	0,20	0,18	0,20	0,13	0,30	0,60	0,36	0,60	0,46	0,10	0,13	0,21	0,13	0,12
3oz9	0,14	0,27	0,21	0,27	0,27	0,14	0,41	0,18	0,41	0,24	0,11	0,20	0,20	0,20	0,12
3p0y	0,12	0,14	0,19	0,14	0,10	0,08	0,22	0,12	0,22	0,12	0,13	0,10	0,16	0,10	0,14
3t65	0,17	0,18	0,13	0,18	0,17	0,15	0,22	0,26	0,22	0,18	0,10	0,13	0,17	0,13	0,13
3umt	0,22	0,36	0,20	0,36	0,25	0,24	0,48	0,23	0,48	0,32	0,13	0,27	0,15	0,27	0,19
3v0w	0,18	0,32	0,18	0,32	0,18	0,16	0,31	0,21	0,31	0,21	0,12	0,15	0,16	0,15	0,17
4f57	0,13	0,12	0,13	0,12	0,12	0,17	0,17	0,14	0,17	0,20	0,13	0,11	0,13	0,11	0,16
4h0h	0,27	0,29	0,25	0,29	0,23	0,11	0,15	0,22	0,15	0,14	0,10	0,13	0,19	0,13	0,13
4h20	0,19	0,30	0,26	0,30	0,25	0,17	0,25	0,20	0,25	0,18	0,16	0,41	0,16	0,41	0,09
4hpy	0,15	0,13	0,10	0,13	0,09	0,19	0,30	0,18	0,30	0,14	0,10	0,11	0,12	0,11	0,15
4nzu	0,23	0,13	0,27	0,13	0,26	0,23	0,25	0,40	0,25	0,24	0,12	0,09	0,14	0,09	0,18
1bey	0,34	0,35	0,34	0,35	0,36	0,22	0,27	0,22	0,27	0,26	0,29	0,36	0,27	0,36	0,30
1cz8	0,22	0,19	0,22	0,19	0,16	0,13	0,18	0,13	0,18	0,19	0,13	0,19	0,16	0,19	0,14
1mim	0,26	0,18	0,26	0,18	0,22	0,30	0,24	0,30	0,24	0,31	0,24	0,19	0,24	0,19	0,23
1sy6	0,14	0,22	0,14	0,22	0,20	0,16	0,24	0,16	0,24	0,18	0,19	0,13	0,26	0,13	0,21
1yy8	0,18	0,17	0,18	0,17	0,19	0,11	0,17	0,11	0,17	0,17	0,14	0,16	0,17	0,16	0,16
2hwz	0,19	0,27	0,19	0,27	0,26	0,19	0,39	0,19	0,39	0,25	0,18	0,21	0,22	0,21	0,18
3b2u	0,20	0,22	0,20	0,22	0,14	0,25	0,29	0,25	0,29	0,25	0,17	0,38	0,17	0,38	0,15
3c08	-	-	-	-	-	0,21	0,24	0,21	0,24	0,13	0,24	0,18	0,14	0,18	0,21
3eo0	0,15	0,12	0,15	0,12	0,15	0,11	0,12	0,11	0,12	0,16	0,09	0,27	0,10	0,27	0,13
3gkw	0,22	0,29	0,22	0,29	0,24	0,19	0,25	0,19	0,25	0,19	0,17	0,19	0,15	0,19	0,19
3hmw	0,15	0,28	0,15	0,28	0,13	0,23	0,32	0,23	0,32	0,28	0,21	0,37	0,22	0,37	0,19
3nfs	0,20	0,23	0,20	0,23	0,13	0,17	0,20	0,17	0,20	0,32	0,25	0,33	0,28	0,33	0,23
3o2d	0,18	0,20	0,18	0,20	0,11	0,20	0,17	0,20	0,17	0,12	0,10	0,24	0,13	0,24	0,13
3pp3	0,19	0,24	0,19	0,24	0,13	0,37	0,32	0,37	0,32	0,26	0,19	0,14	0,16	0,14	0,16
3qw0	0,14	0,11	0,14	0,11	0,13	0,38	0,20	0,38	0,20	0,26	0,09	0,10	0,14	0,10	0,15
3s34	0,15	0,25	0,15	0,25	0,13	0,16	0,21	0,16	0,21	0,17	0,12	0,15	0,13	0,15	0,15
3u0t	0,14	0,20	0,14	0,20	0,11	0,26	0,41	0,26	0,41	0,21	0,12	0,14	0,16	0,14	0,17
4cni	0,18	0,25	0,18	0,25	0,19	0,17	0,22	0,17	0,22	0,15	0,09	0,16	0,11	0,16	0,14
4d9q	0,19	0,13	0,19	0,13	0,14	0,18	0,24	0,18	0,24	0,22	0,12	0,15	0,14	0,15	0,16

4dn3	0,12	0,16	0,12	0,16	0,09	0,22	0,40	0,22	0,40	0,23	0,19	0,14	0,17	0,14	0,13
4edw	0,17	0,27	0,17	0,27	0,14	0,25	0,30	0,25	0,30	0,35	0,11	0,19	0,13	0,19	0,16
4g5z	0,30	0,18	0,30	0,18	0,27	0,14	0,21	0,14	0,21	0,21	0,16	0,13	0,16	0,13	0,11
4g6k	0,13	0,10	0,13	0,10	0,15	0,13	0,15	0,13	0,15	0,18	0,12	0,09	0,16	0,09	0,10
4hkz	0,17	0,17	0,17	0,17	0,14	0,13	0,17	0,13	0,17	0,15	0,08	0,17	0,13	0,17	0,07
4i77	0,14	0,18	0,14	0,18	0,11	0,09	0,27	0,09	0,27	0,18	0,16	0,14	0,11	0,14	0,12
4irz	0,17	0,22	0,17	0,22	0,17	0,23	0,19	0,23	0,19	0,29	0,18	0,14	0,17	0,14	0,25
4k3j	0,18	0,31	0,18	0,31	0,15	0,16	0,35	0,16	0,35	0,17	0,13	0,25	0,15	0,25	0,17
4kaq	0,11	0,26	0,11	0,26	0,15	0,19	0,21	0,19	0,21	0,16	0,14	0,26	0,17	0,26	0,14
4m6n	0,19	0,08	0,19	0,08	0,14	0,28	0,13	0,28	0,13	0,14	0,10	0,10	0,16	0,10	0,11
4nyl	0,15	0,21	0,15	0,21	0,11	0,21	0,30	0,21	0,30	0,22	0,13	0,19	0,14	0,19	0,13
4o02	0,23	0,24	0,23	0,24	0,25	0,29	0,32	0,29	0,32	0,29	0,26	0,23	0,22	0,23	0,24
4od2	0,28	0,29	0,28	0,29	0,17	0,34	0,33	0,34	0,33	0,33	0,23	0,27	0,28	0,27	0,25
4oif	0,28	0,12	0,28	0,12	0,21	0,23	0,14	0,23	0,14	0,18	0,15	0,06	0,21	0,06	0,12
4qyg	0,20	0,22	0,20	0,22	0,17	0,18	0,27	0,18	0,27	0,15	0,09	0,15	0,11	0,15	0,13
4x7s	0,10	0,14	0,10	0,14	0,10	0,10	0,20	0,10	0,20	0,18	0,08	0,17	0,11	0,17	0,10
4ypg	0,14	0,20	0,14	0,20	0,16	0,27	0,23	0,27	0,23	0,25	0,13	0,17	0,15	0,17	0,12
5csz	0,10	0,14	0,10	0,14	0,08	0,21	0,22	0,21	0,22	0,13	0,17	0,16	0,17	0,16	0,16
5dk3	0,14	0,18	0,14	0,18	0,12	0,09	0,19	0,09	0,19	0,23	0,13	0,12	0,13	0,12	0,11
5ggq	0,13	0,07	0,13	0,07	0,10	0,10	0,15	0,10	0,15	0,12	0,15	0,11	0,15	0,11	0,12
5ggu	0,26	0,16	0,26	0,16	0,25	0,17	0,20	0,17	0,20	0,16	0,11	0,19	0,11	0,19	0,12
5i5k	0,53	0,49	0,53	0,49	0,55	0,35	0,56	0,35	0,56	0,29	0,39	0,41	0,39	0,41	0,34
5jxe	0,17	0,15	0,17	0,15	0,15	0,36	0,45	0,36	0,45	0,40	0,16	0,26	0,16	0,26	0,16
5kmv	0,17	0,17	0,17	0,17	0,20	0,27	0,20	0,27	0,20	0,24	0,14	0,10	0,14	0,10	0,19
5l6y	0,12	0,26	0,12	0,26	0,09	0,13	0,40	0,13	0,40	0,18	0,09	0,19	0,09	0,19	0,11
5n2k	0,20	0,20	0,20	0,20	0,11	0,13	0,26	0,13	0,26	0,18	0,13	0,21	0,13	0,21	0,19
5nhw	0,11	0,16	0,11	0,16	0,10	0,23	0,24	0,23	0,24	0,26	0,10	0,13	0,10	0,13	0,13
5sx4	0,23	0,08	0,23	0,08	0,23	0,16	0,21	0,16	0,21	0,19	0,17	0,10	0,17	0,10	0,25
5tru	0,19	0,15	0,19	0,15	0,13	0,18	0,16	0,18	0,16	0,17	0,13	0,22	0,13	0,22	0,16
5vh3	0,43	0,43	0,43	0,43	0,30	0,17	0,15	0,17	0,15	0,12	0,09	0,20	0,09	0,20	0,08
5vkk	0,07	0,24	0,07	0,24	0,19	0,18	0,25	0,18	0,25	0,20	0,17	0,14	0,17	0,14	0,20
5wuv	0,24	0,33	0,24	0,33	0,23	0,10	0,21	0,10	0,21	0,13	0,11	0,14	0,11	0,14	0,10
5xyy	0,21	0,21	0,21	0,21	0,19	0,09	0,26	0,09	0,26	0,15	0,18	0,28	0,18	0,28	0,13
5y9k	0,15	0,17	0,15	0,17	0,16	0,26	0,14	0,26	0,14	0,25	0,12	0,14	0,12	0,14	0,19
6and	-	-	-	-	-	0,24	0,30	0,24	0,30	0,21	0,10	0,13	0,10	0,13	0,14

6.4 Figuras suplementarias




Figura S 1. Distribuciones de Ramachandran específicas de posiciones equivalentes en bucles H2, junto a la distribución final que las agrupa: H2_5/0, H2_6/0 y H2_8/0 en H2/0; y H2_5/1, H2_8/1, H2_8/2 en H2/1.

6.5 Ejemplo de código

➤ Código Mapas CDR en RCD (en C++)

```
// MAP INDEX STUFF

int mdy; //map delay: for each CRR take account it 0 map according to
the position in the map.bin

if (h3_switch) {           // maps 0-28

    // anchors
    if (h3NtShift<4)
        map_index[0]=21+h3NtShift;
    else map_index[0]=-1;
    merge_index[0]=kink_mergeA;

    if (h3CtShift<4)
        map_index[nr_loop+1]= 28-h3CtShift;
    else map_index[nr_loop+1]=-1;
    merge_index[nr_loop+1]=kink_mergeA;

    // LOOP rest of AAs
    for(int i=1;i<nr_loop+1;i++) {
        map_index[i]=-1;
        if ( (i + h3NtShift) < 4)    // Kink Nt
        {
            map_index[i]=(21+i+h3NtShift);
            merge_index[i]=kink_merge;
        }
        else if ((i + h3CtShift) >=nr_loop-2) { // kink Ct
            map_index[i] = (27+i-nr_loop-
h3CtShift);
            merge_index[i]=kink_merge;
        }
        else merge_index[i]= nokink_merge;
    }
}

else if (h1_switch) {      // maps 29-37
    mdy=29;
    if (nr_loop == 7)
        for(int i=0;i<nr_loop+2;i++)
            map_index[i]=i+mdy;

    else if (nr_loop == 8){
        for(int i=0;i<nr_loop+2;i++)
            map_index[i]=-1;
        map_index[0]=7+mdy;
        map_index[1]=1+mdy;
        map_index[2]=2+mdy;
        map_index[4]=5+mdy;
        map_index[5]=6+mdy;
    }

    else if (nr_loop == 9) {
        for(int i=0;i<6;i++)
            map_index[i]=i+mdy;
        for(int i=6;i<nr_loop+2;i++)
            map_index[i]=-1;
    }
}
```

```

        map_index[3]=0+mdy;
        map_index[10]=7+mdy;
        map_index[9]=7+mdy;
    }
    else{
        for(int i=0;i<nr_loop+2;i++)
            map_index[i]=-1;
    }

    for(int i=0;i<nr_loop+2;i++)
        merge_index[i]= nokink_merge;
}

else if (h2_switch ) {    // maps 38-50
    mdy=38;
    if (nr_loop == 5) {
        map_index[0]=0+mdy;        //-      0      X
        map_index[1]=1+mdy;        //-      1      Y
        map_index[2]=3+mdy;        //-      3      H1
        map_index[3]=4+mdy;        //-      4      H2
        map_index[4]=6+mdy;        //-      6      L0
        map_index[5]=10+mdy;       //-     10      Z1
        map_index[6]=12+mdy;       //-     12      Xf
    }
    else if (nr_loop == 6) {
        map_index[0]=0+mdy;        //-      0      X
        map_index[1]=2+mdy;        //-      2      Y2
        map_index[2]=3+mdy;        //-      3      H1
        map_index[3]=5+mdy;        //-      5      H1+H2
        map_index[4]=7+mdy;        //-      7      L1
        map_index[5]=8+mdy;        //-      8      L2
        map_index[6]=11+mdy;       //-     11      Z2
        map_index[7]=12+mdy;       //-     12      Xf
    }
    else if (nr_loop == 7) {
        map_index[0]=0+mdy;        //-      0      X
        map_index[1]=-1;           //-
        map_index[2]=-1;           //-
        map_index[3]=-1;           //-
        map_index[4]=-1;           //-      7      L1

        map_index[5]=-1;           //-
        map_index[6]=-1;           //-
        map_index[7]=11+mdy;       //-     11      Z2
        map_index[8]=12+mdy;       //-     12      Xf
    }
    else if (nr_loop == 8) {
        map_index[0]=0+mdy;        //-      0      X
        map_index[1]=1+mdy;        //-      1      Y
        map_index[2]=1+mdy;        //-      1      Y
        map_index[3]=3+mdy;        //-      3      H1
        map_index[4]=3+mdy;        //-      3      H1
        map_index[5]=4+mdy;        //-      4      H2
        map_index[6]=9+mdy;        //-      9      L3
        map_index[7]=9+mdy;        //-      9      L3
        map_index[8]=10+mdy;       //-     10      Z1
        map_index[9]=12+mdy;       //-     12      Xf
    }
    else{

```

```

        for(int i=0;i<nr_loop+2;i++)
            map_index[i]=-1;
X      map_index[0]=0+mdy;          //-      0
      map_index[nr_loop+1]=12+mdy;      //-      12
Xf    }

      for(int i=0;i<nr_loop+2;i++)
        merge_index[i]= nokink_merge;
}

else if ( ll_switch) {      // maps 51-108
    mdy=51;
    if (nr_loop == 11){
        for(int i=0;i<nr_loop+2;i++)
            map_index[i]=i+mdy;
    }
    else if (nr_loop == 12){
        for(int i=0;i<6;i++)
            map_index[i]=i+mdy;

        map_index[6]=13+mdy;
        map_index[7]=5+mdy;
        map_index[8]=14+mdy;
        map_index[9]=15+mdy;
        map_index[10]=16+mdy;

        for(int i=11;i<nr_loop+2;i++)
            map_index[i]=i-1;
    }
    else if (nr_loop == 13){
        for(int i=0;i<2;i++)
            map_index[i]=i+mdy;
        for(int i=2;i<12;i++)
            map_index[i]=15+i+mdy;
        for(int i=12;i<nr_loop+2;i++)
            map_index[i]=i-2+mdy;
    }

    else if (nr_loop == 14){
        for(int i=0;i<2;i++)
            map_index[i]=i+mdy;
        for(int i=2;i<6;i++)
            map_index[i]=15+i+mdy;
        for(int i=6;i<13;i++)
            map_index[i]=21+i+mdy;
        for(int i=13;i<nr_loop+2;i++)
            map_index[i]=i-3+mdy;
    }
    else if (nr_loop == 15){
        for(int i=0;i<6;i++)
            map_index[i]=i+mdy;
        for(int i=6;i<13;i++)
            map_index[i]=28+i+mdy;
        for(int i=13;i<nr_loop+2;i++)
            map_index[i]=i-4+mdy;
    }
    else if (nr_loop == 16){
        for(int i=0;i<6;i++)
            map_index[i]=i+mdy;

```

```

        for(int i=6;i<14;i++)
            map_index[i]=35+i+mdy;
        for(int i=14;i<nr_loop+2;i++)
            map_index[i]=i-5+mdy;
    }
    else if (nr_loop == 17){
        for(int i=0;i<6;i++)
            map_index[i]=i+mdy;
        for(int i=6;i<15;i++)
            map_index[i]=43+i+mdy;
        for(int i=15;i<nr_loop+2;i++)
            map_index[i]=i-6+mdy;
    }
    else{
        for(int i=0;i<nr_loop+2;i++)
            map_index[i]=-1;
        int lnt, lct;
        if (nr_loop >= 10) { lnt=6; lct=4;}
        else if (nr_loop == 9) { lnt=4; lct=3;}
        else if (nr_loop == 8) { lnt=3; lct=3;}
        else if (nr_loop == 7) { lnt=2; lct=2;}
        else { lnt=0; lct=0;}

        for(int i=0;i<lnt;i++)
            map_index[i]=i+mdy;
        for(int i=0; i<lct;i++)
            map_index[nr_loop-2+i]=9+i+mdy;
    }

    for(int i=0;i<nr_loop+2;i++)
        merge_index[i]= nokink_merge;
}

else if (l2_switch ) { // maps 109-117
    mdy=109;
    if (nr_loop == 7) {
        for(int i=0;i<nr_loop+2;i++)
            map_index[i]=i+mdy;
    }
    else{
        for(int i=0;i<nr_loop+2;i++)
            map_index[i]=-1;
    }

    for(int i=0;i<nr_loop+2;i++)
        merge_index[i]= nokink_merge;
}

else if (l3_switch ) { // maps 118-142
    mdy=118;
    for(int i=0;i<nr_loop+2;i++)
        merge_index[i]= nokink_merge;

    if (nr_loop == 8) {
        map_index[0]=0+mdy; // - 0 X1
        map_index[1]=1+mdy; // - 1 X2
        map_index[2]=2+mdy; // - 2 X3
        map_index[3]=7+mdy; // - 7 D1
        map_index[4]=8+mdy; // - 8 H1
        map_index[5]=-1; // - -1 -1
        map_index[6]=11+mdy; // - 11 G1
    }
}

```

```

        map_index[7]=22+mdy;        //-        22        Xf3
        map_index[8]=23+mdy;        //-        23        Xf2
        map_index[9]=24+mdy;        //-        24        Xf1
    }
    else if (nr_loop == 9) {
        map_index[0]=0+mdy;        //-        0        X1
        map_index[1]=1+mdy;        //-        1        X2
        map_index[2]=2+mdy;        //-        2        X3
        map_index[3]=-1;           //-        -1        -1
        map_index[4]=-1;           //-        -1        -1
        map_index[5]=-1;           //-        -1        -1
        map_index[6]=-1;           //-        -1        -1
        map_index[7]=-1;           //-        -1        -1
        map_index[8]=-1;           //-        -1        -1
        map_index[9]=23+mdy;        //-        23        Xf2
        map_index[10]=24+mdy;       //-        24        Xf1

        if(islower(pdbfile[i_pdb].sequence[7])) {
            fprintf(stdout," detect
%c\n",pdbfile[i_pdb].sequence[7]);
            map_index[3]=7+mdy;        //-        7
            D1
            map_index[4]=8+mdy;        //-        8
            H1
            map_index[5]=10+mdy;       //-        10
            X7
            map_index[6]=14+mdy;       //-        14
            B1
            map_index[7]=15+mdy;       //-        15
            B2
            map_index[8]=16+mdy;       //-        16
            B3
        }
    }

    else if (nr_loop == 10) {
        map_index[0]=0+mdy;        //-        0        X1
        map_index[1]=1+mdy;        //-        1        X2
        map_index[2]=3+mdy;        //-        3        X4
        map_index[3]=5+mdy;        //-        5        X6
        map_index[4]=-1;           //-        -1        -1
        map_index[5]=9+mdy;        //-        9        H2
        map_index[6]=12+mdy;       //-        12        H3
        map_index[7]=17+mdy;       //-        17        L0
        map_index[8]=19+mdy;       //-        19        X8
        map_index[9]=22+mdy;       //-        22        Xf3
        map_index[10]=23+mdy;      //-        23        Xf2
        map_index[11]=24+mdy;      //-        24        Xf1
    }
    else if (nr_loop == 11) {
        map_index[0]=0+mdy;        //-        0        X1
        map_index[1]=1+mdy;        //-        1        X2
        map_index[2]=4+mdy;        //-        4        X5
        map_index[3]=5+mdy;        //-        5        X6
        map_index[4]=6+mdy;        //-        6        B0
        map_index[5]=9+mdy;        //-        9        H2
        map_index[6]=9+mdy;        //-        9        H2
        map_index[7]=13+mdy;       //-        13        H4
        map_index[8]=18+mdy;       //-        18        L1
        map_index[9]=20+mdy;       //-        20        X9
    }

```

```

        map_index[10]=21+mdy;        //-        21        Xf4
        map_index[11]=23+mdy;        //-        23        Xf2
        map_index[12]=24+mdy;        //-        24        Xf1
    }
    else if (nr_loop == 12) {
        map_index[0]=0+mdy;           //-        0        X1
        map_index[1]=1+mdy;           //-        1        X2
        map_index[2]=4+mdy;           //-        4        X5
        map_index[3]=5+mdy;           //-        5        X6
        map_index[4]=6+mdy;           //-        6        B0
        map_index[5]=9+mdy;           //-        9        H2
        map_index[6]=-1;              //-       -1       -1
        map_index[7]=-1;              //-       -1       -1
        map_index[8]=12+mdy;          //-       12        H3
        map_index[9]=17+mdy;          //-       17        L0
        map_index[10]=-1;             //-       -1       -1
        map_index[11]=22+mdy;         //-       22        Xf3
        map_index[12]=23+mdy;         //-       23        Xf2
        map_index[13]=24+mdy;         //-       24        Xf1
    }
    else if (nr_loop == 13) {
        map_index[0]=0+mdy;           //-        0        X1
        map_index[1]=1+mdy;           //-        1        X2
        map_index[2]=4+mdy;           //-        4        X5
        map_index[3]=1+mdy;           //-        1        X2
        map_index[4]=-1;              //-       -1       -1
        map_index[5]=-1;              //-       -1       -1
        map_index[6]=-1;              //-       -1       -1
        map_index[7]=-1;              //-       -1       -1
        map_index[8]=-1;              //-       -1       -1
        map_index[9]=-1;              //-       -1       -1
        map_index[10]=21+mdy;         //-       21        Xf4
        map_index[11]=10+mdy;         //-       10        X7
        map_index[12]=22+mdy;         //-       22        Xf3
        map_index[13]=10+mdy;         //-       13        Xf2
        map_index[14]=24+mdy;         //-       24        Xf1
    }

    else{
        for(int i=2;i<nr_loop;i++)
            map_index[i]=-1;

        map_index[0]=0+mdy;           //-        0
X1
        map_index[1]=1+mdy;           //-        1
X2
        map_index[nr_loop]=23+mdy;    //-       23        Xf2
        map_index[nr_loop+1]=24+mdy;  //-       24
Xf1
    }
}

if (ab_switch) {
    printf ("rcd> Map index");
    for(int i=0;i<nr_loop+2;i++)
        printf ("%d ",map_index[i]);
    printf ("\n");
}

```

7. Bibliografía

- Abanades, B., Georges, G., Bujotzek, A., & Deane, C. M. (2022). ABlooper: fast accurate antibody CDR loop structure prediction with accuracy estimation. *Bioinformatics*, 38(7), 1877–1880. <https://doi.org/10.1093/BIOINFORMATICS/BTAC016>
- Abanades, B., Wong, W. K., Boyles, F., Georges, G., Bujotzek, A., & Deane, C. M. (2023a). ImmuneBuilder: Deep-Learning models for predicting the structures of immune proteins. *Communications Biology* 2023 6:1, 6(1), 1–8. <https://doi.org/10.1038/s42003-023-04927-7>
- Abanades, B., Wong, W. K., Boyles, F., Georges, G., Bujotzek, A., & Deane, C. M. (2023b). ImmuneBuilder: Deep-Learning models for predicting the structures of immune proteins. *Communications Biology* 2023 6:1, 6(1), 1–8. <https://doi.org/10.1038/s42003-023-04927-7>
- Abhinandan, K. R., & Martin, A. C. R. (2008). Analysis and improvements to Kabat and structurally correct numbering of antibody variable domains. *Molecular Immunology*, 45(14), 3832–3839. <https://doi.org/10.1016/J.MOLIMM.2008.05.022>
- Adolf-Bryfogle, J., Xu, Q., North, B., Lehmann, A., & Dunbrack, R. L. (2015). PylgClassify: a database of antibody CDR structural classifications. *Nucleic Acids Research*, 43(Database issue), D432–D438. <https://doi.org/10.1093/NAR/GKU1106>
- Alberts, B., Johnson, A., Lewis, J., Raff, M., Roberts, K., & Walter, P. (2002). *The Generation of Antibody Diversity*. <https://www.ncbi.nlm.nih.gov/books/NBK26860/>
- Al-Lazikani, B., Lesk, A. M., & Chothia, C. (1997). Standard conformations for the canonical structures of immunoglobulins. *Journal of Molecular Biology*, 273(4), 927–948. <https://doi.org/10.1006/JMBI.1997.1354>
- Amzel, L. M., & Poljak, R. J. (1979). Three-Dimensional Structure of Immunoglobulins. *Annual Review of Biochemistry*, 48(Volume 48, 1979), 961–997. <https://doi.org/10.1146/ANNUREV.BI.48.070179.004525>
- Antibody | Definition, Structure, Function, & Types | Britannica*. (n.d.). Retrieved August 28, 2023, from <https://www.britannica.com/science/antibody>

- Arnaout, R., Lee, W., Cahill, P., Honan, T., Sparrow, T., Weiland, M., Nusbaum, C., Rajewsky, K., & Koralov, S. B. (2011). High-Resolution Description of Antibody Heavy-Chain Repertoires in Humans. *PLOS ONE*, 6(8), e22365. <https://doi.org/10.1371/JOURNAL.PONE.0022365>
- Babor, M., & Kortemme, T. (2009). Multi-constraint Computational Design Suggests that Native Sequences of Germline Antibody H3 Loops are Nearly Optimal for Conformational Flexibility. *Proteins*, 75(4), 846. <https://doi.org/10.1002/PROT.22293>
- Baek, M., DiMaio, F., Anishchenko, I., Dauparas, J., Ovchinnikov, S., Lee, G. R., Wang, J., Cong, Q., Kinch, L. N., Dustin Schaeffer, R., Millán, C., Park, H., Adams, C., Glassman, C. R., DeGiovanni, A., Pereira, J. H., Rodrigues, A. V., Van Dijk, A. A., Ebrecht, A. C., ... Baker, D. (2021). Accurate prediction of protein structures and interactions using a three-track neural network. *Science*, 373(6557), 871–876. https://doi.org/10.1126/SCIENCE.ABJ8754/SUPPL_FILE/ABJ8754_MДАР_REPRODUCIBILITY_CHECKLIST.PDF
- Baker, M. (2009). *Circumventing immunogenicity in the development of therapeutic antibodies*. <https://www.researchgate.net/publication/24261437>
- Barozet, A., Chacón, P., & Cortés, J. (2021). Current approaches to flexible loop modeling. *Current Research in Structural Biology*, 3, 187–191. <https://doi.org/10.1016/J.CRSTBI.2021.07.002>
- Bartlett, G. J., Porter, C. T., Borkakoti, N., & Thornton, J. M. (2002). Analysis of Catalytic Residues in Enzyme Active Sites. *Journal of Molecular Biology*, 324(1), 105–121. [https://doi.org/10.1016/S0022-2836\(02\)01036-7](https://doi.org/10.1016/S0022-2836(02)01036-7)
- Beckers, B., & Beckers, P. (2012). A general rule for disk and hemisphere partition into equal-area cells. *Computational Geometry*, 45, 275–283. <https://doi.org/10.1016/j.comgeo.2012.01.011>
- Benevenuta, S., Pancotti, C., Fariselli, P., Birolo, G., & Sanavia, T. (2021). An antisymmetric neural network to predict free energy changes in protein variants. *Journal of Physics D: Applied Physics*, 54(24), 245403. <https://doi.org/10.1088/1361-6463/ABEDFB>

- Berman, H. M., Westbrook, J., Feng, Z., Gilliland, G., Bhat, T. N., Weissig, H., Shindyalov, I. N., & Bourne, P. E. (2000). The Protein Data Bank. *Nucleic Acids Research*, 28(1), 235–242. <https://doi.org/10.1093/NAR/28.1.235>
- bioinf.org.uk* - Prof. Andrew C.R. Martin's group at UCL. (n.d.). Retrieved June 4, 2025, from <http://www.bioinf.org.uk/abs/info.html>
- Canutescu, A. A., & Dunbrack, R. L. (2003). Cyclic coordinate descent: A robotics algorithm for protein loop closure. *Protein Science*, 12(5), 963–972. <https://doi.org/10.1110/PS.0242703>
- Cao, Y. J., Yu, C., Wu, K. L., Wang, X., Liu, D., Tian, Z., Zhao, L., Qi, X., Loredó, A., Chung, A., & Xiao, H. (2021). Synthesis of precision antibody conjugates using proximity-induced chemistry. *Theranostics*, 11(18), 9107. <https://doi.org/10.7150/THNO.62444>
- Charles A Janeway, J., Travers, P., Walport, M., & Shlomchik, M. J. (2001a). *The structure of a typical antibody molecule*. Garland Science.
- Charles A Janeway, J., Travers, P., Walport, M., & Shlomchik, M. J. (2001b). *The structure of a typical antibody molecule*. <https://www.ncbi.nlm.nih.gov/books/NBK27144/>
- Chaudhury, S., Lyskov, S., & Gray, J. J. (2010). PyRosetta: a script-based interface for implementing molecular modeling algorithms using Rosetta. *Bioinformatics (Oxford, England)*, 26(5), 689–691. <https://doi.org/10.1093/BIOINFORMATICS/BTQ007>
- Chaves, E. J. F., Coêlho, D. F., Cruz, C. H. B., Moreira, E. G., Simões, J. C. M., Nascimento-Filho, M. J., & Lins, R. D. (2025). Structure-based computational design of antibody mimetics: challenges and perspectives. *FEBS Open Bio*, 15(2), 223–235. <https://doi.org/10.1002/2211-5463.13855>
- Chiu, M. L., Goulet, D. R., Teplyakov, A., & Gilliland, G. L. (2019). Antibody Structure and Function: The Basis for Engineering Therapeutics. *Antibodies 2019, Vol. 8, Page 55*, 8(4), 55. <https://doi.org/10.3390/ANTIB8040055>

- Choi, Y., & Deane, C. M. (2010a). FREAD revisited: Accurate loop structure prediction using a database search algorithm. *Proteins: Structure, Function, and Bioinformatics*, 78(6), 1431–1440. <https://doi.org/10.1002/PROT.22658>
- Choi, Y., & Deane, C. M. (2010b). FREAD revisited: Accurate loop structure prediction using a database search algorithm. *Proteins: Structure, Function, and Bioinformatics*, 78(6), 1431–1440. <https://doi.org/10.1002/PROT.22658>
- Chothia, C., & Lesk, A. M. (1987a). Canonical structures for the hypervariable regions of immunoglobulins. *Journal of Molecular Biology*, 196(4), 901–917. [https://doi.org/10.1016/0022-2836\(87\)90412-8](https://doi.org/10.1016/0022-2836(87)90412-8)
- Chothia, C., & Lesk, A. M. (1987b). Canonical structures for the hypervariable regions of immunoglobulins. *Journal of Molecular Biology*, 196(4), 901–917. [https://doi.org/10.1016/0022-2836\(87\)90412-8](https://doi.org/10.1016/0022-2836(87)90412-8)
- Chothia, C., Lesk, A. M., Tramontano, A., Levitt, M., Smith-Gill, S. J., Air, G., Sheriff, S., Padlan, E. A., Davies, D., Tulip, W. R., Colman, P. M., Spinelli, S., Alzari, P. M., & Poljak, R. J. (1989). Conformations of immunoglobulin hypervariable regions. *Nature*, 342(6252), 877–883. <https://doi.org/10.1038/342877A0>
- Chys, P., & Chacón, P. (2012). Spinor product computations for protein conformations. *Journal of Computational Chemistry*, 33(21), 1717–1729. <https://doi.org/10.1002/JCC.23002>
- Chys, P., & Chacón, P. (2013). Random coordinate descent with spinor-matrices and geometric filters for efficient loop closure. *Journal of Chemical Theory and Computation*, 9(3), 1821–1829. <https://doi.org/10.1021/ct300977f>
- Cohen, S. (1975). Antibody structure. *Journal of Clinical Pathology. Supplement (Ass. Clin. Path.)*, 6, 1–7. <https://doi.org/10.1128/MICROBIOLSPEC.AID-0012-2013/ASSET/91654D45-F4DE-441D-A6CD-3CD2B33AD48F/ASSETS/GRAPHIC/AID-0012-2013-FIG5.GIF>
- Coutsias, E. A., Seok, C., Jacobson, M. P., & Dill, K. A. (2004). A kinematic view of loop closure. *Journal of Computational Chemistry*, 25(4), 510–528. <https://doi.org/10.1002/JCC.10416>

- Davies, D. R., & Metzger, H. (1983). Structural basis of antibody function. *Annual Review of Immunology*, 1(Volume 1, 1983), 87–117. <https://doi.org/10.1146/ANNUREV.IY.01.040183.000511/CITE/REFWORKS>
- Deane, C. M., & Blundell, T. L. (2001). CODA: A combined algorithm for predicting the structurally variable regions of protein models. *Protein Science*, 10(3), 599–612. <https://doi.org/10.1110/PS.37601>
- Documentation – Rosetta Commons*. (n.d.). Retrieved March 12, 2025, from <https://rosettacommons.org/software/documentation/>
- Dondelinger, M., Filée, P., Sauvage, E., Quinting, B., Muyldermans, S., Galleni, M., & Vandevenne, M. S. (2018). Understanding the significance and implications of antibody numbering and antigen-binding surface/residue definition. *Frontiers in Immunology*, 9(OCT), 2278. <https://doi.org/10.3389/FIMMU.2018.02278/PDF>
- Dreyer, F. A., Schneider, C., Kovaltsuk, A., Cutting, D., Byrne, M. J., Nissley, D. A., Wahome, N., Kenlay, H., Marks, C., Errington, D., Gildea, R. J., Damerell, D., Tizei, P., Bunjobpol, W., Darby, J. F., Drulyte, I., Hurdiss, D. L., Surade, S., Pires, D. E. V., & Deane, C. M. (2024). Computational design of developable therapeutic antibodies: efficient traversal of binder landscapes and rescue of escape mutations. *BioRxiv*, 2024.10.03.616038. <https://doi.org/10.1101/2024.10.03.616038>
- Duan, L., & Mukherjee, E. (2016). Janeway’s Immunobiology, Ninth Edition. *The Yale Journal of Biology and Medicine*, 89(3), 424. <https://pmc.ncbi.nlm.nih.gov/articles/PMC5045153/>
- Ducancel, F., & Muller, B. H. (2012). Molecular engineering of antibodies for therapeutic and diagnostic purposes. *MABs*, 4(4), 445–457. <https://doi.org/10.4161/MABS.20776>
- Dunbar, J., Krawczyk, K., Leem, J., Baker, T., Fuchs, A., Georges, G., Shi, J., & Deane, C. M. (2014a). SAbDab: the structural antibody database. *Nucleic Acids Research*, 42(D1), D1140–D1146. <https://doi.org/10.1093/NAR/GKT1043>
- Dunbar, J., Krawczyk, K., Leem, J., Baker, T., Fuchs, A., Georges, G., Shi, J., & Deane, C. M. (2014b). SAbDab: the structural antibody database. *Nucleic Acids Research*, 42(D1), D1140–D1146. <https://doi.org/10.1093/NAR/GKT1043>

- Eastman, P., Swails, J., Chodera, J. D., McGibbon, R. T., Zhao, Y., Beauchamp, K. A., Wang, L. P., Simmonett, A. C., Harrigan, M. P., Stern, C. D., Wiewiora, R. P., Brooks, B. R., & Pande, V. S. (2017). OpenMM 7: Rapid development of high performance algorithms for molecular dynamics. *PLOS Computational Biology*, 13(7), e1005659. <https://doi.org/10.1371/JOURNAL.PCBI.1005659>
- Ferdous, S., & Martin, A. C. R. (2018). AbDb: antibody structure database—a database of PDB-derived antibody structures. *Database: The Journal of Biological Databases and Curation*, 2018(2018). <https://doi.org/10.1093/DATABASE/BAY040>
- Fernandez-Fuentes, N., Zhai, J., & Fiser, A. (2006). ArchPRED: a template based loop structure prediction server. *Nucleic Acids Research*, 34(Web Server issue), W173. <https://doi.org/10.1093/NAR/GKL113>
- Fersht, A. (1985). *Enzyme structure and mechanism*. 475.
- Fiser, A., & Sali, A. (2003). ModLoop: automated modeling of loops in protein structures. *Bioinformatics (Oxford, England)*, 19(18), 2500–2501. <https://doi.org/10.1093/BIOINFORMATICS/BTG362>
- Frenz, B., Lewis, S. M., King, I., DiMaio, F., Park, H., & Song, Y. (2020). Prediction of Protein Mutational Free Energy: Benchmark and Sampling Improvements Increase Classification Accuracy. *Frontiers in Bioengineering and Biotechnology*, 8, 558247. <https://doi.org/10.3389/FBIOE.2020.558247/BIBTEX>
- Fu, L., Niu, B., Zhu, Z., Wu, S., & Li, W. (2012). CD-HIT: accelerated for clustering the next-generation sequencing data. *Bioinformatics*, 28(23), 3150–3152. <https://doi.org/10.1093/BIOINFORMATICS/BTS565>
- Gray, J. J., Moughon, S., Wang, C., Schueler-Furman, O., Kuhlman, B., Rohl, C. A., & Baker, D. (2003). Protein-protein docking with simultaneous optimization of rigid-body displacement and side-chain conformations. *Journal of Molecular Biology*, 331(1), 281–299. [https://doi.org/10.1016/S0022-2836\(03\)00670-3](https://doi.org/10.1016/S0022-2836(03)00670-3)
- Hernández, I. M., Dehouck, Y., Bastolla, U., López-Blanco, J. R., & Chacón, P. (2023). Predicting protein stability changes upon mutation using a simple orientational potential. *Bioinformatics*, 39(1). <https://doi.org/10.1093/BIOINFORMATICS/BTAD011>

- Hildebrand, P. W., Goede, A., Bauer, R. A., Gruening, B., Ismer, J., Michalsky, E., & Preissner, R. (2009). SuperLooper—a prediction server for the modeling of loops in globular and membrane proteins. *Nucleic Acids Research*, 37(Web Server issue), W571. <https://doi.org/10.1093/NAR/GKP338>
- Holtby, D., Li, S. C., & Li, M. (2013). LoopWeaver: Loop Modeling by the Weighted Scaling of Verified Proteins. *Journal of Computational Biology*, 20(3), 212. <https://doi.org/10.1089/CMB.2012.0078>
- Honegger, A., & Plückthun, A. (2001). Yet another numbering scheme for immunoglobulin variable domains: an automatic modeling and analysis tool. *Journal of Molecular Biology*, 309(3), 657–670. <https://doi.org/10.1006/JMBI.2001.4662>
- Huang, P., Chu, S. K. S., Frizzo, H. N., Connolly, M. P., Caster, R. W., & Siegel, J. B. (2020). Evaluating Protein Engineering Thermostability Prediction Tools Using an Independently Generated Dataset. *ACS Omega*, 5(12), 6487–6493. https://doi.org/10.1021/ACSOMEGA.9B04105/ASSET/IMAGES/LARGE/AO9B04105_0003.JPEG
- Hummer, A. M., Abanades, B., & Deane, C. M. (2022). Advances in computational structure-based antibody design. *Current Opinion in Structural Biology*, 74, 102379. <https://doi.org/10.1016/J.SBI.2022.102379>
- Jeliazkov, J. R., Frick, R., Zhou, J., & Gray, J. J. (2021). Robustification of RosettaAntibody and Rosetta SnugDock. *PLOS ONE*, 16(3), e0234282. <https://doi.org/10.1371/JOURNAL.PONE.0234282>
- Joubbi, S., Micheli, A., Milazzo, P., Maccari, G., Ciano, G., Cardamone, D., & Medini, D. (2024). Antibody design using deep learning: from sequence and structure design to affinity maturation. *Briefings in Bioinformatics*, 25(4). <https://doi.org/10.1093/BIB/BBAE307>
- Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., Tunyasuvunakool, K., Bates, R., Žídek, A., Potapenko, A., Bridgland, A., Meyer, C., Kohl, S. A. A., Ballard, A. J., Cowie, A., Romera-Paredes, B., Nikolov, S., Jain, R., Adler, J., ... Hassabis, D. (2021). Highly accurate protein structure prediction with

- AlphaFold. *Nature* 2021 596:7873, 596(7873), 583–589.
<https://doi.org/10.1038/s41586-021-03819-2>
- Jung, D., Giallourakis, C., Mostoslavsky, R., & Alt, F. W. (2006). Mechanism and control of V(D)J recombination at the immunoglobulin heavy chain locus. *Annual Review of Immunology*, 24, 541–570.
<https://doi.org/10.1146/ANNUREV.IMMUNOL.23.021704.115830>
- Kaas, Q., Ruiz, M., & Lefranc, M. P. (2004). IMGT/3Dstructure-DB and IMGT/StructuralQuery, a database and a tool for immunoglobulin, T cell receptor and MHC structural data. *Nucleic Acids Research*, 32(Database issue).
<https://doi.org/10.1093/NAR/GKH042>
- Kabat, E. A., Wu, T. Te, & Bilofsky, H. (1979). *Sequences of immunoglobulin chains: tabulation and analysis of amino acid sequences of precursors, V-regions, C-regions, J-chain and 2-microglobulins*. National Institute of Health.
- Kabsch, W. (1978). A discussion of the solution for the best rotation to relate two sets of vectors. *Acta Crystallographica Section A*, 34(5), 827–828.
<https://doi.org/10.1107/S0567739478001680>
- Kadukova, M., Machado, K. D. S., Chacón, P., & Grudinin, S. (2021). KORP-PL: a coarse-grained knowledge-based scoring function for protein–ligand interactions. *Bioinformatics*, 37(7), 943–950.
<https://doi.org/10.1093/BIOINFORMATICS/BTAA748>
- Karami, Y., Guyon, F., De Vries, S., & Tufféry, P. (2018). DaReUS-Loop: accurate loop modeling using fragments from remote or unrelated proteins. *Scientific Reports*.
<https://doi.org/10.1038/s41598-018-32079-w>
- Kelow, S., Faezov, B., Xu, Q., Parker, M., Adolf-Bryfogle, J., & Dunbrack, R. L. (2022). A penultimate classification of canonical antibody CDR conformations. *BioRxiv*, 2022.10.12.511988. <https://doi.org/10.1101/2022.10.12.511988>
- Kleywegt, G. J., & Jones, T. A. (1997). [11] Model building and refinement practice. *Methods in Enzymology*, 277, 208–230. [https://doi.org/10.1016/S0076-6879\(97\)77013-7](https://doi.org/10.1016/S0076-6879(97)77013-7)

- Krivov, G. G., Shapovalov, M. V., & Dunbrack, R. L. (2009). Improved prediction of protein side-chain conformations with SCWRL4. *Proteins*, 77(4), 778. <https://doi.org/10.1002/PROT.22488>
- Kryshtafovych, A., Schwede, T., Topf, M., Fidelis, K., & Moult, J. (2021). Critical assessment of methods of protein structure prediction (CASP)—Round XIV. *Proteins: Structure, Function and Bioinformatics*, 89(12), 1607–1617. <https://doi.org/10.1002/PROT.26237>
- Kuhlman, B., Dantas, G., Ireton, G. C., Varani, G., Stoddard, B. L., & Baker, D. (2003). Design of a novel globular protein fold with atomic-level accuracy. *Science (New York, N.Y.)*, 302(5649), 1364–1368. <https://doi.org/10.1126/SCIENCE.1089427>
- Kuroda, D., Shirai, H., Jacobson, M. P., & Nakamura, H. (2012). Computer-aided antibody design. *Protein Engineering, Design and Selection*, 25(10), 507–521. <https://doi.org/10.1093/PROTEIN/GZS024>
- Leem, J., Dunbar, J., Georges, G., Shi, J., & Deane, C. M. (2016). ABodyBuilder: Automated antibody structure prediction with data-driven accuracy estimation. *MAbs*, 8(7), 1259–1268. https://doi.org/10.1080/19420862.2016.1205773/SUPPL_FILE/KMAB_A_1205773_SM1023.PDF
- Leem, J., Georges, G., Shi, J., & Deane, C. M. (2018). Antibody side chain conformations are position-dependent. *Proteins: Structure, Function, and Bioinformatics*, 86(4), 383–392. <https://doi.org/10.1002/PROT.25453>
- Lefranc, M. P., Pommié, C., Ruiz, M., Giudicelli, V., Foulquier, E., Truong, L., Thouvenin-Contet, V., & Lefranc, G. (2003). IMGT unique numbering for immunoglobulin and T cell receptor variable domains and Ig superfamily V-like domains. *Developmental & Comparative Immunology*, 27(1), 55–77. [https://doi.org/10.1016/S0145-305X\(02\)00039-3](https://doi.org/10.1016/S0145-305X(02)00039-3)
- Li, B., Yang, Y. T., Capra, J. A., & Gerstein, M. B. (2020). Predicting changes in protein thermodynamic stability upon point mutation with deep 3D convolutional neural networks. *PLOS Computational Biology*, 16(11), e1008291. <https://doi.org/10.1371/JOURNAL.PCBI.1008291>

- Liang, S., Zhang, C., Sarmiento, J., & Standley, D. M. (2012). Protein Loop Modeling with Optimized Backbone Potential Functions. *Journal of Chemical Theory and Computation*, 8(5), 1820–1827. <https://doi.org/10.1021/CT300131P>
- Liang, S., Zhang, C., & Zhou, Y. (2014). LEAP: highly accurate prediction of protein loop conformations by integrating coarse-grained sampling and optimized energy scores with all-atom refinement of backbone and side chains. *Journal of Computational Chemistry*, 35(4), 335–341. <https://doi.org/10.1002/JCC.23509>
- Liao, H. X., Bonsignori, M., Alam, S. M., McLellan, J. S., Tomaras, G. D., Moody, M. A., Kozink, D. M., Hwang, K. K., Chen, X., Tsao, C. Y., Liu, P., Lu, X., Parks, R. J., Montefiori, D. C., Ferrari, G., Pollara, J., Rao, M., Peachman, K. K., Santra, S., ... Haynes, B. F. (2013). Vaccine Induction of Antibodies against a Structurally Heterogeneous Site of Immune Pressure within HIV-1 Envelope Protein Variable Regions 1 and 2. *Immunity*, 38(1), 176–186. <https://doi.org/10.1016/j.immuni.2012.11.011>
- Liu, Y., Zeng, J., & Gong, H. (2014). Improving the orientation-dependent statistical potential using a reference state. *Proteins*, 82(10), 2383–2393. <https://doi.org/10.1002/PROT.24600>
- López-Blanco, J. R., Canosa-Valls, A. J., Li, Y., & Chacón, P. (2016). RCD+: Fast loop modeling server. *Nucleic Acids Research*, 44(W1), W395–W400. <https://doi.org/10.1093/nar/gkw395>
- López-Blanco, J. R., & Chacón, P. (2019). Korp: knowledge-based 6D potential for fast protein and loop modeling. *Bioinformatics*, 35(17), 3013–3019. <https://doi.org/10.1093/BIOINFORMATICS/BTZ026>
- Lyskov, S., Chou, F. C., Conchúir, S. Ó., Der, B. S., Drew, K., Kuroda, D., Xu, J., Weitzner, B. D., Renfrew, P. D., Sripakdeevong, P., Borgo, B., Havranek, J. J., Kuhlman, B., Kortemme, T., Bonneau, R., Gray, J. J., & Das, R. (2013). Serverification of Molecular Modeling Applications: The Rosetta Online Server That Includes Everyone (ROSIE). *PLOS ONE*, 8(5), e63906. <https://doi.org/10.1371/JOURNAL.PONE.0063906>

- MacCallum, R. M., Martin, A. C. R., & Thornton, J. M. (1996). Antibody-antigen interactions: contact analysis and binding site topography. *Journal of Molecular Biology*, 262(5), 732–745. <https://doi.org/10.1006/JMBI.1996.0548>
- Mandell, D. J., Coutsiadis, E. A., & Kortemme, T. (2009). Sub-angstrom accuracy in protein loop reconstruction by robotics-inspired conformational sampling. *Nature Methods*, 6(8), 551–552. <https://doi.org/10.1038/NMETH0809-551>
- Marks, C., & Deane, C. M. (2017a). Antibody H3 Structure Prediction. *Computational and Structural Biotechnology Journal*, 15, 222. <https://doi.org/10.1016/J.CSBJ.2017.01.010>
- Marks, C., & Deane, C. M. (2017b). Antibody H3 Structure Prediction. *Computational and Structural Biotechnology Journal*, 15, 222–231. <https://doi.org/10.1016/j.csbj.2017.01.010>
- Marks, C., Nowak, J., Klostermann, S., Georges, G., Dunbar, J., Shi, J., Kelm, S., & Deane, C. M. (2017). Sphinx: merging knowledge-based and ab initio approaches to improve protein loop prediction. *Bioinformatics*, 33(9), 1346–1353. <https://doi.org/10.1093/BIOINFORMATICS/BTW823>
- Martin, A., Chahwan, R., Parsa, J. Y., & Scharff, M. D. (2015). Somatic Hypermutation: The Molecular Mechanisms Underlying the Production of Effective High-Affinity Antibodies. *Molecular Biology of B Cells: Second Edition*, 363–388. <https://doi.org/10.1016/B978-0-12-397933-9.00020-5>
- Martí-Renom, M. A., Stuart, A. C., Fiser, A., Sánchez, R., Melo, F., & Šali, A. (2000). Comparative protein structure modeling of genes and genomes. *Annual Review of Biophysics and Biomolecular Structure*, 29, 291–325. <https://doi.org/10.1146/ANNUREV.BIOPHYS.29.1.291>
- Messih, M. A., Lepore, R., & Tramontano, A. (2015). LoopIng: a template-based tool for predicting the structure of protein loops. *Bioinformatics*, 31(23), 3767. <https://doi.org/10.1093/BIOINFORMATICS/BTV438>
- Methot, S. P., & Di Noia, J. M. (2017). Molecular Mechanisms of Somatic Hypermutation and Class Switch Recombination. *Advances in Immunology*, 133, 37–87. <https://doi.org/10.1016/BS.AI.2016.11.002>

- Mirdita, M., Schütze, K., Moriwaki, Y., Heo, L., Ovchinnikov, S., & Steinegger, M. (2022). ColabFold: making protein folding accessible to all. *Nature Methods* 2022 19:6, 19(6), 679–682. <https://doi.org/10.1038/s41592-022-01488-1>
- Montanucci, L., Capriotti, E., Frank, Y., Ben-Tal, N., & Fariselli, P. (2019). DDGun: An untrained method for the prediction of protein stability changes upon single and multiple point variations. *BMC Bioinformatics*, 20(14), 1–10. <https://doi.org/10.1186/S12859-019-2923-1/FIGURES/2>
- Morea, V., Tramontano, A., Rustici, M., Chothia, C., & Lesk, A. M. (1998). Conformations of the third hypervariable region in the VH domain of immunoglobulins. *Journal of Molecular Biology*, 275(2), 269–294. <https://doi.org/10.1006/JMBI.1997.1442>
- Nguyen, S. P., Li, Z., Xu, D., & Shang, Y. (2019). New deep learning methods for protein loop modeling. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 16(2), 596–606. <https://doi.org/10.1109/TCBB.2017.2784434>
- Nikam, R., Kulandaisamy, A., Harini, K., Sharma, D., & Michael Gromiha, M. (2021). ProThermDB: thermodynamic database for proteins and mutants revisited after 15 years. *Nucleic Acids Research*, 49(D1), D420–D424. <https://doi.org/10.1093/NAR/GKAA1035>
- Norman, R. A., Ambrosetti, F., Bonvin, A. M. J. J., Colwell, L. J., Kelm, S., Kumar, S., & Krawczyk, K. (2020). Computational approaches to therapeutic antibody design: established methods and emerging trends. *Briefings in Bioinformatics*, 21(5), 1549–1567. <https://doi.org/10.1093/BIB/BBZ095>
- North, B., Lehmann, A., & Dunbrack, R. L. (2011). A New Clustering of Antibody CDR Loop Conformations. *Journal of Molecular Biology*, 406(2), 228–256. <https://doi.org/10.1016/J.JMB.2010.10.030>
- Nowak, J., Baker, T., Georges, G., Kelm, S., Klostermann, S., Shi, J., Sridharan, S., & Deane, C. M. (2016). Length-independent structural similarities enrich the antibody CDR canonical class model. *MAbs*, 8(4), 751–760. <https://doi.org/10.1080/19420862.2016.1158370>
- Nurk, S., Koren, S., Rhie, A., Rautiainen, M., Bzikadze, A. V., Mikheenko, A., Vollger, M. R., Altemose, N., Uralsky, L., Gershman, A., Aganezov, S., Hoyt, S. J., Diekhans, M.,

- Logsdon, G. A., Alonge, M., Antonarakis, S. E., Borchers, M., Bouffard, G. G., Brooks, S. Y., ... Phillippy, A. M. (2022). The complete sequence of a human genome. *Science*, 376(6588), 44–53. https://doi.org/10.1126/SCIENCE.ABJ6987/SUPPL_FILE/SCIENCE.ABJ6987_MДАР_REPRODUCIBILITY_CHECKLIST.PDF
- Padlan, E. A. (1977). Structural basis for the specificity of antibody-antigen reactions and structural mechanisms for the diversification of antigen-binding specificities. *Quarterly Reviews of Biophysics*, 10(1), 35–65. <https://doi.org/10.1017/S0033583500000135>
- Park, H., Lee, G. R., Heo, L., & Seok, C. (2014). Protein Loop Modeling Using a New Hybrid Energy Function and Its Application to Modeling in Inaccurate Structural Environments. *PLOS ONE*, 9(11), e113811. <https://doi.org/10.1371/JOURNAL.PONE.0113811>
- Petoukhov, M. V., Eady, N. A. J., Brown, K. A., & Svergun, D. I. (2002). Addition of Missing Loops and Domains to Protein Models by X-Ray Solution Scattering. *Biophysical Journal*, 83(6), 3113–3125. [https://doi.org/10.1016/S0006-3495\(02\)75315-0](https://doi.org/10.1016/S0006-3495(02)75315-0)
- Poole, A. M., & Ranganathan, R. (2006). Knowledge-based potentials in protein design. *Current Opinion in Structural Biology*, 16(4), 508–513. <https://doi.org/10.1016/J.SBI.2006.06.013>
- Pucci, F., Bernaerts, K. V., Kwasigroch, J. M., & Rومان, M. (2018). Quantification of biases in predictions of protein stability changes upon mutations. *Bioinformatics*, 34(21), 3659–3665. <https://doi.org/10.1093/BIOINFORMATICS/BTY348>
- Raybould, M. I. J., Marks, C., Lewis, A. P., Shi, J., Bujotzek, A., Taddese, B., & Deane, C. M. (2020). Thera-SAbDab: the Therapeutic Structural Antibody Database. *Nucleic Acids Research*, 48(D1), D383–D388. <https://doi.org/10.1093/NAR/GKZ827>
- Regep, C., Georges, G., Shi, J., Popovic, B., & Deane, C. M. (2017). The H3 loop of antibodies shows unique structural characteristics. *Proteins: Structure, Function, and Bioinformatics*, 85(7), 1311–1318. <https://doi.org/10.1002/PROT.25291>
- Rodrigues, C. H., Pires, D. E., Ascher, D. B., David Ascher, C. B., & eduau, unimelb. (2021). DynaMut2: Assessing changes in stability and flexibility upon single and multiple

- point missense mutations. *Protein Science*, 30(1), 60–69.
<https://doi.org/10.1002/PRO.3942>
- Rohl, C. A., Strauss, C. E. M., Misura, K. M. S., & Baker, D. (2004). Protein Structure Prediction Using Rosetta. *Methods in Enzymology*, 383, 66–93.
[https://doi.org/10.1016/S0076-6879\(04\)83004-0](https://doi.org/10.1016/S0076-6879(04)83004-0)
- Ruffolo, J. A., Guerra, C., Mahajan, S. P., Sulam, J., & Gray, J. J. (2020). Geometric potentials from deep learning improve prediction of CDR H3 loop structures. *Bioinformatics*, 36(Suppl 1), i268.
<https://doi.org/10.1093/BIOINFORMATICS/BTAA457>
- Ruffolo, J. A., Sulam, J., & Gray, J. J. (2022). Antibody structure prediction using interpretable deep learning. *Patterns*, 3(2), 100406.
<https://doi.org/10.1016/J.PATTER.2021.100406>
- Šali, A., & Blundell, T. L. (1993). Comparative protein modelling by satisfaction of spatial restraints. *Journal of Molecular Biology*, 234(3), 779–815.
<https://doi.org/10.1006/JMBI.1993.1626>
- Samudrala, R., & Moult, J. (1998). An all-atom distance-dependent conditional probability discriminatory function for protein structure prediction. *Journal of Molecular Biology*, 275(5), 895–916. <https://doi.org/10.1006/JMBI.1997.1479>
- Schymkowitz, J., Borg, J., Stricher, F., Nys, R., Rousseau, F., & Serrano, L. (2005). The FoldX web server: an online force field. *Nucleic Acids Research*, 33(suppl_2), W382–W388. <https://doi.org/10.1093/NAR/GKI387>
- Simons, K. T., Kooperberg, C., Huang, E., & Baker, D. (1997). Assembly of protein tertiary structures from fragments with similar local sequences using simulated annealing and Bayesian scoring functions. *Journal of Molecular Biology*, 268(1), 209–225.
<https://doi.org/10.1006/JMBI.1997.0959>
- Stein, A., & Kortemme, T. (2013). Improvements to Robotics-Inspired Conformational Sampling in Rosetta. *PLOS ONE*, 8(5), e63090.
<https://doi.org/10.1371/JOURNAL.PONE.0063090>

- Stevens, A. O., & He, Y. (2022). Benchmarking the Accuracy of AlphaFold 2 in Loop Structure Prediction. *Biomolecules*, 12(7). <https://doi.org/10.3390/BIOM12070985/S1>
- Swindells, M. B., Porter, C. T., Couch, M., Hurst, J., Abhinandan, K. R., Nielsen, J. H., Macindoe, G., Hetherington, J., & Martin, A. C. R. (2017). abYsis: Integrated Antibody Sequence and Structure-Management, Analysis, and Prediction. *Journal of Molecular Biology*, 429(3), 356–364. <https://doi.org/10.1016/J.JMB.2016.08.019>
- Tang, K., Wong, S. W. K., Liu, J. S., Zhang, J., & Liang, J. (2015). Conformational sampling and structure prediction of multiple interacting loops in soluble and β -barrel membrane proteins using multi-loop distance-guided chain-growth Monte Carlo method. *Bioinformatics*, 31(16), 2646–2652. <https://doi.org/10.1093/BIOINFORMATICS/BTV198>
- Teplyakov, A., Luo, J., Obmolova, G., Malia, T. J., Sweet, R., Stanfield, R. L., Kodangattil, S., Almagro, J. C., & Gilliland, G. L. (2014). Antibody modeling assessment II. Structures and models. *Proteins*, 82(8), 1563–1582. <https://doi.org/10.1002/PROT.24554>
- Ting, D., Wang, G., Shapovalov, M., Mitra, R., Jordan, M. I., & Dunbrack, R. L. (2010). Neighbor-Dependent Ramachandran Probability Distributions of Amino Acids Developed from a Hierarchical Dirichlet Process Model. *PLoS Computational Biology*, 6(4), 1000763. <https://doi.org/10.1371/JOURNAL.PCBI.1000763>
- Van Walle, I., Gansemans, Y., Parren, P. W. H. I., Stas, P., & Lasters, I. (2007). Immunogenicity screening in protein drug development. *Expert Opinion on Biological Therapy*, 7(3), 405–418. <https://doi.org/10.1517/14712598.7.3.405>
- Wang, C., Bradley, P., & Baker, D. (2007). Protein-protein docking with backbone flexibility. *Journal of Molecular Biology*, 373(2), 503–519. <https://doi.org/10.1016/J.JMB.2007.07.050>
- Wang, F., Ekiert, D. C., Ahmad, I., Yu, W., Zhang, Y., Bazirgan, O., Torkamani, A., Raudsepp, T., Mwangi, W., Criscitiello, M. F., Wilson, I. A., Schultz, P. G., & Smider, V. V. (2013). Reshaping Antibody Diversity. *Cell*, 153(6), 1379–1393. <https://doi.org/10.1016/J.CELL.2013.04.049>

- Wang, G., & Dunbrack, R. L. (2005). PISCES: recent improvements to a PDB sequence culling server. *Nucleic Acids Research*, 33(Web Server issue). <https://doi.org/10.1093/NAR/GKI402>
- Wang, T., Wang, L., Zhang, X., Shen, C., Zhang, O., Wang, J., Wu, J., Jin, R., Zhou, D., Chen, S., Liu, L., Wang, X., Hsieh, C. Y., Chen, G., Pan, P., Kang, Y., & Hou, T. (2023). Comprehensive assessment of protein loop modeling programs on large-scale datasets: prediction accuracy and efficiency. *Briefings in Bioinformatics*, 25(1), 1–14. <https://doi.org/10.1093/BIB/BBAD486>
- Wang, T., Zhang, X., Zhang, O., Chen, G., Pan, P., Wang, E., Wang, J., Wu, J., Zhou, D., Wang, L., Jin, R., Chen, S., Shen, C., Kang, Y., Hsieh, C.-Y., & Hou, T. (2024). Highly Accurate and Efficient Deep Learning Paradigm for Full-Atom Protein Loop Modeling with KarmaLoop. *Research*, 7. https://doi.org/10.34133/RESEARCH.0408/SUPPL_FILE/RESEARCH.0408.F1.DOCX
- Weitzner, B. D., Dunbrack, R. L., & Gray, J. J. (2015). The origin of CDR H3 structural diversity. *Structure (London, England : 1993)*, 23(2), 302. <https://doi.org/10.1016/J.STR.2014.11.010>
- Weitzner, B. D., & Gray, J. J. (2017). Accurate structure prediction of CDR H3 loops enabled by a novel structure-based C-terminal constraint. *Journal of Immunology (Baltimore, Md. : 1950)*, 198(1), 505. <https://doi.org/10.4049/JIMMUNOL.1601137>
- Weitzner, B. D., Jeliaskov, J. R., Lyskov, S., Marze, N., Kuroda, D., Frick, R., Adolf-Bryfogle, J., Biswas, N., Dunbrack, R. L., & Gray, J. J. (2017). Modeling and docking of antibody structures with Rosetta. *Nature Protocols* 2017 12:2, 12(2), 401–416. <https://doi.org/10.1038/nprot.2016.180>
- Wilkinson, A. J., Fersht, A. R., Blow, D. M., Carter, P., & Winter, G. (1984). A large increase in enzyme-substrate affinity by protein engineering. *Nature*, 307(5947), 187–188. <https://doi.org/10.1038/307187A0>
- Wilman, W., Wróbel, S., Bielska, W., Deszynski, P., Dudzic, P., Jaszczyszyn, I., Kaniewski, J., Młokosiewicz, J., Rouyan, A., Szaława, T., Kumar, S., Greiff, V., & Krawczyk, K. (2022). Machine-designed biotherapeutics: opportunities, feasibility and

- advantages of deep learning in computational antibody discovery. *Briefings in Bioinformatics*, 23(4), bbac267. <https://doi.org/10.1093/BIB/BBAC267>
- Wilson, I. A., & Stanfield, R. L. (1994). Antibody-antigen interactions: new structures and new conformational changes. *Current Opinion in Structural Biology*, 4(6), 857–867. [https://doi.org/10.1016/0959-440X\(94\)90267-4](https://doi.org/10.1016/0959-440X(94)90267-4)
- Xavier, J. S., Nguyen, T. B., Karmarkar, M., Portelli, S., Rezende, P. M., Velloso, J. P. L., Ascher, D. B., & Pires, D. E. V. (2021). ThermoMutDB: a thermodynamic database for missense mutations. *Nucleic Acids Research*, 49(D1), D475–D479. <https://doi.org/10.1093/NAR/GKAA925>
- Xiang, Z., Soto, C. S., & Honig, B. (2002). Evaluating conformational free energies: The colony energy and its application to the problem of loop prediction. *Proceedings of the National Academy of Sciences of the United States of America*, 99(11), 7432–7437. <https://doi.org/10.1073/PNAS.102179699/ASSET/68C5F447-6151-4C41-B267-D3266C07AE7B/ASSETS/GRAPHIC/PQ1021796002.JPEG>
- Zhou, H., & Skolnick, J. (2011). GOAP: a generalized orientation-dependent, all-atom statistical potential for protein structure prediction. *Biophysical Journal*, 101(8), 2043–2052. <https://doi.org/10.1016/J.BPJ.2011.09.012>

